

Título - A Definir

Gabriel de Jesus Pereira

Qualificação de Mestrado do Programa Interinstitucional de
Pós-Graduação em Estatística (PIPGes)

DEDICATÓRIA!!!!

AGRADECIMENTOS

AGRADECIMENTOS!!!!

“EPÍGRAFE!!!!”

RESUMO

GABRIEL, J. P. **Título - A Definir**. 2021. 51 p. Monografia (Mestrado em Estatística – Programa Interinstitucional de Pós-Graduação em Estatística) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2021.

Este artigo introduz o GG-KM, uma nova abordagem semiparamétrica para modelagem de taxa de cura no modelo de tempo de promoção. Abordamos as limitações dos preditores lineares tradicionais ao empregar Máquinas de Kernel para modelar o componente de cura dentro de um Reproducing Kernel Hilbert Space (RKHS) (MOHRI; ROSTAMIZADEH; TALWALKAR, 2018). Para fornecer máxima flexibilidade à função de risco dos indivíduos suscetíveis, incorporamos a distribuição Gama Generalizada (STACY, 1962), que engloba diversos modelos clássicos de sobrevivência. Derivamos uma estrutura de log-verossimilhança penalizada e fornecemos gradientes analíticos explícitos para a otimização conjunta dos pesos do kernel, hiperparâmetros e parâmetros da distribuição. O desempenho do modelo é validado por meio do Integrated Brier Score (IBS) com ajuste por IPCW (PRINCE *et al.*, 2025).

Palavras-chave: Análise de Sobrevivência, Censura, Reproducing Kernel Hilbert Space, Gama Generalizada, Representer Theorem.

ABSTRACT

GABRIEL, J. P. **Model of theses and dissertations in LaTeX of the ICMC**. 2021. 51 p. Monografia (Mestrado em Estatística – Programa Interinstitucional de Pós-Graduação em Estatística) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2021.

This paper introduces GG-KM, a novel semiparametric approach to promotion time cure rate modeling. We address the limitations of traditional linear predictors by employing Kernel Machines to model the cure component within a Reproducing Kernel Hilbert Space (RKHS) (MOHRI; ROSTAMIZADEH; TALWALKAR, 2018). To provide maximum flexibility for the hazard of susceptible individuals, we incorporate the Generalized Gamma (GG) distribution (STACY, 1962), which encompasses several standard survival models. We derive a penalized log-likelihood framework and provide explicit analytical gradients for the joint optimization of kernel weights, hyperparameters, and distribution parameters. Model performance is validated through the Integrated Brier Score (IBS) with IPCW adjustment (PRINCE *et al.*, 2025).

Keywords: Survival Analysis, Censoring, Reproducing Kernel Hilbert Space, Generalized Gamma, Representer Theorem.

LISTA DE ILUSTRAÇÕES

Figura 1 – Simulação de curados e não curados sobre os três métodos descritos. Respec- tivamente, pode-se observar o método 1, 2 e 3.	38
Figura 2 – Distribuição do IBS em relação a cada kernel, para diferentes cenários de simulação.	44
Figura 3 – Comparação da curva de sobrevivência estimada pelo GG-KM e KME. . . .	44
Figura 4 – Curva de Kaplan Meier para o conjunto de dados de melanoma, comparando o modelo GG-KM.	46
Figura 5 – Distribuição do IBS em relação a cada kernel.	47

LISTA DE ALGORITMOS

Algoritmo 1 – Algoritmo EM penalizado para estimar o modelo GG-KM - $N_i \sim$ Poisson($\theta(\mathbf{x}_i)$).	33
Algoritmo 2 – Algoritmo ECME para estimar o modelo GG-KM com riscos latentes Binomial Negativa	36
Algoritmo 3 – Geração de dados simulados com fração de cura	40

LISTA DE TABELAS

Tabela 1 – Comparação entre as versões Poisson e Binomial Negativa do modelo GG-KM.	45
Tabela 2 – Resultados do IBS médio, C-index médio e respectivos desvios padrão para cada kernel no conjunto de dados Melanoma.	46

SUMÁRIO

1	INTRODUÇÃO	19
1.1	Objetivo do Trabalho	20
1.2	Organização do Trabalho	20
2	FUNDAMENTOS DE ANÁLISE DE SOBREVIVÊNCIA	21
2.1	Modelos de Longa Duração	21
2.1.1	<i>Modelo de Tempo de Promoção</i>	22
2.1.2	<i>Distribuição Gama Generalizada</i>	25
3	MÉTODOS BASEADOS EM KERNEL	27
3.1	Kernels	27
3.1.1	<i>Kernels positivos definidos</i>	28
3.1.2	<i>Espaços de Hilbert</i>	28
3.1.3	<i>Reproducing Kernel Hilbert Spaces</i>	28
3.1.4	<i>Teorema do Representante</i>	29
3.2	GG-KM	29
3.2.1	<i>Extensão não paramétrica via kernel</i>	30
3.2.2	<i>Estimação via algoritmo EM penalizado</i>	30
3.2.3	<i>Estimação do modelo GG-KM com riscos latentes Binomial Negativa</i>	33
4	AVALIAÇÃO EXPERIMENTAL	37
4.1	Particionamento dos dados	37
4.2	Estudo de simulação e Métricas de Erro	37
5	RESULTADOS	43
5.1	Aplicação a Dados Simulados	43
5.2	Aplicação a Dados Reais	45
6	CONCLUSÃO	49
	REFERÊNCIAS	51

INTRODUÇÃO

A análise de sobrevivência constitui um dos principais ramos da estatística aplicada voltado ao estudo do tempo até a ocorrência de um evento de interesse, como falha de um sistema, recorrência de uma doença ou morte de um indivíduo. Uma característica central desse tipo de dado é a presença de censura, isto é, situações nas quais o tempo exato do evento não é completamente observado. Esse aspecto impõe desafios metodológicos relevantes, exigindo o desenvolvimento de modelos capazes de lidar adequadamente com informações incompletas.

Além da presença de censura, em diversos contextos práticos observa-se a existência de uma fração de indivíduos que não experimentará o evento de interesse, mesmo sob longos períodos de acompanhamento. Essa característica motivou o desenvolvimento dos chamados modelos de fração de cura, que buscam representar explicitamente essa parcela da população.

Tradicionalmente, modelos como o de Cox têm sido amplamente utilizados nesse contexto, devido à sua flexibilidade semiparamétrica e interpretabilidade. No entanto, tais abordagens assumem, em geral, uma estrutura linear no preditor do risco, o que pode ser inadequado em cenários nos quais a relação entre as covariáveis e o tempo de sobrevivência apresenta padrões não lineares ou de maior complexidade.

Nesse cenário, métodos baseados em kernels surgem como alternativas promissoras, pois permitem incorporar flexibilidade ao processo de modelagem por meio de mapeamentos implícitos para espaços de maior dimensão. Essa abordagem possibilita capturar estruturas não lineares sem a necessidade de especificar explicitamente a forma funcional da relação entre covariáveis e sobrevivência.

O presente trabalho propõe um novo modelo semiparamétrico para dados de sobrevivência com fração de cura, denominado GG-KM, que combina a flexibilidade de métodos baseados em kernel com a estrutura do modelo de tempo de promoção. O objetivo principal é investigar o desempenho do modelo sob diferentes especificações de kernel, avaliando sua capacidade preditiva e sua adequação em cenários com diferentes graus de complexidade.

Para isso, são conduzidos experimentos em dados simulados, nos quais é possível controlar a estrutura geradora, e em bases de dados reais amplamente utilizadas na literatura. A avaliação é realizada principalmente por meio do Integrated Brier Score (IBS), permitindo analisar a qualidade preditiva do modelo e a influência da escolha do kernel sob diferentes cenários.

1.1 Objetivo do Trabalho

O objetivo deste trabalho é apresentar os fundamentos teóricos e os principais resultados relacionados à proposta de uma extensão do modelo de tempo de promoção, de modo que seja possível a incorporação de funções kernel na modelagem da fração de cura.

1.2 Organização do Trabalho

Este trabalho está estruturado da seguinte forma. No Capítulo 2 são apresentados fundamentos de análise de sobrevivência, incluindo noções de censura, funções de sobrevivência, modelo de Cox, além de descrever brevemente modelos com fração de cura. No Capítulo 3, são introduzidos alguns conceitos que fundamentam métodos baseados em kernel. Dessa forma, são apresentadas definições como espaços de Hilbert, kernels positivos definidos e alguns kernels principais.

No Capítulo 4, é detalhada a metodologia adotada, abrangendo os recursos computacionais utilizados, particionamento dos dados, a geração de dados simulados com fração de cura. O Capítulo 5 apresenta e discute os resultados obtidos tanto em dados simulados quanto em dados reais. Por fim, o Capítulo 6 apresenta as conclusões do trabalho.

FUNDAMENTOS DE ANÁLISE DE SOBREVIVÊNCIA

2.1 Modelos de Longa Duração

Existem dados de sobrevivência em que uma porcentagem dos indivíduos não apresentará a ocorrência de um evento, mesmo se acompanhados por um longo período de tempo. Neste caso, diz-se que os indivíduos são imunes, ou curados, ao evento de interesse. Tem-se assim a análise de sobrevivência com dados de longa duração.

Diferentemente dos modelos tradicionais de sobrevivência, em que se assume que todos os indivíduos eventualmente experimentarão o evento de interesse, nos modelos de longa duração admite-se a existência de uma fração da população para a qual o evento nunca ocorrerá. Essa característica é usualmente denominada fração de cura.

Seja T uma variável aleatória representando o tempo até a ocorrência do evento. Em modelos clássicos de sobrevivência, a função de sobrevivência é definida por

$$S(t) = P(T > t), \quad t \geq 0,$$

satisfazendo $\lim_{t \rightarrow \infty} S(t) = 0$. Entretanto, em modelos com fração de cura, essa condição deixa de valer, pois há uma probabilidade positiva de o evento nunca ocorrer. Assim, a função de sobrevivência torna-se imprópria, isto é,

$$\lim_{t \rightarrow \infty} S(t) = p_0 > 0,$$

em que p_0 representa a fração de indivíduos curados.

Os modelos de fração de cura podem ser classificados em duas abordagens principais. Isto é, os modelos de mistura e os modelos de não mistura. Nos modelos de mistura, a fração de cura é modelada explicitamente como uma combinação entre curados e suscetíveis. Já nos

modelos de não mistura, a estrutura da função de sobrevivência incorpora a fração de cura de forma implícita.

Entre os modelos de não mistura, destaca-se o modelo de tempo de promoção, também conhecido como modelo de risco acumulado limitado.

2.1.1 Modelo de Tempo de Promoção

De uma forma geral a ideia básica do modelo unificado de fração de cura está baseada na noção de ocorrência do evento de interesse em um processo em dois estágios:

Estágio de iniciação. Seja N uma variável aleatória representando o número de causas ou riscos competitivos da ocorrência do evento de interesse. A causa de ocorrência do evento é desconhecida, e a variável N não é observada, com distribuição de probabilidade p_n e sua cauda dadas, respectivamente, por

$$p_n = P[N = n] \quad \text{e} \quad q_n = P[N > n], \quad (2.1)$$

com $n = 0, 1, 2, \dots$

Estágio de maturação. Dado $N = n$, sejam Z_k , $k = 1, \dots, n$, variáveis aleatórias contínuas (não-negativas) independentes com função distribuição acumulada $F(z) = 1 - S(z)$ e independentes de N , que representam o tempo de ocorrência do evento de interesse devido à k -ésima causa. Afim de incluir os indivíduos que não são suscetíveis ao evento de interesse, seu tempo de ocorrência é definido como

$$T = \min(Z_0, Z_1, Z_2, \dots, Z_N) \quad (2.2)$$

em que $P[Z_0 = \infty] = 1$, admitindo a possibilidade que uma proporção p_0 da população não apresenta a ocorrência do evento de interesse, T é uma variável aleatória observável ou censurada e Z_j e N são variáveis latentes.

Seja $\{a_n\}$ uma sequência de números reais. Se s pertence ao intervalo $[0, 1]$

$$A(s) = a_0 + a_1 s + a_2 s^2 + \dots \quad (2.3)$$

converge, então $A(s)$ é definida como a função geradora da sequência $\{a_n\}$.

A função de sobrevivência da variável aleatória T (função de sobrevivência da população) será indicada por

$$\begin{aligned} S_{\text{pop}}(t) &= P[N = 0] + P[Z_1 > t, Z_2 > t, \dots, Z_N > t, N \geq 1] \\ &= P[N = 0] + \sum_{n=1}^{\infty} P[N = n] P[Z_1 > t, Z_2 > t, \dots, Z_N > t] \\ &= p_0 + \sum_{n=1}^{\infty} p_n S(t)^n \\ &= A(S(t)), \end{aligned} \quad (2.4)$$

sendo que $A(\cdot)$ é a função geradora da sequência p_n . Ou seja, a função de sobrevivência da variável aleatória T , correspondente a um modelo de longa duração em dois estágios, é uma composição da função geradora de probabilidades e a função de sobrevivência. A função de sobrevivência de longa duração em dois estágios $S_{\text{pop}}(t)$ não é uma função de sobrevivência própria.

Observe que, para a função de sobrevivência própria, $\lim_{t \rightarrow 0} S(t) = 1$ e $\lim_{t \rightarrow \infty} S(t) = 0$. Já para a função de sobrevivência imprópria, $\lim_{t \rightarrow 0} S(t) = 1$ e $\lim_{t \rightarrow \infty} S_{\text{pop}}(t) = P[N = 0] = p_0$. Dessa forma, p_0 é a proporção de não ocorrências do evento de interesse na população, ou seja, a fração de cura.

A função de sobrevivência populacional possui as seguintes propriedades:

- Se $p_0 = 1$, então $S_{\text{pop}}(t) = S(t)$;
- $S_{\text{pop}}(0) = 1$;
- $S_{\text{pop}}(t)$ é não crescente;
- $\lim_{t \rightarrow \infty} S_{\text{pop}}(t) = p_0$

As funções de densidade e de risco associadas à função de sobrevivência de longa duração são dadas, respectivamente, por

$$f_{\text{pop}}(t) = f(t) \frac{dA(s)}{ds} \Big|_{s=S(t)} \quad (2.5)$$

e

$$h_{\text{pop}}(t) = \frac{f_{\text{pop}}(t)}{S_{\text{pop}}(t)} = f(t) \frac{\frac{dA(s)}{ds} \Big|_{s=S(t)}}{S_{\text{pop}}(t)}. \quad (2.6)$$

Algumas distribuições são muito utilizadas para as funções geradoras de probabilidade, tais como Bernoulli, Binomial, Poisson, Binomial Negativa e Geométrica e contemplam diferentes modalidades de dispersão. Falaremos de cada uma delas a seguir.

Bernoulli

Seja N uma variável aleatória que representa o número de causas competitivas latentes necessárias para a ocorrência de um determinado evento de interesse, que segue uma distribuição Bernoulli, com parâmetro θ . Sua função de probabilidade de massa dada por

$$P[N = n] = \theta^n (1 - \theta)^{1-n}, \quad n = 0, 1, \dots, \text{ e } 0 < \theta < 1. \quad (2.7)$$

A função geradora de probabilidade de N é dada por

$$A(s) = 1 - \theta + \theta s, \quad 0 \leq s \leq 1. \quad (2.8)$$

E a função de função de sobrevivência de longa duração é dada por

$$S_{\text{pop}}(t) = A(S(t)) = 1 - \theta + \theta S(t), \quad (2.9)$$

obtendo, assim, o modelo conhecido como modelo de mistura padrão (BERKSON; GAGE, 1952), que é um dos mais utilizados na análise de sobrevivência para ajustar dados de longa duração. Ele recebe esse nome, pois consiste de uma mistura de distribuições paramétricas, sendo uma função de sobrevivência própria para a parte da população formada pelos não curados e uma função para os curados, em que a proporção de curados é

$$p_0 = \lim_{t \rightarrow \infty} S_{\text{pop}}(t) = 1 - \theta. \quad (2.10)$$

A função de densidade e de risco são dadas respectivamente por

$$f_{\text{pop}}(t) = \theta f(t) \quad (2.11)$$

e

$$h_{\text{pop}}(t) = \frac{\theta f(t)}{1 - \theta + \theta S(t)}. \quad (2.12)$$

• Binomial

Seja o número N de riscos latentes com distribuição binomial. Uma motivação biológica é, supondo-se que existe um número K de potenciais lugares para a mutação de tumores focalizados numa região do corpo de um indivíduo afetada por uma doença, tem-se que N lugares chegam a sofrer mutações.

Adotamos uma reparametrização do modelo binomial: $\theta^* = \theta / (1 + \theta)$. Assim, seja N uma variável aleatória que representa o número de causas competitivas latentes necessárias para a ocorrência de um determinado evento de interesse com distribuição binomial, sua função de probabilidade de massa é dada por

$$P[N = n^*] = \binom{K}{n^*} \theta^{*n^*} (1 - \theta^*)^{K-n^*}, \quad n^* = 0, 1, \dots, K, \quad 0 < \theta^* < 1, \quad (2.13)$$

com $E[N] = K\theta^*$ e $\text{Var}[N] = K\theta(1 - \theta^*)$, em que K é um número inteiro positivo. A função geradora de probabilidade de N é dada por

$$A(s) = (1 - \theta^* + \theta^* s)^K, \quad 0 \leq s \leq 1. \quad (2.14)$$

A função de função de sobrevivência de longa duração é dada por

$$S_{\text{pop}}(t) = A(S(t)) = S_{\text{pop}}(t) = [1 - \theta^* + \theta^* S(t)]^K, \quad (2.15)$$

sendo que a fração de cura p_0 é dada por

$$p_0 = \lim_{t \rightarrow \infty} S_{\text{pop}}(t) = (1 - \theta^*)^K > 0. \quad (2.16)$$

As funções de densidade e de risco associadas à função de sobrevivência de longa duração binomial são dadas respectivamente por

$$f_{\text{pop}}(t) = K\theta^* f(t)(1 - \theta^* + \theta^* S(t))^{(K-1)} \text{ e } h_{\text{pop}}(t) = \frac{K\theta^* f(t)}{\{1 - \theta^* + \theta^* S(t)\}}, \quad (2.17)$$

em que $f(t) = -S'(t)$ é uma função de densidade própria.

Observa-se que, no caso em que K cresce a fração de cura p_0 decresce.

• Poisson

Seja o número N de causas do evento de interesse com distribuição de probabilidade de Poisson. Assim, considerando a função geradora de probabilidade da distribuição de Poisson $A(s) = \exp[\theta(1 - s)]$, obtemos as funções de sobrevivência, densidade e de risco da população, dadas respectivamente por

$$S_{\text{pop}}(t) = A(S(t)) = \exp[-\theta F(t)], \quad (2.18)$$

$$f_{\text{pop}}(t) = -\frac{dS_{\text{pop}}(t)}{dt} = \theta f(t) \exp[-\theta F(t)] \quad (2.19)$$

e

$$h_{\text{pop}}(t) = \theta f(t). \quad (2.20)$$

Dessa forma, de (2.18) tem-se a fração de cura dada por $p_0 = \lim_{t \rightarrow \infty} S_{\text{pop}}(t) = \exp(-\theta)$.

2.1.2 Distribuição Gama Generalizada

Em relação a distribuição dos tempos de falha dos indivíduos suscetíveis, propõe-se o uso da distribuição Gama Generalizada (GG), devido à sua elevada flexibilidade e capacidade de acomodar diferentes formatos da função de risco.

A função densidade de probabilidade da distribuição GG é dada por

$$f_{\text{GG}}(t; \alpha, d, p) = \frac{p t^{d-1} \exp(-(t/\alpha)^p)}{\alpha^d \Gamma(d/p)},$$

e sua função de distribuição acumulada é definida como

$$F_{\text{GG}}(t; \alpha, d, p) = \frac{\gamma(d/p, (t/\alpha)^p)}{\Gamma(d/p)},$$

onde $\alpha > 0$ é o parâmetro de escala, $d > 0$ e $p > 0$ são parâmetros de forma, $\Gamma(\cdot)$ é a função gama e $\gamma(\cdot, \cdot)$ denota a função gama incompleta inferior.

A escolha dessa distribuição se justifica pelo fato de incluir importantes modelos clássicos como casos particulares. Por exemplo, quando $d = p$, $p = 1$ ou $d/p \rightarrow \infty$, tem-se uma distribuição Weibull, Gama ou converge para uma Log-Normal

MÉTODOS BASEADOS EM KERNEL

Métodos baseados em Kernel são técnicas extremamente flexíveis que podem ser utilizados para estender modelos ou algoritmos para regiões de decisão não lineares ([MOHRI; ROSTAMIZADEH; TALWALKAR, 2018](#)). Estes métodos são baseados nas conhecidas funções de kernel, os quais, sob condições de simetria e positiva definida, definem produtos internos em espaços de alta dimensão, conhecidos como espaços de Hilbert. Dessa forma, este capítulo terá como objetivo definir e apresentar os conceitos fundamentais sobre métodos baseados em kernel, incluindo a definição de funções de kernel, o teorema do representer e Reproducing Kernel Hilbert Space (RKHS).

3.1 Kernels

Por definição, uma função $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ é chamada de kernel sobre $\mathcal{X}$. A ideia central é construir um kernel K tal que, para quaisquer dois pontos $x, x' \in \mathcal{X}$, $K(x, x')$ corresponda ao produto interno entre duas representações desses pontos em um espaço de Hilbert $\mathcal{H}$, isto é,

$$\forall x, x' \in \mathcal{X}, \quad K(x, x') = \langle \phi(x), \phi(x') \rangle, \quad (3.1)$$

para algum mapeamento $\phi : \mathcal{X} \rightarrow \mathcal{H}$. O espaço $\mathcal{H}$ é chamado de feature space.

Sob essa perspectiva, o kernel pode ser interpretado como uma medida de similaridade entre elementos de $\mathcal{X}$, uma vez que o produto interno mensura a similaridade entre dois vetores.

Uma vantagem fundamental dessa abordagem é computacional. Isto é, muitas vezes é significativamente mais eficiente calcular diretamente $K(x, x')$ do que computar explicitamente $\phi(x)$ e $\phi(x')$ e então avaliar seu produto interno.

3.1.1 Kernels positivos definidos

Para que uma função K possa ser utilizada como kernel, é necessário que sejam satisfeitas duas condições, que a função seja simétrica e positiva definida. Satisfazendo essas condições, o kernel é capaz de induzir uma geometria em um espaço de Hilbert.

Formalmente, um kernel $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ é dito simétrico e positivo definido se, para qualquer conjunto finito $\{x_1, \dots, x_n\} \subset \mathcal{X}$, a matriz de Gram

$$\mathbf{K} = [K(x_i, x_j)]_{i,j=1}^n \in \mathbb{R}^{n \times n}$$

for positiva semidefinida. Isto é, para qualquer vetor $\mathbf{c} = (c_1, \dots, c_n)^\top \in \mathbb{R}^n$,

$$\mathbf{c}^\top \mathbf{K} \mathbf{c} = \sum_{i=1}^n \sum_{j=1}^n c_i c_j K(x_i, x_j) \geq 0.$$

Equivalentemente, todos os autovalores de $\mathbf{K}$ são não negativos. Essa propriedade é essencial, pois garante a existência de uma representação geométrica consistente do kernel.

3.1.2 Espaços de Hilbert

A noção de espaço de Hilbert fornece a estrutura matemática necessária para a teoria de kernels.

Por definição, um espaço de Hilbert $\mathcal{H}$ é um espaço vetorial munido de um produto interno $\langle \cdot, \cdot \rangle_{\mathcal{H}}$ e que é completo com relação à norma induzida por esse produto interno. A norma em $\mathcal{H}$ é definida por

$$\forall h \in \mathcal{H}, \quad \|h\|_{\mathcal{H}} = \sqrt{\langle h, h \rangle}.$$

A completude implica que toda sequência de Cauchy em $\mathcal{H}$ converge para um elemento do próprio espaço, garantindo estabilidade analítica para problemas de otimização e aproximação.

No contexto de kernels, o espaço de Hilbert atua como o espaço onde os dados são representados via o mapeamento ϕ .

3.1.3 Reproducing Kernel Hilbert Spaces

A relação entre kernels positivos definidos e espaços de Hilbert é formalizada pelo teorema.

Seja $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ um kernel simétrico e positivo definido. Então existe um espaço de Hilbert $\mathcal{H}$ e um mapeamento $\phi : \mathcal{X} \rightarrow \mathcal{H}$ tais que

$$\forall x, x' \in \mathcal{X}, \quad K(x, x') = \langle \phi(x), \phi(x') \rangle_{\mathcal{H}}.$$

Além disso, esse espaço satisfaz a chamada propriedade de reprodução:

$$\forall h \in \mathcal{H}, \forall x \in \mathcal{X}, \quad h(x) = \langle h, K(x, \cdot) \rangle_{\mathcal{H}}.$$

Essa propriedade estabelece que a avaliação funcional é contínua e pode ser representada por meio do próprio kernel.

O espaço $\mathcal{H}$ associado a K é chamado de Reproducing Kernel Hilbert Space (RKHS), desempenhando papel central em métodos de aprendizado estatístico, particularmente em problemas de regularização, estimação não paramétrica e aprendizado supervisionado.

3.1.4 Teorema do Representante

O resultado mais interessante para a definição do modelo GG-KM é o Teorema do Representante. Sua principal importância reside no fato de garantir que, embora a otimização ocorra em um espaço potencialmente infinito -dimensional, a solução ótima pode ser expressa em termos de uma combinação finita de kernels avaliados nas observações da amostra.

Formalmente, seja $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ um kernel positivo definido e $\mathcal{H}$ seu correspondente RKHS. Assim, para qualquer função $G : \mathbb{R} \rightarrow \mathbb{R}$ não decrescente e qualquer função perda $L : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$, o problema de otimização

$$\arg \min_{h \in \mathcal{H}} F(h) = \arg \min_{h \in \mathcal{H}} G(\|h\|_{\mathcal{H}}) + L(h(x_1), \dots, h(x_n))$$

admite uma solução na forma $h^* = \sum_{i=1}^n \alpha_i K(x_i, \cdot)$. Se G é assumido como sendo crescente, então qualquer solução tem esta forma.

Esse resultado é particularmente relevante porque reduz um problema de otimização funcional em dimensão infinita para um problema de otimização em dimensão finita, dependente apenas dos coeficientes $\alpha = (\alpha_1, \dots, \alpha_n)$. Na prática, isso torna viável o uso de métodos baseados em kernel, além de evidenciar que toda a informação necessária para a estimação está contida na matriz kernel K , sem necessidade de explicitar o mapeamento $\phi(\cdot)$.

A escolha do kernel determina implicitamente a classe de funções admissíveis no espaço RKHS e, conseqüentemente, o grau de complexidade que o modelo pode representar. Neste contexto, os kernels podem ser visto como um hiperparâmetro de complexidade do modelo, bem como as variáveis que os compõe, γ , d e σ .

3.2 GG-KM

O modelo proposto GG-KM, nada mais é que uma proposta de modelar o valor esperado dos riscos latentes do modelo de tempo de promoção a partir da integração de kernels, de forma que seja uma extensão semi-paramétrica. Esta seção terá como objetivo descrever o processo de estimação e fundamentação do modelo.

3.2.1 Extensão não paramétrica via kernel

Embora o modelo de tempo de promoção clássico permita incorporar covariáveis por meio de funções paramétricas para $\theta(\mathbf{x})$, essa abordagem pode ser restritiva em cenários onde a relação entre as covariáveis e a fração de cura apresenta estruturas complexas ou altamente não lineares.

Neste contexto, propõe-se modelar a intensidade média dos riscos latentes $\theta(\mathbf{x})$ por meio de uma função não paramétrica $f(\mathbf{x}) = \log(\theta(\mathbf{x})) > 0$. Dessa forma, suponha que a estimação do modelo de promoção de cura seja feita por meio da maximização da log-verossimilhança penalizada:

$$\min_f \sum_{i=1}^n -l(\mathbf{x}_i) + \frac{\lambda}{2} \|f\|^2 \quad (3.2)$$

em que $l(\mathbf{x}_i)$ representa a log-verossimilhança e λ é um parâmetro de regularização da complexidade do modelo. No entanto, supondo que a função f pertença a um Reproducing Kernel Hilbert Space (RKHS) $\mathcal{H}_K$, associado a um kernel positivo definido $K(\cdot, \cdot)$, o Teorema do Representante garante que a solução do problema da Equação 3.2 pode ser expressa da seguinte forma:

$$f^*(\mathbf{x}) = \sum_{i=1}^n \alpha_i K(\mathbf{x}, \mathbf{x}_i), \quad (3.3)$$

em que $\alpha_1, \dots, \alpha_n \in \mathbb{R}$ são coeficientes a serem estimados. Consequentemente, a intensidade média dos riscos latentes para o indivíduo i pode ser escrita como

$$\theta(\mathbf{x}_i) = \exp \left(\sum_{j=1}^n \alpha_j K(\mathbf{x}_i, \mathbf{x}_j) \right). \quad (3.4)$$

3.2.2 Estimação via algoritmo EM penalizado

A representação obtida pelo Teorema do Representante permite reescrever o modelo de tempo de promoção em termos de um número finito de parâmetros. Seja

$$f(\mathbf{x}_i) = \sum_{j=1}^n \alpha_j K(\mathbf{x}_i, \mathbf{x}_j), \quad (3.5)$$

Sob a formulação do modelo de tempo de promoção, assume-se que o número de riscos latentes associados ao indivíduo i segue uma distribuição de Poisson com média $\theta(\mathbf{x}_i)$, isto é,

$$N_i \sim \text{Poisson}(\theta(\mathbf{x}_i)). \quad (3.6)$$

Para realizar a estimação dos parâmetros, foi considerado o algoritmo EM. Em particular, considera-se uma extensão particular, o EM penalizado (MCLACHLAN; KRISHNAN, 2008).

Dessa forma, considere os dados completos $D_{\text{comp}} = \{t_i, \delta_i, N_i, \mathbf{x}_i\}_{i=1}^n$, em que t_i representa o tempo observado, δ_i o indicador de falha e N_i o número de riscos latentes associados ao i -ésimo indivíduo. A log-verossimilhança completa, menos uma constante aditiva $C = -\sum_{i=1}^n \log(N_i!)$, pode ser escrita como

$$\begin{aligned} l_c = & \sum_{i=1}^n [-\exp(f(\mathbf{x}_i)) + N_i f(\mathbf{x}_i)] \\ & + \sum_{i=1}^n [\delta_i \log f_{\text{GG}}(t_i; \mathbf{a}, \mathbf{d}, \mathbf{p})] \\ & + \sum_{i=1}^n [(N_i - \delta_i) \log S_{\text{GG}}(t_i; \mathbf{a}, \mathbf{d}, \mathbf{p})]. \end{aligned} \quad (3.7)$$

Portanto, tem-se a log-verossimilhança completa penalizada:

$$\ell_{c,p} = l_c - \frac{\lambda}{2} \boldsymbol{\alpha}^\top \mathbf{K} \boldsymbol{\alpha}, \quad (3.8)$$

em que

$$\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_n)^\top \quad (3.9)$$

e $\mathbf{K}$ denota a matriz de kernel com elementos $K_{ij} = K(\mathbf{x}_i, \mathbf{x}_j)$.

O algoritmo EM consiste em alternar entre o cálculo das esperanças condicionais das variáveis latentes e a maximização da esperança da log-verossimilhança completa penalizada.

No passo E, as quantidades não observadas são substituídas por suas respectivas esperanças condicionais, calculadas sob os valores correntes dos parâmetros. Dessa forma, define-se a função auxiliar

$$Q(\boldsymbol{\Theta} | \boldsymbol{\Theta}^{(k)}) = \mathbb{E} \left[\ell_{c,p} | \mathcal{D}_{\text{obs}}, \boldsymbol{\Theta}^{(k)} \right], \quad (3.10)$$

em que

$$\boldsymbol{\Theta} = (\boldsymbol{\alpha}, \mathbf{a}, \mathbf{d}, \mathbf{p})$$

representa o vetor de parâmetros do modelo.

Utilizando propriedades do modelo de tempo de promoção, obtém-se que a esperança condicional do número de riscos latentes possui forma fechada, dada por

$$\hat{N}_i^{(k+1)} = \mathbb{E} \left[N_i | \mathcal{D}_{\text{obs}}, \boldsymbol{\Theta}^{(k)} \right] = \delta_i + \theta_i^{(k)} S_{\text{GG}} \left(t_i; \mathbf{a}^{(k)}, \mathbf{d}^{(k)}, \mathbf{p}^{(k)} \right), \quad (3.11)$$

em que

$$\theta_i^{(k)} = \exp \left(f^{(k)}(\mathbf{x}_i) \right) = \exp \left(\sum_{j=1}^n \alpha_j^{(k)} K(\mathbf{x}_i, \mathbf{x}_j) \right). \quad (3.12)$$

Substituindo N_i por sua esperança condicional na log-verossimilhança completa penalizada e eliminando termos constantes em relação aos parâmetros, obtém-se a função auxiliar penalizada

$$Q_P = Q_\alpha + Q_{GG}, \quad (3.13)$$

em que

$$Q_\alpha = \sum_{i=1}^n \left[-\exp(f(\mathbf{x}_i)) + \hat{N}_i^{(k+1)} f(\mathbf{x}_i) \right] - \frac{\lambda}{2} \boldsymbol{\alpha}^\top \mathbf{K} \boldsymbol{\alpha}, \quad (3.14)$$

e

$$Q_{GG} = \sum_{i=1}^n \left[\delta_i \log f_{GG}(t_i; \alpha, d, p) + (\hat{N}_i^{(k+1)} - \delta_i) \log S_{GG}(t_i; \alpha, d, p) \right]. \quad (3.15)$$

Observa-se que a função auxiliar penalizada é separável em dois blocos de parâmetros: o primeiro associado aos coeficientes do kernel, $\boldsymbol{\alpha}$, e o segundo aos parâmetros da distribuição Gama Generalizada, (α, d, p) . Essa decomposição permite que o passo M seja realizado por meio de atualizações alternadas dos dois blocos.

Inicialmente, atualizam-se os coeficientes do kernel resolvendo

$$\boldsymbol{\alpha}^{(k+1)} = \arg \max_{\boldsymbol{\alpha}} Q_\alpha. \quad (3.16)$$

Em seguida, atualizam-se os parâmetros da distribuição Gama Generalizada por meio de

$$(\alpha^{(k+1)}, d^{(k+1)}, p^{(k+1)}) = \arg \max_{\alpha, d, p} Q_{GG}. \quad (3.17)$$

Ambos os problemas de maximização são resolvidos numericamente por meio do algoritmo L-BFGS-B, utilizando as derivadas analíticas das respectivas funções objetivo.

Após cada iteração, calcula-se a log-verossimilhança penalizada observada

$$\ell_P = \sum_{i=1}^n \left[\delta_i (f(\mathbf{x}_i) + \log f_{GG}(t_i; \alpha, d, p)) - \exp(f(\mathbf{x}_i)) F_{GG}(t_i; \alpha, d, p) \right] - \frac{\lambda}{2} \boldsymbol{\alpha}^\top \mathbf{K} \boldsymbol{\alpha}, \quad (3.18)$$

a qual é utilizada para monitorar a convergência do algoritmo. O procedimento iterativo é interrompido quando a variação absoluta da log-verossimilhança penalizada observada entre duas iterações consecutivas se torna inferior a uma tolerância previamente especificada, isto é,

$$\left| \ell_P^{(k+1)} - \ell_P^{(k)} \right| < \varepsilon, \quad (3.19)$$

em que $\varepsilon > 0$ representa uma constante de tolerância.

Algoritmo 1 – Algoritmo EM penalizado para estimar o modelo GG-KM - $N_i \sim \text{Poisson}(\theta(\mathbf{x}_i))$.

- 1: Inicialize $\alpha^{(0)}$, $\mathbf{a}^{(0)}$, $\mathbf{d}^{(0)}$, $\mathbf{p}^{(0)}$ e escolha uma tolerância $\varepsilon > 0$.
- 2: Defina $k \leftarrow 0$.
- 3: **repita**
- 4: **E-step:** para $i = 1, \dots, n$, calcule

$$\hat{N}_i^{(k+1)} = \delta_i + \exp \left(\sum_{j=1}^n \alpha_j^{(k)} K(x_i, x_j) \right) S_{GG} \left(t_i; \mathbf{a}^{(k)}, \mathbf{d}^{(k)}, \mathbf{p}^{(k)} \right).$$

- 5: **M-step:**

$$\alpha^{(k+1)} = \arg \max_{\alpha} \left\{ \sum_{i=1}^n \left[-\exp \left(\sum_{j=1}^n \alpha_j K(x_i, x_j) \right) + \hat{N}_i^{(k+1)} \sum_{j=1}^n \alpha_j K(x_i, x_j) \right] - \frac{\lambda}{2} \alpha^\top K \alpha \right\}.$$

$$(\mathbf{a}^{(k+1)}, \mathbf{d}^{(k+1)}, \mathbf{p}^{(k+1)}) = \arg \max_{\mathbf{a}, \mathbf{d}, \mathbf{p}} \sum_{i=1}^n \left[\delta_i \log f_{GG}(t_i; \mathbf{a}, \mathbf{d}, \mathbf{p}) + (\hat{N}_i^{(k+1)} - \delta_i) \log S_{GG}(t_i; \mathbf{a}, \mathbf{d}, \mathbf{p}) \right].$$

- 6: Calcule a log-verossimilhança penalizada observada

$$\ell_p^{(k+1)} = \ell_p \left(\alpha^{(k+1)}, \mathbf{a}^{(k+1)}, \mathbf{d}^{(k+1)}, \mathbf{p}^{(k+1)} \right).$$

- 7: Atualize

$$\Delta^{(k+1)} = \left| \ell_p^{(k+1)} - \ell_p^{(k)} \right|.$$

- 8: $k \leftarrow k + 1$.

- 9: **até** $\Delta^{(k+1)} < \varepsilon$
-

3.2.3 Estimação do modelo GG-KM com riscos latentes Binomial Negativa

Uma generalização do modelo apresentado anteriormente consiste em assumir que o número de riscos latentes N_i segue uma distribuição Binomial Negativa em vez de uma distribuição de Poisson. Em vez de especificar essa distribuição por meio de sua função de probabilidade, adota-se a parametrização definida pela função geradora de probabilidades

$$A(u) = [1 + \phi \theta_i (1 - u)]^{-1/\phi}, \quad (3.20)$$

onde $\theta_i > 0$ representa o número médio de riscos latentes e ϕ é um parâmetro de dispersão. Sob essa parametrização,

$$\mathbb{E}(N_i) = \theta_i, \quad \text{Var}(N_i) = \theta_i + \phi \theta_i^2. \quad (3.21)$$

Assim, valores positivos de ϕ produzem sobredispersão em relação ao modelo de Poisson. Além disso, essa parametrização engloba importantes casos particulares. Quando $\phi \rightarrow 0$,

recupera-se a distribuição de Poisson e, conseqüentemente, o modelo GG-KM apresentado na seção anterior. Já o caso $\phi = -1$ conduz ao modelo de mistura de [Berkson e Gage \(1952\)](#). Neste trabalho, entretanto, considera-se apenas o cenário $\phi > 0$, correspondente à presença de sobredispersão.

A função de sobrevivência populacional passa a ser

$$S_{\text{pop}}(t) = [1 + \phi \theta_i F_{\text{GG}}(t; \alpha, d, p)]^{-1/\phi}, \quad (3.22)$$

com

$$\theta_i = \exp \left(\sum_{j=1}^n \alpha_j K(\mathbf{x}_i, \mathbf{x}_j) \right). \quad (3.23)$$

Conseqüentemente, a log-verossimilhança penalizada observada é dada por

$$\ell_p = \sum_{i=1}^n \left\{ \delta_i [f(\mathbf{x}_i) + \log f_{\text{GG}}(t_i; \alpha, d, p)] - \left(\frac{1}{\phi} + \delta_i \right) \log [1 + \phi \theta_i F_{\text{GG}}(t_i; \alpha, d, p)] \right\} - \frac{\lambda}{2} \boldsymbol{\alpha}^\top \mathbf{K} \boldsymbol{\alpha}. \quad (3.24)$$

Quando o parâmetro de dispersão ϕ é previamente especificado, ele é mantido fixo ao longo do processo iterativo e apenas os parâmetros $\boldsymbol{\alpha}$, α , d e p são estimados. Por outro lado, quando ϕ não é previamente informado, sua estimação é realizada conjuntamente com os demais parâmetros do modelo.

Neste último caso, a estimação é realizada por meio de uma extensão do algoritmo EM, o Expectation Conditional Maximization Either (ECME) ([MCLACHLAN; KRISHNAN, 2008](#)). A escolha desse algoritmo decorre da presença do parâmetro de dispersão ϕ , cuja atualização não admite solução analítica em forma fechada. De fato, ϕ aparece simultaneamente nos termos $\log(1 + \phi \theta_i F_{\text{GG}}(t_i))$, $1/\phi$ e nas esperanças condicionais dos riscos latentes, o que torna a maximização da função auxiliar substancialmente mais complexa do que a atualização dos demais parâmetros. Assim, os parâmetros $\boldsymbol{\alpha}$ e (α, d, p) são atualizados por meio da maximização da função auxiliar, enquanto ϕ é atualizado diretamente pela maximização da log-verossimilhança observada.

No passo E, obtém-se

$$\hat{N}_i^{(k+1)} = \mathbb{E}[N_i | \mathcal{D}_{\text{obs}}, \Theta^{(k)}] = \delta_i + \frac{(1 + \phi^{(k)} \delta_i) \theta_i^{(k)} S_{\text{GG}}(t_i; \alpha^{(k)}, d^{(k)}, p^{(k)})}{1 + \phi^{(k)} \theta_i^{(k)} F_{\text{GG}}(t_i; \alpha^{(k)}, d^{(k)}, p^{(k)})}. \quad (3.25)$$

Substituindo as quantidades não observadas por suas respectivas esperanças condicionais, obtém-se uma função auxiliar penalizada que pode ser decomposta em

$$Q_P = Q_\alpha + Q_{\text{GG}}. \quad (3.26)$$

O termo associado aos parâmetros da distribuição Gama Generalizada, Q_{GG} , permanece idêntico ao obtido no caso Poisson. Já a componente dependente de α passa a ser

$$Q_{\alpha} = \sum_{i=1}^n \left[\hat{N}_i^{(k+1)} \log(\theta_i) - \left(\hat{N}_i^{(k+1)} + \frac{1}{\phi} \right) \log(1 + \phi \theta_i) \right] - \frac{\lambda}{2} \alpha^{\top} K \alpha. \quad (3.27)$$

O passo CM consiste então nas atualizações

$$\alpha^{(k+1)} = \arg \max_{\alpha} Q_{\alpha}, \quad (3.28)$$

e

$$(\alpha^{(k+1)}, d^{(k+1)}, p^{(k+1)}) = \arg \max_{\alpha, d, p} Q_{GG}. \quad (3.29)$$

Quando ϕ não é previamente especificado, realiza-se adicionalmente a etapa ECME

$$\phi^{(k+1)} = \arg \max_{\phi > 0} \ell_p \left(\alpha^{(k+1)}, \alpha^{(k+1)}, d^{(k+1)}, p^{(k+1)}, \phi \right). \quad (3.30)$$

A otimização dos problemas de maximização é realizada numericamente por meio do algoritmo L-BFGS-B, utilizando-se as derivadas analíticas das respectivas funções objetivo. O processo iterativo é repetido até a convergência da log-verossimilhança penalizada observada.

Algoritmo 2 – Algoritmo ECME para estimar o modelo GG-KM com riscos latentes Binomial Negativa

- 1: Inicialize $\alpha^{(0)}$, $a^{(0)}$, $d^{(0)}$, $p^{(0)}$, $\phi^{(0)}$ e escolha uma tolerância $\varepsilon > 0$.
- 2: Defina $k \leftarrow 0$.
- 3: **repita**
- 4: Para $i = 1, \dots, n$, calcule

$$\theta_i^{(k)} = \exp \left(\sum_{j=1}^n \alpha_j^{(k)} K(x_i, x_j) \right),$$

$$F_{GG}^{(k)}(t_i) = F_{GG}(t_i; a^{(k)}, d^{(k)}, p^{(k)}), \quad S_{GG}^{(k)}(t_i) = 1 - F_{GG}^{(k)}(t_i).$$

- 5: **E-step:**

$$\hat{N}_i^{(k+1)} = \delta_i + \frac{(1 + \phi^{(k)} \delta_i) \theta_i^{(k)} S_{GG}^{(k)}(t_i)}{1 + \phi^{(k)} \theta_i^{(k)} F_{GG}^{(k)}(t_i)}, \quad i = 1, \dots, n.$$

- 6: **M-step:**

$$\alpha^{(k+1)} = \arg \max_{\alpha} \left\{ \sum_{i=1}^n \left[\hat{N}_i^{(k+1)} \log(\theta_i) - \left(\hat{N}_i^{(k+1)} + \frac{1}{\phi^{(k)}} \right) \log(1 + \phi^{(k)} \theta_i) \right] - \frac{\lambda}{2} \alpha^\top K \alpha \right\},$$

$$(a^{(k+1)}, d^{(k+1)}, p^{(k+1)}) = \arg \max_{a, d, p} \sum_{i=1}^n \left[\delta_i \log f_{GG}(t_i; a, d, p) + (\hat{N}_i^{(k+1)} - \delta_i) \log S_{GG}(t_i; a, d, p) \right].$$

$$\phi^{(k+1)} = \arg \max_{\phi > 0} \ell_O(\alpha^{(k+1)}, a^{(k+1)}, d^{(k+1)}, p^{(k+1)}, \phi).$$

- 7: Calcule a log-verossimilhança penalizada observada

$$\ell_p^{(k+1)} = \ell_p(\alpha^{(k+1)}, a^{(k+1)}, d^{(k+1)}, p^{(k+1)}, \phi^{(k+1)}).$$

- 8: Atualize

$$\Delta^{(k+1)} = \left| \ell_p^{(k+1)} - \ell_p^{(k)} \right|.$$

- 9: $k \leftarrow k + 1$.

- 10: **até** $\Delta^{(k+1)} < \varepsilon$
-

AVALIAÇÃO EXPERIMENTAL

4.1 Particionamento dos dados

A avaliação do desempenho preditivo dos modelos foi conduzida por meio de um esquema de validação baseado na divisão dos dados em conjuntos de treinamento e teste. Especificamente, adotou-se uma estratégia de holdout, na qual 70% das observações foram utilizadas para treinamento e os 30% restantes reservados para teste.

A separação foi realizada de forma aleatória, preservando, sempre que aplicável, a estrutura dos dados censurados, de modo a garantir que ambos os subconjuntos apresentassem proporções semelhantes de observações censuradas e não censuradas. Essa precaução é particularmente importante em problemas de análise de sobrevivência, uma vez que a distribuição dos tipos de censura pode influenciar significativamente o desempenho dos modelos.

Adicionalmente, com o objetivo de reduzir a variabilidade associada a uma única partição, o procedimento de holdout foi repetido múltiplas vezes. As métricas de desempenho foram então agregadas ao longo dessas repetições.

4.2 Estudo de simulação e Métricas de Erro

Com o objetivo de avaliar o desempenho do modelo GG-KM em diferentes cenários de complexidade da fração de cura, foi conduzido um estudo de simulação, seguindo a mesma estrutura de geração de dados proposta por [Pal e Aselisewine \(2023\)](#), adaptada ao contexto do modelo de tempo de promoção.

Foram considerados dois tamanhos de amostra, $n = 300$ e $n = 600$. Em cada replicação, os dados foram particionados em conjunto de treinamento e teste, sendo dois terços das observações destinados ao treinamento e o terço restante utilizado para avaliação preditiva.

Cada conjunto de dados foi gerado a partir de duas covariáveis independentes,

$$x_1, x_2 \sim N(0, 1).$$

A estrutura de cura foi construída a partir de três métodos distintos para a geração da probabilidade de não cura, permitindo avaliar o comportamento do modelo sob diferentes graus de linearidade e não linearidade. Para o primeiro caso, considera-se uma fronteira linear, dada por

$$\pi(\mathbf{x}) = \frac{\exp(0.3 - 5x_1 - 3x_2)}{1 + \exp(0.3 - 5x_1 - 3x_2)}.$$

Esse cenário representa a estrutura clássica de regressão logística, em que indivíduos curados e não curados são linearmente separáveis.

No segundo método, é introduzido uma relação quadrática entre as covariáveis, com o objetivo de avaliar a capacidade do modelo em capturar superfícies de decisão não lineares. Portanto, tem-se:

$$\pi(\mathbf{x}) = \frac{\exp(0.3 + 5x_1^2 - 3x_2^2)}{1 + \exp(0.3 + 5x_1^2 - 3x_2^2)}.$$

Por fim, o para o terceiro método, é considerado uma estrutura não linear e periódica:

$$\pi(\mathbf{x}) = \exp\{-\exp(0.3 - 5\cos(x_1) - 3\sin(x_2))\}.$$




Figura 1 – Simulação de curados e não curados sobre os três métodos descritos. Respectivamente, pode-se observar o método 1, 2 e 3.

Esse cenário impõe fronteiras de classificação complexas, sendo particularmente útil para avaliar a flexibilidade da abordagem baseada em kernels. Os dados simulados, considerando cada um dos três casos, pode ser visualizado na Figura 1.

Para a componente de latência, os tempos associados aos riscos latentes foram gerados a partir de uma distribuição Weibull, cuja função de risco é dada por

$$h(t|\mathbf{x}) = h_0(t) \exp(\beta_1 x_1 + \beta_2 x_2),$$

onde a função de risco basal foi definida como

$$h_0(t) = \alpha t^{\alpha-1}, \quad \alpha > 0.$$

Essa especificação implica que os tempos latentes seguem uma distribuição Weibull com parâmetro de forma α e parâmetro de escala $\lambda(\mathbf{x}) = \{\exp(\beta_1 x_1 + \beta_2 x_2)\}^{-1/\alpha}$.

Os valores utilizados para os parâmetros foram $(\alpha, \beta_1, \beta_2) = (2, 1, 0.5)$. Os tempos de censura foram gerados independentemente a partir de uma distribuição exponencial com taxa igual a 0.2, isto é $C_i \sim \text{Exp}(0.2)$. A partir desta configuração, a proporção de censura obtida para o método 1, 2 e 3 é de aproximadamente 0,60, 0,50 e 0,40, respectivamente. Para a proporção de cura foi obtido aproximadamente 0,50, 0,60 e 0,20.

A geração dos dados simulados foi realizada com base na estrutura do modelo de fração de cura em tempo de promoção. Nesse contexto, cada indivíduo pode pertencer a um de dois grupos: curados ou suscetíveis ao evento de interesse. A probabilidade de um indivíduo ser suscetível é dada por $\pi(\mathbf{x}_i)$, enquanto a probabilidade de ser curado é $1 - \pi(\mathbf{x}_i)$.

O processo de simulação ocorre em duas etapas. Inicialmente, para cada indivíduo, gera-se uma variável uniforme U_i e um tempo de censura C_i . O valor de U_i é utilizado para determinar se o indivíduo pertence ao grupo curado ou suscetível. Caso $U_i \leq 1 - \pi(\mathbf{x}_i)$, o indivíduo é classificado como curado e seu tempo observado corresponde apenas ao tempo de censura.

Por outro lado, se $U_i > 1 - \pi(\mathbf{x}_i)$, o indivíduo é considerado suscetível. Nesse caso, gera-se um tempo latente de falha Y_i utilizando o método da transformada inversa aplicado à função de sobrevivência populacional. Para isso, sorteia-se uma nova variável uniforme no intervalo $(1 - \pi(\mathbf{x}_i), 1)$ e resolve-se a equação associada à função de sobrevivência, obtendo assim o tempo de falha latente.

Por fim, o tempo observado é definido como o mínimo entre o tempo latente de falha e o tempo de censura. O indicador de falha é então determinado de acordo com qual desses tempos ocorreu primeiro. Esse procedimento garante que os dados simulados preservem simultaneamente a estrutura de fração de cura e a presença de censura à direita. O algoritmo pode ser visualizado no Algoritmo 3

Algoritmo 3 – Geração de dados simulados com fração de cura

```

1: para  $i = 1, \dots, n$  faça
2:   Gerar  $U_i \sim \text{Uniform}(0, 1)$ 
3:   Gerar  $C_i \sim \text{Exp}(0.2)$ 
4:   se  $U_i \leq 1 - \pi(\mathbf{x}_i)$  então
5:     Definir  $t_i \leftarrow C_i$ 
6:     Definir  $\delta_i \leftarrow 0$ 
7:   senão
8:     Gerar  $U_i^* \sim \text{Uniform}(1 - \pi(\mathbf{x}_i), 1)$ 
9:     Resolver
                                    $(1 - \pi(\mathbf{x}_i))^{F(Y_i|\mathbf{x}_i)} = U_i^*$ 
10:    Obter
                                    $Y_i = F^{-1} \left( \frac{\log(U_i^*)}{\log(1 - \pi(\mathbf{x}_i))} \right)$ 
11:    Definir  $t_i \leftarrow \min(Y_i, C_i)$ 
12:    se  $t_i = Y_i$  então
13:      Definir  $\delta_i \leftarrow 1$ 
14:    senão
15:      Definir  $\delta_i \leftarrow 0$ 
16:    fim se
17:  fim se
18: fim para

```

O desempenho do modelo GG-KM foi avaliado com base no viés, erro quadrático médio (EQM) e no *Integrated Brier Score* (IBS) com ajuste IPCW (*Inverse Probability of Censoring Weighting*) (DONG *et al.*, 2020), permitindo mensurar tanto a qualidade da estimação dos parâmetros quanto a capacidade preditiva do modelo.

Seja $\hat{S}_i(t)$ a probabilidade de sobrevivência estimada para o indivíduo i no tempo t , e T_i^* o tempo observado. Os pesos IPCW são definidos por

$$\omega_i(t) = \frac{\mathbb{I}(T_i^* \leq t, \delta_i = 1)}{\hat{G}(T_i^*)} + \frac{\mathbb{I}(T_i^* > t)}{\hat{G}(t)},$$

em que $\hat{G}(t)$ representa a função de sobrevivência do mecanismo de censura, geralmente estimada pelo método de Kaplan-Meier.

Com isso, o Brier Score ajustado por IPCW no tempo t é dado por

$$\text{BS}_{\text{IPCW}}(t) = \frac{1}{\tilde{n}(t)} \sum_{i=1}^n \left[\hat{S}_i(t)^2 \frac{\mathbb{I}(T_i^* \leq t, \delta_i = 1)}{\hat{G}(T_i^*)} + (1 - \hat{S}_i(t))^2 \frac{\mathbb{I}(T_i^* > t)}{\hat{G}(t)} \right],$$

em que

$$\tilde{n}(t) = \sum_{i=1}^n \omega_i(t)$$

corresponde à soma dos pesos IPCW no tempo t .

O IBS é então definido como a integral do Brier Score ao longo do intervalo de acompanhamento:

$$\text{IBS} = \frac{1}{\tau} \int_0^{\tau} \text{BS}_{\text{IPCW}}(t) dt,$$

em que τ representa o tempo máximo de observação.

Por fim, a estimativa do EQM e do viés em relação à probabilidade dos não curados foi obtida a partir das seguintes expressões, respectivamente (PAL; ASELISEWINE, 2023):

$$\text{Viés}(\hat{\pi}(\mathbf{x})) = \frac{1}{N_1} \sum_{r=1}^{N_1} \left[\frac{1}{n} \sum_{i=1}^n \{ \pi^{(r)}(\mathbf{x}_i) - \pi^{(r)}(\mathbf{x}_i) \} \right],$$

$$\text{EQM}(\hat{\pi}(\mathbf{x})) = \frac{1}{N_1} \sum_{r=1}^{N_1} \left[\frac{1}{n} \sum_{i=1}^n \left\{ \pi^{(r)}(\mathbf{x}_i) - \pi^{(r)}(\mathbf{x}_i) \right\}^2 \right].$$

RESULTADOS

5.1 Aplicação a Dados Simulados

Nesta seção, avalia-se o desempenho do modelo proposto GG-KM em diferentes cenários de simulação, com o objetivo de investigar sua capacidade de adaptação sob diferentes estruturas do componente de cura. Para isso, foram considerados dois tamanhos de amostra ($n = 300$ e $n = 600$) e três métodos para geração de dados, representando diferentes relações entre covariáveis e fração de cura.

A Figura 2 apresenta a distribuição do IBS para cada kernel, obtida ao longo das replicações da validação cruzada. Como medida global de desempenho preditivo em análise de sobrevivência, menores valores de IBS indicam melhor ajuste.

De forma geral, observa-se que a escolha do kernel impacta diretamente a qualidade das estimativas, sobretudo em cenários mais complexos. No método 1, o desempenho entre os kernels é relativamente mais heterogêneo, com vantagem para kernels como cauchy, exponential e sigmoid, que apresentam menores valores centrais de IBS e menor variabilidade.

Nos métodos 2 e 3, por outro lado, o padrão é mais consistente: kernels não lineares, em especial rbf, cauchy, exponential e polynomial, tendem a apresentar melhor desempenho e maior estabilidade quando comparados ao kernel linear. Esse comportamento sugere que tais cenários envolvem estruturas mais complexas, cuja modelagem é favorecida por espaços de maior flexibilidade induzidos por esses kernels.

Dessa forma, os resultados mostram que o desempenho do GG-KM é fortemente dependente da especificação do kernel, sendo os kernels não lineares particularmente mais adequados em cenários com maior complexidade nos dados.

Como indicativo da capacidade do modelo proposto em capturar a fração de cura presente nos dados, foi realizada também uma comparação entre o estimador de Kaplan-Meier e a curva de




Figura 2 – Distribuição do IBS em relação a cada kernel, para diferentes cenários de simulação.

sobrevivência estimada pelo modelo GG-KM. Essa comparação pode ser observada na Figura 3. De modo geral, observa-se que o modelo GG-KM apresenta boa aderência ao comportamento do estimador de Kaplan-Meier, sugerindo que o componente de cura está sendo adequadamente modelado. Contudo, no cenário em que $n = 600$ para o método 3, nota-se um afastamento maior entre as curvas, indicando um ajuste inferior nesse caso específico.




Figura 3 – Comparação da curva de sobrevivência estimada pelo GG-KM e KME.

A Tabela ?? complementa a análise anterior ao sintetizar, para cada cenário, o kernel com melhor desempenho segundo o critério de menor IBS médio. Os resultados reforçam a evidência de que kernels não lineares tendem a oferecer melhor capacidade de adaptação às diferentes estruturas simuladas.

Observa-se que o kernel cauchy foi selecionado nos cenários com $n = 300$ para os métodos 1 e 2, enquanto os kernels exponential, rbf, sigmoid e polynomial também se destacaram em diferentes configurações.

Além disso, nota-se que o aumento do tamanho amostral resultou, em geral, em redução do IBS médio e do viés absoluto, especialmente nos métodos 2 e 3, indicando ganhos em precisão e estabilidade na estimação da fração de cura. Em particular, o cenário com $n = 600$ e método 3 apresentou o melhor desempenho, com menor IBS e menor EQM.

Tabela 1 – Comparação entre as versões Poisson e Binomial Negativa do modelo GG-KM.

n	Método	Poisson				Binomial Negativa - com ϕ estimado			
		K	IBS	Viés ($\hat{\pi}(\mathbf{x})$)	EQM ($\hat{\pi}(\mathbf{x})$)	K	IBS	Viés ($\hat{\pi}(\mathbf{x})$)	EQM ($\hat{\pi}(\mathbf{x})$)
300	1	exp.	0.1221	-0.0505	0.0305	exp.	0.1220	-0.0443	0.0292
	2	poly.	0.1528	0.0709	0.0778	cauchy	0.1528	0.0539	0.0706
	3	exp.	0.1248	-0.0088	0.0211	exp.	0.1226	-0.0039	0.0197
600	1	exp.	0.1009	0.0100	0.0249	sigmoid	0.1008	0.0118	0.0300
	2	cauchy	0.1429	-0.0048	0.0260	exp.	0.1430	-0.0046	0.0297
	3	cauchy	0.0854	0.0052	0.0213	cauchy	0.0856	0.0052	0.0213

5.2 Aplicação a Dados Reais

O conjunto de dados reais escolhido para aplicação do modelo foi o Melanoma, amplamente utilizado em estudos de análise de sobrevivência. Esse conjunto contém informações de 205 pacientes diagnosticados com melanoma maligno, um tipo agressivo de câncer de pele, submetidos a cirurgia radical no Hospital Universitário de Odense, na Dinamarca, entre os anos de 1962 e 1977.

Os pacientes foram acompanhados até o final de 1977, período no qual 134 indivíduos permaneceram vivos, enquanto 71 evoluíram para óbito, sendo 57 mortes atribuídas diretamente ao melanoma e 14 decorrentes de outras causas. Este conjunto de dados, especificamente, é utilizado em textos de modelos com fração de cura, pois há o conhecimento de que existe de fato uma fração de cura no conjunto de dados.

A base é composta por sete variáveis: tempo de acompanhamento em dias (time), status do paciente ao final do estudo (status), sexo (sex), idade no momento da cirurgia (age), ano da cirurgia (year), espessura do tumor em milímetros (thickness) e presença de ulceração (ulcer).

Para fins de modelagem, consideramos como evento de interesse o óbito por melanoma, tratando os demais casos, pacientes vivos ao final do estudo ou óbitos por outras causas, como observações censuradas. Portanto, ao final, tem-se aproximadamente 73% de observações censuradas.

Inicialmente, assim como foi feito com os dados simulados, foi realizada a comparação entre a curva de sobrevivência estimada pelo modelo proposto e o estimador de Kaplan-Meier, conforme apresentado na Figura 4. Como pode ser observado a partir da figura, há de fato indícios de que o modelo está conseguindo capturar adequadamente a fração de cura presente nos dados.




Figura 4 – Curva de Kaplan Meier para o conjunto de dados de melanoma, comparando o modelo GG-KM.

Na Figura 5, pode-se observar a variação do desempenho do modelo GG-KM para cada kernel, com base na distribuição do IBS. Nota-se que o kernel cauchy, embora tenha alcançado um dos menores valores de IBS, foi também o que apresentou maior variabilidade nessa métrica. Os kernels linear e gaussiano apresentaram desempenhos bastante semelhantes entre si. De forma análoga, os kernels laplaciano e exponencial também exibiram resultados próximos, destacando-se por apresentarem menor variabilidade, embora não tenham atingido os menores valores de IBS. Por fim, os kernels sigmoid e polinomial também apresentaram comportamento semelhante, tanto em termos de nível quanto de dispersão do erro.

Tabela 2 – Resultados do IBS médio, C-index médio e respectivos desvios padrão para cada kernel no conjunto de dados Melanoma.

N	Métrica	linear	exponential	cauchy	rbf	laplacian	polynomial	sigmoid
Poisson	IBS	0.1511	0.1545	0.1549	0.1556	0.1559	0.1570	0.1594
	DP IBS	0.0293	0.0222	0.0260	0.0289	0.0239	0.0312	0.0267
	C-index	0.7088	0.7186	0.7127	0.7108	0.6976	0.7009	0.6815
	DP C-index	0.0435	0.0337	0.0420	0.0416	0.0481	0.0435	0.0644
Binomial Negativa com ϕ estimado	IBS	0.1573	0.1544	0.1548	0.1572	0.1559	0.1592	0.1598
	DP IBS	0.0246	0.0223	0.0250	0.0245	0.0239	0.0178	0.0264

A Tabela 2 resume esses resultados ao apresentar o IBS médio e seu respectivo desvio padrão para cada kernel. Observa-se que o kernel linear apresentou o menor IBS médio, indicando o melhor desempenho preditivo global nesse conjunto de dados, seguido de perto pelos kernels exponencial e polynomial.

Embora o kernel cauchy tenha apresentado alguns bons resultados, seu IBS médio mais elevado e maior variabilidade indicam menor estabilidade no processo de estimação. Por outro lado, o kernel exponencial se destaca por combinar desempenho preditivo próximo ao melhor




Figura 5 – Distribuição do IBS em relação a cada kernel.

observado com a menor dispersão entre todos os kernels avaliados, sugerindo maior robustez. De modo geral, os resultados indicam que, para o conjunto de dados Melanoma, estruturas mais simples ou moderadamente flexíveis parecem ser suficientes para capturar adequadamente a dinâmica da sobrevivência e a fração de cura presente nos dados.

CONCLUSÃO

Este trabalho apresentou uma extensão do modelo de tempo de promoção para a modelagem da componente de cura por meio da incorporação de funções kernel, resultando no modelo GG-KM. Essa abordagem permite maior flexibilidade na estimação, tornando possível capturar relações complexas e não lineares entre as covariáveis e a fração de cura.

Nos experimentos com dados simulados, os resultados evidenciaram que kernels não lineares apresentaram desempenho superior em cenários com maior complexidade, particularmente nos métodos 2 e 3, nos quais alcançaram os menores valores de IBS. Em contrapartida, o kernel linear apresentou desempenho inferior nesses cenários, reforçando a importância da flexibilidade introduzida pelos kernels.

Além disso, tanto nos dados simulados quanto na aplicação ao conjunto de dados reais, observou-se bom ajuste entre a curva de sobrevivência estimada pelo modelo GG-KM e o estimador de Kaplan-Meier. Esse comportamento fornece evidências de que o modelo proposto é capaz de representar adequadamente a fração de cura presente nos dados.

De forma geral, os resultados obtidos indicam que o GG-KM constitui uma alternativa promissora para modelagem de sobrevivência com fração de cura, especialmente em contextos onde a estrutura da relação entre covariáveis e sobrevivência apresenta maior complexidade.

REFERÊNCIAS

BERKSON, J.; GAGE, R. P. Survival curve for cancer patients following treatment. **Journal of the American Statistical Association**, Taylor & Francis, v. 47, n. 259, p. 501–515, 1952. Citado nas páginas 24 e 34.

DONG, G.; MAO, L.; HUANG, B.; GAMALO-SIEBERS, M.; WANG, J.; YU, G.; HOAGLIN, D. C. The inverse-probability-of-censoring weighting (ipcw) adjusted win ratio statistic: an unbiased estimator in the presence of independent censoring. **Journal of biopharmaceutical statistics**, Taylor & Francis, v. 30, n. 5, p. 882–899, 2020. Citado na página 40.

MCLACHLAN, G. J.; KRISHNAN, T. **The EM algorithm and extensions**. [S.l.]: John Wiley & Sons, 2008. Citado nas páginas 30 e 34.

MOHRI, M.; ROSTAMIZADEH, A.; TALWALKAR, A. **Foundations of machine learning**. [S.l.]: MIT press, 2018. Citado nas páginas 7, 9 e 27.

PAL, S.; ASELISEWINE, W. A semiparametric promotion time cure model with support vector machine. **The Annals of Applied Statistics**, Institute of Mathematical Statistics, v. 17, n. 3, p. 2680–2699, 2023. Citado nas páginas 37 e 41.

PRINCE, T.; BOMMERT, A.; RAHNENFÜHRER, J.; SCHMID, M. On the estimation of inverse-probability-of-censoring weights for the evaluation of survival prediction error. **PloS one**, Public Library of Science San Francisco, CA USA, v. 20, n. 1, p. e0318349, 2025. Citado nas páginas 7 e 9.

STACY, E. W. A generalization of the gamma distribution. **The Annals of mathematical statistics**, JSTOR, p. 1187–1192, 1962. Citado nas páginas 7 e 9.

