

Model of theses and dissertations in LaTeX of the ICMC

Gabriel de Jesus Pereira

Qualificação de Mestrado do Programa Interinstitucional de
Pós-Graduação em Estatística (PIPGes)

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Gabriel de Jesus Pereira

Model of theses and dissertations in LaTeX of the ICMC

Monograph submitted to the Institute of Mathematics and Computer Science – ICMC-USP and to the Department of Statistics – DEs-UFSCar – as part of the qualifying exam requisites of the Statistics Interagency Graduate Program, for the degree of Master in Statistics.

Concentration Area: Statistics

Advisor: Profa. Dra. Vera Lucia
Damasceno Tomazella

USP – São Carlos
August 2021

Ficha Exemplo

Utilize o link: <https://www.icmc.usp.br/institucional/estrutura-administrativa/biblioteca/servicos/ficha> para montar a ficha da sua dissertação e substitua essa.

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi
e Seção Técnica de Informática, ICMC/USP,
com os dados inseridos pelo(a) autor(a)

A634m Antonelli, Humberto Lidio
 Modelo de teses e dissertações em LaTeX do ICMC /
Humberto Lidio Antonelli; orientador Renata Pontin
de Mattos Fortes. -- São Carlos, 2018.
 81 p.

 Tese (Doutorado - Programa de Pós-Graduação em
Ciências de Computação e Matemática Computacional) --
Instituto de Ciências Matemáticas e de Computação,
Universidade de São Paulo, 2018.

 1. Modelo. 2. Monografia de qualificação. 3.
Dissertação. 4. Tese. 5. Latex. I. Fortes, Renata
Pontin de Mattos, orient. II. Título.

Bibliotecários responsáveis pela estrutura de catalogação da publicação de acordo com a AACR2:
Gláucia Maria Saia Cristianini - CRB - 8/4938
Juliana de Souza Moraes - CRB - 8/6176

Gabriel de Jesus Pereira

Título - A Definir

Monografia apresentada ao Instituto de Ciências Matemáticas e de Computação – ICMC-USP e ao Departamento de Estatística – DEs-UFSCar, para o Exame de Qualificação, como parte dos requisitos para obtenção do título de Mestre em Estatística – Programa Interinstitucional de Pós-Graduação em Estatística.

Área de Concentração: Estatística

Orientadora: Profa. Dra. Vera Lucia
Damasceno Tomazella

USP – São Carlos
Agosto de 2021

DEDICATÓRIA!!!!

ACKNOWLEDGEMENTS

AGRADECIMENTOS!!!!

“EPÍGRAFE!!!!”

RESUMO

GABRIEL, J. P. **Título - A Definir**. 2021. 70 p. Monografia (Mestrado em Estatística – Programa Interinstitucional de Pós-Graduação em Estatística) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2021.

Este artigo introduz o GG-KM, uma nova abordagem semiparamétrica para modelagem de taxa de cura no modelo de tempo de promoção. Abordamos as limitações dos preditores lineares tradicionais ao empregar Máquinas de Kernel para modelar o componente de cura dentro de um Reproducing Kernel Hilbert Space (RKHS) (MOHRI; ROSTAMIZADEH; TALWALKAR, 2018). Para fornecer máxima flexibilidade à função de risco dos indivíduos suscetíveis, incorporamos a distribuição Gama Generalizada (STACY, 1962), que engloba diversos modelos clássicos de sobrevivência. Derivamos uma estrutura de log-verossimilhança penalizada e fornecemos gradientes analíticos explícitos para a otimização conjunta dos pesos do kernel, hiperparâmetros e parâmetros da distribuição. O desempenho do modelo é validado por meio do Integrated Brier Score (IBS) com ajuste por IPCW (PRINCE *et al.*, 2025).

Palavras-chave: Análise de Sobrevivência, Censura, Reproducing Kernel Hilbert Space, Gama Generalizada, Representer Theorem.

ABSTRACT

GABRIEL, J. P. **Model of theses and dissertations in LaTeX of the ICMC**. 2021. 70 p. Monografia (Mestrado em Estatística – Programa Interinstitucional de Pós-Graduação em Estatística) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2021.

This paper introduces GG-KM, a novel semiparametric approach to promotion time cure rate modeling. We address the limitations of traditional linear predictors by employing Kernel Machines to model the cure component within a Reproducing Kernel Hilbert Space (RKHS) (MOHRI; ROSTAMIZADEH; TALWALKAR, 2018). To provide maximum flexibility for the hazard of susceptible individuals, we incorporate the Generalized Gamma (GG) distribution (STACY, 1962), which encompasses several standard survival models. We derive a penalized log-likelihood framework and provide explicit analytical gradients for the joint optimization of kernel weights, hyperparameters, and distribution parameters. Model performance is validated through the Integrated Brier Score (IBS) with IPCW adjustment (PRINCE *et al.*, 2025).

Keywords: Survival Analysis, Censoring, Reproducing Kernel Hilbert Space, Generalized Gamma, Representer Theorem.

LIST OF FIGURES

Figure 1 – Illustration of observed events and censoring types in survival analysis: observed event, right censoring, left censoring, and interval censoring.	26
Figure 2 – Illustration of observed events and censoring types in survival analysis: observed event, right censoring, left censoring, and interval censoring.	28
Figure 3 – Exemplo de estrutura de árvore de regressão. A árvore tem cinco folhas e quatro nós internos.	38
Figure 4 – Simulação de curados e não curados sobre os três métodos descritos. Respe- tivamente, pode-se observar o método 1, 2 e 3.	56
Figure 5 – Distribuição do IBS em relação a cada kernel, para diferentes cenários de simulação.	62
Figure 6 – Comparação da curva de sobrevivência estimada pelo GG-KM e KME. . . .	62
Figure 7 – Curva de Kaplan Meier para o conjunto de dados de melanoma, comparando o modelo GG-KM.	64
Figure 8 – Distribuição do IBS em relação a cada kernel.	65

LIST OF ALGORITHMS

Algorithm 1 – Algoritmo para crescer uma árvore de regressão (JAMES <i>et al.</i> , 2021). .	40
Algorithm 2 – Algoritmo EM penalizado para estimar o modelo GG-KM - $N_i \sim$ Poisson($\theta(\mathbf{x}_i)$).	48
Algorithm 3 – Algoritmo ECME para estimar o modelo GG-KM com riscos latentes Binomial Negativa	51
Algorithm 4 – Algoritmo EM penalizado para estimar o modelo GG-KM - $N_i \sim$ Binomial(K, θ_i^*).	52
Algorithm 5 – EM with functional gradient boosting for the GG-KM model - $N_i \sim$ Binomial(K, θ_i^*).	53
Algorithm 6 – Geração de dados simulados com fração de cura	58

LIST OF TABLES

Table 1 – Long-term survival, density, hazard, and cure fraction for the different distributions considered for the latent number of competing causes N	32
Table 2 – Comparação entre as versões Poisson e Binomial Negativa do modelo GG-KM.	63
Table 3 – Resultados do IBS médio, C-index médio e respectivos desvios padrão para cada kernel no conjunto de dados Melanoma.	64

CONTENTS

1	INTRODUCTION	23
2	FOUNDATIONS OF SURVIVAL ANALYSIS	25
2.1	Introduction	25
2.2	Censoring	25
2.3	Survival and hazard rate functions	27
2.3.1	<i>Likelihood for censored survival times</i>	29
2.4	Long-term survival models	30
2.4.1	<i>Bernoulli distribution</i>	32
2.4.2	<i>Binomial distribution</i>	33
2.4.3	<i>Negative Binomial distribution</i>	34
2.4.4	<i>Poisson distribution</i>	35
2.5	Kaplan–Meier estimator	35
3	FOUNDATIONS OF MACHINE LEARNING	37
3.1	Introduction	37
3.2	Decision tree	37
3.3	Ensemble Methods	40
3.3.1	<i>Bagging</i>	41
3.4	Gradient Boost	42
3.5	Kernel	42
3.6	Kernels	43
3.6.1	<i>Kernels positivos definidos</i>	43
3.6.2	<i>Espaços de Hilbert</i>	43
3.6.3	<i>Reproducing Kernel Hilbert Spaces</i>	44
3.6.4	<i>Teorema do Representante</i>	44
3.7	GG-KM	45
3.7.1	<i>Extensão não paramétrica via kernel</i>	45
3.7.2	<i>Estimação via algoritmo EM penalizado</i>	46
3.7.3	<i>Estimação do modelo GG-KM com riscos latentes Binomial Negativa</i>	48
4	EXPERIMENTAL EVALUATION	55
4.1	Particionamento dos dados	55
4.2	Estudo de simulação e Métricas de Erro	55

5	RESULTS	61
5.1	Aplicação a Dados Simulados	61
5.2	Aplicação a Dados Reais	63
6	CONCLUSION AND DISCUSSION	67
	BIBLIOGRAPHY	69

INTRODUCTION

FOUNDATIONS OF SURVIVAL ANALYSIS

2.1 Introduction

Knowing whether an event of interest will occur is crucial. However, in many situations, knowing when it will occur can be even more informative. In this context, a statistical methodology known as survival analysis arises. The elapsed time until the occurrence of an event of interest is referred to as the survival time (AALEN; BORGAN; GJESSING, 2008). For example, in a study concerned with loan default among credit union members, the survival time may be defined as the time until a member defaults on a loan. Survival analysis is therefore concerned with modeling the distribution of this time and investigating factors that may influence its occurrence. Thus, the objective of this chapter is to present the fundamental concepts underlying survival analysis.

2.2 Censoring

The main characteristic that distinguishes survival analysis from other areas of statistics is the presence of censored data. For example, consider a study in which credit union members are followed over time to investigate the occurrence of loan default. In this context, two situations may happen. Some members may default during the follow-up period, whereas others may not experience the event before the end of the study. In the latter case, censoring occurs because the survival time of these individuals is not fully observed; it is only known that the event will occur after a certain point in time.

Censoring can occur in three different forms. The example described above can be regarded as right censoring. Right censoring occurs when the event takes place after a certain time, but its exact occurrence time is unknown. Another type is left censoring, which occurs when the event has taken place before a certain time. In the context of loan default, an example of left censoring would be a member who was already in default at the beginning of the study, while the

exact time at which the default occurred is unknown. Finally, interval censoring occurs when the event takes place within a given time interval, but its exact occurrence time is unknown. Given the loan default example, interval censoring could arise if members were evaluated periodically and default was detected only during these assessments, without knowledge of the exact time at which it occurred. Figure 1 illustrates each type of censoring.




Figure 1 – Illustration of observed events and censoring types in survival analysis: observed event, right censoring, left censoring, and interval censoring.

Formally, let T denote the survival time and let l and u denote the lower and upper bounds of the censoring interval, respectively. Under interval censoring, it is only known that $l < T \leq u$, where both l and u are finite. Notice that left and right censoring can be viewed as special cases of interval censoring. Hence, left censoring corresponds to the interval $(-\infty, u]$, whereas right censoring corresponds to the interval (l, ∞) .

The methods presented in this work consider only right censoring, since it is the most common type encountered in practice. Thus, to represent survival data, let T^* be a random variable representing the time to failure, i.e., the time until the occurrence of the event of interest, and let U be a random variable representing the time to a censoring event. The observed time is $T = \min(T^*, U)$ and a censoring indicator $\delta = I[T^* \leq U]$. That is, δ takes the value 0 or 1 according to whether T is an observed failure time or a censored time (MOORE *et al.*, 2016). Hence, throughout this work, survival data will be represented by the triplet $\{(\mathbf{x}_i, t_i, \delta_i)\}_{i=1}^n$, where $\mathbf{x}_i \in \mathbb{R}^p$ denotes the vector of covariates, t_i the observed time, and δ_i an indicator variable associated with the i -th individual. The sample size is denoted by n , and p denotes the number of covariates.

Therefore, survival data are generally composed of both complete and incomplete observations (AALEN; BORGAN; GJESSING, 2008). As a result, survival analysis methods seek to incorporate censored observations into their methodology. Given the definition of censoring presented in this section, the next section introduces the definitions of the survival function and hazard rate, as well as some relationships between these functions.

2.3 Survival and hazard rate functions

Survival analysis is concerned with the study of the time until the occurrence of an event of interest. A survival distribution can be characterized through several equivalent functions, among which the survival function and the hazard rate function are fundamental (MOORE *et al.*, 2016). The survival function describes the probability that the event has not occurred by a given time t . Formally, let T denote the nonnegative random variable representing the survival time. The survival function is defined as

$$S(t) = P(T > t), \quad t \geq 0. \quad (2.1)$$

Thus, $S(t)$ represents the probability that an individual survives beyond time t , or, equivalently, that the event of interest has not occurred by that time. The survival function is a non-increasing function satisfying $S(0) = 1$ and $\lim_{t \rightarrow \infty} S(t) \geq 0$.

In the usual setting, the survival function decreases as t increases, reflecting the accumulation of events over time. However, it need not converge to zero. In particular, if $\lim_{t \rightarrow \infty} S(t) = 0$, the corresponding distribution is said to be proper. Conversely, when $\lim_{t \rightarrow \infty} S(t) > 0$, the distribution is said to be improper. The latter case is of particular relevance in cure-rate models, where the positive limiting value of the survival function can be interpreted as the probability of an individual belonging to a cured fraction. This distinction will be discussed in greater detail in the next section.

The hazard rate function, denoted by $h(t)$, characterizes the instantaneous risk of experiencing the event of interest, conditional on survival up to time t . More precisely, assuming that T is an absolutely continuous random variable with probability density function $f(t)$, the hazard rate at time t is defined as

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} P(t \leq T < t + \Delta t \mid T \geq t). \quad (2.2)$$

Thus, for a sufficiently small time interval Δt , the quantity

$$h(t)\Delta t$$

provides a first-order approximation to the conditional probability of experiencing the event during the interval $[t, t + \Delta t)$, given that the individual has survived up to time t . It is important to note that the hazard rate itself is not a probability and, consequently, is not restricted to the interval $[0, 1]$.

Under the assumption of absolute continuity, the hazard rate can be expressed in terms of the probability density function and the survival function as

$$h(t) = \frac{f(t)}{S(t)}. \quad (2.3)$$

Conversely, the survival function can be recovered from the hazard rate through the cumulative hazard function, defined as

$$H(t) = \int_0^t h(u) du. \quad (2.4)$$

Consequently,

$$S(t) = \exp \{-H(t)\} = \exp \left\{ - \int_0^t h(u) du \right\}. \quad (2.5)$$

Equation (2.5) establishes the fundamental relationship between the hazard rate and the survival function. In particular, the survival function is determined by the cumulative hazard over time. Consequently, different hazard profiles may lead to substantially different survival patterns, even when they are defined on the same time scale.




Figure 2 – Illustration of observed events and censoring types in survival analysis: observed event, right censoring, left censoring, and interval censoring.

Figure 2 illustrates this relationship. In panels (a) and (b), the hazard rate is relatively high at early times, resulting in a more pronounced decline in the corresponding survival function. Such a pattern may arise, for example, in populations characterized by a high risk of death shortly after entering the study. In contrast, panels (c) and (d) illustrate a hazard with a lower initial risk, leading to a slower decline in the corresponding survival function. These examples emphasize that the shape of the survival function is directly determined by the evolution of the hazard rate over time.

Although the survival and hazard rate functions provide two fundamental ways of characterizing a survival distribution, other distributional functions are also useful, particularly when deriving likelihoods and establishing relationships among different representations of the survival distribution. Among these, the cumulative distribution function and the probability density function are of particular importance.

The cumulative distribution function (CDF) of the survival time T is defined by

$$F(t) = P(T \leq t), \quad (2.6)$$

and, for a nonnegative random variable, is related to the survival function through

$$F(t) = 1 - S(t). \quad (2.7)$$

When T is absolutely continuous, its probability density function (PDF) is given by the derivative of the CDF,

$$f(t) = \frac{d}{dt}F(t) = -\frac{d}{dt}S(t). \quad (2.8)$$

Consequently, the principal functions associated with an absolutely continuous survival distribution are connected through

$$f(t) = h(t)S(t),$$

which follows directly from the definition of the hazard rate.

These relationships provide equivalent representations of the same underlying survival distribution. In particular, knowledge of any one of the functions, under the appropriate regularity conditions, allows the others to be obtained. The relationships among these functions will be used throughout the subsequent development of the survival and cure-rate models considered in this work.

2.3.1 Likelihood for censored survival times

In the absence of censoring, suppose that the survival times $T_1^*, \dots, T_n^*$ are independent and identically distributed with probability density function $f(t; \boldsymbol{\theta})$ and survival function $S(t; \boldsymbol{\theta})$, where $\boldsymbol{\theta}$ denotes the vector of model parameters. The likelihood function based on the complete survival times is then given by

$$L(\boldsymbol{\theta}) = \prod_{i=1}^n f(t_i^*; \boldsymbol{\theta}). \quad (2.9)$$

In practice, however, survival times are frequently subject to right censoring. As defined previously, let T^* denote the time to failure and U the censoring time. The observed time and censoring indicator are given by $T = \min(T^*, U)$ and $\delta = I[T^* \leq U]$, respectively. Thus, $\delta = 1$ indicates that the event of interest was observed, whereas $\delta = 0$ indicates that the observation was right-censored.

Accordingly, the observed survival data considered throughout this work are represented by the triplet $\{(\mathbf{x}_i, t_i, \delta_i)\}_{i=1}^n$, where $\mathbf{x}_i \in \mathbb{R}^p$ denotes the vector of covariates for the i th individual, t_i is the observed time, and δ_i is the corresponding event indicator.

For an individual with $\delta_i = 1$, the event is observed at time t_i , and the likelihood contribution is given by the density $f(t_i; \boldsymbol{\theta})$. In contrast, when $\delta_i = 0$, the event has not occurred by time

t_i , and the available information is that $T_i^* > t_i$. Consequently, the likelihood contribution is given by the survival probability $S(t_i; \boldsymbol{\theta})$. These two cases can be combined into the single expression

$$L_i(\boldsymbol{\theta}) = f(t_i; \boldsymbol{\theta})^{\delta_i} S(t_i; \boldsymbol{\theta})^{1-\delta_i}. \quad (2.10)$$

Assuming independence among individuals, the likelihood function based on the observed survival data is therefore

$$L(\boldsymbol{\theta}) = \prod_{i=1}^n f(t_i; \boldsymbol{\theta})^{\delta_i} S(t_i; \boldsymbol{\theta})^{1-\delta_i}. \quad (2.11)$$

Using the relationship $f(t; \boldsymbol{\theta}) = h(t; \boldsymbol{\theta})S(t; \boldsymbol{\theta})$, the likelihood can equivalently be expressed in terms of the hazard rate as

$$L(\boldsymbol{\theta}) = \prod_{i=1}^n h(t_i; \boldsymbol{\theta})^{\delta_i} S(t_i; \boldsymbol{\theta}). \quad (2.12)$$

This formulation is fundamental in survival analysis because it accounts simultaneously for observed failures and right-censored observations. It will also provide the basis for the likelihood formulations considered later for the long-term survival and cure-rate models developed in this work.

In conventional survival models, it is typically assumed that every individual is eventually susceptible to the event, implying that $\lim_{t \rightarrow \infty} S(t) = 0$. However, this assumption may be inappropriate in settings where a subset of individuals is considered effectively immune to the event of interest. In such cases, the survival function may converge to a positive limiting value, $\lim_{t \rightarrow \infty} S(t) = \pi > 0$, where π represents the asymptotic probability of remaining event-free. This behavior is characteristic of cure-rate models and provides a natural framework for explicitly modeling a cured fraction within the population. The distinction between these two settings is central to the development of cure-rate models and will be considered in the following section.

2.4 Long-term survival models

In some survival studies, a non-negligible proportion of individuals may never experience the event of interest, even when followed for an arbitrarily long period of time. Such individuals are commonly referred to as cured or immune with respect to the event under consideration (MALLER; ZHOU, 1996). The presence of such individuals gives rise to the class of models commonly referred to as long-term survival models or cure-rate models.

This setting differs fundamentally from that of conventional survival models, which generally assume that every individual is susceptible to the event of interest and that the event will eventually occur with probability one. Under this assumption, the survival function satisfies

$$\lim_{t \rightarrow \infty} S(t) = 0. \quad (2.13)$$

In contrast, when a proportion of the population is not susceptible to the event, the population survival function may converge to a positive value,

$$\lim_{t \rightarrow \infty} S(t) = \pi, \quad 0 < \pi < 1, \quad (2.14)$$

where π represents the long-term survival probability, commonly interpreted as the population cure fraction.

The formulation of long-term survival models considered in this work follows the extension proposed by [Rodrigues *et al.* \(2009\)](#). In this extension, the occurrence of the event of interest is represented through a collection of competing causes. Let N be a random variable denoting the number of competing causes related to the occurrence of the event of interest, with probability distribution

$$p_n = P(N = n), \quad n = 0, 1, 2, \dots \quad (2.15)$$

Conditional on $N = n$, let $Z_1, \dots, Z_n$ denote the latent times to the event associated with these causes. Assume that these random variables are independent and identically distributed, with proper survival function $S(t)$ that does not depend on N . In order to include individuals who are not susceptible to the event, the event time is defined as the minimum among the latent times,

$$T = \min\{Z_1, \dots, Z_N\}, \quad (2.16)$$

with $P(Z_0 = \infty) = 1$, which leads to a proportion p_0 of the population not susceptible to the event occurrence.

Given the previous definitions, let $\{a_n\}$ be a real-valued sequence and $s \in [0, 1]$. The generating function ([FELLER *et al.*, 1971](#)), denoted by $A(s)$, of the sequence $\{a_n\}$ is given by

$$A(s) = a_0 + a_1s + a_2s^2 + \dots \quad (2.17)$$

The survival function of the random variable T is then obtained as

$$\begin{aligned} S_p(t) &= P(N = 0) + P(Z_1 > t, Z_2 > t, \dots, Z_N > t, N \geq 1) \\ &= P(N = 0) + \sum_{n=1}^{\infty} P(N = n)P(Z_1 > t, Z_2 > t, \dots, Z_n > t) \\ &= p_0 + \sum_{n=1}^{\infty} p_n \{S(t)\}^n \\ &= A(S(t)), \end{aligned} \quad (2.18)$$

where $A(\cdot)$ is the generating function associated with the probability mass function $\{p_n\}$, as defined in Equation (2.17), and $S(t)$ is a proper survival function. Since $\lim_{t \rightarrow 0} S(t) = 1$ and $\lim_{t \rightarrow \infty} S(t) = 0$, it follows that $\lim_{t \rightarrow \infty} S_p(t) = A(0) = P(N = 0) = p_0$.

Thus, when $p_0 > 0$, the long-term survival function has a positive limiting value, which can be interpreted as the proportion of individuals in the population who are not susceptible to

the event of interest, i.e., the cure fraction. Consequently, $S_p(t)$ is an improper survival function. It is a non-increasing function and satisfies $S_p(0) = 1$.

The probability density function and the hazard rate function associated with the long-term survival function are given, respectively, by

$$f_p(t) = f(t) \frac{dA(s)}{ds} \Big|_{s=S(t)}, \quad (2.19)$$

$$h_p(t) = \frac{f_p(t)}{S_p(t)} = f(t) \frac{\frac{dA(s)}{ds} \Big|_{s=S(t)}}{S_p(t)}. \quad (2.20)$$

Table 1 – Long-term survival, density, hazard, and cure fraction for the different distributions considered for the latent number of competing causes N .

Distribution of N	$S_p(t)$	$f_p(t)$	$h_p(t)$	p_0
Bernoulli(θ)	$1 - \theta + \theta S(t)$	$\theta f(t)$	$\frac{\theta f(t)}{1 - \theta + \theta S(t)}$	$1 - \theta$
Binomial $\left(K, \theta^* = \frac{\theta}{1+\theta}\right)$	$[1 - \theta^* + \theta^* S(t)]^K$	$K \theta^* f(t) [1 - \theta^* + \theta^* S(t)]^{K-1}$	$\frac{K \theta^* f(t)}{1 - \theta^* + \theta^* S(t)}$	$(1 - \theta^*)^K$
Negative Binomial(α, θ)	$\{1 + \alpha \theta [1 - S(t)]\}^{-1/\alpha}$	$\theta f(t) \{1 + \alpha \theta [1 - S(t)]\}^{-1/\alpha-1}$	$\frac{\theta f(t)}{1 + \alpha \theta [1 - S(t)]}$	$(1 + \alpha \theta)^{-1/\alpha}$
Poisson(θ)	$\exp\{-\theta[1 - S(t)]\}$	$\theta f(t) \exp\{-\theta[1 - S(t)]\}$	$\theta f(t)$	$e^{-\theta}$

The methods developed in this work consider different distributions for the latent variable N , representing the number of competing causes. Specifically, the Bernoulli, Binomial, Negative Binomial, and Poisson distributions are considered. The corresponding results are summarized in Table 1, and their derivations are given below, beginning with the Bernoulli distribution.

2.4.1 Bernoulli distribution

Let N be a random variable representing the number of latent competing causes associated with the occurrence of a given event, following a Bernoulli distribution with parameter $\theta \in (0, 1)$, i.e., $N \sim \text{Bernoulli}(\theta)$. Its probability mass function is given by

$$P(N = n) = \theta^n (1 - \theta)^{1-n}, \quad n = 0, 1. \quad (2.21)$$

The generating function of N is given by

$$A(s) = 1 - \theta + \theta s,$$

and, therefore, the long-term survival function is

$$S_p(t) = A(S(t)) = 1 - \theta + \theta S(t). \quad (2.22)$$

This corresponds to the mixture cure model introduced by (BERKSON; GAGE, 1952), one of the most widely used models for long-term survival data. The model is referred to as a mixture

cure model because the population survival function can be expressed as a mixture of a cure component and a proper survival function corresponding to the susceptible population. In this case, the cure fraction is given by

$$p_0 = \lim_{t \rightarrow \infty} S_p(t) = 1 - \theta. \quad (2.23)$$

The probability density and hazard rate functions are given, respectively, by

$$f_p(t) = \theta f(t) \quad (2.24)$$

and

$$h_p(t) = \frac{\theta f(t)}{1 - \theta + \theta S(t)}. \quad (2.25)$$

2.4.2 Binomial distribution

The Binomial distribution provides a natural extension of the Bernoulli specification by allowing the number of latent competing causes to take values from 0 to K . Let N be a random variable representing the number of latent competing causes associated with the occurrence of the event of interest, following a Binomial distribution with parameters K and $\theta^* \in (0, 1)$, i.e.,

$$N \sim \text{Binomial} \left(K, \theta^* = \frac{\theta}{1 + \theta} \right),$$

where K is a positive integer. Its probability mass function is given by

$$P(N = n) = \binom{K}{n} (\theta^*)^n (1 - \theta^*)^{K-n}, \quad n = 0, 1, \dots, K. \quad (2.26)$$

The probability generating function of N is

$$A(s) = (1 - \theta^* + \theta^* s)^K. \quad (2.27)$$

Consequently, the corresponding long-term survival function is

$$S_p(t) = A(S(t)) = [1 - \theta^* + \theta^* S(t)]^K. \quad (2.28)$$

The cure fraction is obtained by taking the limit as $t \rightarrow \infty$,

$$p_0 = \lim_{t \rightarrow \infty} S_p(t) = (1 - \theta^*)^K. \quad (2.29)$$

Thus, increasing K , while keeping θ^* fixed, decreases the cure fraction, since a larger number of potential competing causes increases the probability that at least one cause is present.

Differentiating (2.28) with respect to t , the corresponding density function is

$$f_p(t) = K \theta^* f(t) [1 - \theta^* + \theta^* S(t)]^{K-1}, \quad (2.30)$$

where $f(t) = -S'(t)$ is the density associated with the proper survival function $S(t)$. Therefore, the corresponding hazard rate function is

$$h_p(t) = \frac{K \theta^* f(t)}{1 - \theta^* + \theta^* S(t)}. \quad (2.31)$$

2.4.3 Negative Binomial distribution

A more flexible specification is obtained by assuming that the number of latent competing causes follows a Negative Binomial distribution. Let N follow a Negative Binomial distribution with parameters α and θ , where $\theta > 0$ and $\alpha\theta > -1$. Its probability mass function can be written as

$$P(N = n) = \frac{\Gamma(\alpha^{-1} + n)}{\Gamma(\alpha^{-1})n!} \left(\frac{\alpha\theta}{1 + \alpha\theta} \right)^n (1 + \alpha\theta)^{-1/\alpha}, \quad n = 0, 1, 2, \dots, \quad (2.32)$$

with the corresponding probability generating function

$$A(s) = [1 + \alpha\theta(1 - s)]^{-1/\alpha}. \quad (2.33)$$

The long-term survival function is consequently given by

$$S_p(t) = \{1 + \alpha\theta[1 - S(t)]\}^{-1/\alpha}. \quad (2.34)$$

Its cure fraction is

$$p_0 = \lim_{t \rightarrow \infty} S_p(t) = (1 + \alpha\theta)^{-1/\alpha}. \quad (2.35)$$

Under this parametrization, $E[N] = \theta$ and $\text{Var}(N) = \theta + \alpha\theta$. Therefore, the parameter α controls the dispersion of the number of latent competing causes. For $\alpha > 0$, the distribution is overdispersed relative to a Poisson distribution, whereas $\alpha < 0$ corresponds to underdispersion, subject to the condition $\alpha\theta > -1$.

This parametrization is particularly useful because it provides a continuous connection among the Binomial, Poisson, and Negative Binomial distributions. Specifically, when $\alpha = -1/K$, the Negative Binomial distribution reduces to a Binomial distribution with parameters K and θ/K , provided that $0 \leq \theta/K \leq 1$. As $\alpha \rightarrow 0$, the distribution converges to a Poisson distribution with parameter θ . For $\alpha > 0$, it corresponds to the usual overdispersed Negative Binomial formulation.

Differentiating (2.34), the density function associated with the long-term survival distribution is

$$f_p(t) = \theta f(t) \{1 + \alpha\theta[1 - S(t)]\}^{-1/\alpha - 1}, \quad (2.36)$$

and its hazard rate function is

$$h_p(t) = \frac{\theta f(t)}{1 + \alpha\theta[1 - S(t)]}. \quad (2.37)$$

The flexibility of this formulation is particularly relevant for long-term survival modeling, since it encompasses several important cure-rate models as special or limiting cases. In particular, the choice $\alpha = -1$ corresponds to the Bernoulli case and consequently recovers the classical mixture cure model, whereas the limit $\alpha \rightarrow 0$ yields the Poisson model and the corresponding promotion-time cure model.

2.4.4 Poisson distribution

The Poisson distribution is obtained as the limiting case of the Negative Binomial formulation when $\alpha \rightarrow 0$. Let N follow a Poisson distribution with parameter $\theta > 0$, i.e., $N \sim \text{Poisson}(\theta)$. Its probability mass function is

$$P(N = n) = \frac{e^{-\theta} \theta^n}{n!}, \quad n = 0, 1, 2, \dots, \quad (2.38)$$

and its probability generating function is $A(s) = \exp\{\theta(s - 1)\}$. Therefore, the corresponding long-term survival function is

$$S_p(t) = A(S(t)) = \exp\{-\theta[1 - S(t)]\} = \exp\{-\theta F(t)\}. \quad (2.39)$$

The cure fraction is given by $p_0 = \lim_{t \rightarrow \infty} S_p(t) = e^{-\theta}$, the corresponding density function is $f_p(t) = \theta f(t) \exp\{-\theta F(t)\}$, and the associated hazard rate function is $h_p(t) = \theta f(t)$. The Poisson specification is particularly important in long-term survival analysis because it leads to the promotion-time cure model (YAKOVLEV; TSODIKOV, 1996).

The Kaplan–Meier estimator (KME) is one of the most widely used nonparametric methods for estimating the survival function in the presence of right-censored observations. In the context of long-term survival analysis, the estimated survival curve can also provide an indication of the presence of a cure fraction when it approaches a positive plateau at large observed times. Although the Kaplan–Meier estimator does not, by itself, identify or consistently estimate the cure fraction without additional assumptions regarding the follow-up period, it provides a useful nonparametric reference for assessing whether a long-term survival pattern is supported by the data. In this work, the Kaplan–Meier estimator is used for this purpose and to assess whether the proposed long-term survival models adequately capture the observed survival pattern.

2.5 Kaplan–Meier estimator

The Kaplan–Meier estimator (KME) is one of the most widely used nonparametric methods for estimating the survival function in the presence of right-censored observations (KAPLAN; MEIER, 1958). Let $\{(t_i, \delta_i)\}_{i=1}^n$ denote the observed survival data, where t_i is the observed time and δ_i is the censoring indicator, with $\delta_i = 1$ indicating an observed event and $\delta_i = 0$ indicating right censoring. Let $t_{(1)} < \dots < t_{(m)}$ denote the distinct observed event times. If d_j individuals experience the event at $t_{(j)}$ and Y_j individuals are at risk immediately before $t_{(j)}$, the KME is given by

$$\hat{S}_{KM}(t) = \prod_{t_{(j)} \leq t} \left(1 - \frac{d_j}{Y_j}\right). \quad (2.40)$$

The KME is a step function that changes only at observed event times, while censored observations contribute to the risk set up to their censoring times. In the context of long-term

survival analysis, a survival curve that approaches a positive plateau at large follow-up times may provide empirical evidence of a nonzero long-term survivor fraction. However, such a plateau should be interpreted with caution, as limited follow-up and heavy censoring can also produce a positive tail.

In this work, the KME is used as a nonparametric reference for assessing the long-term survival pattern in the data and for evaluating whether the proposed long-term survival models adequately capture the observed cure fraction.

FOUNDATIONS OF MACHINE LEARNING

3.1 Introduction

3.2 Decision tree

Árvores de decisão podem ser utilizadas tanto para regressão quanto para classificação. Elas servem de base para os modelos baseados em árvores empregados neste trabalho, com foco especial nas árvores de regressão¹. O processo de construção de uma árvore se baseia no particionamento recursivo do espaço dos preditores, onde cada particionamento é chamado de nó e o resultado final é chamado de folha ou nó terminal. Em cada nó, é definida uma condição e, caso essa condição seja satisfeita, o resultado será uma das folhas desse nó. Caso contrário, o processo segue para o próximo nó e verifica a próxima condição, podendo gerar uma folha ou outro nó. Veja um exemplo na Figura 3.

O espaço dos preditores é dividido em J regiões distintas e disjuntas denotadas por $R_1, R_2, \dots, R_J$. Essas regiões são construídas em formato de caixa de forma a minimizar a soma dos quadrados dos resíduos. Dessa forma, pode-se modelar a variável resposta como uma constante c_j em cada região R_j . Isto é

$$f(x) = \sum_{j=1}^J c_j I(x \in R_j). \quad (3.1)$$

O estimador para a constante c_j é encontrado pelo método de mínimos quadrados. Assim, deve-se minimizar $\sum_{x_i \in R_j} [y_i - f(x_i)]^2$. No entanto, percebe-se que $f(x_i)$ está sendo avaliado somente em um ponto específico x_i , o que reduzirá $f(x_i)$ para uma constante c_j . É fácil de se

¹ Uma árvore de regressão é um caso específico da árvore de decisão, mas para regressão.




Figure 3 – Exemplo de estrutura de árvore de regressão. A árvore tem cinco folhas e quatro nós internos.

chegar ao resultado se for observada a definição da função indicadora $I(x \in R_j)$:

$$I_{R_j}(x_i) = \begin{cases} 1, & \text{se } x_i \in R_j \\ 0, & \text{se } x_i \notin R_j \end{cases}. \quad (3.2)$$

Como as regiões são disjuntas, x_i não pode estar simultaneamente em duas regiões. Assim, para um ponto específico x_i , apenas um dos casos da função indicadora será diferente de 0. Portanto, $f(x_i) = c_j$. Agora, derivando $\sum_{x_i \in R_j} (y_i - c_j)^2$ em relação a c_j

$$\frac{\partial}{\partial c_j} \sum_{x_i \in R_j} (y_i - c_j)^2 = -2 \sum_{x_i \in R_j} (y_i - c_j) \quad (3.3)$$

e, ao igualar a Equação 3.3 a 0, tem-se a seguinte igualdade:

$$\sum_{x_i \in R_j} (y_i - \hat{c}_j) = 0. \quad (3.4)$$

Expandindo o somatório e dividindo pelo número total de pontos N_j na região R_j , conclui-se que o estimador de c_j , denotado por $\hat{c}_j$, é simplesmente a média dos valores observados y_i na região R_j :

$$\sum_{x_i \in R_j} y_i - \hat{c}_j N_j = 0 \Rightarrow \hat{c}_j = \frac{1}{N_j} \sum_{x_i \in R_j} y_i. \quad (3.5)$$

No entanto, [James et al. \(2021\)](#) caracteriza como inviável considerar todas as possíveis partições do espaço das variáveis independentes em J caixas devido ao alto custo computacional. Dessa forma, a abordagem a ser adotada é uma divisão binária recursiva. O processo começa

no topo da árvore, o ponto em que contém todas as observações, e continua sucessivamente dividindo o espaço dos preditores. As divisões são indicadas como dois novos ramos na árvore, como pode ser visto na Figura 3.

Para executar a divisão binária recursiva, deve-se primeiramente selecionar a variável independente X_j e o ponto de corte s tal que a divisão do espaço dos preditores conduza a maior redução possível na soma dos quadrados dos resíduos. Dessa forma, definimos dois semi-planos:

$$R_1(j, s) = \{X | X_j \leq s\} \quad \text{e} \quad R_2(j, s) = \{X | X_j > s\}, \quad (3.6)$$

e procura-se a divisão da variável j e o ponto de corte s que minimizem a seguinte expressão:

$$\min_{j, s} \left[\min_{c_1} \sum_{x_i \in R_1(j, s)} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in R_2(j, s)} (y_i - c_2)^2 \right], \quad (3.7)$$

em que c_1 e c_2 é a média da variável dependente para as observações nas regiões $R_1(j, s)$ e $R_2(j, s)$, respectivamente. Após determinar a melhor divisão, os dados são particionados nessas duas regiões, e o processo é repetido recursivamente para todas as sub-regiões resultantes.

O tamanho da árvore pode ser considerado um hiperparâmetro para regular a complexidade do modelo, pois uma árvore muito grande pode causar sobreajuste aos dados de treinamento, capturando não apenas os padrões relevantes, mas também o ruído. Como resultado, o modelo pode apresentar bom desempenho nos dados de treinamento, mas falhar ao lidar com novos dados devido à sua incapacidade de generalização. Por outro lado, uma árvore muito pequena pode não captar padrões, relações e estruturas importantes presentes nos dados. Dessa forma, a estratégia adotada para selecionar o tamanho da árvore consiste em crescer uma grande árvore T_0 , interrompendo o processo de divisão apenas ao atingir um tamanho mínimo de observações nos nós. Posteriormente, a árvore T_0 é podada utilizando o critério de custo de complexidade, que será definido a seguir.

Para o processo de poda da árvore, definimos uma árvore qualquer T que pode ser obtida através do processo da poda de T_0 , de modo que $T \subset T_0$. Assim, sendo N_j a quantidade de pontos na região R_j , seja

$$Q_j(T) = \frac{1}{N_j} \sum_{x_i \in R_j} (y_i - \hat{c}_j)^2 \quad (3.8)$$

uma medida de impureza do nó pelo erro quadrático médio. Assim, define-se o critério de custo de complexidade:

$$C_\alpha(T) = \sum_{j=1}^{|T|} N_j Q_j(T) + \alpha |T|, \quad (3.9)$$

em que $|T|$ denota a quantidade total de folhas, e $\alpha \geq 0$ é um hiperparâmetro que equilibra o tamanho da árvore e a adequação aos dados. A ideia é encontrar, para cada α , a árvore $T_\alpha \subset T_0$ que minimiza $C_\alpha(T)$. Valores grandes de α resultam em árvores menores, enquanto valores menores resultam em árvores maiores, e $\alpha = 0$ resulta na própria árvore T_0 . A busca por T_α

envolve colapsar sucessivamente o nó interno que provoca o menor aumento em $\sum_j N_j Q_j(T)$, continuando o processo até produzir uma árvore com um único nó. Esse processo gera uma sequência de subárvores, dentre as quais existe, para cada valor de α , uma única subárvore que minimiza $C_\alpha(T)$.

A estimação de α pode ser realizada por validação cruzada com cinco ou dez folds. Assim, a árvore final será $T_{\hat{\alpha}}$. O Algoritmo 1 exemplifica o processo de crescimento de uma árvore de regressão:

Algorithm 1 – Algoritmo para crescer uma árvore de regressão (JAMES *et al.*, 2021).

- 1: **1.** Use a divisão binária recursiva para crescer uma árvore grande T_0 nos dados de treinamento, parando apenas quando cada folha tiver menos do que um número mínimo de observações.
 - 2: **2.** Aplique o critério de custo de complexidade à árvore grande T_0 para obter uma sequência de melhores subárvores T_α , em função de α .
 - 3: **3.** Use validação cruzada K -Fold para escolher α . Isto é, divida as observações de treinamento em K folds. Para cada $k = 1, \dots, K$:
 - 4: (a) Repita os Passos 1 e 2 em todos os folds, exceto no k -ésimo fold dos dados de treinamento.
 - 5: (b) Avalie o erro quadrático médio da estimação no k -ésimo fold deixado de fora, em função de α .
 - 6: Faça a média dos resultados para cada valor de α e escolha α que minimize o erro médio.
 - 7: **4.** Retorne a subárvore $T_{\hat{\alpha}}$ do Passo 2 que corresponde ao valor estimado de α .
-

No caso de uma árvore de decisão para classificação, a principal diferença está no critério de divisão dos nós e na poda da árvore. Para a classificação, a predição em um nó j , correspondente a uma região R_j com N_j observações, será simplesmente a classe majoritária. Assim, tem-se:

$$\hat{p}_{jk} = \frac{1}{N_j} \sum_{x_i \in R_j} I(y_i = k), \quad (3.10)$$

como sendo a proporção de observações da classe k no nó j . Dessa forma, as observações no nó j são classificadas na classe $k(j) = \arg \max_k \hat{p}_{jk}$, correspondente à classe majoritária nesse nó.

Para a divisão dos nós no caso da regressão, foi utilizado o erro quadrático médio como medida de impureza. Para a classificação, algumas medidas comuns para $Q_j(T)$ são o erro de classificação, o índice de Gini ou a entropia cruzada.

3.3 Ensemble Methods

As árvores de decisão são conhecidas por sua alta interpretabilidade, mas geralmente apresentam um desempenho preditivo inferior em comparação com outros modelos e algoritmos. No entanto, é possível superar essa limitação construindo um modelo preditivo que combina a força de uma coleção de estimadores base, um processo conhecido como aprendizado em conjunto (Ensemble Learning). De acordo com Hastie *et al.* (2009), o aprendizado em conjunto

pode ser dividido em duas etapas principais: a primeira etapa consiste em desenvolver uma população de algoritmos de aprendizado base a partir dos dados de treinamento, e a segunda etapa envolve a combinação desses algoritmos para formar um estimador agregado. Portanto, nesta seção, serão definidos os métodos de aprendizado em conjunto utilizados neste trabalho.

3.3.1 Bagging

O algoritmo de Bootstrap Aggregation, ou Bagging, foi introduzido por Breiman (1996). Sua ideia principal é gerar um estimador agregado a partir de múltiplas versões de um preditor, que são criadas por meio de amostras bootstrap do conjunto de treinamento, utilizadas como novos conjuntos de treinamento. O Bagging pode ser empregado para melhorar a estabilidade e a predição de modelos ou algoritmos de aprendizado de máquina, além de reduzir a variância e evitar o sobreajuste. Por exemplo, o Bagging pode ser utilizado para melhorar o desempenho da árvore de regressão descrita anteriormente.

Breiman (1996) define formalmente o algoritmo de Bagging, que utiliza um conjunto de treinamento $\mathcal{L}$. A partir desse conjunto, são geradas amostras bootstrap $\mathcal{L}^{(B)}$ com B réplicas, formando uma coleção de modelos $\{f(x, \mathcal{L}^{(B)})\}$, onde f representa um modelo estatístico ou algoritmo treinado nas amostras bootstrap para prever ou classificar uma variável dependente y com base em variáveis independentes. Se a variável dependente y for numérica, a predição é obtida pela média das estimações dos modelos:

$$f_B(x) = \frac{1}{B} \sum_{b=1}^B f(x, \mathcal{L}^{(B)}), \quad (3.11)$$

em que f_B representa a predição agregada. No caso em que y prediz uma classe, utiliza-se a votação majoritária. Ou seja, se estivermos classificando em classes $j \in \{1, \dots, J\}$, então $N_j = \#\{B; f(x, \mathcal{L}^{(B)}) = j\}$ representa o número de vezes que a classe j foi predita pelos estimadores. Assim:

$$f_B(x) = \arg \max_j N_j. \quad (3.12)$$

isto é, o j para o qual N_j é máximo

Embora a técnica de Bagging possa melhorar o desempenho de uma árvore de regressão ou de classificação, isso geralmente vem ao custo de menor interpretabilidade. Quando o Bagging é aplicado a uma árvore de regressão, construímos B árvores de regressão usando B réplicas de amostras bootstrap e tomamos a média das predições resultantes (JAMES et al., 2013). Nesse processo, as árvores de regressão crescem até seu máximo, sem passar pelo processo de poda, resultando em cada árvore individual com alta variância e baixo viés. No entanto, ao agregar as predições das B árvores, a variância é reduzida.

Para mitigar a falta de interpretabilidade do método Bagging aplicado a árvores de regressão, pode-se utilizar a medida de impureza baseada no erro quadrático médio como uma métrica para avaliar a importância das variáveis independentes. Um valor elevado na redução total

média do erro quadrático médio, calculado com base nas divisões realizadas por um determinado preditor em todas as B árvores, indica que o preditor é importante.

As árvores construídas pelo algoritmo de árvore de decisão se beneficiam da estratégia de agregação do Bagging, principalmente por meio da redução da variância das previsões. No entanto, esse benefício é limitado pela correlação existente entre as árvores geradas. Se essas árvores forem variáveis aleatórias independentes e identicamente distribuídas (i.i.d.), cada uma com variância σ^2 , a variância da média das previsões das B árvores será $\frac{1}{B}\sigma^2$.

Contudo, se as árvores forem apenas identicamente distribuídas (i.d.), mas não independentes, apresentando uma correlação positiva ρ , a variância da média das previsões passa a ser dada por:

$$\rho\sigma^2 + \frac{1-\rho}{B}\sigma^2. \quad (3.13)$$

Nesse caso, à medida que o número de árvores B tende ao infinito, o segundo termo da expressão se aproxima de zero, mas o primeiro termo permanece constante. Isso demonstra que os ganhos proporcionados pelo Bagging são limitados pela correlação entre as árvores [Hastie et al. \(2009\)](#).

Essa correlação ocorre porque as árvores geradas pelo Bagging tendem a ser bastante semelhantes. As variáveis selecionadas para as divisões são escolhidas com base na maior redução do erro nas regiões, e, frequentemente, as mesmas variáveis são as que mais contribuem para essa redução, sendo repetidamente escolhidas. Uma forma de reduzir essa correlação - e, com isso, melhorar o desempenho do Bagging - é por meio do algoritmo Random Forest, que será apresentado a seguir.

3.4 Gradient Boost

3.5 Kernel

Métodos baseados em Kernel são técnicas extremamente flexíveis que podem ser utilizados para estender modelos ou algoritmos para regiões de decisão não lineares ([MOHRI; ROS-TAMIZADEH; TALWALKAR, 2018](#)). Estes métodos são baseados nas conhecidas funções de kernel, os quais, sob condições de simetria e positiva definida, definem produtos internos em espaços de alta dimensão, conhecidos como espaços de Hilbert. Dessa forma, este capítulo terá como objetivo definir e apresentar os conceitos fundamentais sobre métodos baseados em kernel, incluindo a definição de funções de kernel, o teorema do representer e Reproducing Kernel Hilbert Space (RKHS).

3.6 Kernels

Por definição, uma função $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ é chamada de kernel sobre $\mathcal{X}$. A ideia central é construir um kernel K tal que, para quaisquer dois pontos $x, x' \in \mathcal{X}$, $K(x, x')$ corresponda ao produto interno entre duas representações desses pontos em um espaço de Hilbert $\mathcal{H}$, isto é,

$$\forall x, x' \in \mathcal{X}, \quad K(x, x') = \langle \phi(x), \phi(x') \rangle, \quad (3.14)$$

para algum mapeamento $\phi : \mathcal{X} \rightarrow \mathcal{H}$. O espaço $\mathcal{H}$ é chamado de feature space.

Sob essa perspectiva, o kernel pode ser interpretado como uma medida de similaridade entre elementos de $\mathcal{X}$, uma vez que o produto interno mensura a similaridade entre dois vetores.

Uma vantagem fundamental dessa abordagem é computacional. Isto é, muitas vezes é significativamente mais eficiente calcular diretamente $K(x, x')$ do que computar explicitamente $\phi(x)$ e $\phi(x')$ e então avaliar seu produto interno.

3.6.1 Kernels positivos definidos

Para que uma função K possa ser utilizada como kernel, é necessário que sejam satisfeitas duas condições, que a função seja simétrica e positiva definida. Satisfazendo essas condições, o kernel é capaz de induzir uma geometria em um espaço de Hilbert.

Formalmente, um kernel $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ é dito simétrico e positivo definido se, para qualquer conjunto finito $\{x_1, \dots, x_n\} \subset \mathcal{X}$, a matriz de Gram

$$\mathbf{K} = [K(x_i, x_j)]_{i,j=1}^n \in \mathbb{R}^{n \times n}$$

for positiva semidefinida. Isto é, para qualquer vetor $\mathbf{c} = (c_1, \dots, c_n)^\top \in \mathbb{R}^n$,

$$\mathbf{c}^\top \mathbf{K} \mathbf{c} = \sum_{i=1}^n \sum_{j=1}^n c_i c_j K(x_i, x_j) \geq 0.$$

Equivalentemente, todos os autovalores de $\mathbf{K}$ são não negativos. Essa propriedade é essencial, pois garante a existência de uma representação geométrica consistente do kernel.

3.6.2 Espaços de Hilbert

A noção de espaço de Hilbert fornece a estrutura matemática necessária para a teoria de kernels.

Por definição, um espaço de Hilbert $\mathcal{H}$ é um espaço vetorial munido de um produto interno $\langle \cdot, \cdot \rangle_{\mathcal{H}}$ e que é completo com relação à norma induzida por esse produto interno. A norma em $\mathcal{H}$ é definida por

$$\forall h \in \mathcal{H}, \quad \|h\|_{\mathcal{H}} = \sqrt{\langle h, h \rangle}.$$

A completude implica que toda sequência de Cauchy em $\mathcal{H}$ converge para um elemento do próprio espaço, garantindo estabilidade analítica para problemas de otimização e aproximação.

No contexto de kernels, o espaço de Hilbert atua como o espaço onde os dados são representados via o mapeamento ϕ .

3.6.3 Reproducing Kernel Hilbert Spaces

A relação entre kernels positivos definidos e espaços de Hilbert é formalizada pelo teorema.

Seja $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ um kernel simétrico e positivo definido. Então existe um espaço de Hilbert $\mathcal{H}$ e um mapeamento $\phi : \mathcal{X} \rightarrow \mathcal{H}$ tais que

$$\forall x, x' \in \mathcal{X}, \quad K(x, x') = \langle \phi(x), \phi(x') \rangle_{\mathcal{H}}.$$

Além disso, esse espaço satisfaz a chamada propriedade de reprodução:

$$\forall h \in \mathcal{H}, \forall x \in \mathcal{X}, \quad h(x) = \langle h, K(x, \cdot) \rangle_{\mathcal{H}}.$$

Essa propriedade estabelece que a avaliação funcional é contínua e pode ser representada por meio do próprio kernel.

O espaço $\mathcal{H}$ associado a K é chamado de Reproducing Kernel Hilbert Space (RKHS), desempenhando papel central em métodos de aprendizado estatístico, particularmente em problemas de regularização, estimação não paramétrica e aprendizado supervisionado.

3.6.4 Teorema do Representante

O resultado mais interessante para a definição do modelo GG-KM é o Teorema do Representante. Sua principal importância reside no fato de garantir que, embora a otimização ocorra em um espaço potencialmente infinito-dimensional, a solução ótima pode ser expressa em termos de uma combinação finita de kernels avaliados nas observações da amostra.

Formalmente, seja $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ um kernel positivo definido e $\mathcal{H}$ seu correspondente RKHS. Assim, para qualquer função $G : \mathbb{R} \rightarrow \mathbb{R}$ não decrescente e qualquer função perda $L : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$, o problema de otimização

$$\arg \min_{h \in \mathcal{H}} F(h) = \arg \min_{h \in \mathcal{H}} G(\|h\|_{\mathcal{H}}) + L(h(x_1), \dots, h(x_n))$$

admite uma solução na forma $h^* = \sum_{i=1}^n \alpha_i K(x_i, \cdot)$. Se G é assumido como sendo crescente, então qualquer solução tem esta forma.

Esse resultado é particularmente relevante porque reduz um problema de otimização funcional em dimensão infinita para um problema de otimização em dimensão finita, dependente

apenas dos coeficientes $\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_n)$. Na prática, isso torna viável o uso de métodos baseados em kernel, além de evidenciar que toda a informação necessária para a estimação está contida na matriz kernel K , sem necessidade de explicitar o mapeamento $\phi(\cdot)$.

A escolha do kernel determina implicitamente a classe de funções admissíveis no espaço RKHS e, consequentemente, o grau de complexidade que o modelo pode representar. Neste contexto, os kernels podem ser visto como um hiperparâmetro de complexidade do modelo, bem como as variáveis que os compõe, γ , d e σ .

3.7 GG-KM

O modelo proposto GG-KM, nada mais é que uma proposta de modelar o valor esperado dos riscos latentes do modelo de tempo de promoção a partir da integração de kernels, de forma que seja uma extensão semi-paramétrica. Esta seção terá como objetivo descrever o processo de estimação e fundamentação do modelo.

3.7.1 Extensão não paramétrica via kernel

Embora o modelo de tempo de promoção clássico permita incorporar covariáveis por meio de funções paramétricas para $\theta(\mathbf{x})$, essa abordagem pode ser restritiva em cenários onde a relação entre as covariáveis e a fração de cura apresenta estruturas complexas ou altamente não lineares.

Neste contexto, propõe-se modelar a intensidade média dos riscos latentes $\theta(\mathbf{x})$ por meio de uma função não paramétrica $f(\mathbf{x}) = \log(\theta(\mathbf{x})) > 0$. Dessa forma, suponha que a estimação do modelo de promoção de cura seja feita por meio da maximização da log-verossimilhança penalizada:

$$\min_f \sum_{i=1}^n -l(\mathbf{x}_i) + \frac{\lambda}{2} \|f\|^2 \quad (3.15)$$

em que $l(\mathbf{x}_i)$ representa a log-verossimilhança e λ é uma parâmetro de regularização da complexidade do modelo. No entanto, supondo que a função f pertença a um Reproducing Kernel Hilbert Space (RKHS) $\mathcal{H}_K$, associado a um kernel positivo definido $K(\cdot, \cdot)$, o Teorema do Representante garante que a solução do problema da Equação 3.15 pode ser expressa da seguinte forma:

$$f^*(\mathbf{x}) = \sum_{i=1}^n \alpha_i K(\mathbf{x}, \mathbf{x}_i), \quad (3.16)$$

em que $\alpha_1, \dots, \alpha_n \in \mathbb{R}$ são coeficientes a serem estimados. Consequentemente, a intensidade média dos riscos latentes para o indivíduo i pode ser escrita como

$$\theta(\mathbf{x}_i) = \exp \left(\sum_{j=1}^n \alpha_j K(\mathbf{x}_i, \mathbf{x}_j) \right). \quad (3.17)$$

3.7.2 Estimação via algoritmo EM penalizado

A representação obtida pelo Teorema do Representante permite reescrever o modelo de tempo de promoção em termos de um número finito de parâmetros. Seja

$$f(\mathbf{x}_i) = \sum_{j=1}^n \alpha_j K(\mathbf{x}_i, \mathbf{x}_j), \quad (3.18)$$

Sob a formulação do modelo de tempo de promoção, assume-se que o número de riscos latentes associados ao indivíduo i segue uma distribuição de Poisson com média $\theta(\mathbf{x}_i)$, isto é,

$$N_i \sim \text{Poisson}(\theta(\mathbf{x}_i)). \quad (3.19)$$

Para realizar a estimação dos parâmetros, foi considerado o algoritmo EM. Em particular, considera-se uma extensão particular, o EM penalizado (MCLACHLAN; KRISHNAN, 2008).

Dessa forma, considere os dados completos $D_{\text{comp}} = \{t_i, \delta_i, N_i, \mathbf{x}_i\}_{i=1}^n$, em que t_i representa o tempo observado, δ_i o indicador de falha e N_i o número de riscos latentes associados ao i -ésimo indivíduo. A log-verossimilhança completa, menos uma constante aditiva $C = -\sum_{i=1}^n \log(N_i!)$, pode ser escrita como

$$\begin{aligned} l_c = & \sum_{i=1}^n [-\exp(f(\mathbf{x}_i)) + N_i f(\mathbf{x}_i)] \\ & + \sum_{i=1}^n [\delta_i \log f_{GG}(t_i; a, d, p)] \\ & + \sum_{i=1}^n [(N_i - \delta_i) \log S_{GG}(t_i; a, d, p)]. \end{aligned} \quad (3.20)$$

Portanto, tem-se a log-verossimilhança completa penalizada:

$$\ell_{c,P} = l_c - \frac{\lambda}{2} \boldsymbol{\alpha}^\top K \boldsymbol{\alpha}, \quad (3.21)$$

em que

$$\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_n)^\top \quad (3.22)$$

e K denota a matriz de kernel com elementos $K_{ij} = K(\mathbf{x}_i, \mathbf{x}_j)$.

O algoritmo EM consiste em alternar entre o cálculo das esperanças condicionais das variáveis latentes e a maximização da esperança da log-verossimilhança completa penalizada.

No passo E, as quantidades não observadas são substituídas por suas respectivas esperanças condicionais, calculadas sob os valores correntes dos parâmetros. Dessa forma, define-se a função auxiliar

$$\mathcal{Q}(\boldsymbol{\Theta} \mid \boldsymbol{\Theta}^{(k)}) = \mathbb{E} \left[\ell_{c,P} \mid \mathcal{D}_{\text{obs}}, \boldsymbol{\Theta}^{(k)} \right], \quad (3.23)$$

em que

$$\Theta = (\boldsymbol{\alpha}, a, d, p)$$

representa o vetor de parâmetros do modelo.

Utilizando propriedades do modelo de tempo de promoção, obtém-se que a esperança condicional do número de riscos latentes possui forma fechada, dada por

$$\widehat{N}_i^{(k+1)} = \mathbb{E}[N_i \mid \mathcal{D}_{\text{obs}}, \Theta^{(k)}] = \delta_i + \theta_i^{(k)} S_{GG}(t_i; a^{(k)}, d^{(k)}, p^{(k)}), \quad (3.24)$$

em que

$$\theta_i^{(k)} = \exp(f^{(k)}(\mathbf{x}_i)) = \exp\left(\sum_{j=1}^n \alpha_j^{(k)} K(\mathbf{x}_i, \mathbf{x}_j)\right). \quad (3.25)$$

Substituindo N_i por sua esperança condicional na log-verossimilhança completa penalizada e eliminando termos constantes em relação aos parâmetros, obtém-se a função auxiliar penalizada

$$Q_P = Q_\alpha + Q_{GG}, \quad (3.26)$$

em que

$$Q_\alpha = \sum_{i=1}^n \left[-\exp(f(\mathbf{x}_i)) + \widehat{N}_i^{(k+1)} f(\mathbf{x}_i) \right] - \frac{\lambda}{2} \boldsymbol{\alpha}^\top K \boldsymbol{\alpha}, \quad (3.27)$$

e

$$Q_{GG} = \sum_{i=1}^n \left[\delta_i \log f_{GG}(t_i; a, d, p) + (\widehat{N}_i^{(k+1)} - \delta_i) \log S_{GG}(t_i; a, d, p) \right]. \quad (3.28)$$

Observa-se que a função auxiliar penalizada é separável em dois blocos de parâmetros: o primeiro associado aos coeficientes do kernel, $\boldsymbol{\alpha}$, e o segundo aos parâmetros da distribuição Gama Generalizada, (a, d, p) . Essa decomposição permite que o passo M seja realizado por meio de atualizações alternadas dos dois blocos.

Inicialmente, atualizam-se os coeficientes do kernel resolvendo

$$\boldsymbol{\alpha}^{(k+1)} = \arg \max_{\boldsymbol{\alpha}} Q_\alpha. \quad (3.29)$$

Em seguida, atualizam-se os parâmetros da distribuição Gama Generalizada por meio de

$$(a^{(k+1)}, d^{(k+1)}, p^{(k+1)}) = \arg \max_{a, d, p} Q_{GG}. \quad (3.30)$$

Ambos os problemas de maximização são resolvidos numericamente por meio do algoritmo L-BFGS-B, utilizando as derivadas analíticas das respectivas funções objetivo.

Após cada iteração, calcula-se a log-verossimilhança penalizada observada

$$\ell_P = \sum_{i=1}^n \left[\delta_i (f(\mathbf{x}_i) + \log f_{GG}(t_i; a, d, p)) - \exp(f(\mathbf{x}_i)) F_{GG}(t_i; a, d, p) \right] - \frac{\lambda}{2} \boldsymbol{\alpha}^\top K \boldsymbol{\alpha}, \quad (3.31)$$

a qual é utilizada para monitorar a convergência do algoritmo. O procedimento iterativo é interrompido quando a variação absoluta da log-verossimilhança penalizada observada entre duas iterações consecutivas se torna inferior a uma tolerância previamente especificada, isto é,

$$\left| \ell_P^{(k+1)} - \ell_P^{(k)} \right| < \varepsilon, \quad (3.32)$$

em que $\varepsilon > 0$ representa uma constante de tolerância.

Algorithm 2 – Algoritmo EM penalizado para estimar o modelo GG-KM - $N_i \sim \text{Poisson}(\theta(\mathbf{x}_i))$.

- 1: Inicialize $\alpha^{(0)}, a^{(0)}, d^{(0)}, p^{(0)}$ e escolha uma tolerância $\varepsilon > 0$.
- 2: Defina $k \leftarrow 0$.
- 3: **repeat**
- 4: **E-step:** para $i = 1, \dots, n$, calcule

$$\hat{N}_i^{(k+1)} = \delta_i + \exp \left(\sum_{j=1}^n \alpha_j^{(k)} K(x_i, x_j) \right) S_{GG}(t_i; a^{(k)}, d^{(k)}, p^{(k)}).$$

- 5: **M-step:**

$$\alpha^{(k+1)} = \arg \max_{\alpha} \left\{ \sum_{i=1}^n \left[-\exp \left(\sum_{j=1}^n \alpha_j K(x_i, x_j) \right) + \hat{N}_i^{(k+1)} \sum_{j=1}^n \alpha_j K(x_i, x_j) \right] - \frac{\lambda}{2} \alpha^\top K \alpha \right\}.$$

$$(a^{(k+1)}, d^{(k+1)}, p^{(k+1)}) = \arg \max_{a, d, p} \sum_{i=1}^n \left[\delta_i \log f_{GG}(t_i; a, d, p) + (\hat{N}_i^{(k+1)} - \delta_i) \log S_{GG}(t_i; a, d, p) \right].$$

- 6: Calcule a log-verossimilhança penalizada observada

$$\ell_P^{(k+1)} = \ell_P(\alpha^{(k+1)}, a^{(k+1)}, d^{(k+1)}, p^{(k+1)}).$$

- 7: Atualize

$$\Delta^{(k+1)} = \left| \ell_P^{(k+1)} - \ell_P^{(k)} \right|.$$

- 8: $k \leftarrow k + 1$.
 - 9: **until** $\Delta^{(k+1)} < \varepsilon$
-

3.7.3 Estimação do modelo GG-KM com riscos latentes Binomial Negativa

Uma generalização do modelo apresentado anteriormente consiste em assumir que o número de riscos latentes N_i segue uma distribuição Binomial Negativa em vez de uma distribuição de Poisson. Em vez de especificar essa distribuição por meio de sua função de probabilidade, adota-se a parametrização definida pela função geradora de probabilidades

$$A(u) = [1 + \phi \theta_i (1 - u)]^{-1/\phi}, \quad (3.33)$$

onde $\theta_i > 0$ representa o número médio de riscos latentes e ϕ é um parâmetro de dispersão. Sob essa parametrização,

$$\mathbb{E}(N_i) = \theta_i, \quad \text{Var}(N_i) = \theta_i + \phi \theta_i^2. \quad (3.34)$$

Assim, valores positivos de ϕ produzem sobredispersão em relação ao modelo de Poisson. Além disso, essa parametrização engloba importantes casos particulares. Quando $\phi \rightarrow 0$, recupera-se a distribuição de Poisson e, conseqüentemente, o modelo GG-KM apresentado na seção anterior. Já o caso $\phi = -1$ conduz ao modelo de mistura de [Berkson and Gage \(1952\)](#). Neste trabalho, entretanto, considera-se apenas o cenário $\phi > 0$, correspondente à presença de sobredispersão.

A função de sobrevivência populacional passa a ser

$$S_{\text{pop}}(t) = [1 + \phi \theta_i F_{GG}(t; a, d, p)]^{-1/\phi}, \quad (3.35)$$

com

$$\theta_i = \exp \left(\sum_{j=1}^n \alpha_j K(\mathbf{x}_i, \mathbf{x}_j) \right). \quad (3.36)$$

Conseqüentemente, a log-verossimilhança penalizada observada é dada por

$$\ell_P = \sum_{i=1}^n \left\{ \delta_i [f(\mathbf{x}_i) + \log f_{GG}(t_i; a, d, p)] - \left(\frac{1}{\phi} + \delta_i \right) \log [1 + \phi \theta_i F_{GG}(t_i; a, d, p)] \right\} - \frac{\lambda}{2} \boldsymbol{\alpha}^\top K \boldsymbol{\alpha}. \quad (3.37)$$

Quando o parâmetro de dispersão ϕ é previamente especificado, ele é mantido fixo ao longo do processo iterativo e apenas os parâmetros $\boldsymbol{\alpha}$, a , d e p são estimados. Por outro lado, quando ϕ não é previamente informado, sua estimação é realizada conjuntamente com os demais parâmetros do modelo.

Neste último caso, a estimação é realizada por meio de uma extensão do algoritmo EM, o Expectation Conditional Maximization Either (ECME) ([MCLACHLAN; KRISHNAN, 2008](#)). A escolha desse algoritmo decorre da presença do parâmetro de dispersão ϕ , cuja atualização não admite solução analítica em forma fechada. De fato, ϕ aparece simultaneamente nos termos $\log(1 + \phi \theta_i F_{GG}(t_i))$, $1/\phi$ e nas esperanças condicionais dos riscos latentes, o que torna a maximização da função auxiliar substancialmente mais complexa do que a atualização dos demais parâmetros. Assim, os parâmetros $\boldsymbol{\alpha}$ e (a, d, p) são atualizados por meio da maximização da função auxiliar, enquanto ϕ é atualizado diretamente pela maximização da log-verossimilhança observada.

No passo E, obtém-se

$$\hat{N}_i^{(k+1)} = \mathbb{E}[N_i \mid \mathcal{D}_{\text{obs}}, \Theta^{(k)}] = \delta_i + \frac{(1 + \phi^{(k)} \delta_i) \theta_i^{(k)} S_{GG}(t_i; a^{(k)}, d^{(k)}, p^{(k)})}{1 + \phi^{(k)} \theta_i^{(k)} F_{GG}(t_i; a^{(k)}, d^{(k)}, p^{(k)})}. \quad (3.38)$$

Substituindo as quantidades não observadas por suas respectivas esperanças condicionais, obtém-se uma função auxiliar penalizada que pode ser decomposta em

$$Q_P = Q_\alpha + Q_{GG}. \quad (3.39)$$

O termo associado aos parâmetros da distribuição Gama Generalizada, Q_{GG} , permanece idêntico ao obtido no caso Poisson. Já a componente dependente de α passa a ser

$$Q_\alpha = \sum_{i=1}^n \left[\hat{N}_i^{(k+1)} \log(\theta_i) - \left(\hat{N}_i^{(k+1)} + \frac{1}{\phi} \right) \log(1 + \phi \theta_i) \right] - \frac{\lambda}{2} \alpha^\top K \alpha. \quad (3.40)$$

O passo CM consiste então nas atualizações

$$\alpha^{(k+1)} = \arg \max_{\alpha} Q_\alpha, \quad (3.41)$$

e

$$(a^{(k+1)}, d^{(k+1)}, p^{(k+1)}) = \arg \max_{a, d, p} Q_{GG}. \quad (3.42)$$

Quando ϕ não é previamente especificado, realiza-se adicionalmente a etapa ECME

$$\phi^{(k+1)} = \arg \max_{\phi > 0} \ell_P(\alpha^{(k+1)}, a^{(k+1)}, d^{(k+1)}, p^{(k+1)}, \phi). \quad (3.43)$$

A otimização dos problemas de maximização é realizada numericamente por meio do algoritmo L-BFGS-B, utilizando-se as derivadas analíticas das respectivas funções objetivo. O processo iterativo é repetido até a convergência da log-verossimilhança penalizada observada.

Algorithm 3 – Algoritmo ECME para estimar o modelo GG-KM com riscos latentes Binomial Negativa

- 1: Inicialize $\alpha^{(0)}, a^{(0)}, d^{(0)}, p^{(0)}, \phi^{(0)}$ e escolha uma tolerância $\varepsilon > 0$.
- 2: Defina $k \leftarrow 0$.
- 3: **repeat**
- 4: Para $i = 1, \dots, n$, calcule

$$\theta_i^{(k)} = \exp \left(\sum_{j=1}^n \alpha_j^{(k)} K(x_i, x_j) \right),$$

$$F_{GG}^{(k)}(t_i) = F_{GG}(t_i; a^{(k)}, d^{(k)}, p^{(k)}), \quad S_{GG}^{(k)}(t_i) = 1 - F_{GG}^{(k)}(t_i).$$

- 5: **E-step:**

$$\hat{N}_i^{(k+1)} = \delta_i + \frac{(1 + \phi^{(k)} \delta_i) \theta_i^{(k)} S_{GG}^{(k)}(t_i)}{1 + \phi^{(k)} \theta_i^{(k)} F_{GG}^{(k)}(t_i)}, \quad i = 1, \dots, n.$$

- 6: **M-step:**

$$\alpha^{(k+1)} = \arg \max_{\alpha} \left\{ \sum_{i=1}^n \left[\hat{N}_i^{(k+1)} \log(\theta_i) - \left(\hat{N}_i^{(k+1)} + \frac{1}{\phi^{(k)}} \right) \log(1 + \phi^{(k)} \theta_i) \right] - \frac{\lambda}{2} \alpha^\top K \alpha \right\},$$

$$(a^{(k+1)}, d^{(k+1)}, p^{(k+1)}) = \arg \max_{a, d, p} \sum_{i=1}^n \left[\delta_i \log f_{GG}(t_i; a, d, p) + (\hat{N}_i^{(k+1)} - \delta_i) \log S_{GG}(t_i; a, d, p) \right].$$

$$\phi^{(k+1)} = \arg \max_{\phi > 0} \ell_O(\alpha^{(k+1)}, a^{(k+1)}, d^{(k+1)}, p^{(k+1)}, \phi).$$

- 7: Calcule a log-verossimilhança penalizada observada

$$\ell_P^{(k+1)} = \ell_P(\alpha^{(k+1)}, a^{(k+1)}, d^{(k+1)}, p^{(k+1)}, \phi^{(k+1)}).$$

- 8: Atualize

$$\Delta^{(k+1)} = \left| \ell_P^{(k+1)} - \ell_P^{(k)} \right|.$$

- 9: $k \leftarrow k + 1$.

- 10: **until** $\Delta^{(k+1)} < \varepsilon$
-

Algorithm 4 – Algoritmo EM penalizado para estimar o modelo GG-KM - $N_i \sim \text{Binomial}(K, \theta_i^*)$.

- 1: Inicialize $\alpha^{(0)}, a^{(0)}, d^{(0)}, p^{(0)}$ e escolha uma tolerância $\varepsilon > 0$.
- 2: Defina $k \leftarrow 0$.
- 3: **repeat**
- 4: **E-step:** para $i = 1, \dots, n$, calcule

$$f_i^{(k)} = \sum_{j=1}^n \alpha_j^{(k)} K(x_i, x_j),$$

$$\theta_i^{*(k)} = \frac{\exp(f_i^{(k)})}{1 + \exp(f_i^{(k)})},$$

e

$$\hat{N}_i^{(k+1)} = \delta_i + (K - \delta_i) \frac{\theta_i^{*(k)} S_{GG}(t_i; a^{(k)}, d^{(k)}, p^{(k)})}{1 - \theta_i^{*(k)} + \theta_i^{*(k)} S_{GG}(t_i; a^{(k)}, d^{(k)}, p^{(k)})}.$$

- 5: **M-step:**
 Atualize α resolvendo

$$\alpha^{(k+1)} = \arg \max_{\alpha} \left\{ \sum_{i=1}^n \left[\hat{N}_i^{(k+1)} f_i - K \log(1 + \exp(f_i)) \right] - \frac{\lambda}{2} \alpha^\top K \alpha \right\},$$

onde

$$f_i = \sum_{j=1}^n \alpha_j K(x_i, x_j).$$

- 6: Atualize os parâmetros da distribuição Generalizada Gama:

$$(a^{(k+1)}, d^{(k+1)}, p^{(k+1)}) = \arg \max_{a, d, p} \sum_{i=1}^n \left[\delta_i \log f_{GG}(t_i; a, d, p) + (\hat{N}_i^{(k+1)} - \delta_i) \log S_{GG}(t_i; a, d, p) \right].$$

- 7: Calcule a log-verossimilhança penalizada observada

$$\ell_P^{(k+1)} = \ell_P(\alpha^{(k+1)}, a^{(k+1)}, d^{(k+1)}, p^{(k+1)}).$$

- 8: Atualize

$$\Delta^{(k+1)} = \left| \ell_P^{(k+1)} - \ell_P^{(k)} \right|.$$

- 9: $k \leftarrow k + 1$.
 - 10: **until** $\Delta^{(k+1)} < \varepsilon$
-

Algorithm 5 – EM with functional gradient boosting for the GG-KM model - $N_i \sim \text{Binomial}(K, \theta_i^*)$.

- 1: Initialize $f^{(0)}(\cdot), a^{(0)}, d^{(0)}, p^{(0)}$ and choose $\varepsilon > 0$, $\varepsilon_{\text{tree}} > 0$, and the maximum number of trees M .
- 2: Set $k \leftarrow 0$.
- 3: **repeat**
- 4: **E-step:** compute, for $i = 1, \dots, n$,

$$\theta_i^{*(k)} = \frac{\exp\{f^{(k)}(x_i)\}}{1 + \exp\{f^{(k)}(x_i)\}},$$

$$\widehat{N}_i^{(k+1)} = \delta_i + (K - \delta_i) \frac{\theta_i^{*(k)} S_{GG}(t_i; a^{(k)}, d^{(k)}, p^{(k)})}{1 - \theta_i^{*(k)} + \theta_i^{*(k)} S_{GG}(t_i; a^{(k)}, d^{(k)}, p^{(k)})}.$$

- 5: **M-step for $f(x)$:** set $f_0(x) \leftarrow f^{(k)}(x)$ and, for $m = 1, \dots, M$, compute

$$g_{i,m} = \widehat{N}_i^{(k+1)} - K \frac{\exp\{f_{m-1}(x_i)\}}{1 + \exp\{f_{m-1}(x_i)\}},$$

fit a regression tree $h_m(x)$ to $\{(x_i, g_{i,m})\}_{i=1}^n$, and obtain

$$\rho_m = \arg \max_{\rho \geq 0} \sum_{i=1}^n \left[\widehat{N}_i^{(k+1)} \{f_{m-1}(x_i) + \rho h_m(x_i)\} - K \log(1 + \exp\{f_{m-1}(x_i) + \rho h_m(x_i)\}) \right].$$

- 6: Update

$$f_m(x) = f_{m-1}(x) + \rho_m h_m(x),$$

and stop the boosting iterations if

$$\frac{1}{n} \sum_{i=1}^n |f_m(x_i) - f_{m-1}(x_i)| < \varepsilon_{\text{tree}}.$$

- 7: Set $f^{(k+1)}(x) \leftarrow f_m(x)$.
- 8: **M-step for the Generalized Gamma parameters:**

$$(a^{(k+1)}, d^{(k+1)}, p^{(k+1)}) = \arg \max_{a, d, p} \sum_{i=1}^n \left[\delta_i \log f_{GG}(t_i; a, d, p) + (\widehat{N}_i^{(k+1)} - \delta_i) \log S_{GG}(t_i; a, d, p) \right].$$

- 9: Compute

$$\Delta^{(k+1)} = \left| \ell_P^{(k+1)} - \ell_P^{(k)} \right|,$$

where

$$\ell_P^{(k+1)} = \ell_P \left(f^{(k+1)}, a^{(k+1)}, d^{(k+1)}, p^{(k+1)} \right).$$

- 10: $k \leftarrow k + 1$.
 - 11: **until** $\Delta^{(k+1)} < \varepsilon$
-

EXPERIMENTAL EVALUATION

4.1 Particionamento dos dados

A avaliação do desempenho preditivo dos modelos foi conduzida por meio de um esquema de validação baseado na divisão dos dados em conjuntos de treinamento e teste. Especificamente, adotou-se uma estratégia de holdout, na qual 70% das observações foram utilizadas para treinamento e os 30% restantes reservados para teste.

A separação foi realizada de forma aleatória, preservando, sempre que aplicável, a estrutura dos dados censurados, de modo a garantir que ambos os subconjuntos apresentassem proporções semelhantes de observações censuradas e não censuradas. Essa precaução é particularmente importante em problemas de análise de sobrevivência, uma vez que a distribuição dos tipos de censura pode influenciar significativamente o desempenho dos modelos.

Adicionalmente, com o objetivo de reduzir a variabilidade associada a uma única partição, o procedimento de holdout foi repetido múltiplas vezes. As métricas de desempenho foram então agregadas ao longo dessas repetições.

4.2 Estudo de simulação e Métricas de Erro

Com o objetivo de avaliar o desempenho do modelo GG-KM em diferentes cenários de complexidade da fração de cura, foi conduzido um estudo de simulação, seguindo a mesma estrutura de geração de dados proposta por [Pal and Aselisewine \(2023\)](#), adaptada ao contexto do modelo de tempo de promoção.

Foram considerados dois tamanhos de amostra, $n = 300$ e $n = 600$. Em cada replicação, os dados foram particionados em conjunto de treinamento e teste, sendo dois terços das observações destinados ao treinamento e o terço restante utilizado para avaliação preditiva.

Cada conjunto de dados foi gerado a partir de duas covariáveis independentes,

$$x_1, x_2 \sim N(0, 1).$$

A estrutura de cura foi construída a partir de três métodos distintos para a geração da probabilidade de não cura, permitindo avaliar o comportamento do modelo sob diferentes graus de linearidade e não linearidade. Para o primeiro caso, considera-se uma fronteira linear, dada por

$$\pi(\mathbf{x}) = \frac{\exp(0.3 - 5x_1 - 3x_2)}{1 + \exp(0.3 - 5x_1 - 3x_2)}.$$

Esse cenário representa a estrutura clássica de regressão logística, em que indivíduos curados e não curados são linearmente separáveis.

No segundo método, é introduzido uma relação quadrática entre as covariáveis, com o objetivo de avaliar a capacidade do modelo em capturar superfícies de decisão não lineares. Portanto, tem-se:

$$\pi(\mathbf{x}) = \frac{\exp(0.3 + 5x_1^2 - 3x_2^2)}{1 + \exp(0.3 + 5x_1^2 - 3x_2^2)}.$$

Por fim, o para o terceiro método, é considerado uma estrutura não linear e periódica:

$$\pi(\mathbf{x}) = \exp\{-\exp(0.3 - 5\cos(x_1) - 3\sin(x_2))\}.$$




Figure 4 – Simulação de curados e não curados sobre os três métodos descritos. Respectivamente, pode-se observar o método 1, 2 e 3.

Esse cenário impõe fronteiras de classificação complexas, sendo particularmente útil para avaliar a flexibilidade da abordagem baseada em kernels. Os dados simulados, considerando cada um dos três casos, pode ser visualizado na Figura 4.

Para a componente de latência, os tempos associados aos riscos latentes foram gerados a partir de uma distribuição Weibull, cuja função de risco é dada por

$$h(t|\mathbf{x}) = h_0(t) \exp(\beta_1 x_1 + \beta_2 x_2),$$

onde a função de risco basal foi definida como

$$h_0(t) = \alpha t^{\alpha-1}, \quad \alpha > 0.$$

Essa especificação implica que os tempos latentes seguem uma distribuição Weibull com parâmetro de forma α e parâmetro de escala $\lambda(\mathbf{x}) = \{\exp(\beta_1 x_1 + \beta_2 x_2)\}^{-1/\alpha}$.

Os valores utilizados para os parâmetros foram $(\alpha, \beta_1, \beta_2) = (2, 1, 0.5)$. Os tempos de censura foram gerados independentemente a partir de uma distribuição exponencial com taxa igual a 0.2, isto é $C_i \sim \text{Exp}(0.2)$. A partir desta configuração, a proporção de censura obtida para o método 1, 2 e 3 é de aproximadamente 0,60, 0,50 e 0,40, respectivamente. Para a proporção de cura foi obtido aproximadamente 0,50, 0,60 e 0,20.

A geração dos dados simulados foi realizada com base na estrutura do modelo de fração de cura em tempo de promoção. Nesse contexto, cada indivíduo pode pertencer a um de dois grupos: curados ou suscetíveis ao evento de interesse. A probabilidade de um indivíduo ser suscetível é dada por $\pi(\mathbf{x}_i)$, enquanto a probabilidade de ser curado é $1 - \pi(\mathbf{x}_i)$.

O processo de simulação ocorre em duas etapas. Inicialmente, para cada indivíduo, gera-se uma variável uniforme U_i e um tempo de censura C_i . O valor de U_i é utilizado para determinar se o indivíduo pertence ao grupo curado ou suscetível. Caso $U_i \leq 1 - \pi(\mathbf{x}_i)$, o indivíduo é classificado como curado e seu tempo observado corresponde apenas ao tempo de censura.

Por outro lado, se $U_i > 1 - \pi(\mathbf{x}_i)$, o indivíduo é considerado suscetível. Nesse caso, gera-se um tempo latente de falha Y_i utilizando o método da transformada inversa aplicado à função de sobrevivência populacional. Para isso, sorteia-se uma nova variável uniforme no intervalo $(1 - \pi(\mathbf{x}_i), 1)$ e resolve-se a equação associada à função de sobrevivência, obtendo assim o tempo de falha latente.

Por fim, o tempo observado é definido como o mínimo entre o tempo latente de falha e o tempo de censura. O indicador de falha é então determinado de acordo com qual desses tempos ocorreu primeiro. Esse procedimento garante que os dados simulados preservem simultaneamente a estrutura de fração de cura e a presença de censura à direita. O algoritmo pode ser visualizado no Algoritmo 6

Algorithm 6 – Geração de dados simulados com fração de cura

```

1: for  $i = 1, \dots, n$  do
2:   Gerar  $U_i \sim \text{Uniform}(0, 1)$ 
3:   Gerar  $C_i \sim \text{Exp}(0.2)$ 
4:   if  $U_i \leq 1 - \pi(\mathbf{x}_i)$  then
5:     Definir  $t_i \leftarrow C_i$ 
6:     Definir  $\delta_i \leftarrow 0$ 
7:   else
8:     Gerar  $U_i^* \sim \text{Uniform}(1 - \pi(\mathbf{x}_i), 1)$ 
9:     Resolver
                                    $(1 - \pi(\mathbf{x}_i))^{F(Y_i|\mathbf{x}_i)} = U_i^*$ 
10:    Obter
                                    $Y_i = F^{-1} \left( \frac{\log(U_i^*)}{\log(1 - \pi(\mathbf{x}_i))} \right)$ 
11:    Definir  $t_i \leftarrow \min(Y_i, C_i)$ 
12:    if  $t_i = Y_i$  then
13:      Definir  $\delta_i \leftarrow 1$ 
14:    else
15:      Definir  $\delta_i \leftarrow 0$ 
16:    end if
17:  end if
18: end for

```

O desempenho do modelo GG-KM foi avaliado com base no viés, erro quadrático médio (EQM) e no *Integrated Brier Score* (IBS) com ajuste IPCW (*Inverse Probability of Censoring Weighting*) (DONG *et al.*, 2020), permitindo mensurar tanto a qualidade da estimação dos parâmetros quanto a capacidade preditiva do modelo.

Seja $\hat{S}_i(t)$ a probabilidade de sobrevivência estimada para o indivíduo i no tempo t , e T_i^* o tempo observado. Os pesos IPCW são definidos por

$$\omega_i(t) = \frac{\mathbb{I}(T_i^* \leq t, \delta_i = 1)}{\hat{G}(T_i^*)} + \frac{\mathbb{I}(T_i^* > t)}{\hat{G}(t)},$$

em que $\hat{G}(t)$ representa a função de sobrevivência do mecanismo de censura, geralmente estimada pelo método de Kaplan-Meier.

Com isso, o Brier Score ajustado por IPCW no tempo t é dado por

$$BS_{IPCW}(t) = \frac{1}{\tilde{n}(t)} \sum_{i=1}^n \left[\hat{S}_i(t)^2 \frac{\mathbb{I}(T_i^* \leq t, \delta_i = 1)}{\hat{G}(T_i^*)} + (1 - \hat{S}_i(t))^2 \frac{\mathbb{I}(T_i^* > t)}{\hat{G}(t)} \right],$$

em que

$$\tilde{n}(t) = \sum_{i=1}^n \omega_i(t)$$

corresponde à soma dos pesos IPCW no tempo t .

O IBS é então definido como a integral do Brier Score ao longo do intervalo de acompanhamento:

$$IBS = \frac{1}{\tau} \int_0^{\tau} BS_{IPCW}(t) dt,$$

em que τ representa o tempo máximo de observação.

Por fim, a estimativa do EQM e do viés em relação à probabilidade dos não curados foi obtida a partir das seguintes expressões, respectivamente (PAL; ASELISEWINE, 2023):

$$\text{Viés}(\hat{\pi}(\mathbf{x})) = \frac{1}{N_1} \sum_{r=1}^{N_1} \left[\frac{1}{n} \sum_{i=1}^n \{ \pi^{(r)}(\mathbf{x}_i) - \pi^{(r)}(\mathbf{x}_i) \} \right],$$

$$\text{EQM}(\hat{\pi}(\mathbf{x})) = \frac{1}{N_1} \sum_{r=1}^{N_1} \left[\frac{1}{n} \sum_{i=1}^n \left\{ \pi^{(r)}(\mathbf{x}_i) - \pi^{(r)}(\mathbf{x}_i) \right\}^2 \right].$$

RESULTS

5.1 Aplicação a Dados Simulados

Nesta seção, avalia-se o desempenho do modelo proposto GG-KM em diferentes cenários de simulação, com o objetivo de investigar sua capacidade de adaptação sob diferentes estruturas do componente de cura. Para isso, foram considerados dois tamanhos de amostra ($n = 300$ e $n = 600$) e três métodos para geração de dados, representando diferentes relações entre covariáveis e fração de cura.

A Figura 5 apresenta a distribuição do IBS para cada kernel, obtida ao longo das replicações da validação cruzada. Como medida global de desempenho preditivo em análise de sobrevivência, menores valores de IBS indicam melhor ajuste.

De forma geral, observa-se que a escolha do kernel impacta diretamente a qualidade das estimativas, sobretudo em cenários mais complexos. No método 1, o desempenho entre os kernels é relativamente mais heterogêneo, com vantagem para kernels como cauchy, exponential e sigmoid, que apresentam menores valores centrais de IBS e menor variabilidade.

Nos métodos 2 e 3, por outro lado, o padrão é mais consistente: kernels não lineares, em especial rbf, cauchy, exponential e polynomial, tendem a apresentar melhor desempenho e maior estabilidade quando comparados ao kernel linear. Esse comportamento sugere que tais cenários envolvem estruturas mais complexas, cuja modelagem é favorecida por espaços de maior flexibilidade induzidos por esses kernels.

Dessa forma, os resultados mostram que o desempenho do GG-KM é fortemente dependente da especificação do kernel, sendo os kernels não lineares particularmente mais adequados em cenários com maior complexidade nos dados.

Como indicativo da capacidade do modelo proposto em capturar a fração de cura presente nos dados, foi realizada também uma comparação entre o estimador de Kaplan-Meier e a curva de




Figure 5 – Distribuição do IBS em relação a cada kernel, para diferentes cenários de simulação.

sobrevivência estimada pelo modelo GG-KM. Essa comparação pode ser observada na Figura 6. De modo geral, observa-se que o modelo GG-KM apresenta boa aderência ao comportamento do estimador de Kaplan-Meier, sugerindo que o componente de cura está sendo adequadamente modelado. Contudo, no cenário em que $n = 600$ para o método 3, nota-se um afastamento maior entre as curvas, indicando um ajuste inferior nesse caso específico.




Figure 6 – Comparação da curva de sobrevivência estimada pelo GG-KM e KME.

A Tabela ?? complementa a análise anterior ao sintetizar, para cada cenário, o kernel com melhor desempenho segundo o critério de menor IBS médio. Os resultados reforçam a evidência de que kernels não lineares tendem a oferecer melhor capacidade de adaptação às diferentes estruturas simuladas.

Observa-se que o kernel cauchy foi selecionado nos cenários com $n = 300$ para os métodos 1 e 2, enquanto os kernels exponential, rbf, sigmoid e polynomial também se destacaram em diferentes configurações.

Além disso, nota-se que o aumento do tamanho amostral resultou, em geral, em redução do IBS médio e do viés absoluto, especialmente nos métodos 2 e 3, indicando ganhos em precisão e estabilidade na estimação da fração de cura. Em particular, o cenário com $n = 600$ e método 3 apresentou o melhor desempenho, com menor IBS e menor EQM.

Table 2 – Comparação entre as versões Poisson e Binomial Negativa do modelo GG-KM.

n	Método	Poisson				Binomial Negativa - com ϕ estimado			
		K	IBS	Viés ($\hat{\pi}(\mathbf{x})$)	EQM ($\hat{\pi}(\mathbf{x})$)	K	IBS	Viés ($\hat{\pi}(\mathbf{x})$)	EQM ($\hat{\pi}(\mathbf{x})$)
300	1	exp.	0.1221	-0.0505	0.0305	exp.	0.1220	-0.0443	0.0292
	2	poly.	0.1528	0.0709	0.0778	cauchy	0.1528	0.0539	0.0706
	3	exp.	0.1248	-0.0088	0.0211	exp.	0.1226	-0.0039	0.0197
600	1	exp.	0.1009	0.0100	0.0249	sigmoid	0.1008	0.0118	0.0300
	2	cauchy	0.1429	-0.0048	0.0260	exp.	0.1430	-0.0046	0.0297
	3	cauchy	0.0854	0.0052	0.0213	cauchy	0.0856	0.0052	0.0213

5.2 Aplicação a Dados Reais

O conjunto de dados reais escolhido para aplicação do modelo foi o Melanoma, amplamente utilizado em estudos de análise de sobrevivência. Esse conjunto contém informações de 205 pacientes diagnosticados com melanoma maligno, um tipo agressivo de câncer de pele, submetidos a cirurgia radical no Hospital Universitário de Odense, na Dinamarca, entre os anos de 1962 e 1977.

Os pacientes foram acompanhados até o final de 1977, período no qual 134 indivíduos permaneceram vivos, enquanto 71 evoluíram para óbito, sendo 57 mortes atribuídas diretamente ao melanoma e 14 decorrentes de outras causas. Este conjunto de dados, especificamente, é utilizado em textos de modelos com fração de cura, pois há o conhecimento de que existe de fato uma fração de cura no conjunto de dados.

A base é composta por sete variáveis: tempo de acompanhamento em dias (time), status do paciente ao final do estudo (status), sexo (sex), idade no momento da cirurgia (age), ano da cirurgia (year), espessura do tumor em milímetros (thickness) e presença de ulceração (ulcer).

Para fins de modelagem, consideramos como evento de interesse o óbito por melanoma, tratando os demais casos, pacientes vivos ao final do estudo ou óbitos por outras causas, como observações censuradas. Portanto, ao final, tem-se aproximadamente 73% de observações censuradas.

Inicialmente, assim como foi feito com os dados simulados, foi realizada a comparação entre a curva de sobrevivência estimada pelo modelo proposto e o estimador de Kaplan-Meier, conforme apresentado na Figura 7. Como pode ser observado a partir da figura, há de fato indícios de que o modelo está conseguindo capturar adequadamente a fração de cura presente nos dados.




Figure 7 – Curva de Kaplan Meier para o conjunto de dados de melanoma, comparando o modelo GG-KM.

Na Figura 8, pode-se observar a variação do desempenho do modelo GG-KM para cada kernel, com base na distribuição do IBS. Nota-se que o kernel cauchy, embora tenha alcançado um dos menores valores de IBS, foi também o que apresentou maior variabilidade nessa métrica. Os kernels linear e gaussiano apresentaram desempenhos bastante semelhantes entre si. De forma análoga, os kernels laplaciano e exponencial também exibiram resultados próximos, destacando-se por apresentarem menor variabilidade, embora não tenham atingido os menores valores de IBS. Por fim, os kernels sigmoid e polinomial também apresentaram comportamento semelhante, tanto em termos de nível quanto de dispersão do erro.

Table 3 – Resultados do IBS médio, C-index médio e respectivos desvios padrão para cada kernel no conjunto de dados Melanoma.

N	Métrica	linear	exponential	cauchy	rbf	laplacian	polynomial	sigmoid
Poisson	IBS	0.1511	0.1545	0.1549	0.1556	0.1559	0.1570	0.1594
	DP IBS	0.0293	0.0222	0.0260	0.0289	0.0239	0.0312	0.0267
	C-index	0.7088	0.7186	0.7127	0.7108	0.6976	0.7009	0.6815
	DP C-index	0.0435	0.0337	0.0420	0.0416	0.0481	0.0435	0.0644
Binomial Negativa com ϕ estimado	IBS	0.1573	0.1544	0.1548	0.1572	0.1559	0.1592	0.1598
	DP IBS	0.0246	0.0223	0.0250	0.0245	0.0239	0.0178	0.0264
	C-index	0.6955	0.7196	0.7146	0.6982	0.6976	0.6809	0.6847
	DP C-index	0.0657	0.0338	0.0375	0.0692	0.0481	0.0674	0.0694
Bernoulli	IBS	0.1590	0.1595	0.1586	0.1568	0.1602	0.1555	0.1651
	DP IBS	0.0168	0.0207	0.0222	0.0239	0.0184	0.0231	0.0210
	C-index	0.6812	0.7107	0.7104	0.7060	0.6884	0.7046	0.5580
	DP C-index	0.0592	0.0416	0.0418	0.0445	0.0591	0.0464	0.2850
Binomial	IBS	0.1506	0.1563	0.1545	0.1546	0.1541	0.1675	0.1524
	DP IBS	0.0200	0.0249	0.0263	0.0264	0.0228	0.0306	0.0287
	C-index	0.6830	0.7190	0.7000	0.7042	0.6877	0.4071	0.7124
	DP C-index	0.0593	0.0329	0.0382	0.0431	0.0504	0.3338	0.0412




Figure 8 – Distribuição do IBS em relação a cada kernel.

A Tabela 3 resume esses resultados ao apresentar o IBS médio e seu respectivo desvio padrão para cada kernel. Observa-se que o kernel linear apresentou o menor IBS médio, indicando o melhor desempenho preditivo global nesse conjunto de dados, seguido de perto pelos kernels exponencial e polynomial.

Embora o kernel cauchy tenha apresentado alguns bons resultados, seu IBS médio mais elevado e maior variabilidade indicam menor estabilidade no processo de estimação. Por outro lado, o kernel exponencial se destaca por combinar desempenho preditivo próximo ao melhor observado com a menor dispersão entre todos os kernels avaliados, sugerindo maior robustez. De modo geral, os resultados indicam que, para o conjunto de dados Melanoma, estruturas mais simples ou moderadamente flexíveis parecem ser suficientes para capturar adequadamente a dinâmica da sobrevivência e a fração de cura presente nos dados.

CONCLUSION AND DISCUSSION

Este trabalho apresentou uma extensão do modelo de tempo de promoção para a modelagem da componente de cura por meio da incorporação de funções kernel, resultando no modelo GG-KM. Essa abordagem permite maior flexibilidade na estimação, tornando possível capturar relações complexas e não lineares entre as covariáveis e a fração de cura.

Nos experimentos com dados simulados, os resultados evidenciaram que kernels não lineares apresentaram desempenho superior em cenários com maior complexidade, particularmente nos métodos 2 e 3, nos quais alcançaram os menores valores de IBS. Em contrapartida, o kernel linear apresentou desempenho inferior nesses cenários, reforçando a importância da flexibilidade introduzida pelos kernels.

Além disso, tanto nos dados simulados quanto na aplicação ao conjunto de dados reais, observou-se bom ajuste entre a curva de sobrevivência estimada pelo modelo GG-KM e o estimador de Kaplan-Meier. Esse comportamento fornece evidências de que o modelo proposto é capaz de representar adequadamente a fração de cura presente nos dados.

De forma geral, os resultados obtidos indicam que o GG-KM constitui uma alternativa promissora para modelagem de sobrevivência com fração de cura, especialmente em contextos onde a estrutura da relação entre covariáveis e sobrevivência apresenta maior complexidade.

BIBLIOGRAPHY

AALEN, O. O.; BORGAN, Ø.; GJESSING, H. K. **Survival and event history analysis: a process point of view**. [S.l.]: Springer, 2008. Citations on pages 25 and 26.

BERKSON, J.; GAGE, R. P. Survival curve for cancer patients following treatment. **Journal of the American Statistical Association**, Taylor & Francis, v. 47, n. 259, p. 501–515, 1952. Citations on pages 32 and 49.

BREIMAN, L. Bagging predictors. **Machine learning**, Springer, v. 24, n. 2, p. 123–140, 1996. Citation on page 41.

DONG, G.; MAO, L.; HUANG, B.; GAMALO-SIEBERS, M.; WANG, J.; YU, G.; HOAGLIN, D. C. The inverse-probability-of-censoring weighting (ipcw) adjusted win ratio statistic: an unbiased estimator in the presence of independent censoring. **Journal of biopharmaceutical statistics**, Taylor & Francis, v. 30, n. 5, p. 882–899, 2020. Citation on page 58.

FELLER, W. *et al.* **An introduction to probability theory and its applications**. [S.l.]: Wiley New York, 1971. Citation on page 31.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. *et al.* **The elements of statistical learning**. [S.l.]: Springer series in statistics New-York, 2009. Citations on pages 40 and 42.

JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. *et al.* **An introduction to statistical learning: with applications in R**. [S.l.]: Springer, 2021. Citations on pages 17, 38, and 40.

KAPLAN, E. L.; MEIER, P. Nonparametric estimation from incomplete observations. **Journal of the American statistical association**, Taylor & Francis, v. 53, n. 282, p. 457–481, 1958. Citation on page 35.

MALLER, R. A.; ZHOU, X. Survival analysis with long-term survivors. **(No Title)**, 1996. Citation on page 30.

MCLACHLAN, G. J.; KRISHNAN, T. **The EM algorithm and extensions**. [S.l.]: John Wiley & Sons, 2008. Citations on pages 46 and 49.

MOHRI, M.; ROSTAMIZADEH, A.; TALWALKAR, A. **Foundations of machine learning**. [S.l.]: MIT press, 2018. Citations on pages 11, 13, and 42.

MOORE, D. F. *et al.* **Applied survival analysis using R**. [S.l.]: Springer, 2016. Citations on pages 26 and 27.

PAL, S.; ASELISEWINE, W. A semiparametric promotion time cure model with support vector machine. **The Annals of Applied Statistics**, Institute of Mathematical Statistics, v. 17, n. 3, p. 2680–2699, 2023. Citations on pages 55 and 59.

PRINCE, T.; BOMMERT, A.; RAHNENFÜHRER, J.; SCHMID, M. On the estimation of inverse-probability-of-censoring weights for the evaluation of survival prediction error. **PloS one**, Public Library of Science San Francisco, CA USA, v. 20, n. 1, p. e0318349, 2025. Citations on pages 11 and 13.

RODRIGUES, J.; CANCHO, V. G.; CASTRO, M. de; LOUZADA-NETO, F. On the unification of long-term survival models. **Statistics & Probability Letters**, Elsevier, v. 79, n. 6, p. 753–759, 2009. Citation on page [31](#).

STACY, E. W. A generalization of the gamma distribution. **The Annals of mathematical statistics**, JSTOR, p. 1187–1192, 1962. Citations on pages [11](#) and [13](#).

YAKOVLEV, A. Y.; TSODIKOV, A. D. **Stochastic models of tumor latency and their biostatistical applications**. [S.l.]: World Scientific, 1996. Citation on page [35](#).

