

GG-KM: Flexible Semiparametric Promotion Time Cure Modeling Based on The Generalized Gamma Distribution and Kernel Machines

Gabriel de Jesus Pereira¹ Vera Lucia Damasceno Tomazella

¹Mestrado - PIPGEs
UFSCar & USP

1 de julho de 2026



Sumário

1. Métodos Baseados em Kernel
2. Modelos de Longa Duração
3. Modelo de Tempo de Promoção
4. GG-KM
5. Avaliação de Experimento
6. Geração dos Dados Simulados
7. Resultados
8. Conclusão



Métodos Baseados em Kernel

Métodos Baseados em Kernel

- Uma função kernel é definida por:

$$K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$$

- Interpreta similaridade entre observações;
- Equivale a um produto interno em um espaço de características:

$$K(x, x') = \langle \phi(x), \phi(x') \rangle$$

- Evita calcular explicitamente $\phi(x)$.

RKHS

- Kernels positivos definidos induzem um espaço de Hilbert;
- A matriz de Gram deve satisfazer:

$$K = [K(x_i, x_j)]_{i,j=1}^n \succeq 0$$

- O espaço associado a K é chamado de Reproducing Kernel Hilbert Space (RKHS);

Teorema do Representante

Seja $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ um kernel PDS e $\mathcal{H}$ seu RHKS correspondente. Então, para qualquer função não-decrescente $G : \mathbb{R} \rightarrow \mathbb{R}$ e qualquer função de perda $\mathcal{L} : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$, a solução do problema

$$\arg \min_{h \in \mathcal{H}} \{ \mathcal{L}(h(x_1), \dots, h(x_n)) + G(\|h\|_{\mathcal{H}}) \}$$

admite uma solução na forma

$$h^*(x) = \sum_{i=1}^n \alpha_i K(x_i, x).$$

Kernels conhecidos

- Kernel linear

$$K(x_i, x_j) = x_i^\top x_j$$

- Kernel polinomial

$$K(x_i, x_j) = (x_i^\top x_j + c)^d$$

- Kernel Gaussiano (RBF)

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$$

- Kernel Laplaciano

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|)$$

- Kernel Sigmoidal

$$K(x_i, x_j) = \tanh(\gamma x_i^\top x_j + c)$$

- Kernel Cauchy

$$K(x_i, x_j) = \left(1 + \frac{\|x_i - x_j\|^2}{\sigma^2}\right)^{-1}$$

- Kernel exponencial

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|)$$



Modelos de Longa Duração

Modelos de Longa Duração

- Em alguns estudos, parte dos indivíduos nunca experimenta o evento de interesse;
- Esses indivíduos são chamados de:
 - imunes;
 - curados.
- Exemplos:
 - recorrência de câncer;
 - falha de dispositivos;
 - inadimplência.

Fração de Cura

- Modelos clássicos assumem:

$$\lim_{t \rightarrow \infty} S(t) = 0$$

- Em modelos de longa duração:

$$\lim_{t \rightarrow \infty} S(t) = p_0 > 0$$

- p_0 representa a fração de cura da população.

Função de Sobrevivência Imprópria

- A função de sobrevivência continua definida como:

$$S(t) = P(T > t)$$

- Mas agora admite:

$$P(T = \infty) = p_0$$

- Isso gera uma sobrevivência imprópria;
- A curva estabiliza em um patamar positivo.

Modelo de Tempo de Promoção

- O modelo de tempo de promoção, também conhecido como *Promotion Time Cure Model*, é uma classe de modelos de longa duração baseada em riscos latentes;
- Assume-se que cada indivíduo está exposto a um número aleatório de causas latentes capazes de produzir o evento de interesse;
- Essas causas podem ser interpretadas, por exemplo, como células cancerígenas capazes de promover a recorrência de uma doença.

Estrutura Probabilística

- Seja N o número de riscos latentes:

$$N \sim \text{Poisson}(\theta(x)), \quad \theta(x) > 0$$

- O tempo observado é definido como:

$$T = \min(T_1, \dots, T_N)$$

Função de Sobrevivência Populacional

- A sobrevivência populacional corresponde à probabilidade de nenhum risco latente produzir o evento até o tempo t :

$$S_{pop}(t|x) = P(N = 0) + P(N > 0, T_1 > t, \dots, T_N > t)$$

- Sob independência entre os riscos latentes:

$$S_{pop}(t|x) = \exp\{-\theta(x)F(t)\}$$

Fração de Cura

- Como:

$$F(t) \rightarrow 1, \quad t \rightarrow \infty$$

- A fração de cura é obtida por:

$$p_0(x) = \lim_{t \rightarrow \infty} S_{pop}(t|x)$$

$$p_0(x) = \exp(-\theta(x))$$

- Assim, a probabilidade de cura está diretamente ligada à intensidade média dos riscos latentes.



Extensão Não Paramétrica via Kernel

Verossimilhança Penalizada

- Seja (x_i, t_i, δ_i) o conjunto de dados observados;
- Considerando:

$$\theta(x) = \exp(f(x))$$

- A função objetivo penalizada é dada por:

$$J(\Theta) = \left[\delta^\top (K\alpha + \log f_{GG}) w^\top F_{GG} \right] + \frac{\lambda}{2} \alpha^\top K \alpha$$

- onde:

$$w = \exp(K\alpha)$$

Verossimilhança Penalizada

GG é uma Gama Generalizada com função de densidade de probabilidade dada por:

$$f_{GG}(t; a, d, p) = \frac{pt^{d-1} \exp(-(t/a)^p)}{a^d \Gamma(d/p)},$$

e sua função de distribuição acumulada é definida como

$$F_{GG}(t; a, d, p) = \frac{\gamma(d/p, (t/a)^p)}{\Gamma(d/p)}.$$

γ é a função incompleta inferior, $a, d, p > 0$ parâmetro de escala e forma, respectivamente.

Justificativa via Teorema do Representante

- Supondo que $f(x)$ pertença a um RKHS;
- Pelo Teorema do Representante, a solução ótima admite:

$$f(x) = \sum_{j=1}^n \alpha_j K(x, x_j)$$

- Isso reduz um problema infinito-dimensional para dimensão finita;
- Assim, toda a estimação depende apenas da matriz kernel.

Algoritmo de Estimação do GG-KM

Algorithm 1 Processo de estimação do modelo GG-KM

- 1: **Entrada:** Dados (X, t, δ) , hiperparâmetros (λ_{reg}, γ)
 - 2: Inicializar $\alpha \leftarrow 0$ e $\theta_{GG} \leftarrow a = 1, d = 1, p = 1$
 - 3: Construir a matriz de Gram K , com $K_{ij} = K(\mathbf{x}_i, \mathbf{x}_j)$
 - 4: **while** critério de convergência não satisfeito **do**
 - 5: Calcular $w_i = \exp\left(\sum_j \alpha_j K_{ij}\right)$
 - 6: Calcular $f_{GG}(t_i)$ e $F_{GG}(t_i)$
 - 7: Avaliar $J(\alpha, \theta_{GG})$
 - 8: Calcular $\nabla_{\alpha} J$ e $\nabla_{\theta_{GG}} J$
 - 9: Atualizar $\Theta = \alpha, a, d, p$ via L-BFGS
 - 10: **end while**
 - 11: **Saída:** $\hat{\alpha}, \hat{a}, \hat{d}, \hat{p}$
-



Avaliação de Experimento

Estrutura dos Dados Simulados

- Foram geradas duas covariáveis independentes:

$$x_1, x_2 \sim N(0, 1)$$

- A estrutura de cura foi construída a partir de três cenários.
- O objetivo é avaliar flexibilidade do GG-KM.

Cenários para Fração de Cura

Cenário 1:

$$\pi(x) = \frac{\exp(0.3 - 5x_1 - 3x_2)}{1 + \exp(0.3 - 5x_1 - 3x_2)}$$

Cenário 2:

$$\pi(x) = \frac{\exp(0.3 + 5x_1^2 - 3x_2^2)}{1 + \exp(0.3 + 5x_1^2 - 3x_2^2)}$$

Cenário 3:

$$\pi(x) = \exp\{-\exp(0.3 - 5\cos(x_1) - 3\sin(x_2))\}$$

Geração dos Dados Simulados: Passo 1

- Para cada indivíduo $i = 1, \dots, n$:
- Gerar:

$$U_i \sim Uniform(0, 1)$$

$$C_i \sim Exp(0.2)$$

- U_i : determina se o indivíduo será suscetível ou curado;
- C_i : tempo de censura.

Geração dos Dados Simulados: Passo 2

- Verificar:

$$U_i \leq 1 - \pi(x_i)$$

Se verdadeiro, indivíduo pertence ao grupo curado, e portanto:

$$t_i = C_i$$

$$\delta_i = 0$$

Componente de Latência

- Para indivíduos suscetíveis, os tempos latentes são gerados a partir de uma Weibull;

- A função de risco condicional é dada por:

$$h(t|x) = h_0(t) \exp(\beta_1 x_1 + \beta_2 x_2)$$

- Com risco basal:

$$h_0(t) = \alpha t^{\alpha-1}, \quad \alpha > 0$$

- Isso implica:

$$Y_i \sim Weibull(\alpha, \lambda(x_i)), \lambda(x_i) = \exp(\beta_1 x_1 + \beta_2 x_2)^{-1/\alpha}$$

$$(\alpha, \beta_1, \beta_2) = (2, 1, 0.5)$$

Geração dos Dados Simulados: Passo 3

- Caso contrário, o indivíduo é suscetível;
- Gerar:

$$U_i^* \sim Uniform(1 - \pi(x_i), 1)$$

- Obter o tempo latente:

$$Y_i = F^{-1} \left(\frac{\log(U_i^*)}{\log(1 - \pi(x_i))} \right)$$

Geração dos Dados Simulados: Passo 4

- Comparar tempo latente e censura:

$$t_i = \min(Y_i, C_i)$$

- Indicador do evento:

$$\delta_i = \begin{cases} 1, & t_i = Y_i \\ 0, & t_i = C_i \end{cases}$$

Por fim, obtém-se (x_i, t_i, δ_i) para cada indivíduo.

Dados Gerados para Cada Cenário




Figura 1: Simulação de curados e não curados sobre os três métodos descritos. Respectivamente, pode-se observar o método 1, 2 e 3.

Métricas para avaliação do desempenho do modelo

Integrated Brier Score com ajuste IPCW:

$$IBS = \frac{1}{\tau} \int_0^{\tau} BS_{IPCW}(t) dt,$$

$$BS_{IPCW}(t) = \frac{1}{\tilde{n}(t)} \sum_{i=1}^n \left[\hat{S}_i(t)^2 \frac{\mathbb{I}(T_i^* \leq t, \delta_i = 1)}{\hat{G}(T_i^*)} + (1 - \hat{S}_i(t))^2 \frac{\mathbb{I}(T_i^* > t)}{\hat{G}(t)} \right],$$

em que

$$\tilde{n}(t) = \sum_{i=1}^n \omega_i(t), \omega_i(t) = \frac{\mathbb{I}(T_i^* \leq t, \delta_i = 1)}{\hat{G}(T_i^*)} + \frac{\mathbb{I}(T_i^* > t)}{\hat{G}(t)}.$$

Métricas para avaliação do desempenho do modelo

$$\text{Viés}(\hat{\pi}(\mathbf{x})) = \frac{1}{N_1} \sum_{r=1}^{N_1} \left[\frac{1}{n} \sum_{i=1}^n \{ \pi^{(\hat{r})}(\mathbf{x}_i) - \pi^{(r)}(\mathbf{x}_i) \} \right],$$

$$\text{EQM}(\hat{\pi}(\mathbf{x})) = \frac{1}{N_1} \sum_{r=1}^{N_1} \left[\frac{1}{n} \sum_{i=1}^n \left\{ \pi^{(\hat{r})}(\mathbf{x}_i) - \pi^{(r)}(\mathbf{x}_i) \right\}^2 \right].$$



Resultados em Dados Simulados

Resultados em Dados Simulados




Figura 2: Comparação da curva de sobrevivência estimada pelo GG-KM e KME.

Resultados em Dados Simulados




Figura 3: Distribuição do IBS em relação a cada kernel, para diferentes cenários de simulação.

Resultados em Dados Simulados

Tabela 1: Resultados dos melhores kernels para cada tamanho amostral e método.

n	Método	K	Média IBS	Viés ($\hat{\pi}(\mathbf{x})$)	EQM ($\hat{\pi}(\mathbf{x})$)
300	1	cauchy	0.1198	-0.0229	0.0264
300	2	cauchy	0.1564	0.0574	0.0710
300	3	exponential	0.1295	-0.0103	0.0220
600	1	sigmoid	0.1027	0.0210	0.0363
600	2	rbf	0.1456	-0.0043	0.0307
600	3	polynomial	0.0863	-0.0043	0.0192



Resultados em Dados Reais

Resultados em Dados Reais




Figura 4: Curva de Kaplan Meier para o conjunto de dados de melanoma, comparando o modelo GG-KM.

Resultados em Dados Reais




Figura 5: Distribuição do IBS em relação a cada kernel.

Resultados em Dados Reais

Tabela 2: Resultados do IBS médio e desvio padrão para cada kernel no conjunto de dados Melanoma.

Kernel	Média IBS	DP IBS
linear	0.1517	0.0295
exponential	0.1536	0.0170
polynomial	0.1539	0.0295
rbf	0.1562	0.0312
laplacian	0.1584	0.0192
sigmoid	0.1586	0.0231
cauchy	0.1663	0.0439



Conclusão

Conclusão

- Foi proposta uma extensão do modelo de tempo de promoção baseada em funções kernel (GG-KM);
- A abordagem permite maior flexibilidade na modelagem da fração de cura;
- Kernels não lineares apresentaram melhor desempenho em cenários complexos;
- O modelo apresentou bom ajuste às curvas de Kaplan-Meier em dados simulados e reais;
- Os resultados indicam que o GG-KM é uma alternativa promissora para análise de sobrevivência com fração de cura.

Referências I

MOHRI, Mehryar; ROSTAMIZADEH, Afshin; TALWALKAR, Ameet. *Foundations of Machine Learning*. 2. ed. Cambridge: MIT Press, 2018.

WAHBA, Grace; WANG, Yuedong. Representer theorem. *Wiley StatsRef: Statistics Reference Online*, v. 1155, p. 1178, 2019.

PAL, Suvra; ASELISEWINE, Wisdom. A semiparametric promotion time cure model with support vector machine. *The Annals of Applied Statistics*, v. 17, n. 3, p. 2680–2699, 2023.