

GG-KM: Flexible Semiparametric Promotion Time Cure Modeling Based on The Generalized Gamma Distribution and Kernel Machines

Gabriel de Jesus Pereira¹ Vera Lucia Damasceno Tomazella

¹Mestrado - PIPGEs
UFSCar & USP

1 de julho de 2026



Sumário

1. Funções de Kernel
2. Modelos de Longa Duração
3. Modelo de Tempo de Promoção
4. GG-KM
5. Avaliação de Experimento
6. Geração dos Dados Simulados
7. Resultados



Funções de Kernel

Funções de Kernel

- Técnicas flexíveis para modelagem de relações não lineares;
- Permitem estender algoritmos lineares para espaços de maior dimensão;
- Fundamentados em funções de kernel e espaços de Hilbert;
- Amplamente utilizados em:
 - Support Vector Machines (SVM);
 - Kernel Ridge Regression;
 - Gaussian Processes.

Funções de Kernel

- Uma função kernel é definida por:

$$K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$$

- Interpreta similaridade entre observações;
- Equivale a um produto interno em um espaço de características:

$$K(x, x') = \langle \phi(x), \phi(x') \rangle$$

- Evita calcular explicitamente $\phi(x)$.

RKHS

- Kernels positivos definidos induzem um espaço de Hilbert;
- A matriz de Gram deve satisfazer:

$$K = [K(x_i, x_j)]_{i,j=1}^n \succeq 0$$

- O espaço associado a K é chamado de Reproducing Kernel Hilbert Space (RKHS);

Teorema do Representante

Seja $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ um kernel PDS e $\mathcal{H}$ seu RHKS correspondente. Então, para qualquer função não-decrescente $G : \mathbb{R} \rightarrow \mathbb{R}$ e qualquer função de perda $\mathcal{L} : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$, a solução do problema

$$\arg \min_{h \in \mathcal{H}} \{ \mathcal{L}(h(x_1), \dots, h(x_n)) + G(\|h\|_{\mathcal{H}}) \}$$

admite uma solução na forma

$$h^*(x) = \sum_{i=1}^n \alpha_i K(x_i, x).$$



Modelos de Longa Duração

Modelos de Longa Duração

- Em alguns estudos, parte dos indivíduos nunca experimenta o evento de interesse;
- Esses indivíduos são chamados de:
 - imunes;
 - curados.
- Exemplos:
 - recorrência de câncer;
 - falha de dispositivos;
 - inadimplência.

Fração de Cura

- Modelos clássicos assumem:

$$\lim_{t \rightarrow \infty} S(t) = 0$$

- Em modelos de longa duração:

$$\lim_{t \rightarrow \infty} S(t) = p_0 > 0$$

- p_0 representa a fração de cura da população.

Função de Sobrevivência Imprópria

- A função de sobrevivência continua definida como:

$$S(t) = P(T > t)$$

- Mas agora admite:

$$P(T = \infty) = p_0$$

- Isso gera uma sobrevivência imprópria;
- A curva estabiliza em um patamar positivo.

Modelo de Tempo de Promoção

- Também conhecido como:
 - *Promotion Time Cure Model*;
 - *Bounded Cumulative Hazard Model*.
- Baseado na ideia de riscos latentes;
- Exemplo: células cancerígenas que podem promover a recorrência da doença.

Formulação do Modelo

- Seja N o número de riscos latentes:

$$N \sim \text{Poisson}(\theta(x))$$

- Cada risco possui tempo de promoção:

$$T_1, T_2, \dots, T_N \sim F(t)$$

- O tempo observado é dado pelo mínimo:

$$T = \min(T_1, \dots, T_N)$$

Sobrevivência Populacional

- A função de sobrevivência populacional é:

$$S_{pop}(t|x) = P(T > t)$$

- Sob independência:

$$S_{pop}(t|x) = \exp\{-\theta(x)F(t)\}$$

- A fração de cura é obtida por:

$$p_0(x) = \lim_{t \rightarrow \infty} S_{pop}(t|x) = \exp(-\theta(x))$$



Extensão Não Paramétrica via Kernel

Verossimilhança Penalizada

- Seja (x_i, t_i, δ_i) o conjunto de dados observados;
- Considerando:

$$\theta(x) = \exp(f(x))$$

- A função objetivo penalizada é dada por:

$$J(\Theta) = \left[\delta^\top (K\alpha + \log f_{GG}) w^\top F_{GG} \right] + \frac{\lambda}{2} \alpha^\top K \alpha$$

- onde:

$$w = \exp(K\alpha)$$

Justificativa via Teorema do Representante

- Supondo que $f(x)$ pertença a um RKHS;
- Pelo Teorema do Representante, a solução ótima admite:

$$f(x) = \sum_{j=1}^n \alpha_j K(x, x_j)$$

- Isso reduz um problema infinito-dimensional para dimensão finita;
- Assim, toda a estimação depende apenas da matriz kernel.

Algoritmo de Estimação do GG-KM

Algorithm 1 Processo de estimação do modelo GG-KM

- 1: **Entrada:** Dados (X, t, δ) , hiperparâmetros (λ_{reg}, γ)
 - 2: Inicializar $\alpha \leftarrow 0$ e $\theta_{GG} \leftarrow a = 1, d = 1, p = 1$
 - 3: Construir a matriz de Gram K , com $K_{ij} = K(\mathbf{x}_i, \mathbf{x}_j)$
 - 4: **while** critério de convergência não satisfeito **do**
 - 5: Calcular $w_i = \exp\left(\sum_j \alpha_j K_{ij}\right)$
 - 6: Calcular $f_{GG}(t_i)$ e $F_{GG}(t_i)$
 - 7: Avaliar $J(\alpha, \theta_{GG})$
 - 8: Calcular $\nabla_{\alpha} J$ e $\nabla_{\theta_{GG}} J$
 - 9: Atualizar $\Theta = \alpha, a, d, p$ via L-BFGS
 - 10: **end while**
 - 11: **Saída:** $\hat{\alpha}, \hat{a}, \hat{d}, \hat{p}$
-



Avaliação de Experimento

Estrutura dos Dados Simulados

- Foram geradas duas covariáveis independentes:

$$x_1, x_2 \sim N(0, 1)$$

- A estrutura de cura foi construída a partir de três cenários:
 - linear;
 - quadrático;
 - não linear periódico.
- Objetivo:
 - avaliar flexibilidade do GG-KM.

Cenários para Fração de Cura

Cenário 1: Linear

$$\pi(x) = \frac{\exp(0.3 - 5x_1 - 3x_2)}{1 + \exp(0.3 - 5x_1 - 3x_2)}$$

Cenário 2: Quadrático

$$\pi(x) = \frac{\exp(0.3 + 5x_1^2 - 3x_2^2)}{1 + \exp(0.3 + 5x_1^2 - 3x_2^2)}$$

Cenário 3: Não linear periódico

$$\pi(x) = \exp\{-\exp(0.3 - 5\cos(x_1) - 3\sin(x_2))\}$$

Geração dos Dados Simulados: Passo 1

- Para cada indivíduo $i = 1, \dots, n$:
- Gerar:

$$U_i \sim Uniform(0, 1)$$

$$C_i \sim Exp(0.2)$$

- U_i : determina se o indivíduo será suscetível ou curado;
- C_i : tempo de censura.

Geração dos Dados Simulados: Passo 2

- Verificar:

$$U_i \leq 1 - \pi(x_i)$$

Se verdadeiro, indivíduo pertence ao grupo curado, e portanto:

$$t_i = C_i$$

$$\delta_i = 0$$

Geração dos Dados Simulados: Passo 3

- Caso contrário, o indivíduo é suscetível;
- Gerar:

$$U_i^* \sim Uniform(1 - \pi(x_i), 1)$$

- Obter o tempo latente:

$$Y_i = F^{-1} \left(\frac{\log(U_i^*)}{\log(1 - \pi(x_i))} \right)$$

Geração dos Dados Simulados: Passo 4

- Comparar tempo latente e censura:

$$t_i = \min(Y_i, C_i)$$

- Indicador do evento:

$$\delta_i = \begin{cases} 1, & t_i = Y_i \\ 0, & t_i = C_i \end{cases}$$

Por fim, obtém-se (x_i, t_i, δ_i) para cada indivíduo.

Métricas para avaliação do desempenho do modelo

Integrated Brier Score com ajuste IPCW:

$$IBS = \frac{1}{\tau} \int_0^{\tau} BS_{IPCW}(t) dt,$$

$$BS_{IPCW}(t) = \frac{1}{\tilde{n}(t)} \sum_{i=1}^n \left[\hat{S}_i(t)^2 \frac{\mathbb{I}(T_i^* \leq t, \delta_i = 1)}{\hat{G}(T_i^*)} + (1 - \hat{S}_i(t))^2 \frac{\mathbb{I}(T_i^* > t)}{\hat{G}(t)} \right],$$

em que

$$\tilde{n}(t) = \sum_{i=1}^n \omega_i(t), \omega_i(t) = \frac{\mathbb{I}(T_i^* \leq t, \delta_i = 1)}{\hat{G}(T_i^*)} + \frac{\mathbb{I}(T_i^* > t)}{\hat{G}(t)}.$$



Resultados