Relatório I

Gabriel de Jesus Pereira[1] **Vera Lucia Damasceno Tomazella**

[1]Mestrado - PIPGEs
UFSCar & USP

3 de maio de 2026

Vetores de Suporte

Máquina de Vetores de Suporte

- Método de aprendizado supervisionado
- Objetivo: maximizar a margem entre classes
- Relações não lineares podem ser modeladas a através de funções de kernel
- A solução é determinada apenas por parte dos conjuntos de dados, conhecidos como vetores de suporte
- Formulação como problema de otimização convexa

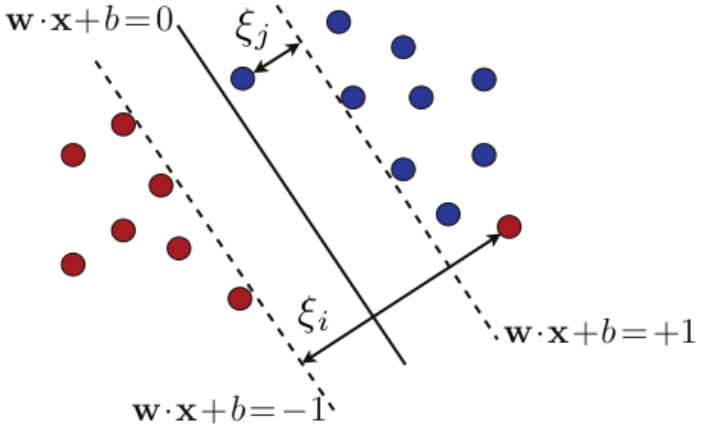
$\mathbf{w}\cdot\mathbf{x}+b=0$
ξ_j
ξ_i
$\mathbf{w}\cdot\mathbf{x}+b=+1$
$\mathbf{w}\cdot\mathbf{x}+b=-1$

SVM: Formulação Primal

Problema de otimização:

$$\min_{w,b,\boldsymbol{\xi}} \quad \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m} \xi_i$$

Sujeito a:

$$y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad i = 1, \ldots, m$$

$$\xi_i \geq 0, \quad i = 1, \ldots, m$$

- C: parâmetro de regularização
- ξ_i: variáveis de folga

SVM: Formulação Dual

Problema dual (Lagrangiano):

$$\max_{\boldsymbol{\alpha}} \quad \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle$$

Sujeito a:

$$0 \leq \alpha_i \leq C, \quad i = 1, \ldots, m$$

$$\sum_{i=1}^{m} \alpha_i y_i = 0$$

- α_i: multiplicadores de Lagrange

SVM para Regressão (SVR)

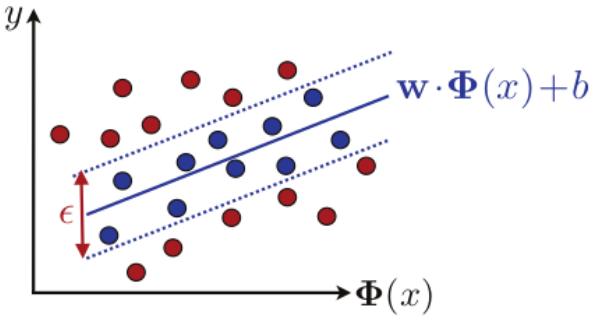

Interpretação Geométrica

- Ajuste de um tubo de largura 2ϵ
- Pontos dentro do tubo:
  - Sem penalização
- Pontos fora do tubo:
  - Penalização proporcional ao erro

- Solução tende a ser esparsa

Problema Primal (SVR)

$$\min_{w,b,\xi,\xi'} \quad \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m}(\xi_i + \xi_i')$$

sujeito a:

$$w \cdot \Phi(x_i) + b - y_i \leq \epsilon + \xi_i$$

$$y_i - w \cdot \Phi(x_i) - b \leq \epsilon + \xi_i'$$

$$\xi_i, \xi_i' \geq 0$$

Problema Dual (SVR)

$$\max_{\alpha,\alpha'} \quad \epsilon \sum(\alpha_i + \alpha_i') - \sum y_i(\alpha_i' - \alpha_i)$$

$$-\frac{1}{2}\sum_{i,j}(\alpha_i' - \alpha_i)(\alpha_j' - \alpha_j)K_{ij}$$

sujeito a:

$$\sum(\alpha_i' - \alpha_i) = 0$$

$$0 \leq \alpha_i, \alpha_i' \leq C$$

Solução Final

$$h(x) = \sum_{i=1}^{m} (\alpha_i' - \alpha_i) K(x_i, x) + b$$

- Apenas vetores de suporte contribuem
- Pontos dentro do tubo:
  - $\alpha_i = \alpha_i' = 0$

SVCR

Ideia central

- Extensão do SVR para dados com censura

- Dados: $(\mathbf{x}_i, l_i, u_i)$
- Tempo verdadeiro: $T_i \in [l_i, u_i]$

- Sem censura: $l_i = u_i$
- Censura à direita: $u_i = +\infty$
- Censura à esquerda: $l_i = -\infty$

Função de perda

- Sem penalização dentro do intervalo
- Penaliza apenas violações

$$c(f(x_i), l_i, u_i) = \max\{l_i - f(x_i),\ f(x_i) - u_i,\ 0\}$$

Formulação primal

$$\min_{w,b,\xi,\xi^*} \frac{1}{2}\|w\|^2 + C\left(\sum_{i\in U}\xi_i + \sum_{i\in L}\xi_i^*\right)$$

- Restrições:
  - $w^\top x_i + b \leq u_i + \xi_i^*$
  - $w^\top x_i + b \geq l_i - \xi_i$
- $\xi_i, \xi_i^* \geq 0$

Formulação dual

$$\max_{\alpha,\alpha^*} -\frac{1}{2}\sum_{i,j}(\alpha_i - \alpha_i^*)(\alpha_j - \alpha_j^*)K(x_i, x_j) - \sum_{i\in L} l_i\alpha_i + \sum_{i\in U} u_i\alpha_i^*$$

- $0 \leq \alpha_i, \alpha_i^* \leq C$
- $\sum \alpha_i = \sum \alpha_i^*$

- Problema quadrático convexo

Funções Wavelet

- Ferramenta para **decompor funções e sinais**
- Capturam simultaneamente:
  - **localização** (onde ocorre)
  - **escala** (nível de detalhe)

- Diferente de bases globais (ex.: Fourier)
- Permitem análise **local** e **multiescala**

$$h_{A,B}(x) = |A|^{-1/2}\, h\left(\frac{x-B}{A}\right)$$

- A: escala $\rightarrow$ controla o nível de detalhe
- B: translação $\rightarrow$ desloca a função no domínio

- Aproximação de funções:

Kernel Wavelet

- Wavelet mãe:

$$h(x) = \cos(1.75x)\exp(-0.5x^2)$$

- Kernel multidimensional:

$$K(\mathbf{x}, \mathbf{x}') = \prod_{k=1}^{p} h\left(\frac{x_k - x'_k}{A}\right)$$

- Compara diferenças **localmente** em cada dimensão
- A: controla a escala da similaridade

Metodologia

Particionamento dos dados

- Estratégia de partição dos dados:
  - 70% treino
  - 30% teste
- Preservação da proporção de censura
- Repetição do procedimento
- Redução da variabilidade

Seleção de hiperparâmetros

- Procedimento: Grid Search
- Ajuste em conjunto de treino
- Principais parâmetros:
  - C: regularização ($C \in \{0.05, 0.25, 0.5, 1, 2, 4\}$)
  - Parâmetros dos kernels ($\gamma, A \in \{0.125, 0.25, 0.5, 1, 2, 4, 8\}$)

Kernels considerados

Linear

$$K(\mathbf{x}, \mathbf{x}') = \mathbf{x}^\top \mathbf{x}'$$

Polinomial

$$K(\mathbf{x}, \mathbf{x}') = (\gamma\, \mathbf{x}^\top \mathbf{x}' + r)^d$$

Gaussiano

$$K(\mathbf{x}, \mathbf{x}') = \exp\left(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2\right)$$

Exponencial

$$K(\mathbf{x}, \mathbf{x}') = \exp\left(-\gamma \|\mathbf{x} - \mathbf{x}'\|\right)$$

Laplaciano

$$K(\mathbf{x}, \mathbf{x}') = \exp\left(-\gamma \|\mathbf{x} - \mathbf{x}'\|_1\right)$$

Cauchy

$$K(\mathbf{x}, \mathbf{x}') = \frac{1}{1 + \gamma \|\mathbf{x} - \mathbf{x}'\|^2}$$

Wavelet

$$K(\mathbf{x}, \mathbf{x}') = \prod_{k=1}^{p} \cos\left(1.75 \frac{x_k - x'_k}{A}\right) \exp\left(-\frac{1}{2}\left(\frac{x_k - x'_k}{A}\right)^2\right)$$

Geração de dados simulados

- Covariáveis:

$$X_1 \sim \mathcal{N}(1,1)$$
$$X_2 \sim \mathcal{N}(2,2)$$
$$X_3 \sim \text{Exp}(1)$$

- Tempo de sobrevivência:

$$T \sim \text{Weibull}(\lambda(\mathbf{X}), k)$$

$$\lambda(\mathbf{X}) = 5\exp(-X_1 \ln|X_2| + \sin(X_3^2))$$

Avaliação dos modelos

- Métrica principal: C-index (concordance index)
- Mede concordância entre risco predito $v(\mathbf{x})$ e tempo observado

$$C = \frac{\sum_{i \neq j} \mathbb{I}\Big[(v(\mathbf{x}_i) - v(\mathbf{x}_j))(y_i - y_j) \geq 0\Big]}{\sum_{i \neq j} \text{comp}(i, j)}$$

- comp(i, j): pares comparáveis (considera censura)
- $C = 1$: concordância perfeita
- Resultados agregados: média e desvio padrão

Resultado

Resultado em dados simulados

Tabela 1: Resultados em dados simulados com a média da métrica C-index para os conjuntos de dados.

n	**50**			**100**			**300**			**Média**
censura (%)	**0.1**	**0.25**	**0.5**	**0.1**	**0.25**	**0.5**	**0.1**	**0.25**	**0.5**	
laplacian	0.730	0.751	0.777	0.771	0.784	0.795	0.825	0.833	0.848	0.791
cauchy	0.739	0.754	0.774	0.771	0.773	0.799	0.817	0.825	0.846	0.789
poly	0.734	0.757	0.779	0.776	0.783	0.813	0.798	0.808	0.842	0.788
exponential	0.730	0.736	0.763	0.772	0.788	0.791	0.819	0.827	0.848	0.786
rbf	0.720	0.726	0.760	0.769	0.782	0.783	0.809	0.815	0.836	0.778
wavelet	0.709	0.718	0.723	0.758	0.769	0.783	0.794	0.801	0.821	0.764
cox	0.727	0.736	0.782	0.750	0.755	0.793	0.743	0.766	0.806	0.762
linear	0.704	0.742	0.755	0.730	0.750	0.782	0.748	0.764	0.804	0.753

Dados reais

- Três bases em análise de sobrevivência:
- **gbsg2**
  - 686 observações, 8 variáveis
  - Recorrência do câncer
  - $\sim 43{,}6\%$ não censurados
- **whas500**
  - 500 observações, 14 variáveis
  - Mortalidade
  - $\sim 43{,}0\%$ não censurados
- **veterans**
  - 137 observações, 6 variáveis
  - Câncer de pulmão
  - $\sim 93{,}4\%$ não censurados

Resultados em dados reais

Tabela 2: Resultados em dados reais com a média da métrica C-index.

Método	gbsg2	veterans	whas500	Média
linear	0.691	0.740	0.765	0.732
poly	0.682	0.712	0.762	0.719
cox	0.680	0.711	0.763	0.718
exponential	0.674	0.716	0.761	0.717
wavelet	0.681	0.716	0.730	0.709
cauchy	0.671	0.703	0.751	0.709
laplacian	0.681	0.702	0.742	0.708
rbf	0.640	0.706	0.696	0.681

Conclusões

- Avaliação de modelos de sobrevivência com foco em SVCR e kernels
- Dados simulados:
  - Superioridade de kernels não lineares (Laplaciano, Cauchy, Polinomial)
  - Capacidade de capturar relações complexas
- Dados reais:
  - Modelos lineares e Cox competitivos ou superiores
  - Importância do equilíbrio viés–variância

Muito obrigado pela atenção!

Contatos:

- E-mail 1
- E-mail 2