

Representer Theorem

Gabriel de Jesus Pereira¹ Vera Lucia Damasceno Tomazella

¹Mestrado - PIPGEs
UFSCar & USP

26 de junho de 2026



Representer Theorem

Por que é importante?

- Muitos problemas minimizam:

$$\mathcal{L}(f(x_1), \dots, f(x_n)) + \lambda \|f\|_{\mathcal{H}}^2$$

- Mas $\mathcal{H}$ pode ser infinito-dimensional
- Como otimizar sobre infinitas funções?
- O Teorema do Representante fornece a resposta.


Intuição

- A perda depende apenas de:

$$f(x_1), \dots, f(x_n)$$

- Portanto, apenas o comportamento no conjunto de treino importa
- Qualquer componente extra fora dessas observações apenas aumenta a complexidade
- A melhor solução pertence a um subespaço de dimensão finita

Intuição



Representer theorem

Seja $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ um kernel PDS e $\mathcal{H}$ seu RHKS correspondente. Então, para qualquer função não-decrescente $G : \mathbb{R} \rightarrow \mathbb{R}$ e qualquer função de perda $\mathcal{L} : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$, a solução do problema

$$\arg \min_{f \in \mathcal{H}} \{ \mathcal{L}(f(x_1), \dots, f(x_n)) + \lambda \|f\|_{\mathcal{H}}^2 \}$$

admite uma solução na forma

$$f^*(x) = \sum_{i=1}^n \alpha_i K(x_i, x).$$

O que isso significa?

- Problema de dimensão infinita
- Otimização em dimensão finita
- Apenas os coeficientes $\alpha_1, \dots, \alpha_n$ são necessários
- Métodos de kernel tornam-se computacionalmente viáveis



Exemplos de aplicação do Representer Theorem

SVM e Representer Theorem

No SVM, resolvemos o seguinte problema de otimização:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{sujeito a} \quad & y_i (\mathbf{w}^\top x_i + b) \geq 1, \quad i \in [n] \end{aligned}$$

A solução ótima $\mathbf{w}^*$ pode ser expressa como uma combinação linear, como visto no Representer Theorem:

$$\mathbf{w}^* = \sum_{i=1}^n \alpha_i y_i x_i, \text{ em que } y_i \in \{-1, 1\}.$$

Portanto, o problema se torna equivalente a otimizar sobre os coeficientes $\alpha_1, \dots, \alpha_n$ em vez de $\mathbf{w}$.

SVM e Representer Theorem

Dessa forma, o problema de otimização do SVM pode ser reformulado como:

$$\begin{aligned} \min \quad & \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle \\ \text{sujeito a} \quad & y_i \left(\sum_j \alpha_j y_j \langle x_j, x_i \rangle + b \right) \geq 1, \quad i \in [n] \end{aligned}$$

Kernel Ridge Regression e Representer Theorem

No Kernel Ridge Regression, resolvemos o seguinte problema de otimização:

$$\begin{aligned} \min_{\mathbf{w}} \quad & \sum_{i=1}^n (\mathbf{w}\Phi(x_i) - y_i)^2 \\ \text{sujeito a} \quad & \|\mathbf{w}\|^2 \leq \Lambda^2 \end{aligned}$$

Pelas condições de KKT, $\mathbf{w}$ pode ser determinado por

$$\mathbf{w} = \sum_{i=1}^n \alpha_i \Phi(x_i) = \mathbf{X}\alpha, \alpha = \mathbf{X}(\mathbf{K} + \lambda\mathbf{I})^{-1} \mathbf{Y},$$

em que a resposta final é dada por $h(x) = \mathbf{w}\Phi(x) = \sum_{i=1}^n \alpha_i K(x_i, x)$.