Relatório I

Gabriel de Jesus Pereira[1] **Vera Lucia Damasceno Tomazella**

[1]Mestrado - PIPGEs
UFSCar & USP

3 de maio de 2026

Vetores de Suporte

Máquina de Vetores de Suporte

- Método de aprendizado supervisionado
- Objetivo: maximizar a margem entre classes
- Relações não lineares podem ser modeladas a através de funções de kernel
- A solução é determinada apenas por parte dos conjuntos de dados, conhecidos como vetores de suporte
- Formulação como problema de otimização convexa

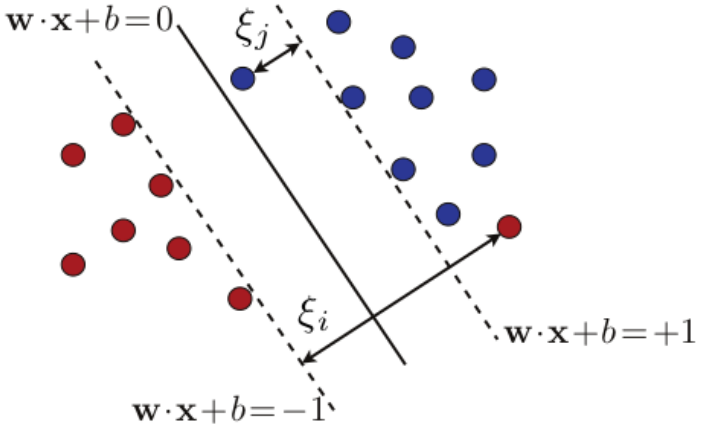
$\mathbf{w}\cdot\mathbf{x}+b=0$
ξ_j
ξ_i
$\mathbf{w}\cdot\mathbf{x}+b=+1$
$\mathbf{w}\cdot\mathbf{x}+b=-1$

SVM: Formulação Primal

Problema de otimização:

$$\min_{w,b,\boldsymbol{\xi}} \quad \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m} \xi_i$$

Sujeito a:

$$y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad i = 1, \ldots, m$$

$$\xi_i \geq 0, \quad i = 1, \ldots, m$$

- C: parâmetro de regularização
- ξ_i: variáveis de folga

SVM: Formulação Dual

Problema dual (Lagrangiano):

$$\max_{\boldsymbol{\alpha}} \quad \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle$$

Sujeito a:

$$0 \leq \alpha_i \leq C, \quad i = 1, \ldots, m$$

$$\sum_{i=1}^{m} \alpha_i y_i = 0$$

- α_i: multiplicadores de Lagrange

SVM para Regressão (SVR)

- Objetivo: aproximar uma função $f(x)$
- Controle de:
  - Complexidade do modelo
  - Erro de ajuste

- Ideia central:
  - Erros menores que ϵ não são penalizados

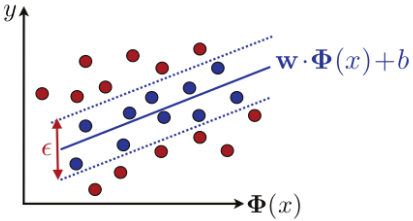

Interpretação Geométrica

- Ajuste de um tubo de largura 2ϵ
- Pontos dentro do tubo:
  - Sem penalização
- Pontos fora do tubo:
  - Penalização proporcional ao erro

- Solução tende a ser esparsa

Perda ϵ-insensível

$$|y - y'|_\epsilon = \max(0, |y - y'| - \epsilon)$$

- Ignora pequenos erros
- Apenas desvios relevantes são penalizados

- Promove:
  - Esparsidade
  - Robustez

Problema Primal (SVR)

$$\min_{w,b,\xi,\xi'} \quad \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m}(\xi_i + \xi_i')$$

sujeito a:

$$w \cdot \Phi(x_i) + b - y_i \leq \epsilon + \xi_i$$

$$y_i - w \cdot \Phi(x_i) - b \leq \epsilon + \xi_i'$$

$$\xi_i, \xi_i' \geq 0$$

Problema Dual (SVR)

$$\max_{\alpha,\alpha'} \quad \epsilon \sum(\alpha_i + \alpha_i') - \sum y_i(\alpha_i' - \alpha_i)$$

$$-\frac{1}{2}\sum_{i,j}(\alpha_i' - \alpha_i)(\alpha_j' - \alpha_j)K_{ij}$$

sujeito a:

$$\sum(\alpha_i' - \alpha_i) = 0$$

$$0 \leq \alpha_i, \alpha_i' \leq C$$

Solução Final

$$h(x) = \sum_{i=1}^{m} (\alpha_i' - \alpha_i) K(x_i, x) + b$$

- Apenas vetores de suporte contribuem
- Pontos dentro do tubo:
  - $\alpha_i = \alpha_i' = 0$

SVCR

Ideia central

- Extensão do SVR para dados com censura
- Utiliza informação parcial sem imputação
- Proposto por Shivaswamy, Chu e Jansche (2007)

- Dados: (x_i, l_i, u_i)
- Objetivo: $f(x_i) \in [l_i, u_i]$

Função de perda

- Sem penalização dentro do intervalo
- Penaliza apenas violações

$$c(f(x_i), l_i, u_i) = \max\{l_i - f(x_i),\ f(x_i) - u_i,\ 0\}$$

- Generaliza censura à direita, esquerda e intervalar
- Função convexa

Formulação primal

$$\min_{w,b,\xi,\xi^*} \frac{1}{2}\|w\|^2 + C\left(\sum_{i\in U}\xi_i + \sum_{i\in L}\xi_i^*\right)$$

- Restrições:
  - $w^\top x_i + b \leq u_i + \xi_i^*$
  - $w^\top x_i + b \geq l_i - \xi_i$
- $\xi_i, \xi_i^* \geq 0$

Formulação dual

$$\max_{\alpha,\alpha^*} -\frac{1}{2}\sum_{i,j}(\alpha_i - \alpha_i^*)(\alpha_j - \alpha_j^*)K(x_i, x_j) - \sum_{i\in L} l_i\alpha_i + \sum_{i\in U} u_i\alpha_i^*$$

- $0 \leq \alpha_i, \alpha_i^* \leq C$
- $\sum \alpha_i = \sum \alpha_i^*$

- Problema quadrático convexo

Propriedades

- Uso de kernels $\rightarrow$ não linearidade
- Solução esparsa (vetores de suporte)
- Integra diferentes tipos de censura

- Complexidade similar ao SVR
- Adequado para dados de sobrevivência

Funções Wavelet

- Ferramenta para **decompor funções e sinais**
- Capturam simultaneamente:
  - **localização** (onde ocorre)
  - **escala** (nível de detalhe)

- Diferente de bases globais (ex.: Fourier)
- Permitem análise **local** e **multiescala**

$$h_{A,B}(x) = |A|^{-1/2}\, h\left(\frac{x-B}{A}\right)$$

- A: escala $\rightarrow$ controla o nível de detalhe
- B: translação $\rightarrow$ desloca a função no domínio

- Aproximação de funções:

Kernel Wavelet

- Wavelet mãe:

$$h(x) = \cos(1.75x)\exp(-0.5x^2)$$

- Kernel multidimensional:

$$K(\mathbf{x}, \mathbf{x}') = \prod_{k=1}^{p} h\left(\frac{x_k - x'_k}{A}\right)$$

- Compara diferenças **localmente** em cada dimensão
- A: controla a escala da similaridade

Metodologia

Estratégia geral

- Construção, treinamento e avaliação dos modelos
- Dados simulados e dados reais

- Três etapas principais:
  - Particionamento dos dados
  - Seleção de hiperparâmetros
  - Avaliação preditiva

- Repetições para maior robustez

Particionamento dos dados

- Estratégia holdout:
  - 70% treino
  - 30% teste

$$\mathcal{D} = \mathcal{D}_{train} \cup \mathcal{D}_{test}$$

- Amostragem aleatória
- Preservação da proporção de censura

- Repetição do procedimento
- Redução da variabilidade

Seleção de hiperparâmetros

- Procedimento: Grid Search
- Avaliação em conjunto de treino

- Principais parâmetros:
  - C: regularização
  - ϵ: largura do tubo (SVR)
  - Parâmetros dos kernels

- Avaliação exaustiva:

$$\theta^* = \arg\max_{\theta \in \Theta} \text{Desempenho}(\theta)$$

- Seleção sem uso do conjunto de teste

Kernels considerados

- Linear
- Polinomial
- RBF (Gaussiano)

- Alternativos:
  - Exponencial
  - Laplaciano
  - Cauchy
  - Wavelet

- Objetivo: avaliar diferentes estruturas de similaridade

Geração de dados simulados

- Covariáveis:

$$X_1 \sim \mathcal{N}(1,1)$$
$$X_2 \sim \mathcal{N}(2,2)$$
$$X_3 \sim \text{Exp}(1)$$

- Tempo de sobrevivência:

$$T \sim \text{Weibull}(\lambda(\mathbf{X}), k)$$

$$\lambda(\mathbf{X}) = 5\exp(-X_1 \ln|X_2| + \sin(X_3^2))$$

- Relação altamente não linear

Mecanismo de censura

- Censura não informativa
- C independente de T

$$Y = \min(T, C), \quad \delta = \mathbb{I}(T \leq C)$$

- Controle da proporção de censura
- Cenários:
  - diferentes tamanhos amostrais
  - diferentes níveis de censura

- Avaliação da robustez dos modelos

Avaliação dos modelos

- Métrica principal: C-index
- Mede concordância entre risco e tempo observado
- Resultados agregados:
  - média
  - desvio padrão
- Comparação entre modelos e kernels

Muito obrigado pela atenção!

Contatos:

- E-mail 1
- E-mail 2