

# Representer Theorem

**Gabriel de Jesus Pereira<sup>1</sup>   Vera Lucia Damasceno Tomazella**

<sup>1</sup>Mestrado - PIPGEs  
UFSCar & USP

**26 de junho de 2026**



# Representer Theorem

# Por que é importante?

- Muitos problemas minimizam:

$$\mathcal{L}(h(x_1), \dots, h(x_n)) + \lambda \|h\|_{\mathcal{H}}^2$$

- Mas  $\mathcal{H}$  pode ser infinito-dimensional
- Como otimizar sobre infinitas funções?
- O Teorema do Representante fornece a resposta.


# Intuição

- A perda depende apenas de:

$$h(x_1), \dots, h(x_n)$$

- Portanto, apenas o comportamento no conjunto de treino importa
- Qualquer componente extra fora dessas observações apenas aumenta a complexidade
- A melhor solução pertence a um subespaço de dimensão finita

# Intuição



# Representer theorem

Seja  $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$  um kernel PDS e  $\mathcal{H}$  seu RHKS correspondente. Então, para qualquer função não-decrescente  $G : \mathbb{R} \rightarrow \mathbb{R}$  e qualquer função de perda  $\mathcal{L} : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ , a solução do problema

$$\arg \min_{h \in \mathcal{H}} \{ \mathcal{L}(h(x_1), \dots, h(x_n)) + G(\|h\|_{\mathcal{H}}) \}$$

admite uma solução na forma

$$h^*(x) = \sum_{i=1}^n \alpha_i K(x_i, x).$$

# O que isso significa?

- Problema de dimensão infinita
- Otimização em dimensão finita
- Apenas os coeficientes  $\alpha_1, \dots, \alpha_n$  são necessários
- Métodos de kernel tornam-se computacionalmente viáveis



# Exemplo de aplicação do Representer Theorem



# Kernel Ridge Regression

No Kernel Ridge Regression, resolvemos:

$$\min_{\mathbf{w}} \sum_{i=1}^n (\mathbf{w} \cdot \Phi(x_i) - y_i)^2 + \lambda \|\mathbf{w}\|^2$$

Pelo Teorema do Representante, a solução ótima deve pertencer ao subespaço gerado por:

$$\mathbf{w} = \sum_{i=1}^n \alpha_i \Phi(x_i)$$

Substituindo essa representação no modelo:

$$h(x) = \mathbf{w} \cdot \Phi(x) = \sum_{i=1}^n \alpha_i K(x_i, x)$$

# Support Vector Machine

No Support Vector Machine (sem intercepto), resolvemos:

$$\min_{f \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \max(0, 1 - y_i f(x_i)) + \frac{\lambda}{2} \|f\|_{\mathcal{H}}^2$$

Pelo Teorema do Representante, a solução ótima tem a forma:

$$f(x) = \sum_{i=1}^n \alpha_i K(x_i, x)$$

Substituindo na otimização:

$$\min_{\alpha} - \sum_{i=1}^n \alpha_i + \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n y_i y_j \alpha_i \alpha_j K(x_i, x_j) \quad \text{sujeito a} \quad 0 \leq \alpha_i \leq \frac{1}{n\lambda}$$



# Conclusão

# Conclusões

- O Teorema do Representante reduz problemas de dimensão infinita para dimensão finita
- A solução ótima pertence ao subespaço gerado pelos dados:

$$f^*(x) = \sum_{i=1}^n \alpha_i K(x_i, x)$$

- Isso torna métodos de kernel computacionalmente viáveis
- Kernel Ridge Regression e SVM são aplicações diretas desse resultado



# Referências

# Referências I

 Mehryar Mohri, Afshin Rostamizadeh, and Ameet Talwalkar.  
*Foundations of machine learning.*  
MIT press, 2018.

 Grace Wahba and Yuedong Wang.  
Representer theorem.  
*Wiley StatsRef: Statistics Reference Online*, 1155:1178, 2019.

[1]

[2]