UNIVERSIDADE DE SÃO PAULO
Instituto de Ciências Matemáticas e de Computação

# EST 5105 – Tópicos de Pesquisa I

**Gabriel de Jesus Pereira**

Dissertação de Mestrado do Programa Interinstitucional de Pós-Graduação em Estatística (PIPGEs)

ICMC USP
SÃO CARLOS

# RESUMO

GABRIEL, J. P. **EST 5105 – Tópicos de Pesquisa I**. 2021. 45 p. Dissertação (Mestrado em Estatística – Programa Interinstitucional de Pós-Graduação em Estatística) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2021.

Este trabalho é um breve modelo para a escrita de monografias de qualificação, dissertações e teses utilizando o ambiente LaTeX, de acordo com as normas exigidas pelo Instituto de Ciências Matemáticas e de Computação (ICMC), da Universidade de São Paulo (USP). Para a confecção deste modelo foi utilizado a última versão (1.9.7) do pacote de classes *abnTeX2* que segue as normas da Associação Brasileira de Normas Técnicas. A elaboração de uma monografia, dissertação ou tese pode ser feita sobrescrevendo o conteúdo deste modelo.

**Palavras-chave:** Modelo, Monografia de qualificação, Dissertação, Tese, Latex.

# ABSTRACT

GABRIEL, J. P. **Model of theses and dissertations in LaTeX of the ICMC**. 2021. 45 p. Dissertação (Mestrado em Estatística – Programa Interinstitucional de Pós-Graduação em Estatística) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2021.

This paper is a brief model for writing qualification monographs, dissertations and thesis using LaTeXenvironment, in accordance with the standards required by the Institute of Mathematics and Computer Sciences (ICMC), University of São Paulo (USP). For making this model, the latest version (1.9.7) *abnTeX2* classes package was used. This package follow the rules of the Brazilian Association of Technical Standards. A drafting a monograph, dissertation or thesis can be done by overwriting the contents of this model.

**Keywords:** Template, Qualification monograph, Dissertation, Thesis, Latex.

# LISTA DE ILUSTRAÇÕES

Figura 1 – Exemplo de hiperplanos de separação. O hiperplano à direita maximiza a margem entre as classes. . . . . 16
Figura 2 – Hiperplano de separação no caso não separável. As variáveis de folga $\xi_i$ permitem a violação das restrições de margem. . . . . 18
Figura 3 – SVM para regressão. O objetivo é ajustar um tubo de largura $2\epsilon$ de modo que a maioria das observações esteja contida em seu interior. . . . . 20

# LISTA DE TABELAS

Tabela 1 – Resultados em dados simulados com a média da métrica C-index para os conjuntos de dados. . . . . 37

# SUMÁRIO


1 INTRODUÇÃO . . . . . 11

2 RECURSOS COMPUTACIONAIS . . . . . 13
2.1 Ambiente de desenvolvimento e escrita . . . . . 13
2.2 Linguagem de programação e implementação dos modelos . . . . . 14
*2.2.1 Otimização convexa . . . . . 14*

3 MÁQUINAS DE VETORES DE SUPORTE . . . . . 15
3.1 Máquinas de Vetores de Suporte para Classificação (SVM) . . . . . 15
*3.1.1 Caso não separável . . . . . 17*
3.2 Máquinas de Vetores de Suporte para Regressão (SVR) . . . . . 20

4 ANÁLISE DE SOBREVIVÊNCIA . . . . . 23
4.1 Censura . . . . . 23
4.2 Funções importantes para análise de sobrevivência e suas relações . 24
4.3 Modelo de Riscos Proporcionais de Cox . . . . . 26
4.4 SVR com Censura (SVCR) . . . . . 27
4.5 Wavelet Support Vector Censored Regression . . . . . 29

5 METODOLOGIA . . . . . 33
5.1 Particionamento dos dados . . . . . 33
5.2 Seleção de hiperparâmetros . . . . . 34
5.3 Geração de dados simulados . . . . . 34

6 RESULTADOS . . . . . 37
6.1 Aplicação em Dados Simulados . . . . . 37
6.2 Aplicação em Dados Reais . . . . . 38

7 CONCLUSÃO . . . . . 39

REFERÊNCIAS . . . . . 41

APÊNDICE A RESULTADOS DE OTIMIZAÇÃO CONVEXA . . . . 43
A.1 Definição de Problema de Otimização com Restrições . . . . . 43
A.2 Definição da Função de Lagrange . . . . . 43

A.3 Função dual . . . . . 44
A.4 Problema dual . . . . . 44
A.5 Teorema de Karush-Kuhn-Tucker (KKT) . . . . . 45

CAPÍTULO

1

# INTRODUÇÃO

CAPÍTULO

2

# RECURSOS COMPUTACIONAIS

Nesta seção, são apresentados os principais recursos computacionais utilizados no desenvolvimento deste trabalho, incluindo ferramentas para escrita do documento, linguagens de programação empregadas na implementação dos modelos e bibliotecas utilizadas na resolução dos problemas de otimização convexa. A escolha dessas ferramentas foi guiada pela necessidade de garantir rigor científico, reprodutibilidade dos experimentos e eficiência computacional na implementação dos algoritmos propostos.

## 2.1 Ambiente de desenvolvimento e escrita

A redação deste trabalho foi realizada utilizando o sistema de preparação de documentos LaTeX, amplamente adotado na comunidade científica devido à sua capacidade de lidar de forma robusta com expressões matemáticas, referências bibliográficas e formatação de documentos técnicos. O uso do LaTeX foi particularmente importante neste trabalho, dado o elevado número de equações e demonstrações envolvidas na formulação dos modelos baseados em máquinas de vetores de suporte.

Para a edição do código-fonte e do documento, foi utilizado o editor Visual Studio Code (VSCode), que oferece um ambiente leve e altamente configurável. O VSCode permite integração com diversas extensões, possibilitando suporte eficiente tanto para a escrita em LaTeX quanto para o desenvolvimento em linguagens de programação como Python. Entre as funcionalidades utilizadas, destacam-se a navegação facilitada entre arquivos, realce de sintaxe, execução de scripts e integração com sistemas de controle de versão.

## 2.2 Linguagem de programação e implementação dos modelos

A implementação dos modelos propostos neste trabalho foi realizada na linguagem de programação Python, devido à sua ampla adoção na área de ciência de dados e aprendizado de máquina, bem como à disponibilidade de bibliotecas eficientes para computação numérica.

O Python foi utilizado tanto para a geração de dados simulados quanto para a implementação dos algoritmos de Support Vector Regression (SVR) e sua extensão para dados censurados (SVCR e WSVCR). A manipulação de dados foi realizada com o auxílio da biblioteca NumPy, que oferece estruturas eficientes para operações matriciais e vetoriais, fundamentais para a implementação de métodos baseados em kernel.

Além disso, o Python permite uma integração natural com bibliotecas de otimização e facilita a prototipagem de modelos matemáticos complexos, o que foi essencial para o desenvolvimento e validação das abordagens propostas neste trabalho.

### *2.2.1 Otimização convexa*

A resolução dos problemas de otimização associados aos modelos SVCR e WSVCR foi realizada por meio da biblioteca CVXOPT, uma biblioteca especializada em programação convexa desenvolvida para a linguagem Python.

A escolha do CVXOPT deve-se ao fato de que os problemas dual dos modelos baseados em máquinas de vetores de suporte podem ser formulados como problemas de programação quadrática convexa. Nesse contexto, o CVXOPT fornece rotinas eficientes e numericamente estáveis para a obtenção da solução ótima global, garantindo a correta resolução do problema sem a necessidade de implementação manual de algoritmos iterativos, como o Sequential Minimal Optimization (SMO).

O uso de uma biblioteca consolidada como o CVXOPT também contribui para a reprodutibilidade dos resultados, uma vez que os algoritmos de otimização empregados são amplamente testados e documentados na literatura.

CAPÍTULO

3

# MÁQUINAS DE VETORES DE SUPORTE

Introduzido por (VAPNIK, 1997), o método de Máquinas de Vetores de Suporte (Support Vector Machines, SVM) constitui uma das abordagens mais influentes no contexto do aprendizado estatístico. Sua principal característica reside na construção de fronteiras de decisão potencialmente não lineares no espaço original de entrada, por meio da indução de um hiperplano linear em um espaço de características de maior dimensão, obtido a partir de uma transformação, possivelmente implícita, dos dados. Essa formulação permite controlar a complexidade do modelo ao mesmo tempo em que busca maximizar a margem de separação, o que confere ao método sólidas garantias teóricas de generalização.

Este capítulo apresenta o SVM nos contextos de classificação e regressão. Inicialmente, é abordado o problema de classificação, cuja formulação estabelece os fundamentos teóricos essenciais, tais como margem, vetores de suporte e dualidade, que são posteriormente estendidos para os demais cenários considerados.

## 3.1 Máquinas de Vetores de Suporte para Classificação (SVM)

O objetivo do SVM para classificação é determinar um hiperplano que maximize a margem de separação entre as classes. Formalmente, conforme apresentado por Mohri, Rostamizadeh e Talwalkar (2018, p. 79), considere um espaço de covariáveis $\mathcal{X} \subseteq \mathbb{R}^{\mathrm{d}}$ e um espaço de rótulos $\mathcal{Y} = \{-1, +1\}$. Seja $f : \mathcal{X} \to \mathcal{Y}$ a função alvo desconhecida.

Dado um conjunto de hipóteses $\mathcal{H}$ de funções que mapeiam $\mathcal{X}$ em $\mathcal{Y}$, o problema de classificação binária consiste em encontrar uma hipótese $h \in \mathcal{H}$ que minimize o erro de generalização:

$$R_{\mathcal{D}}(h) = \mathbb{P}_{x \sim \mathcal{D}}\left[h(x) \neq f(x)\right],$$

em que $\mathcal{D}$ é uma distribuição desconhecida sobre $\mathcal{X}$.

Para isso, o modelo recebe um conjunto de treinamento

$$S = ((x_1, y_1), \ldots, (x_m, y_m)) \in (\mathcal{X} \times \mathcal{Y})^m,$$

composto por $m$ observações i.i.d. geradas segundo a distribuição $\mathcal{D}$, tais que $y_i = f(x_i)$.

Um conjunto de hipóteses natural para esse problema é dado por classificadores lineares, definidos por hiperplanos. Nesse caso,

$$\mathcal{H} = \left\{ \mathbf{x} \mapsto \operatorname{sgn}(\mathbf{w} \cdot \mathbf{x} + b) : \mathbf{w} \in \mathbb{R}^d,\ b \in \mathbb{R} \right\},$$

em que $\mathbf{w} \cdot \mathbf{x} + b = 0$ representa um hiperplano em $\mathbb{R}^d$, com $\mathbf{w} \in \mathbb{R}^d$ um vetor normal não nulo ao hiperplano e $b \in \mathbb{R}$ um escalar. A regra de decisão associada é dada por

$$h(\mathbf{x}) = \operatorname{sgn}(\mathbf{w} \cdot \mathbf{x} + b),$$

conforme ilustrado na Figura 1.

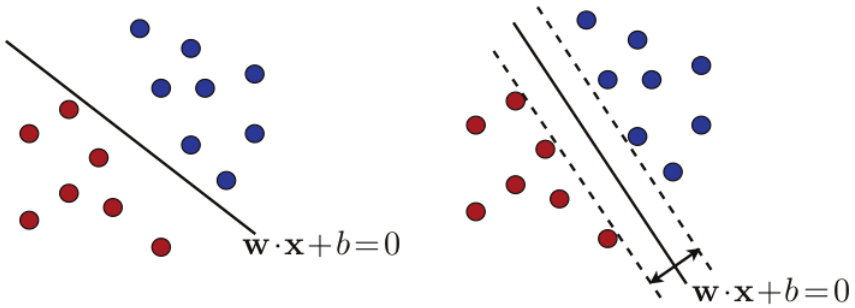


Figura 1 – Exemplo de hiperplanos de separação. O hiperplano à direita maximiza a margem entre as classes.

Em geral, podem existir infinitos hiperplanos que separam corretamente os dados. No entanto, o SVM seleciona aquele que maximiza a margem geométrica entre as classes.

A margem geométrica $\rho_h(\mathbf{x})$ de um classificador $h$ em um ponto $\mathbf{x}$ é definida como a distância Euclidiana desse ponto ao hiperplano:

$$\rho_h(\mathbf{x}) = \frac{|\mathbf{w} \cdot \mathbf{x} + b|}{\|\mathbf{w}\|_2}.$$

Para uma amostra $S = (\mathbf{x}_1, \ldots, \mathbf{x}_m)$, a margem geométrica do classificador é definida como o menor valor entre as margens individuais:

$$\rho_h = \min_{i \in [m]} \rho_h(\mathbf{x}_i),$$

o que corresponde à distância do hiperplano aos pontos mais próximos da amostra.

Assim, o problema de maximização da margem pode ser formulado como

$$\rho = \max_{\mathbf{w},b} \min_{i\in[m]} \frac{y_i(\mathbf{w}\cdot\mathbf{x}_i + b)}{\|\mathbf{w}\|},$$

sob a condição de correta classificação dos dados.

Observe que essa expressão é invariante à multiplicação de $(\mathbf{w}, b)$ por um escalar positivo. Dessa forma, pode-se impor a normalização

$$\min_{i\in[m]} y_i(\mathbf{w}\cdot\mathbf{x}_i + b) = 1,$$

o que conduz à formulação equivalente

$$\rho = \max_{\mathbf{w},b} \frac{1}{\|\mathbf{w}\|} \quad \text{sujeito a} \quad y_i(\mathbf{w}\cdot\mathbf{x}_i + b) \geqslant 1,\ \forall i \in [m].$$

Como maximizar $\frac{1}{\|\mathbf{w}\|}$ é equivalente a minimizar $\frac{1}{2}\|\mathbf{w}\|^2$, obtém-se o seguinte problema de otimização convexa:

$$\begin{aligned} \min_{\mathbf{w},b} \quad & \frac{1}{2}\|\mathbf{w}\|^2 \\ \text{sujeito a:} \quad & y_i(\mathbf{w}\cdot\mathbf{x}_i + b) \geqslant 1, \quad \forall i \in [m]. \end{aligned} \tag{3.1}$$

A função objetivo $F(\mathbf{w}) = \frac{1}{2}\|\mathbf{w}\|^2$ é estritamente convexa, uma vez que sua matriz Hessiana é a identidade, que é definida positiva. As restrições são funções afins e, portanto, convexas. Assim, o problema definido em 3.1 é um problema de otimização convexa que admite solução ótima única.

Essa propriedade constitui uma vantagem fundamental do SVM, pois garante que a solução encontrada corresponde ao ótimo global e pode ser obtida de forma eficiente por métodos de otimização convexa.

A formulação apresentada pode ser reescrita em termos de variáveis Lagrangeanas, conduzindo ao problema dual. No entanto, essa abordagem será desenvolvida na próxima seção, no contexto de dados não linearmente separáveis, que é mais representativo de aplicações reais.

### 3.1.1 Caso não separável

Na prática, é comum que os dados não sejam linearmente separáveis, isto é, exista ao menos um índice $i \in [m]$ tal que $y_i(\mathbf{w}\cdot\mathbf{x}_i + b) < 1$, como ilustrado na Figura 2. Nesse cenário, introduzem-se variáveis de folga $\xi_i \geqslant 0$, que permitem a violação controlada das restrições de margem, tornando o problema mais flexível e robusto a ruídos e outliers.

Dessa forma, as restrições de separação passam a ser escritas como

$$y_i(\mathbf{w}\cdot\mathbf{x}_i + b) \geqslant 1 - \xi_i, \quad \forall i \in [m].$$

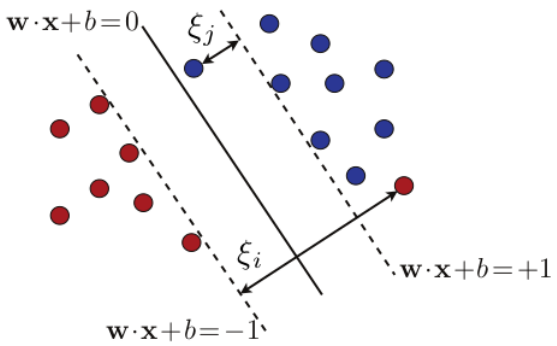


Figura 2 – Hiperplano de separação no caso não separável. As variáveis de folga $\xi_i$ permitem a violação das restrições de margem.

A variável $\xi_i$ quantifica o grau de violação da restrição associada à observação $\mathbf{x}_i$. Em particular, quando $0 < \xi_i < 1$, o ponto é corretamente classificado, mas encontra-se dentro da margem; quando $\xi_i \geqslant 1$, ocorre erro de classificação. Assim, as variáveis de folga permitem distinguir diferentes níveis de violação das condições ideais de separação.

Nesse contexto, surge um compromisso entre maximizar a margem geométrica e penalizar violações, o que leva à seguinte formulação de otimização:

$$\begin{aligned} \min_{\mathbf{w},b,\boldsymbol{\xi}} \quad & \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{m}\xi_i \\ \text{sujeito a:} \quad & y_i\left(\mathbf{w}\cdot\mathbf{x}_i + b\right) \geqslant 1 - \xi_i, \quad \forall i \in [m], \\ & \xi_i \geqslant 0, \quad \forall i \in [m], \end{aligned} \tag{3.2}$$

em que $C > 0$ é um parâmetro de regularização que controla o equilíbrio entre a maximização da margem e a penalização das violações.

O problema em (3.2) é um programa quadrático convexo, uma vez que a função objetivo é estritamente convexa e as restrições são afins. Para derivar sua forma dual, introduzem-se multiplicadores de Lagrange $\alpha_i \geqslant 0$ associados às restrições de margem e $\mu_i \geqslant 0$ associados às restrições $\xi_i \geqslant 0$. A função Lagrangiana é então dada por:

$$L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{m}\xi_i - \sum_{i=1}^{m}\alpha_i\left[y_i(\mathbf{w}\cdot\mathbf{x}_i + b) - 1 + \xi_i\right] - \sum_{i=1}^{m}\mu_i\xi_i. \tag{3.3}$$

As condições de Karush-Kuhn-Tucker (KKT) são obtidas impondo estacionariedade em relação às variáveis primais e complementaridade:

$$\nabla_{\mathbf{w}} L = \mathbf{w} - \sum_{i=1}^{m} \alpha_i y_i \mathbf{x}_i = 0 \qquad \Longrightarrow \qquad \mathbf{w} = \sum_{i=1}^{m} \alpha_i y_i \mathbf{x}_i, \tag{3.4}$$

$$\nabla_{b} L = -\sum_{i=1}^{m} \alpha_i y_i = 0 \qquad \Longrightarrow \qquad \sum_{i=1}^{m} \alpha_i y_i = 0, \tag{3.5}$$

$$\nabla_{\xi_i} L = C - \alpha_i - \mu_i = 0 \qquad \Longrightarrow \qquad 0 \leqslant \alpha_i \leqslant C, \tag{3.6}$$

$$\alpha_i \left[ y_i (\mathbf{w} \cdot \mathbf{x}_i + b) - 1 + \xi_i \right] = 0, \tag{3.7}$$

$$\mu_i \xi_i = 0. \tag{3.8}$$

Da condição (3.4), observa-se que $\mathbf{w}$ pertence ao subespaço gerado pelos dados de treinamento. Além disso, apenas observações com $\alpha_i > 0$ contribuem para a solução, sendo denominadas vetores de suporte. Esses pontos são precisamente aqueles que estão sobre ou dentro da margem, incluindo possíveis violações.

Substituindo as condições de estacionariedade na Lagrangiana, obtém-se o problema dual:

$$\begin{aligned} \max_{\boldsymbol{\alpha}} \quad & \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i,j=1}^{m} \alpha_i \alpha_j y_i y_j \left( \mathbf{x}_i \cdot \mathbf{x}_j \right) \\ \text{sujeito a:} \quad & \sum_{i=1}^{m} \alpha_i y_i = 0, \\ & 0 \leqslant \alpha_i \leqslant C, \quad \forall i \in [m]. \end{aligned} \tag{3.9}$$

A função objetivo dual é côncava, pois sua Hessiana é dada por $-\mathbf{Q}$, com $\mathbf{Q}$ sendo semidefinida positiva. Assim, o problema dual é um problema de otimização convexa bem posto, com solução ótima global.

A hipótese final pode ser expressa como:

$$h(\mathbf{x}) = \operatorname{sgn}\left( \sum_{i=1}^{m} \alpha_i y_i (\mathbf{x}_i \cdot \mathbf{x}) + b \right). \tag{3.10}$$

Essa formulação evidencia que a solução depende exclusivamente de produtos internos entre observações, o que possibilita a generalização para espaços de alta dimensão por meio de funções de kernel.

Por fim, a relação entre a norma de $\mathbf{w}$ e os multiplicadores de Lagrange permite interpretar a margem geométrica em termos da norma $\ell_1$ de $\boldsymbol{\alpha}$, reforçando que a solução do SVM é essencialmente determinada pelos vetores de suporte.

Com base nesses fundamentos, a próxima seção apresenta a extensão natural do SVM para problemas de regressão, na qual a noção de margem é adaptada para lidar com variáveis resposta contínuas.

## 3.2 Máquinas de Vetores de Suporte para Regressão (SVR)

No contexto de regressão, o objetivo das Máquinas de Vetores de Suporte consiste em aproximar uma função a partir dos dados de treinamento, controlando simultaneamente a complexidade do modelo e o erro de ajuste. Diferentemente do caso de classificação, em que se busca uma fronteira de decisão, no SVR procura-se ajustar uma função tal que os desvios em relação aos valores observados sejam, sempre que possível, inferiores a um limiar previamente especificado $\epsilon > 0$.

Geometricamente, essa ideia pode ser interpretada como o ajuste de um tubo de largura $2\epsilon$ em torno da função estimada, conforme ilustrado na Figura 3. Observações cujos valores preditos se encontram no interior desse tubo não são penalizadas, enquanto aquelas situadas fora do tubo incorrem em penalizações proporcionais à magnitude da violação.

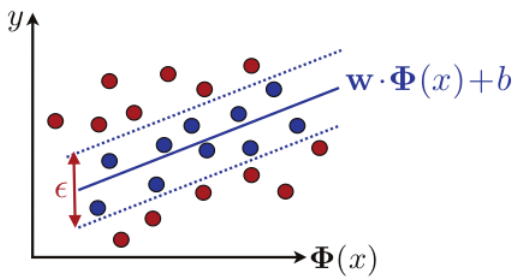


Figura 3 – SVM para regressão. O objetivo é ajustar um tubo de largura $2\epsilon$ de modo que a maioria das observações esteja contida em seu interior.

Formalmente, considere o conjunto de hipóteses

$$\mathcal{H} = \{x \mapsto \mathbf{w}\cdot\Phi(x) + b : \mathbf{w} \in \mathbb{R}^N, b \in \mathbb{R}\},$$

em que $\Phi$ é uma aplicação de mapeamento associada a um kernel definido positivo (PDS) K. O problema de otimização do SVR pode ser formulado como:

$$\min_{\mathbf{w},b} \quad \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{m} |y_i - (\mathbf{w}\cdot\Phi(x_i) + b)|_\epsilon, \tag{3.11}$$

em que $|\cdot|_\epsilon$ denota a perda $\epsilon$-insensível, definida por:

$$|y - y'|_\epsilon = \max\{0, |y - y'| - \epsilon\}. \tag{3.12}$$

Essa função de perda ignora erros de pequena magnitude, promovendo soluções esparsas, uma vez que apenas observações fora do tubo $\epsilon$ contribuem para a função objetivo.

Para obter uma formulação tratável, introduzem-se variáveis de folga $\xi_i \geqslant 0$ e $\xi_i' \geqslant 0$, que capturam, respectivamente, desvios acima e abaixo do tubo. O problema pode então ser reescrito como:

$$\begin{aligned} \min_{\mathbf{w},b,\boldsymbol{\xi},\boldsymbol{\xi}'} \quad & \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{m}(\xi_i + \xi_i') \\ \text{sujeito a:} \quad & \mathbf{w}\cdot\Phi(x_i) + b - y_i \leqslant \epsilon + \xi_i, \\ & y_i - \mathbf{w}\cdot\Phi(x_i) - b \leqslant \epsilon + \xi_i', \\ & \xi_i \geqslant 0, \quad \xi_i' \geqslant 0, \quad \forall i \in [m]. \end{aligned} \tag{3.13}$$

Esse problema é um programa quadrático convexo com restrições afins. Introduzindo multiplicadores de Lagrange e aplicando as condições de Karush-Kuhn-Tucker, obtém-se a seguinte formulação dual:

$$\begin{aligned} \max_{\boldsymbol{\alpha},\boldsymbol{\alpha}'} \quad & \varepsilon\sum_{i=1}^{m}(\alpha_i + \alpha_i') - \sum_{i=1}^{m} y_i(\alpha_i' - \alpha_i) \\ & -\frac{1}{2}\sum_{i,j=1}^{m}(\alpha_i' - \alpha_i)(\alpha_j' - \alpha_j)K_{ij} \\ \text{sujeito a:} \quad & \sum_{i=1}^{m}(\alpha_i' - \alpha_i) = 0, \\ & 0 \leqslant \alpha_i \leqslant C, \quad 0 \leqslant \alpha_i' \leqslant C, \quad \forall i \in [m], \end{aligned} \tag{3.14}$$

em que $K_{ij} = K(x_i, x_j) = \Phi(x_i)\cdot\Phi(x_j)$.

A hipótese resultante pode ser expressa como:

$$h(x) = \sum_{i=1}^{m}(\alpha_i' - \alpha_i)K(x_i, x) + b. \tag{3.15}$$

O termo $b$ pode ser estimado a partir de condições de complementaridade, utilizando pontos para os quais $0 < \alpha_i < C$ ou $0 < \alpha_i' < C$.

As condições de complementaridade implicam que, para cada $i$, no máximo um dos multiplicadores $\alpha_i$ ou $\alpha_i'$ é estritamente positivo, refletindo o fato de que uma observação não pode simultaneamente violar o tubo em ambas as direções. Além disso, para pontos situados no interior do tubo $\epsilon$, tem-se $\alpha_i = \alpha_i' = 0$, de modo que tais observações não contribuem para a solução.

Consequentemente, apenas os pontos que violam a margem $\epsilon$ influenciam diretamente a hipótese final, caracterizando-se como vetores de suporte. Quando uma fração significativa dos

dados encontra-se no interior do tubo, a solução tende a ser esparsa, o que é uma propriedade desejável do ponto de vista computacional e estatístico.

O parâmetro $\epsilon$ desempenha um papel central nesse contexto, estabelecendo um compromisso entre esparsidade e qualidade de ajuste. Valores maiores de $\epsilon$ resultam em soluções mais esparsas, ao custo de uma possível perda de precisão, enquanto valores menores aumentam a sensibilidade do modelo aos dados.

O SVR apresenta diversas propriedades favoráveis. Em particular, está fundamentado em princípios teóricos sólidos, admite soluções esparsas e permite a incorporação natural de kernels, possibilitando a modelagem de relações não lineares em espaços de alta dimensão. Ademais, o método apresenta propriedades de estabilidade que garantem boa capacidade de generalização, conforme discutido em Mohri, Rostamizadeh e Talwalkar (2018, p. 339–340).

Por outro lado, o desempenho do SVR depende da escolha adequada dos hiperparâmetros $C$ e $\epsilon$, cuja seleção usualmente requer procedimentos de validação cruzada, potencialmente custosos em termos computacionais. Além disso, a resolução do problema de otimização pode se tornar onerosa para conjuntos de dados de grande escala.

CAPÍTULO

4

# ANÁLISE DE SOBREVIVÊNCIA

Em diversos contextos aplicados, não é suficiente determinar se um evento de interesse ocorrerá; torna-se igualmente, e frequentemente mais relevante, modelar o tempo até a sua ocorrência. Considere, por exemplo, um paciente acometido por uma doença crônica. Nesse caso, profissionais da saúde estão interessados não apenas em avaliar a eficácia de diferentes intervenções terapêuticas, mas também em estimar o tempo de sobrevivência associado a cada estratégia. De maneira análoga, no setor financeiro, instituições buscam modelar o tempo até a ocorrência de inadimplência de um cliente, com o objetivo de aprimorar mecanismos de controle e gestão de risco. De forma semelhante, em aplicações de marketing e negócios, o fenômeno de *churn* refere-se ao tempo até que um cliente deixe de utilizar um serviço, sendo sua antecipação fundamental para a implementação de políticas eficazes de retenção.

Esses exemplos evidenciam a ampla gama de aplicações em que o tempo até a ocorrência de um evento constitui a principal variável de interesse. Nesse contexto, a análise de sobrevivência emerge como um arcabouço estatístico voltado à modelagem de tempos até evento, caracterizando-se, em particular, pela presença de observações incompletas, decorrentes de mecanismos de censura. A incorporação adequada dessas informações parciais é um dos aspectos centrais que distinguem a análise de sobrevivência de abordagens tradicionais de modelagem estatística.

## 4.1 Censura

A principal característica que distingue a análise de sobrevivência de outras áreas da estatística é a presença de censura. De forma geral, diz-se que uma observação é censurada quando o tempo exato de ocorrência do evento de interesse não é completamente observado. Assim, enquanto para alguns indivíduos o tempo até o evento é conhecido, para outros apenas se dispõe de informação parcial, o que caracteriza a presença de dados censurados (CLARK *et al.*, 2003).

No contexto da análise de sobrevivência, a censura pode ser classificada em três categorias principais: à direita, à esquerda e intervalar. A censura à direita ocorre quando o evento de interesse não é observado durante o período de acompanhamento, seja em razão da saída do indivíduo do estudo antes de sua conclusão, seja pelo término do estudo sem a ocorrência do evento. A censura à esquerda, por sua vez, ocorre quando o evento já aconteceu antes do início do período de observação, embora o instante exato de sua ocorrência seja desconhecido. Por fim, a censura intervalar caracteriza-se pelo fato de que o evento é conhecido apenas como tendo ocorrido em algum instante dentro de um intervalo de tempo, delimitado por duas observações sucessivas.

Neste trabalho, o foco será direcionado aos casos de censura à esquerda e à direita, que são os mais frequentemente encontrados em aplicações práticas. Formalmente, uma observação censurada pode ser representada por um triplo $(\mathbf{x}_i, l_i, u_i)$, para $i = 1, \ldots, m$, em que $\mathbf{x}_i \in \mathbb{R}^d$ denota o vetor de covariáveis, $l_i \in \mathbb{R} \cup \{-\infty\}$ representa o limite inferior e $u_i \in \mathbb{R} \cup \{+\infty\}$ o limite superior do intervalo no qual o tempo de ocorrência do evento está contido.

Nesse formalismo, a censura à direita é representada por observações da forma $(\mathbf{x}_i, l_i, +\infty)$, indicando que o evento ocorreu após o tempo $l_i$, mas seu instante exato é desconhecido. Analogamente, a censura à esquerda é representada por $(\mathbf{x}_i, -\infty, u_i)$, indicando que o evento ocorreu antes de $u_i$. Quando ambos os limites são finitos, isto é, $l_i < u_i < +\infty$, tem-se o caso de censura intervalar.

No caso particular de observações não censuradas, o tempo de ocorrência do evento é conhecido exatamente, de modo que $l_i = u_i = y_i$. Nesse caso, a observação pode ser representada simplesmente por $(\mathbf{x}_i, y_i)$, em que $y_i$ corresponde ao tempo de sobrevivência observado.

Essa representação unificada permite tratar, de forma coerente, diferentes mecanismos de censura dentro de um mesmo arcabouço matemático, sendo particularmente útil na formulação de métodos de aprendizado que incorporam explicitamente a informação parcial disponível nos dados.

## 4.2 Funções importantes para análise de sobrevivência e suas relações

Os métodos de análise de sobrevivência são fundamentados na caracterização da distribuição do tempo até a ocorrência de um evento aleatório. As principais formas de descrever essa distribuição são por meio da função de sobrevivência e da função de risco, que oferecem interpretações complementares e desempenham papel central tanto na formulação teórica quanto na modelagem estatística.

A função de sobrevivência descreve a probabilidade de o evento de interesse não ter

ocorrido até um instante $t$, sendo definida por:

$$S(t) = P(T > t), \quad 0 < t < \infty. \tag{4.1}$$

Sob condições usuais, tem-se que $S(0) = 1$ e $\lim_{t\to\infty} S(t) = 0$. Além disso, a função de sobrevivência é não crescente e contínua à direita, propriedades que decorrem diretamente de sua definição probabilística.

Outra quantidade fundamental é a função de risco, que descreve a taxa instantânea de ocorrência do evento no tempo $t$, condicionada à sobrevivência até esse instante. Formalmente, a função de risco é definida por:

$$h(t) = \lim_{\delta\to 0} \frac{P(t < T \leqslant t+\delta \mid T > t)}{\delta}. \tag{4.2}$$

Essa definição evidencia que $h(t)$ não é uma probabilidade, mas sim uma taxa, podendo assumir valores maiores que 1. Intuitivamente, ela quantifica a propensão instantânea de ocorrência do evento em torno de $t$, dado que o indivíduo sobreviveu até esse momento.

A partir dessas definições, podem ser estabelecidas diversas relações que caracterizam completamente a distribuição de $T$. Em particular, a função de distribuição acumulada é dada por:

$$F(t) = P(T \leqslant t) = 1 - S(t), \quad 0 < t < \infty. \tag{4.3}$$

Assim como $S(t)$, a função $F(t)$ é contínua à direita e não decrescente. No contexto da análise de sobrevivência, $F(t)$ pode ser interpretada como a probabilidade acumulada de ocorrência do evento até o tempo $t$, não devendo ser confundida com a função de risco acumulado definida adiante.

Quando a distribuição de $T$ admite densidade, a função densidade de probabilidade é obtida como:

$$f(t) = \frac{d}{dt}F(t) = -\frac{d}{dt}S(t). \tag{4.4}$$

A função de risco pode então ser expressa em termos da densidade e da função de sobrevivência como:

$$h(t) = \frac{f(t)}{S(t)}, \tag{4.5}$$

o que explicita sua interpretação como uma taxa condicional: trata-se da densidade de ocorrência do evento em $t$, ponderada pela probabilidade de sobrevivência até esse instante.

A integral da função de risco ao longo do tempo define a função de risco acumulado:

$$H(t) = \int_0^t h(u)\, du. \tag{4.6}$$

Essa função é não decrescente e desempenha papel central na teoria da sobrevivência, uma vez que estabelece uma relação direta e particularmente conveniente com a função de

sobrevivência. De fato, pode-se demonstrar que:

$$S(t) = \exp\left(-\int_0^t h(u)\,du\right) = \exp\left(-H(t)\right). \tag{4.7}$$

Essa expressão evidencia que a função de sobrevivência é completamente determinada pela função de risco, e vice-versa. Do ponto de vista prático, essa relação é de grande relevância, pois muitos modelos em análise de sobrevivência são especificados diretamente em termos da função de risco, como é o caso do modelo de riscos proporcionais de Cox. Além disso, a representação exponencial garante que $S(t)$ permaneça no intervalo unitário e preserve suas propriedades fundamentais.

Em conjunto, essas funções e suas inter-relações fornecem um arcabouço matemático consistente para a modelagem de dados de sobrevivência, permitindo diferentes formas de especificação de modelos conforme as características do problema e dos dados disponíveis.

## 4.3 Modelo de Riscos Proporcionais de Cox

O modelo de riscos proporcionais de Cox, proposto por (COX, 1972), constitui uma das abordagens mais influentes e amplamente empregadas na análise de sobrevivência. Sua principal característica reside na natureza semiparamétrica da modelagem, na qual a função de risco é decomposta em um componente basal arbitrário e um componente paramétrico associado às covariáveis, sem a necessidade de especificação explícita da forma funcional do risco basal ao longo do tempo.

Formalmente, seja $\mathbf{x}_i \in \mathbb{R}^p$ o vetor de covariáveis associado ao $i$-ésimo indivíduo. O modelo de Cox é definido por:

$$h(t \mid \mathbf{x}_i) = h_0(t) \exp\left(\mathbf{x}_i^\top \boldsymbol{\beta}\right), \tag{4.8}$$

em que $h_0(t)$ é a função de risco basal, comum a todos os indivíduos, e $\boldsymbol{\beta} \in \mathbb{R}^p$ é o vetor de parâmetros que quantifica o efeito das covariáveis sobre o risco.

A hipótese central do modelo é a de riscos proporcionais, segundo a qual a razão entre as funções de risco de quaisquer dois indivíduos permanece constante ao longo do tempo. Mais precisamente, para dois indivíduos com vetores de covariáveis $\mathbf{x}_i$ e $\mathbf{x}_j$, tem-se:

$$\frac{h(t \mid \mathbf{x}_i)}{h(t \mid \mathbf{x}_j)} = \exp\left((\mathbf{x}_i - \mathbf{x}_j)^\top \boldsymbol{\beta}\right), \tag{4.9}$$

o que evidencia que essa razão independe do tempo $t$. Essa propriedade confere ao modelo uma interpretação particularmente conveniente, pois o termo $\exp(\beta_k)$ pode ser interpretado como o efeito multiplicativo associado a um aumento unitário na $k$-ésima covariável sobre o risco instantâneo, mantendo as demais fixas.

Uma das principais vantagens do modelo de Cox é que a estimação do vetor de parâmetros $\boldsymbol{\beta}$ pode ser realizada sem a necessidade de especificar a função de risco basal $h_0(t)$. Esse resultado é obtido por meio da verossimilhança parcial, que explora apenas a informação contida na ordenação dos tempos de falha observados. Seja $t_{(1)} < \cdots < t_{(D)}$ a sequência dos tempos de falha distintos e $\mathcal{R}(t_{(d)})$ o conjunto de risco imediatamente antes de $t_{(d)}$. A verossimilhança parcial é definida por:

$$L(\boldsymbol{\beta}) = \prod_{d=1}^{D} \frac{\exp\left(\mathbf{x}_{(d)}^{\top}\boldsymbol{\beta}\right)}{\sum_{j\in\mathcal{R}(t_{(d)})} \exp\left(\mathbf{x}_j^{\top}\boldsymbol{\beta}\right)}. \tag{4.10}$$

Sob condições de regularidade, a maximização dessa função conduz a estimativas consistentes e assintoticamente normais para $\boldsymbol{\beta}$, mesmo na presença de censura à direita. Uma vez obtidas as estimativas dos parâmetros, é possível recuperar a função de risco basal, tipicamente por meio do estimador de Breslow, e, consequentemente, a função de sobrevivência.

A função de sobrevivência condicional associada ao indivíduo $i$ pode ser expressa como:

$$S(t \mid \mathbf{x}_i) = S_0(t)^{\exp\left(\mathbf{x}_i^{\top}\boldsymbol{\beta}\right)}, \tag{4.11}$$

em que $S_0(t)$ denota a função de sobrevivência basal correspondente a $h_0(t)$. Essa expressão evidencia que o efeito das covariáveis atua de forma multiplicativa sobre o risco e, de maneira equivalente, exponencial sobre a função de sobrevivência.

Apesar de sua ampla aplicabilidade e interpretabilidade, o modelo de Cox depende criticamente da validade da hipótese de riscos proporcionais. Violações dessa suposição podem resultar em estimativas viesadas e comprometer a interpretação dos coeficientes. Nesse contexto, diversas extensões têm sido propostas na literatura, incluindo modelos com coeficientes dependentes do tempo, abordagens estratificadas e métodos baseados em aprendizado de máquina, que buscam maior flexibilidade na modelagem de relações complexas entre covariáveis e o risco de ocorrência do evento, especialmente em cenários de alta dimensionalidade.

## 4.4 SVR com Censura (SVCR)

O modelo de Support Vector Regression (SVR), apresentado na Seção 3.2, pode ser estendido de forma natural para o caso em que as observações estão sujeitas à censura. Essa generalização, proposta por Shivaswamy, Chu e Jansche (2007), permite incorporar explicitamente a informação parcial contida nos dados censurados, evitando a necessidade de procedimentos auxiliares, como imputações ou transformações ad hoc, que podem introduzir viés ou perda de informação.

Considere um conjunto de dados censurados $\{(\mathbf{x}_i, l_i, u_i)\}_{i=1}^{n}$, em que $\mathbf{x}_i \in \mathbb{R}^p$ representa o vetor de covariáveis, enquanto $l_i$ e $u_i$ denotam, respectivamente, os limites inferior e superior do intervalo no qual o valor alvo verdadeiro está contido. O objetivo consiste em estimar uma função $f : \mathbb{R}^p \to \mathbb{R}$ tal que, idealmente, $f(\mathbf{x}_i) \in [l_i, u_i]$ para a maior parte das observações.

Nesse contexto, não há penalização quando a predição pertence ao intervalo observado. A penalização ocorre apenas quando há violação dos limites, isto é, quando $f(\mathbf{x}_i) < l_i$ ou $f(\mathbf{x}_i) > u_i$. A função de perda correspondente pode ser definida por:

$$c\left(f(\mathbf{x}_i), l_i, u_i\right) = \max\{l_i - f(\mathbf{x}_i),\ f(\mathbf{x}_i) - u_i,\ 0\}. \tag{4.12}$$

Essa função de perda é convexa e coincide com o erro absoluto fora do intervalo permitido, sendo nula quando a predição se encontra dentro do intervalo. Nos casos particulares em que $l_i = -\infty$ ou $u_i = +\infty$, a perda torna-se unilateral, refletindo, respectivamente, situações de censura à esquerda e à direita.

Para a formulação do problema, particiona-se o conjunto de índices $\{1, \ldots, n\}$ em três subconjuntos disjuntos:

$$I_u = \{i \mid l_i > -\infty,\ u_i < +\infty\}, \tag{4.13}$$

$$I_r = \{i \mid u_i = +\infty\}, \tag{4.14}$$

$$I_l = \{i \mid l_i = -\infty\}. \tag{4.15}$$

O conjunto $I_u$ corresponde às observações com limites inferior e superior finitos, enquanto $I_r$ e $I_l$ representam, respectivamente, observações censuradas à direita e à esquerda. Define-se ainda:

$$L = I_u \cup I_r, \quad U = I_u \cup I_l, \tag{4.16}$$

em que $L$ contém os índices das observações com limite inferior finito, e $U$ aqueles com limite superior finito.

Com base nessas definições, o problema de otimização associado ao SVCR pode ser formulado como:

$$\begin{aligned}
\min_{\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\xi}^*} \quad & \frac{1}{2}\|\mathbf{w}\|^2 + C\left(\sum_{i \in U} \xi_i + \sum_{i \in L} \xi_i^*\right) \\
\text{sujeito a:} \quad & \mathbf{w}^\top \mathbf{x}_i + b - u_i \leqslant \xi_i^*, \quad \forall i \in U, \\
& l_i - \mathbf{w}^\top \mathbf{x}_i - b \leqslant \xi_i, \quad \forall i \in L, \\
& \xi_i \geqslant 0, \quad \forall i \in U, \\
& \xi_i^* \geqslant 0, \quad \forall i \in L.
\end{aligned} \tag{4.17}$$

Essa formulação evidencia que o modelo utiliza de forma integrada todas as informações disponíveis, tratando simultaneamente observações não censuradas, censuradas à direita, à esquerda e intervalares. As variáveis de folga $\xi_i$ e $\xi_i^*$ quantificam, respectivamente, as violações dos limites inferior e superior impostos pelos intervalos observados.

Introduzindo multiplicadores de Lagrange $\alpha_i \geqslant 0$ e $\alpha_i^* \geqslant 0$ associados às restrições, obtém-se a formulação dual do problema:

$$\begin{aligned} \max_{\boldsymbol{\alpha},\boldsymbol{\alpha}^*} \quad & -\frac{1}{2}\sum_{i,j=1}^{n}(\alpha_i-\alpha_i^*)(\alpha_j-\alpha_j^*)K(\mathbf{x}_i,\mathbf{x}_j) \\ & -\sum_{i\in L} l_i\alpha_i + \sum_{i\in U} u_i\alpha_i^* \\ \text{sujeito a:} \quad & \sum_{i\in L}\alpha_i - \sum_{i\in U}\alpha_i^* = 0, \\ & 0 \leqslant \alpha_i \leqslant C, \quad 0 \leqslant \alpha_i^* \leqslant C. \end{aligned} \tag{4.18}$$

A função objetivo dual é côncava, uma vez que a matriz de Gram associada ao kernel é semidefinida positiva, o que garante que o problema constitui um programa quadrático convexo bem posto. Além disso, variáveis $\alpha_i$ e $\alpha_i^*$ fora de seus respectivos conjuntos podem ser consideradas nulas, permitindo uma formulação uniforme para todo $i = 1,\ldots,n$.

Assim como no SVR clássico, a solução depende exclusivamente de produtos internos entre vetores de entrada, o que permite a substituição desses produtos por uma função de kernel $K(\mathbf{x}_i,\mathbf{x}_j)$, viabilizando a modelagem de relações não lineares no espaço original. Consequentemente, a função estimada pode ser expressa como:

$$h(\mathbf{x}) = \sum_{i=1}^{n}(\alpha_i-\alpha_i^*)K(\mathbf{x}_i,\mathbf{x}) + b. \tag{4.19}$$

Na solução ótima, apenas uma fração dos coeficientes $\alpha_i - \alpha_i^*$ assume valores não nulos, caracterizando os vetores de suporte. Essa propriedade de esparsidade é fundamental tanto para a eficiência computacional quanto para a interpretabilidade do modelo.

Do ponto de vista computacional, o problema dual consiste em um programa quadrático com restrições lineares, podendo ser resolvido por métodos clássicos de otimização convexa, como métodos de pontos interiores, ou por abordagens mais escaláveis, como o método de otimização mínima sequencial (SMO). Em termos de complexidade, o SVCR apresenta comportamento comparável ao do SVR padrão, tornando-o adequado para problemas de dimensão moderada a elevada.

## 4.5 Wavelet Support Vector Censored Regression

Wavelets constituem uma ferramenta matemática amplamente utilizada para a decomposição de funções, sinais e operadores em componentes localizadas no tempo (ou espaço) e na frequência. Diferentemente de abordagens baseadas em transformadas globais, a análise por wavelets permite capturar simultaneamente características locais e multiescala, sendo particularmente adequada para a modelagem de fenômenos não lineares e não estacionários.

A ideia central consiste em representar uma função $g : \mathbb{R} \to \mathbb{R}$ como uma combinação de funções geradas a partir de uma função base, denominada wavelet mãe, por meio de operações de dilatação e translação. Formalmente, define-se a família de wavelets como:

$$h_{A,B}(x) = |A|^{-1/2} h\left(\frac{x-B}{A}\right), \tag{4.20}$$

em que $h(x)$ é a wavelet mãe, $A \in \mathbb{R} \setminus \{0\}$ é o parâmetro de escala e $B \in \mathbb{R}$ é o parâmetro de translação.

A partir dessa construção, uma função $g(x)$ pode ser aproximada por:

$$\hat{g}(x) = \sum_{i=1}^{t} w_i h_{A_i,B_i}(x), \tag{4.21}$$

em que $w_i \in \mathbb{R}$ são coeficientes reais. Essa representação evidencia a capacidade das wavelets de aproximar funções complexas, especialmente em contextos com variações locais.

No contexto de máquinas de vetores de suporte, essas propriedades podem ser incorporadas por meio da definição de funções kernel. Para que uma função $K(\mathbf{x}, \mathbf{x}')$ seja um kernel válido, ela deve satisfazer as condições do teorema de Mercer, assegurando a existência de um espaço de características associado.

Uma escolha amplamente utilizada é a wavelet cosseno-Gaussiana, definida por:

$$h(x) = \cos(1.75x)\exp(-0.5x^2), \tag{4.22}$$

que corresponde à parte real da wavelet de Morlet. Essa função apresenta boas propriedades de localização conjunta no domínio do tempo e da frequência.

Com base nessa função, define-se o kernel de wavelet multidimensional como:

$$K(\mathbf{x}, \mathbf{x}') = \prod_{k=1}^{p} h\left(\frac{x_k - x'_k}{A}\right), \tag{4.23}$$

em que $A > 0$ é um parâmetro de escala.

Esse kernel é invariante por translação e capaz de capturar estruturas locais e não lineares nos dados, oferecendo maior flexibilidade em comparação com kernels clássicos.

O modelo Wavelet Support Vector Censored Regression incorpora esse kernel na formulação dual do SVCR. Dessa forma, substituindo o kernel na Equação (4.18), obtém-se:

$$\begin{aligned} \max_{\boldsymbol{\alpha},\boldsymbol{\alpha}^*} \quad & -\frac{1}{2}\sum_{i,j=1}^{n}(\alpha_i - \alpha_i^*)(\alpha_j - \alpha_j^*)\prod_{k=1}^{p} h\left(\frac{x_{ik} - x_{jk}}{A}\right) \\ & -\sum_{i\in L} l_i \alpha_i + \sum_{i\in U} u_i \alpha_i^*, \end{aligned} \tag{4.24}$$

sob as mesmas restrições definidas anteriormente.

Essa formulação permite combinar a robustez do SVCR com a capacidade de representação multiescala dos kernels de wavelet, tornando o modelo particularmente adequado para cenários em que a relação entre covariáveis e tempo de sobrevivência apresenta elevada complexidade não linear.

CAPÍTULO

5

# METODOLOGIA

Este capítulo descreve, de forma sistemática, os procedimentos adotados para a construção, treinamento e avaliação dos modelos considerados neste trabalho. Em particular, são detalhados os processos de particionamento dos dados, seleção de hiperparâmetros e geração de dados experimentais, seguindo práticas consolidadas na literatura de aprendizado de máquina aplicado à análise de sobrevivência.

## 5.1 Particionamento dos dados

A avaliação do desempenho preditivo dos modelos foi conduzida por meio de um esquema de validação baseado na divisão dos dados em conjuntos de treinamento e teste. Especificamente, adotou-se uma estratégia de holdout, na qual 70% das observações foram utilizadas para treinamento e os 30% restantes reservados para teste.

Seja $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{n}$ o conjunto de dados disponível. Esse conjunto foi particionado em dois subconjuntos disjuntos, $\mathcal{D}_{\text{train}}$ e $\mathcal{D}_{\text{test}}$, tais que:

$$\mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{test}} = \mathcal{D}, \quad \mathcal{D}_{\text{train}} \cap \mathcal{D}_{\text{test}} = \emptyset,$$

com $|\mathcal{D}_{\text{train}}| \approx 0{,}7n$ e $|\mathcal{D}_{\text{test}}| \approx 0{,}3n$.

A separação foi realizada de forma aleatória, preservando, sempre que aplicável, a estrutura dos dados censurados, de modo a garantir que ambos os subconjuntos apresentassem proporções semelhantes de observações censuradas e não censuradas. Essa precaução é particularmente importante em problemas de análise de sobrevivência, uma vez que a distribuição dos tipos de censura pode influenciar significativamente o desempenho dos modelos.

Adicionalmente, com o objetivo de reduzir a variabilidade associada a uma única partição, o procedimento de holdout foi repetido múltiplas vezes, conforme sugerido na literatura empírica :contentReference[oaicite:0]index=0. As métricas de desempenho foram então agrega-

das ao longo dessas repetições, considerando medidas como média, mediana e desvio padrão, proporcionando uma avaliação mais robusta e estável.

## 5.2 Seleção de hiperparâmetros

A escolha adequada dos hiperparâmetros é um elemento crucial para o desempenho de modelos baseados em máquinas de vetores de suporte. Nesse contexto, foi empregado um procedimento de busca em grade (grid search), amplamente utilizado devido à sua simplicidade e efetividade.

Para cada modelo considerado, definiu-se um conjunto finito de valores candidatos para os hiperparâmetros relevantes. No caso do SVR e de suas extensões, foram considerados, entre outros:

- o parâmetro de regularização $C$, que controla o equilíbrio entre ajuste aos dados e complexidade do modelo;
- o parâmetro $\epsilon$, no caso do SVR, que define a largura do tubo de insensibilidade;
- os parâmetros específicos de cada função kernel, como o grau no kernel polinomial ou o parâmetro de escala em kernels gaussianos e wavelet.

Formalmente, seja $\Theta$ o espaço de hiperparâmetros. O grid search consiste em avaliar exaustivamente o desempenho do modelo para cada combinação $\theta \in \Theta$, selecionando aquela que otimiza uma métrica de interesse.

A avaliação das combinações foi realizada exclusivamente no conjunto de treinamento, utilizando validação interna, de modo a evitar vazamento de informação do conjunto de teste. O modelo final foi então treinado com os hiperparâmetros selecionados e avaliado no conjunto de teste.

Em consonância com o estudo de referência :contentReference[oaicite:1]index=1, foram considerados diferentes tipos de funções kernel, incluindo não apenas os kernels tradicionais (linear, polinomial e gaussiano), mas também alternativas como os kernels exponencial, Laplaciano e Cauchy, que têm demonstrado bom desempenho em cenários de dados censurados.

## 5.3 Geração de dados simulados

Com o objetivo de avaliar o desempenho dos modelos em um ambiente controlado, foram conduzidos experimentos com dados simulados, seguindo a estratégia adotada na literatura recente. A utilização de dados artificiais permite controlar características fundamentais do

problema, tais como a estrutura de dependência entre covariáveis, o grau de não linearidade e a proporção de censura.

Considere um vetor de covariáveis $\mathbf{X} = (X_1, X_2, X_3)^\top$, cujas componentes são geradas independentemente segundo as distribuições:

$$X_1 \sim \mathcal{N}(1,1), \tag{5.1}$$

$$X_2 \sim \mathcal{N}(2,2), \tag{5.2}$$

$$X_3 \sim \mathrm{Exp}(1). \tag{5.3}$$

O tempo de sobrevivência $T$ é gerado a partir de uma distribuição Weibull, amplamente utilizada em estudos de simulação por sua flexibilidade em modelar diferentes formas da função de risco. Especificamente, considera-se:

$$T \sim \mathrm{Weibull}(\lambda(\mathbf{X}), k), \tag{5.4}$$

em que o parâmetro de forma é fixado em $k = 3$, enquanto o parâmetro de escala depende das covariáveis segundo a relação não linear:

$$\lambda(\mathbf{X}) = 5 \exp\left(-X_1 \ln|X_2| + \sin(X_3^2)\right). \tag{5.5}$$

Essa especificação induz uma relação altamente não linear entre as covariáveis e o tempo de sobrevivência, constituindo um cenário desafiador para os modelos avaliados. Em particular, a presença de termos como $\ln|X_2|$ e $\sin(X_3^2)$ introduz efeitos não aditivos e não monotônicos, dificultando a captura da estrutura subjacente por métodos lineares.

Para incorporar censura aos dados, foram gerados tempos de censura $C$ independentes de $T$, de modo a satisfazer a hipótese de censura não informativa. Os tempos observados são então definidos por:

$$Y = \min(T, C), \quad \delta = \mathbb{I}(T \leqslant C), \tag{5.6}$$

em que $Y$ representa o tempo observado e $\delta$ é o indicador de falha.

A distribuição de $C$ foi escolhida de forma a controlar a proporção de observações censuradas no conjunto de dados. Dessa forma, diferentes cenários foram considerados, variando-se tanto o tamanho da amostra quanto o nível de censura, permitindo uma análise abrangente da robustez dos modelos sob condições distintas.

Esse procedimento de simulação possibilita avaliar o desempenho dos métodos em um ambiente no qual a função geradora dos dados é conhecida, permitindo uma comparação mais precisa entre os modelos considerados.

CAPÍTULO

6

# RESULTADOS

## 6.1 Aplicação em Dados Simulados

A Tabela 1 apresenta o desempenho preditivo dos modelos considerados em dados simulados, avaliados por meio do C-index, para diferentes tamanhos amostrais e proporções de censura. Os resultados refletem um cenário no qual a relação entre as covariáveis e o tempo de falha é explicitamente não linear, o que permite analisar a capacidade dos métodos em capturar tais estruturas.

Tabela 1 – Resultados em dados simulados com a média da métrica C-index para os conjuntos de dados.

| **n** | **50** | | | **100** | | | **300** | | | **Média** |
|---|---|---|---|---|---|---|---|---|---|---|
| **censura (%)** | **0.1** | **0.25** | **0.5** | **0.1** | **0.25** | **0.5** | **0.1** | **0.25** | **0.5** | |
| laplacian | 0.730 | 0.751 | 0.777 | 0.771 | 0.784 | 0.795 | 0.825 | 0.833 | 0.848 | 0.791 |
| cauchy | 0.739 | 0.754 | 0.774 | 0.771 | 0.773 | 0.799 | 0.817 | 0.825 | 0.846 | 0.789 |
| poly | 0.734 | 0.757 | 0.779 | 0.776 | 0.783 | 0.813 | 0.798 | 0.808 | 0.842 | 0.788 |
| exponential | 0.730 | 0.736 | 0.763 | 0.772 | 0.788 | 0.791 | 0.819 | 0.827 | 0.848 | 0.786 |
| rbf | 0.720 | 0.726 | 0.760 | 0.769 | 0.782 | 0.783 | 0.809 | 0.815 | 0.836 | 0.778 |
| wavelet | 0.709 | 0.718 | 0.723 | 0.758 | 0.769 | 0.783 | 0.794 | 0.801 | 0.821 | 0.764 |
| CoxPH | 0.727 | 0.736 | 0.782 | 0.750 | 0.755 | 0.793 | 0.743 | 0.766 | 0.806 | 0.762 |
| linear | 0.704 | 0.742 | 0.755 | 0.730 | 0.750 | 0.782 | 0.748 | 0.764 | 0.804 | 0.753 |

De forma geral, observa-se que os modelos baseados em SVCR com kernels não lineares apresentam desempenho superior ao modelo de Cox e ao modelo linear em praticamente todos os cenários considerados. Em particular, os kernels Laplaciano, Cauchy e Polinomial destacam-se como os mais eficazes, apresentando os maiores valores médios de C-index. Esse comportamento é consistente com o fato de que tais kernels são capazes de modelar relações não lineares complexas por meio de mapeamentos implícitos para espaços de maior dimensão, o que lhes confere maior flexibilidade em comparação a modelos lineares.

O modelo de Cox, por sua vez, apresenta desempenho intermediário. Embora seja competitivo em algumas configurações — especialmente para amostras maiores —, seu desempenho é, em média, inferior ao dos melhores modelos baseados em kernel. Esse resultado é esperado, dado que o modelo de Cox assume uma estrutura linear no preditor do log-risco, o que o torna potencialmente inadequado quando a verdadeira relação entre as covariáveis e o tempo de sobrevivência é não linear, como no caso do mecanismo gerador dos dados considerado neste estudo.

Outro aspecto relevante refere-se ao efeito do tamanho amostral. Observa-se um aumento consistente do C-index à medida que o número de observações cresce de $n = 50$ para $n = 300$. Esse padrão é verificado para todos os modelos analisados e está alinhado com resultados teóricos, uma vez que o aumento do tamanho da amostra reduz a variabilidade dos estimadores e melhora a capacidade de generalização dos modelos, especialmente em abordagens mais flexíveis, como aquelas baseadas em kernels.

No que diz respeito à proporção de censura, nota-se, em diversos casos, um aumento do valor do C-index à medida que a censura se eleva de 10% para 50%. No entanto, essa evidência deve ser interpretada com cautela. Do ponto de vista metodológico, o aumento da censura reduz o número de pares comparáveis utilizados no cálculo do C-index, o que pode levar a estimativas mais instáveis e, em alguns casos, artificialmente elevadas. Assim, esse comportamento não deve ser interpretado como uma melhoria efetiva da capacidade preditiva dos modelos, mas sim como um efeito da estrutura da censura sobre a métrica de avaliação.

Entre os diferentes kernels, o kernel Laplaciano apresenta o melhor desempenho médio global, seguido de perto pelos kernels Cauchy e Polinomial. Esses resultados sugerem que kernels com maior sensibilidade a variações locais podem ser mais adequados para capturar a estrutura dos dados simulados. Por outro lado, o kernel Gaussiano (RBF), embora também não linear, apresenta desempenho ligeiramente inferior, possivelmente devido à sua maior suavidade. O kernel wavelet, por sua vez, apresenta desempenho competitivo, porém inferior aos demais kernels não lineares, o que pode estar relacionado à sua dependência de parâmetros de escala e à natureza oscilatória de suas funções base.

Em síntese, os resultados obtidos indicam que, em cenários caracterizados por relações não lineares e presença de censura, métodos baseados em SVCR com kernels adequados apresentam vantagens relevantes em termos de desempenho preditivo quando comparados a abordagens lineares ou semiparamétricas clássicas. Além disso, reforçam a importância de considerar cuidadosamente tanto a estrutura dos dados quanto a escolha da métrica de avaliação na análise de modelos de sobrevivência.

## 6.2 Aplicação em Dados Reais

CAPÍTULO

7

# CONCLUSÃO

# REFERÊNCIAS

CLARK, T. G.; BRADBURN, M. J.; LOVE, S. B.; ALTMAN, D. G. Survival analysis part i: basic concepts and first analyses. **British journal of cancer**, Nature Publishing Group, v. 89, n. 2, p. 232–238, 2003. Citado na página 23.

COX, D. R. Regression models and life-tables. **Journal of the royal statistical society: Series B (methodological)**, Wiley Online Library, v. 34, n. 2, p. 187–202, 1972. Citado na página 26.

MOHRI, M.; ROSTAMIZADEH, A.; TALWALKAR, A. **Foundations of machine learning**. [S.l.]: MIT press, 2018. Citado nas páginas 15 e 22.

SHIVASWAMY, P. K.; CHU, W.; JANSCHE, M. A support vector approach to censored targets. In: IEEE. **Seventh IEEE international conference on data mining (ICDM 2007)**. [S.l.], 2007. p. 655–660. Citado na página 27.

VAPNIK, V. N. The support vector method. In: SPRINGER. **International conference on artificial neural networks**. [S.l.], 1997. p. 261–271. Citado na página 15.

APÊNDICE

A

# RESULTADOS DE OTIMIZAÇÃO CONVEXA

## A.1 Definição de Problema de Otimização com Restrições

Seja $X \subseteq \mathbb{R}^N$ e $f, g_i : X \to \mathbb{R}$, para todo $i \in [m]$. Então, um problema de otimização com restrições tem a forma:

$$\begin{aligned} &\min_{\mathbf{x} \in X} \quad f(\mathbf{x}) \\ &\text{sujeito a:} \quad g_i(\mathbf{x}) \leqslant 0, \quad \forall i \in \{1, \ldots, m\}. \end{aligned}$$

Essa formulação geral não faz quaisquer suposições de convexidade e pode ser ampliada com restrições de igualdade. Ela é denominada problema primal, em contraste com um problema relacionado introduzido posteriormente. Denotaremos por $p^*$ o valor ótimo da função objetivo.

Para qualquer $\mathbf{x} \in X$, denotaremos por $g(\mathbf{x})$ o vetor $(g_1(\mathbf{x}), \ldots, g_m(\mathbf{x}))^\top$. Assim, as restrições podem ser escritas como $g(\mathbf{x}) \leqslant \mathbf{0}$. A qualquer problema de otimização com restrições, podemos associar uma função de Lagrange que desempenha um papel importante na análise do problema e em sua relação com outro problema de otimização relacionado.

## A.2 Definição da Função de Lagrange

A função de Lagrange, ou o Lagrangiano, associada ao problema geral de otimização com restrições definido em (B.21) é a função definida em $X \times \mathbb{R}_+$ por:

$$L(\mathbf{x}, \boldsymbol{\alpha}) = f(\mathbf{x}) + \sum_{i=1}^{m} \alpha_i g_i(\mathbf{x}), \quad \forall \mathbf{x} \in X, \forall \boldsymbol{\alpha} \geqslant 0,$$

onde as variáveis $\alpha_i$ são conhecidas como variáveis de Lagrange ou variáveis duais, com $\boldsymbol{\alpha} = (\alpha_1, \ldots, \alpha_m)^\top$.

Qualquer restrição de igualdade da forma $g(\mathbf{x}) = 0$, para uma função $g$, pode ser expressa de forma equivalente por duas desigualdades: $-g(\mathbf{x}) \leqslant 0$ e $g(\mathbf{x}) \leqslant 0$. Seja $\alpha^- \geqslant 0$ a variável de

Lagrange associada à primeira restrição e $\alpha^+ \geqslant 0$ a associada à segunda. A soma dos termos correspondentes a essas restrições na definição da função de Lagrange pode, portanto, ser escrita como $\alpha g(\mathbf{x})$, com $\alpha = (\alpha^+ - \alpha^-)$.

Assim, em geral, para uma restrição de igualdade $g(\mathbf{x}) = 0$, o Lagrangiano é acrescido de um termo $\alpha g(\mathbf{x})$, mas com $\alpha \in \mathbb{R}$ não restrito a ser não negativo. Note que, no caso de um problema de otimização convexa, as restrições de igualdade $g(\mathbf{x})$ devem ser afins, uma vez que tanto $g(\mathbf{x})$ quanto $-g(\mathbf{x})$ devem ser convexas.

## A.3 Função dual

A função dual (de Lagrange) associada ao problema de otimização com restrições é definida por

$$\forall \boldsymbol{\alpha} \geqslant 0, \quad F(\boldsymbol{\alpha}) = \inf_{\mathbf{x} \in X} L(\mathbf{x}, \boldsymbol{\alpha}) = \inf_{\mathbf{x} \in X} \left[ f(\mathbf{x}) + \sum_{i=1}^{m} \alpha_i g_i(\mathbf{x}) \right].$$

Note que $F$ é sempre côncava, uma vez que o Lagrangiano é linear em relação a $\boldsymbol{\alpha}$ e que o ínfimo preserva a concavidade. Observamos ainda que,

$$\forall \boldsymbol{\alpha} \geqslant 0, \quad F(\boldsymbol{\alpha}) \leqslant p^*, \tag{A.1}$$

pois, para qualquer $\mathbf{x}$ viável, tem-se $f(\mathbf{x}) + \sum_{i=1}^{m} \alpha_i g_i(\mathbf{x}) \leqslant f(\mathbf{x})$. A função dual conduz naturalmente ao seguinte problema de otimização.

## A.4 Problema dual

O problema dual (de otimização) associado ao problema de otimização com restrições é

$$\begin{aligned} \max_{\boldsymbol{\alpha}} \quad & F(\boldsymbol{\alpha}) \\ \text{sujeito a:} \quad & \boldsymbol{\alpha} \geqslant 0. \end{aligned}$$

O problema dual é sempre um problema de otimização convexa (como a maximização de uma função côncava). Seja $d^*$ um valor ótimo. Pela Equação A.1, a seguinte desigualdade sempre vale:

$$d^* \leqslant p^* \quad \text{(dualidade fraca).}$$

A diferença $(p^* - d^*)$ é conhecida como gap de dualidade. O caso de igualdade

$$d^* = p^* \quad \text{(dualidade forte)}$$

não vale em geral. No entanto, a dualidade forte vale quando problemas convexos satisfazem uma condição de qualificação das restrições. Denotaremos por $\text{int}(X)$ o interior do conjunto $X$.

## A.5 Teorema de Karush-Kuhn-Tucker (KKT)

Suponha que $f, g_i : X \to \mathbb{R}$, $\forall i \in [m]$, sejam convexas e diferenciáveis e que as restrições sejam qualificadas. Então, $\bar{\mathbf{x}}$ é uma solução do problema de otimização com restrições se, e somente se, existe $\bar{\boldsymbol{\alpha}} \geqslant 0$ tal que,

$$\begin{aligned}
\nabla_{\mathbf{x}} L(\bar{\mathbf{x}}, \bar{\boldsymbol{\alpha}}) &= \nabla_{\mathbf{x}} f(\bar{\mathbf{x}}) + \bar{\boldsymbol{\alpha}} \cdot \nabla_{\mathbf{x}} g(\bar{\mathbf{x}}) = 0 \\
\nabla_{\boldsymbol{\alpha}} L(\bar{\mathbf{x}}, \bar{\boldsymbol{\alpha}}) &= g(\bar{\mathbf{x}}) \leqslant 0 \\
\bar{\boldsymbol{\alpha}} \cdot g(\bar{\mathbf{x}}) &= \sum_{i=1}^{m} \bar{\alpha}_i g_i(\bar{\mathbf{x}}) = 0
\end{aligned}$$

As condições anteriores são conhecidas como condições KKT. Note que as duas últimas condições KKT são equivalentes a

$$g(\bar{\mathbf{x}}) \leqslant 0 \wedge (\forall i \in \{1, \ldots, m\},\ \bar{\boldsymbol{\alpha}}_i g_i(\bar{\mathbf{x}}) = 0).$$

Essas igualdades são conhecidas como condições de complementaridade.

ICMC USP
SÃO CARLOS