UNIVERSIDADE DE SÃO PAULO
Instituto de Ciências Matemáticas e de Computação

# Modelo de teses e dissertações em LaTeX do ICMC

**Gabriel de Jesus Pereira**

Dissertação de Mestrado do Programa Interinstitucional de Pós-Graduação em Estatística (PIPGEs)

ICMC USP
SÃO CARLOS

# RESUMO

GABRIEL, J. P. **Modelo de teses e dissertações em LaTeX do ICMC**. 2021. 33 p. Dissertação (Mestrado em Estatística – Programa Interinstitucional de Pós-Graduação em Estatística) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2021.

Este trabalho é um breve modelo para a escrita de monografias de qualificação, dissertações e teses utilizando o ambiente LaTeX, de acordo com as normas exigidas pelo Instituto de Ciências Matemáticas e de Computação (ICMC), da Universidade de São Paulo (USP). Para a confecção deste modelo foi utilizado a última versão (1.9.7) do pacote de classes *abnTeX2* que segue as normas da Associação Brasileira de Normas Técnicas. A elaboração de uma monografia, dissertação ou tese pode ser feita sobrescrevendo o conteúdo deste modelo.

**Palavras-chave:** Modelo, Monografia de qualificação, Dissertação, Tese, Latex.

# ABSTRACT

GABRIEL, J. P. **Model of theses and dissertations in LaTeX of the ICMC**. 2021. 33 p. Dissertação (Mestrado em Estatística – Programa Interinstitucional de Pós-Graduação em Estatística) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2021.

This paper is a brief model for writing qualification monographs, dissertations and thesis using LaTeXenvironment, in accordance with the standards required by the Institute of Mathematics and Computer Sciences (ICMC), University of São Paulo (USP). For making this model, the latest version (1.9.7) *abnTeX2* classes package was used. This package follow the rules of the Brazilian Association of Technical Standards. A drafting a monograph, dissertation or thesis can be done by overwriting the contents of this model.

**Keywords:** Template, Qualification monograph, Dissertation, Thesis, Latex.

# LISTA DE ILUSTRAÇÕES

Figura 1 – Dois hiperplanos de separação. O hiperplano à direita é aquele que maximiza a margem de separação, que é o interesse do SVM. . . . . 16
Figura 2 – Hiperplano de separação representando caso não separável. As variáveis de folga $\xi_i$ permitem que as condições de separação sejam satisfeitas e flexibilizadas. . . . . 18
Figura 3 – SVM para regressão. O objetivo é ajustar um tubo com largura $\epsilon$ aos dados, de forma que a maioria dos pontos de treinamento estejam dentro do tubo. . 21

# LISTA DE QUADROS

# LISTA DE TABELAS

# SUMÁRIO


1 INTRODUÇÃO . . . . . 13

2 MÁQUINAS DE VETORES DE SUPORTE . . . . . 15
2.1 Máquinas de Vetores de Suporte para Classificação (SVM) . . . . . 15
*2.1.1 Caso não separável* . . . . . *17*
2.2 Máquinas de Vetores de Suporte para Regressão (SVR) . . . . . 21
*2.2.1 Máquinas de Vetores de Suporte para Ranking* . . . . . *23*

3 ANÁLISE DE SOBREVIVÊNCIA . . . . . 25
3.1 Censura . . . . . 25
3.2 Funções importantes para análise de sobrevivência e suas relações . 26

REFERÊNCIAS . . . . . 29

APÊNDICE A RESULTADOS DE OTIMIZAÇÃO CONVEXA . . . . 31
A.1 Definição de Problema de Otimização com Restrições . . . . . 31
A.2 Definição da Função de Lagrange . . . . . 31
A.3 Função dual . . . . . 32
A.4 Problema dual . . . . . 32
A.5 Teorema de Karush-Kuhn-Tucker (KKT) . . . . . 33

CAPÍTULO

1

# INTRODUÇÃO

CAPÍTULO

2

# MÁQUINAS DE VETORES DE SUPORTE

Proposto por (VAPNIK, 1997), o algoritmo de Máquinas de Vetores de Suporte (SVM) permite construir fronteiras de decisão não lineares por meio da indução de um hiperplano linear em um espaço de características de alta dimensão, obtido por meio de uma transformação do espaço original. Este capítulo aborda o SVM nos contextos de classificação, regressão e ranking. A apresentação do caso de classificação tem como objetivo servir de base para os demais, uma vez que estes herdam seus principais conceitos.

## 2.1 Máquinas de Vetores de Suporte para Classificação (SVM)

O objetivo do SVM para classificação é encontrar um hiperplano que maximize a margem de separação entre as classes. Formalmente, conforme definido por Mohri, Rostamizadeh e Talwalkar (2018, p. 79), considere um espaço de covariáveis $\mathcal{X} \subseteq \mathbb{R}^{\mathrm{d}}$ e um espaço de rótulos $\mathcal{Y} = -1, +1$. Seja $f : \mathcal{X} \to \mathcal{Y}$ a função alvo desconhecida.

Dado um conjunto de hipóteses $\mathcal{H}$ de funções que mapeiam $\mathcal{X}$ em $\mathcal{Y}$, o problema de classificação binária consiste em encontrar uma hipótese $h \in \mathcal{H}$ que minimize o erro de generalização:

$$R_{\mathcal{D}}(h) = \underset{x \sim \mathcal{D}}{\mathbb{P}} [h(x) \neq f(x)],$$

em que $\mathcal{D}$ é uma distribuição desconhecida sobre $\mathcal{X}$.

Para isso, o modelo recebe um conjunto de treinamento $S = ((x_1, y_1), \ldots, (x_{\mathrm{m}}, y_{\mathrm{m}})) \in (\mathcal{X} \times \mathcal{Y})^{\mathrm{m}}$ composto por $m$ observações i.i.d. de $\mathcal{X} \times \mathcal{Y}$, geradas segundo a distribuição $\mathcal{D}$, tais que $y_{\mathrm{i}} = f(x_{\mathrm{i}})$. Um conjunto de hipóteses natural é um hiperplano, definido da seguinte forma:

$$\mathcal{H} = \{\mathbf{x} \mapsto \operatorname{sgn}(\mathbf{w} \cdot \mathbf{x} + \mathrm{b}) : \mathbf{w} \in \mathbb{R}^{\mathrm{d}}, \mathrm{b} \in \mathbb{R}\}$$

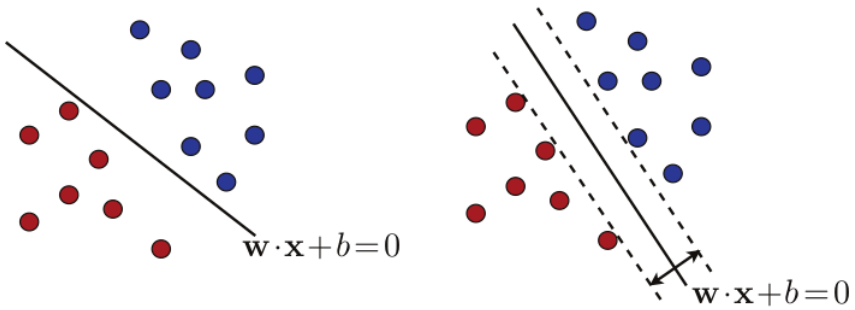


Figura 1 – Dois hiperplanos de separação. O hiperplano à direita é aquele que maximiza a margem de separação, que é o interesse do SVM.

em que $\mathbf{w}\cdot\mathbf{x}+\mathrm{b}=0$ é a equação de um hiperplano em $\mathbb{R}^{\mathrm{d}}$, com $\mathbf{w}\in\mathbb{R}^{\mathrm{d}}$ um vetor normal não nulo ao hiperplano e $\mathrm{b}\in\mathbb{R}$ um escalar. Dessa forma, a hipótese $\mathbf{x}\mapsto\operatorname{sgn}(\mathbf{w}\cdot\mathbf{x}+\mathrm{b})$ define a regra de classificação

$$h(\mathbf{x})=\operatorname{sgn}(\mathbf{w}\cdot\mathbf{x}+\mathrm{b})$$

como ilustrado na Figura 1.

Observe que, na Figura 1, podem existir infinitos hiperplanos que separam as classes. No entanto, conforme discutido anteriormente, a solução do SVM baseia-se na escolha do hiperplano que maximiza a margem geométrica entre as classes.

A margem geométrica $\rho_h(\mathbf{x})$ de um classificador $h:\mathbf{x}\mapsto\operatorname{sgn}(\mathbf{w}\cdot\mathbf{x}+\mathrm{b})$, em um ponto $\mathbf{x}$, é definida como a sua distância Euclidiana ao hiperplano $\mathbf{w}\cdot\mathbf{x}+\mathrm{b}=0$:

$$\rho_h(x)=\frac{|\mathbf{w}\cdot\mathbf{x}+\mathrm{b}|}{\|\mathbf{w}\|_2}.$$

Como a margem deve ser garantida para todas as observações, para uma amostra $S=(\mathbf{x}_1,\ldots,\mathbf{x}_{\mathrm{m}})$, define-se a margem geométrica do classificador $h$ como o menor valor entre as margens dos pontos da amostra valor entre as margens dos pontos da amostra, isto é,

$$\rho_h=\min_{\mathrm{i}\in[m]}\rho_h(\mathbf{x}_{\mathrm{i}}),$$

que corresponde aos pontos da amostra mais próximos ao hiperplano.

Dessa forma, a margem geométrica a ser maximizada é aquela definida por

$$\rho=\max_{\mathbf{w},\mathrm{b}:y_{\mathrm{i}}(\mathbf{w}\cdot\mathbf{x}_{\mathrm{i}}+\mathrm{b})\geqslant 0}\min_{\mathrm{i}\in[m]}\frac{|\mathbf{w}\cdot\mathbf{x}_{\mathrm{i}}+\mathrm{b}|}{\|\mathbf{w}\|}=\max_{\mathbf{w},\mathrm{b}}\min_{\mathrm{i}\in[m]}\frac{y_{\mathrm{i}}(\mathbf{w}\cdot\mathbf{x}_{\mathrm{i}}+\mathrm{b})}{\|\mathbf{w}\|}.$$

Note que, para o caso em que os dados estejam sendo corretamente classificados e a margem esteja sendo maximizada para os pares $(\mathbf{w},\mathrm{b})$, temos que $|\mathbf{w}\cdot\mathbf{x}_{\mathrm{i}}+\mathrm{b}|\geqslant 0$ e, dessa forma $y_{\mathrm{i}}(\mathbf{w}\cdot\mathbf{x}_{\mathrm{i}}+\mathrm{b})\geqslant 0$. Essa relação explica a segunda igualdade da expressão acima. Além

disso, observe que para a última expressão é invariante para qualquer multiplicador de escalar positivo de $(\mathbf{w}, b)$. Assim, pode-se restringir a busca por $(\mathbf{w}, b)$ para aqueles que satisfazem $\min_{i\in[m]} y_i(\mathbf{w}\cdot\mathbf{x}_i + b) = 1$. Dessa forma:

$$\rho = \max_{\mathbf{w},b:\min_{i\in[m]} y_i(\mathbf{w}\cdot\mathbf{x}_i+b)=1} \frac{1}{\|\mathbf{w}\|} = \max_{\mathbf{w},b:\forall i\in[m], y_i(\mathbf{w}\cdot\mathbf{x}_i+b)\geqslant 1} \frac{1}{\|\mathbf{w}\|}.$$

Como maximizar $\frac{1}{\|\mathbf{w}\|}$ é o mesmo que minimizar $\frac{1}{2}\|\mathbf{w}\|^2$, o par $(\mathbf{w}, b)$ retornado pelo SVM, para o caso em que os dados são linearmente separáveis, é a solução do seguinte problema de otimização convexa:

$$\begin{aligned} \min_{\mathbf{w},b} \quad & \frac{1}{2}\|\mathbf{w}\|^2 \\ \text{sujeito a:} \quad & y_i(\mathbf{w}\cdot\mathbf{x}_i + b) \geqslant 1, \forall i \in [m]. \end{aligned} \tag{2.1}$$

A função objetivo $F : \mathbf{w} \mapsto \frac{1}{2}\|\mathbf{w}\|^2$ é infinitamente diferenciável, seu gradiente é $\nabla F(\mathbf{w}) = \mathbf{w}$ e a sua matriz Hessiana é $\nabla^2 F(\mathbf{w}) = \mathbf{I}$ é a matriz identidade, que é definida positiva. Portanto, $F$ é estritamente convexo, bem como a restrição $1 - y_i(\mathbf{w}\cdot\mathbf{x}_i + b)$ é convexa, pois é uma função afim. Assim, o problema de otimização definido na Equação 2.1 se trata de um problema de otimização convexa e, dessa forma, adimite solução única. Essa é uma das principais vantagens do SVM, pois a solução ótima é garantida e pode ser encontrada de forma eficiente por meio de algoritmos de otimização convexa.

O problema de otimização convexa definido na Equação 2.1 poderá ser reduzido em termos de variáveis Lagrangeanas. No entanto, isso será descrito apenas para o caso em que os dados não são separáveis, o que é o mais comum em casos reais. Este caso será descrito na seção a seguir.

### 2.1.1 Caso não separável

Para o caso em que os dados não são linearmente separáveis, tem-se que $\exists i \in [m]$ tal que $y_i(\mathbf{w}\cdot\mathbf{x}_i + b) \ngeqslant 1$, como pode ser visto na Figura 2. Nesse caso, assume-se variáveis de folga $\xi_i \geqslant 0$ de forma que as condições de separação sejam satisfeitas e flexibilizadas. Ou seja, é assumido que erros possam ocorrer. Portanto, para o caso em que os dados não são separáveis, a restrição se torna:

$$y_i(\mathbf{w}\cdot\mathbf{x}_i + b) \geqslant 1 - \xi_i.$$

A variável de folga $\xi_i$ mede o quanto o vetor $\mathbf{x}_i$ viola a restrição desejada, $y_i(\mathbf{w}\cdot\mathbf{x}_i + b) \geqslant 1$, como pode ser visto na Figura 2. Para um hiperplano $\mathbf{w}\cdot\mathbf{x} + b = 0$, um vetor $\mathbf{x}_i$ com $\xi_i > 0$ pode ser visto como sendo um outlier. Observe que na Figura 2, $\mathbf{x}_j$ para $\xi_j$ está corretamente

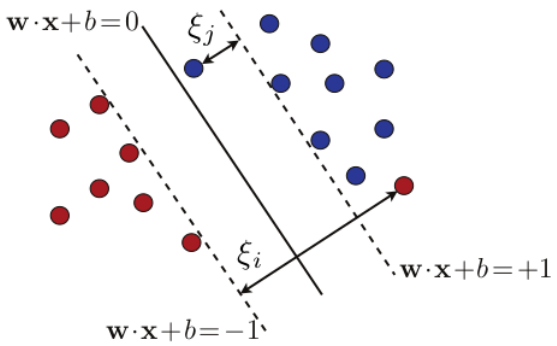


Figura 2 – Hiperplano de separação representando caso não separável. As variáveis de folga $\xi_i$ permitem que as condições de separação sejam satisfeitas e flexibilizadas.

classificado, mas a sua margem é menor do que 1, ou seja, $0 < y_j\left(\mathbf{w}\cdot\mathbf{x}_j + b\right) < 1$. Por outro lado, para $\xi_i$, tem-se que $y_i\left(\mathbf{w}\cdot\mathbf{x}_i + b\right) < 0$ e, portanto, $\xi_i > 1$, representando um erro de classificação.

Nesse contexto, tem-se um trade-off: diminuir a quantidade total de folga dos outliers, que podem ser medidos por $\sum_{i=1}^{m}\xi_i$. Por outro lado, o hiperplano a ser procurado é aquele com a maior margem possível, mas uma maior margem pode levar a uma maior quantidade de outliers e assim a maior folga. Dessa forma, para o caso não linear, tem-se o seguinte problema de otimização:

$$\begin{aligned} \min_{\mathbf{w},b,\boldsymbol{\xi}} \quad & \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{m}\xi_i \\ \text{sujeito a:} \quad & y_i\left(\mathbf{w}\cdot\mathbf{x}_i + b\right) \geqslant 1 - \xi_i, \forall i \in [m], \\ & \xi_i \geqslant 0, \forall i \in [m]. \end{aligned} \tag{2.2}$$

em que $C > 0$ é um hiperparâmetro de regularização que controla o trade-off entre a maximização da margem e a quantidade total de folga dos outliers. Como no caso separável, o problema de otimização definido na Equação 2.2 é um problema de otimização convexa, pois a função objetivo é convexa e as restrições são funções afim e, portanto, convexas. Tem-se que o problema de otimização da Equação 2.2 pode ser reduzido em termos de variáveis Lagrangeanas $\alpha_i \geqslant 0$, $i \in [m]$, associado às $m$ restrições (veja a Seção A.2 do Apêndice A). Dessa forma, a função de Lagrange pode ser definida para todo $\mathbf{w} \in \mathbb{R}^N$, $b \in \mathbb{R}$ e $\boldsymbol{\alpha} \in \mathbb{R}_+^m$ por:

$$L\left(\mathbf{w}, b, \boldsymbol{\alpha}\right) = \frac{1}{2}\|\mathbf{w}\|^2 - \sum_{i=1}^{m}\alpha_i\left[y_i\left(\mathbf{w}\cdot\mathbf{x}_i + b\right) - 1\right]. \tag{2.3}$$

As condições de otimalidade de KKT podem ser obtidas ao igualar o gradiente de L a

zero em relação as variáveis primais $\mathbf{w}$ e $b$ e ao escrever o complementar das condições:

$$\nabla_{\mathbf{w}} L = \mathbf{w} - \sum_{i=1}^{m} \alpha_i y_i \mathbf{x}_i = 0 \qquad \Longrightarrow \qquad \mathbf{w} = \sum_{i=1}^{m} \alpha_i y_i \mathbf{x}_i \tag{2.4}$$

$$\nabla_{b} L = -\sum_{i=1}^{m} \alpha_i y_i = 0 \qquad \Longrightarrow \qquad \sum_{i=1}^{m} \alpha_i y_i = 0 \tag{2.5}$$

$$\forall i,\ \alpha_i \left[ y_i (\mathbf{w} \cdot \mathbf{x}_i + b) - 1 \right] = 0 \qquad \Longrightarrow \qquad \alpha_i = 0 \vee y_i (\mathbf{w} \cdot \mathbf{x}_i + b) = 1 \tag{2.6}$$

Pela equação 2.4, tem-se que o vetor de pesos $\mathbf{w}$ para a solução do SVM é uma combinação linear dos conjuntos de treinamento $\mathbf{x}_1, \ldots, \mathbf{x}_m$. O vetor $\mathbf{x}_i$ só vai aparecer na expansão se $\alpha_i \neq 0$, então $y_i (\mathbf{w} \cdot \mathbf{x}_i + b) = 1$. Portanto, os vetores de suporte se referem àqueles vetores $\mathbf{x}_i$ estão sobre os hiperplanos marginais $\mathbf{w} \cdot \mathbf{x}_i + b = \pm 1$. Isso motiva o nome do algoritmo. Observando a Equação 2.4, se os vetores não estiverem sobre os hiperplanos marginais, a solução do SVM não se altera. No entanto, embora a solução do $\mathbf{w}$ seja única, a solução dos vetores de suporte não são únicas. Isso acontece pois na dimensão $N$, são suficientes $N+1$ para definir um hiperplano. Assim, quando mais de $N+1$ pontos estão sobre o hiperplano, diferentes escolhas são possíveis para $N+1$ vetores de suporte.

Para derivar a forma dual (Veja a Seção A.3 do Apêndice A), tem-se que

$$\begin{aligned} L &= \underbrace{\frac{1}{2} \| \sum_{i=1}^{m} \alpha_i y_i \mathbf{x}_i \|^2 - \sum_{i,j=1}^{m} \alpha_i \alpha_j y_i y_j \left( \mathbf{x}_i \cdot \mathbf{x}_j \right)}_{-\frac{1}{2} \sum_{i,j=1}^{m} \alpha_i \alpha_j y_i y_j \left( \mathbf{x}_i \cdot \mathbf{x}_j \right)} + \sum_{i=1}^{m} \alpha_i - \underbrace{b \sum_{i=1}^{m} \alpha_i y_i}_{0} \\ L &= \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i,j=1}^{m} \alpha_i \alpha_j y_i y_j \left( \mathbf{x}_i \cdot \mathbf{x}_j \right). \end{aligned} \tag{2.7}$$

Assim, o problema de otimização dual do SVM é definido por (Veja a Seção A.4 do Apêndice A):

$$\begin{aligned} \max_{\boldsymbol{\alpha}} \quad & \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i,j=1}^{m} \alpha_i \alpha_j y_i y_j \left( \mathbf{x}_i \cdot \mathbf{x}_j \right) \\ \text{sujeito a:} \quad & \sum_{i=1}^{m} \alpha_i y_i = 0, \\ & \alpha_i \geqslant 0, \forall i \in [m]. \end{aligned} \tag{2.8}$$

A função objetivo $G : \boldsymbol{\alpha} \mapsto \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i,j=1}^{m} \alpha_i \alpha_j y_i y_j \left( \mathbf{x}_i \cdot \mathbf{x}_j \right)$ é infinitamente diferenciável, seu gradiente é dado por $\nabla G(\boldsymbol{\alpha}) = \mathbf{1} - \mathbf{Q}\boldsymbol{\alpha}$, em que $\mathbf{1}$ é um vetor de uns e $\mathbf{Q}$ é a matriz de Gram definida por $Q_{ij} = y_i y_j \left( \mathbf{x}_i \cdot \mathbf{x}_j \right)$, e a sua matriz Hessiana é dada por $\nabla^2 G(\boldsymbol{\alpha}) = -\mathbf{Q}$, que é uma matriz semidefinida negativa. Portanto, $G$ é uma função côncava e o problema de otimização

dual do SVM é um problema de otimização convexa. Além disso, como as restrições são funções afim, as condições estão qualificadas e, portanto, a dualidade forte é garantida. Assim, a solução do problema dual e primal (definido na Equação 2.2) são equivalentes. Dessa forma, a hipótese $h$ retornada pelo SVM é dada por:

$$h(\mathbf{x}) = \operatorname{sgn}(\mathbf{w} \cdot \mathbf{x} + b) = \operatorname{sgn}\left(\sum_{i=1}^{m} \alpha_i y_i (\mathbf{x}_i \cdot \mathbf{x})\right) \tag{2.9}$$

Além disso, como os vetores de suporte estão localizados sobre os hiperplanos marginais, para qualquer vetor de suporte $\mathbf{x}_i$ tem-se que $\mathbf{w} \cdot \mathbf{x}_i + b = y_i$. Dessa forma, o termo de bias $b$ pode ser obtido a partir de:

$$b = y_i - \sum_{j=1}^{m} \alpha_j y_j (\mathbf{x}_j \cdot \mathbf{x}_i). \tag{2.10}$$

As expressões obtidas para $\mathbf{w}$ e $b$, juntamente com o problema dual, evidenciam uma propriedade fundamental das Máquinas de Vetores de Suporte: a solução do classificador depende apenas de produtos internos entre observações, e não diretamente dos vetores em si. Essa característica é central para a extensão do método a casos não lineares por meio do uso de funções de kernel.

A Equação (2.10) também permite obter uma expressão alternativa para a margem geométrica em função dos multiplicadores de Lagrange. Como a igualdade é válida para todo índice $i$ tal que $\alpha_i > 0$, multiplicando ambos os lados por $\alpha_i y_i$ e somando sobre $i$, obtém-se:

$$\sum_{i=1}^{m} \alpha_i y_i^2 - \sum_{i=1}^{m} \alpha_i y_i b = \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j). \tag{2.11}$$

Utilizando o fato de que $y_i^2 = 1$ e a condição $\sum_{i=1}^{m} \alpha_i y_i = 0$, segue que:

$$\sum_{i=1}^{m} \alpha_i = \|\mathbf{w}\|^2. \tag{2.12}$$

Como a margem geométrica é dada por $\rho = \frac{1}{\|\mathbf{w}\|}$, pode-se reescrevê-la em termos dos multiplicadores de Lagrange como:

$$\rho^2 = \frac{1}{\|\mathbf{w}\|^2} = \frac{1}{\sum_{i=1}^{m} \alpha_i} = \frac{1}{\|\boldsymbol{\alpha}\|_1}. \tag{2.13}$$

Essa relação mostra que a margem geométrica pode ser interpretada diretamente em função da norma $\ell_1$ do vetor $\boldsymbol{\alpha}$, reforçando a interpretação de que a solução do SVM é determinada essencialmente pelos vetores de suporte.

Por fim, esta é a formulação para o SVM para classificação. Com base nesses conceitos, na próxima seção será apresentada a formulação do SVM para regressão, que é uma extensão natural do caso de classificação.

## 2.2 Máquinas de Vetores de Suporte para Regressão (SVR)

Para o caso em que o SVM está sendo utilizado para regressão, o objetivo ajustar um tubo com largura $\epsilon$ aos dados, de forma que a maioria dos pontos de treinamento estejam dentro do tubo, como pode ser visto na Figura 3. Como no caso de classificação binária, dois conjuntos de pontos são definidos, aqueles que estão dentro do tubo, que são $\epsilon$ próximos da função predita e portanto não são penalizados, e aqueles que estão fora do tubo, que são penalizados de acordo com a função predita.

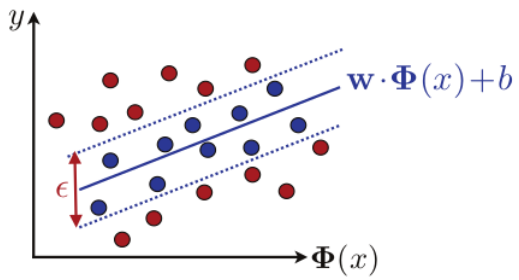


Figura 3 – SVM para regressão. O objetivo é ajustar um tubo com largura $\epsilon$ aos dados, de forma que a maioria dos pontos de treinamento estejam dentro do tubo.

Formalmente, seja $H = x \mapsto \mathbf{w}\cdot\Phi(x)+b : \mathbf{w}\in\mathbb{R}^N, b\in\mathbb{R}$, em que $\Phi$ é uma função de mapeamento associada a um kernel definido positivo (PDS) $K$. Considerando esse conjunto de hipóteses lineares no espaço de características, o problema de otimização do SVR pode ser formulado como:

$$\min_{\mathbf{w},b} \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{m} |y_i - (\mathbf{w}\cdot\Phi(x_i)+b)|_\epsilon, \tag{2.14}$$

em que $|\cdot|_\varepsilon$ denota a perda $\varepsilon$-insensível, definida por:

$$\forall y, y' \in \mathcal{Y}, \quad |y-y'|_\epsilon = \max\{0, |y-y'|-\epsilon\}. \tag{2.15}$$

O uso dessa função de perda conduz a soluções esparsas, caracterizadas por um número relativamente pequeno de vetores de suporte. Introduzindo variáveis de folga $\xi_i \geqslant 0$ e $\xi_i' \geqslant 0$, para todo $i\in[m]$, o problema de otimização pode ser reescrito de forma equivalente como

$$\begin{aligned} \min_{\mathbf{w},b,\boldsymbol{\xi},\boldsymbol{\xi}'} \quad & \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{m}(\xi_i+\xi_i') \\ \text{sujeito a:} \quad & \mathbf{w}\cdot\Phi(x_i)+b-y_i \leqslant \epsilon+\xi_i, \\ & y_i-\mathbf{w}\cdot\Phi(x_i)-b \leqslant \epsilon+\xi_i', \\ & \xi_i \geqslant 0, \xi_i' \geqslant 0, \forall i\in[m] \end{aligned} \tag{2.16}$$

Da mesma forma que foi feita para o caso de classificação, é possível derivar a forma dual do problema de otimização. Dessa forma, introduzindo os multiplicadores de Lagrange e aplicando as condições de otimalidade de KKT, tem-se o problema de otimização dual definido por:

$$\begin{aligned} \max_{\alpha,\alpha'} \quad & \varepsilon \sum_{i=1}^{m} (\alpha_i + \alpha_i') - \sum_{i=1}^{m} y_i(\alpha_i' - \alpha_i) \\ & -\frac{1}{2} \sum_{i,j=1}^{m} (\alpha_i' - \alpha_i)(\alpha_j' - \alpha_j) K_{ij} \\ \text{sujeito a:} \quad & 0 \leqslant \alpha_i \leqslant C, \quad 0 \leqslant \alpha_i' \leqslant C, \\ & \sum_{i=1}^{m} (\alpha_i' - \alpha_i) = 0. \end{aligned} \tag{2.17}$$

em que $K_{ij}$ é um kernel definido positivo, associado à função de mapeamento $\Phi$ definido por:

$$K_{ij} = K\left(x_i, x_j\right) = \Phi\left(x_i\right) \cdot \Phi\left(x_j\right). \tag{2.18}$$

Portanto, a hipótese $h$ retornada pelo SVR é dada por:

$$\forall x \in X, \quad h(x) = \sum_{i=1}^{m} (\alpha_i' - \alpha_i) K(\mathbf{x}_i, \mathbf{x}) + b \tag{2.19}$$

em que $b$ pode ser obtido a partir de um ponto $x_j$ com $0 < \alpha_j < C$ por:

$$b = -\sum_{i=1}^{m} (\alpha_i' - \alpha_i) K(x_i, x_j) + y_j + \epsilon, \tag{2.20}$$

ou de um ponto $x_j$ com $0 < \alpha_j' < C$ por:

$$b = -\sum_{i=1}^{m} (\alpha_i' - \alpha_i) K(x_i, x_j) + y_j - \epsilon. \tag{2.21}$$

Pelas condições complementares, para todo $i \in [m]$, valem as seguintes desigualdades:

$$\alpha_i \left(\mathbf{w} \cdot \Phi\left(x_i\right) + b - y_i - \epsilon - \xi_i\right) = 0 \tag{2.22}$$

$$\alpha_i' \left(y_i - \mathbf{w} \cdot \Phi\left(x_i\right) - b - \epsilon - \xi_i'\right) = 0 \tag{2.23}$$

Dessa forma, perceba que se $\alpha_i \neq 0$ or $\alpha_i' \neq 0$, então $x_i$ é um vetor de suporte e vale $\mathbf{w} \cdot \Phi\left(x_i\right) + b - y_i - \epsilon = \xi_i$ ou $y_i - \mathbf{w} \cdot \Phi\left(x_i\right) - b - \epsilon = \xi_i'$. Além disso, observa-se que, para cada observação $\mathbf{x}_i$, no máximo um dos multiplicadores de Lagrange $\alpha_i$ ou $\alpha_i'$ pode ser estritamente positivo, uma vez que a predição do modelo não pode simultaneamente superestimar e subestimar o valor real além da margem $\epsilon$.

Por outro lado, para os pontos que se encontram no interior do tubo $\epsilon$, isto é, aqueles para os quais $|y_i - (\mathbf{w} \cdot \Phi(x_i) + b)| \leqslant \epsilon$, tem-se que $\alpha_i = \alpha_i' = 0$. Consequentemente, tais observações não contribuem para a construção da hipótese final obtida pelo SVR. Dessa forma, apenas os pontos localizados fora do tubo $\epsilon$, isto é, aqueles associados a violações da margem, influenciam diretamente a solução do modelo, caracterizando-os como vetores de suporte. Em particular, quando uma parcela significativa das observações está contida no interior do tubo, a solução obtida tende a ser esparsa.

Por fim, o parâmetro $\epsilon$ desempenha um papel fundamental nesse contexto, estabelecendo um trade-off entre esparsidade e precisão. Valores maiores de $\epsilon$ permitem que mais pontos sejam considerados adequadamente ajustados dentro do tubo, reduzindo o número de vetores de suporte e, consequentemente, tornando a solução mais esparsa, ao custo potencial de uma menor capacidade de ajuste aos dados.

O algoritmo do SVR tem diversos tipos de vantagens. Ele permite a utilização de kernels, o que permite estender o método a casos não lineares, além de admitir propriedades de estabilidade (Veja Mohri, Rostamizadeh e Talwalkar (2018, p. 339–340)). Algumas de suas desvantagens é ter que encontrar dois hiperparâmetros, $C$ e $\epsilon$, que podem ser encontrados por validação cruzada, mas requer um conjunto de validação relativamente grande. Outra disvantagem é que o SVR pode ser custoso computacionalmente caso esteja sendo utilizado um conjunto de treinamento muito grande.

### 2.2.1 Máquinas de Vetores de Suporte para Ranking

Nesta seção, considera-se o problema de aprendizado de ranking sob a perspectiva de comparações pareadas, no qual o objetivo é aprender uma função capaz de ordenar elementos a partir de preferências relativas. Diferentemente do problema de classificação, em que se predizem rótulos absolutos, no contexto de ranking busca-se modelar relações do tipo "$x_i$ é preferível a $x_i'$", o que pode ser formalizado por meio de pares ordenados de observações.

Seja $\mathcal{X}$ o espaço de entrada e considere um conjunto de treinamento composto por pares $(x_i, x_i')$, $i \in [m]$, juntamente com rótulos $y_i \in \{-1, +1\}$ indicando a preferência relativa entre os elementos do par. O objetivo é encontrar uma função de pontuação $f : \mathcal{X} \to \mathbb{R}$ tal que

$$y_i\big(f(x_i') - f(x_i)\big) > 0,$$

isto é, que respeite a ordenação observada nos dados.

Assumindo uma parametrização linear no espaço de características, $f(x) = \mathbf{w} \cdot \Phi(x)$, com $\Phi : \mathcal{X} \to \mathcal{H}$ sendo um mapeamento associado a um kernel definido positivo, a condição acima pode ser reescrita como:

$$y_i \mathbf{w} \cdot \big(\Phi(x_i') - \Phi(x_i)\big) > 0.$$

Com base em garantias teóricas de generalização, pode-se construir um algoritmo que busca simultaneamente minimizar a complexidade do modelo e penalizar violações dessa condição. Introduzindo variáveis de folga $\xi_i \geqslant 0$, o problema de otimização pode ser formulado como:

$$\begin{aligned} \min_{\mathbf{w},\boldsymbol{\xi}} \quad & \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{m} \xi_i \\ \text{sujeito a:} \quad & y_i\,\mathbf{w}\cdot\big(\Phi(x_i') - \Phi(x_i)\big) \geqslant 1 - \xi_i, \\ & \xi_i \geqslant 0, \quad \forall i \in [m]. \end{aligned} \tag{2.24}$$

Observa-se que esse problema coincide formalmente com o problema primal do SVM para classificação, ao se considerar um novo mapeamento de características $\Psi : \mathcal{X} \times \mathcal{X} \to \mathcal{H}$ definido por:

$$\Psi(x, x') = \Phi(x') - \Phi(x).$$

Dessa forma, o problema de ranking pode ser interpretado como um problema de classificação binária no espaço de pares, no qual as instâncias são diferenças entre representações no espaço de características. Consequentemente, todas as propriedades previamente estabelecidas para o SVM, incluindo convexidade, existência de solução única e possibilidade de uso de kernels, permanecem válidas neste contexto.

Em particular, a formulação dual do problema pode ser expressa em termos de uma matriz de kernel induzida pelos pares de entrada. Seja $K$ o kernel associado a $\Phi$. Define-se então um novo kernel $K'$ sobre pares por:

$$K'_{ij} = K(x_i, x_j) + K(x_i', x_j') - K(x_i', x_j) - K(x_i, x_j'), \tag{2.25}$$

para todo $i, j \in [m]$. Essa construção permite que o algoritmo opere inteiramente em termos de produtos internos, preservando o chamado *truque do kernel*.

Do ponto de vista prático, essa abordagem fornece uma solução eficaz para problemas de ranking pareado (pairwise ranking), sendo amplamente utilizada em aplicações como recuperação de informação e sistemas de recomendação. Além disso, a formulação pode ser naturalmente estendida para cenários mais gerais, incluindo casos em que os rótulos pertencem ao conjunto $\{-1, 0, +1\}$, permitindo modelar situações de indiferença entre pares.

CAPÍTULO

3

# ANÁLISE DE SOBREVIVÊNCIA

Em muitos cenários do mundo real, compreender se um evento irá ocorrer é uma tarefa importante. No entanto, compreender quando esse evento ocorrerá pode ser ainda mais informativo. Considere, por exemplo, um paciente com uma doença crônica. Profissionais da saúde frequentemente estão interessados não apenas na eficácia de um tratamento, mas também no tempo esperado de sobrevivência do paciente sob diferentes estratégias terapêuticas. De maneira análoga, no setor financeiro, instituições podem buscar modelar o tempo até que um cliente entre em inadimplência, com o objetivo de gerenciar de forma mais eficiente a exposição ao risco. De forma semelhante, empresas frequentemente se preocupam com o fenômeno de churn, isto é, o tempo até que um cliente deixe de utilizar um serviço ou cancele uma assinatura. Antecipar esse momento permite a implementação de estratégias direcionadas de retenção, contribuindo para a melhoria da lucratividade no longo prazo. Esses exemplos ilustram a ubiquidade de problemas em que o tempo até a ocorrência de um evento é a principal variável de interesse. Nesse contexto, a análise de sobrevivência tem como objetivo modelar o tempo até a ocorrência de um evento, especialmente na presença de observações incompletas.

## 3.1 Censura

A principal característica que distingue a análise de sobrevivência de outras áreas da estatística é a presença de censura. Em termos gerais, a censura ocorre quando o tempo exato de ocorrência do evento de interesse não é observado para todos os indivíduos da amostra. Assim, enquanto para alguns indivíduos o evento é observado, para outros apenas se dispõe de informação parcial sobre o tempo de ocorrência, caracterizando observações censuradas (CLARK *et al.*, 2003).

No contexto da análise de sobrevivência, a censura pode ser classificada em três tipos principais: à direita, à esquerda e intervalar. A censura à direita ocorre quando o evento de interesse não é observado até o final do período de acompanhamento, seja porque o indivíduo

deixa o estudo precocemente, seja porque o estudo se encerra antes da ocorrência do evento. A censura à esquerda ocorre quando o evento já ocorreu antes do início do período de observação, mas seu tempo exato é desconhecido. Por fim, a censura intervalar ocorre quando se sabe que o evento ocorreu entre dois instantes de observação, mas não se conhece o momento exato.

Neste trabalho, será dada ênfase aos casos de censura à esquerda e à direita. Formalmente, uma observação censurada pode ser representada por $(\mathbf{x}_i, l_i, u_i)$, para $i = 1, \ldots, m$, em que $\mathbf{x}_i$ denota o vetor de covariáveis, $l_i$ o limite inferior e $u_i$ o limite superior do intervalo no qual o evento ocorreu. Em particular, a censura à direita e à esquerda podem ser representadas, respectivamente, por $(\mathbf{x}_i, l_i, +\infty)$ e $(\mathbf{x}_i, -\infty, u_i)$.

No caso de observações não censuradas, tem-se $l_i = u_i = y_i$, de modo que a observação pode ser representada por $(\mathbf{x}_i, y_i)$, em que $y_i$ corresponde ao tempo de sobrevivência observado.

## 3.2 Funções importantes para análise de sobrevivência e suas relações

Os métodos de análise de sobrevivência dependem da distribuição de sobrevivência e, as principais formas para sua especificação, é através da função de risco e de sobrevivência. A função de sobrevivência define a probabilidade de não experenciar o evento após um tempo $t$ e é definida como:

$$S(t) = P(T > t), \quad 0 < t < \infty. \tag{3.1}$$

Para a Equação 3.1, quando $t = 0 \implies S(0) = 1$ e, quando $t \to \infty \implies S(t) \to 0$. Além disso, a $S(t)$, como foi definido, é contínuo à direita.

A função de sobrevivência também pode ser definido em termos da função de risco, que é a taxa instantânea de falha. É a probabilidade de, dado que um indivíduo sobreviveu depois de um tempo $t$, qual a é a probabilidade de que ele falhe em um próximo pequeno intervalo de tempo, dividido pelo comprimento do intervalo. Formalmente, tem-se a sua expressão dada por:

$$h(t) = \lim_{\delta \to 0} \frac{\mathrm{P}(t < T < \mathrm{t} + \delta | T > t)}{\delta}$$

A partir das últimas duas últimas expressões, é possível obter outras representações para a distribuição de sobrevivência. Começando pelo complementar da função de sobrevivência, que é a função de distribuição acumulada, ela é dada por

$$F(t) = P(T \leqslant t) = 1 - S(t), \quad 0 < t < \infty \tag{3.2}$$

Esta função corresponde ao complementar da função de sobrevivência e, assim como esta, é contínua à direita. No contexto da análise de sobrevivência, $F(\mathrm{t})$ também pode ser interpretada

como a função de risco acumulado em termos probabilísticos, não devendo ser confundida com a função de risco acumulado definida a seguir.

A função densidade de probabilidade (f.d.p.), quando existente, é obtida como a derivada da função de distribuição acumulada, ou, equivalentemente, como o oposto da derivada da função de sobrevivência:

$$f(t) = \frac{d}{dt}F(t) = -\frac{d}{dt}S(t). \tag{3.3}$$

A função de risco pode então ser expressa em termos da função densidade e da função de sobrevivência como:

$$h(t) = \frac{f(t)}{S(t)}. \tag{3.4}$$

Essa relação mostra que a função de risco em um instante $t$ pode ser interpretada como a razão entre a densidade de ocorrência do evento nesse instante e a probabilidade de o indivíduo ter sobrevivido até $t$. Em outras palavras, trata-se de uma taxa instantânea de ocorrência condicionada à sobrevivência até o tempo considerado.

A função de risco acumulado é definida como a integral da função de risco ao longo do tempo:

$$H(t) = \int_0^t h(u)\,du. \tag{3.5}$$

Essa função desempenha um papel central na análise de sobrevivência, pois permite estabelecer uma relação direta com a função de sobrevivência. De fato, pode-se mostrar que:

$$S(t) = \exp\left(-\int_0^t h(u)\,du\right) = \exp\left(-H(t)\right). \tag{3.6}$$

Essa expressão evidencia que a função de sobrevivência pode ser completamente determinada a partir da função de risco. Tal relação é fundamental tanto do ponto de vista teórico quanto prático, uma vez que muitos modelos em análise de sobrevivência, como o modelo de riscos proporcionais, são especificados diretamente em termos da função de risco.

# REFERÊNCIAS

CLARK, T. G.; BRADBURN, M. J.; LOVE, S. B.; ALTMAN, D. G. Survival analysis part i: basic concepts and first analyses. **British journal of cancer**, Nature Publishing Group, v. 89, n. 2, p. 232–238, 2003. Citado na página 25.

MOHRI, M.; ROSTAMIZADEH, A.; TALWALKAR, A. **Foundations of machine learning**. [S.l.]: MIT press, 2018. Citado nas páginas 15 e 23.

VAPNIK, V. N. The support vector method. In: SPRINGER. **International conference on artificial neural networks**. [S.l.], 1997. p. 261–271. Citado na página 15.

APÊNDICE

A

# RESULTADOS DE OTIMIZAÇÃO CONVEXA

## A.1 Definição de Problema de Otimização com Restrições

Seja $X \subseteq \mathbb{R}^N$ e $f, g_i : X \to \mathbb{R}$, para todo $i \in [m]$. Então, um problema de otimização com restrições tem a forma:

$$\begin{aligned} &\min_{\mathbf{x} \in X} \quad f(\mathbf{x}) \\ &\text{sujeito a:} \quad g_i(\mathbf{x}) \leqslant 0, \quad \forall i \in \{1, \ldots, m\}. \end{aligned}$$

Essa formulação geral não faz quaisquer suposições de convexidade e pode ser ampliada com restrições de igualdade. Ela é denominada problema primal, em contraste com um problema relacionado introduzido posteriormente. Denotaremos por $p^*$ o valor ótimo da função objetivo.

Para qualquer $\mathbf{x} \in X$, denotaremos por $g(\mathbf{x})$ o vetor $(g_1(\mathbf{x}), \ldots, g_m(\mathbf{x}))^\top$. Assim, as restrições podem ser escritas como $g(\mathbf{x}) \leqslant \mathbf{0}$. A qualquer problema de otimização com restrições, podemos associar uma função de Lagrange que desempenha um papel importante na análise do problema e em sua relação com outro problema de otimização relacionado.

## A.2 Definição da Função de Lagrange

A função de Lagrange, ou o Lagrangiano, associada ao problema geral de otimização com restrições definido em (B.21) é a função definida em $X \times \mathbb{R}_+$ por:

$$L(\mathbf{x}, \boldsymbol{\alpha}) = f(\mathbf{x}) + \sum_{i=1}^{m} \alpha_i g_i(\mathbf{x}), \quad \forall \mathbf{x} \in X, \forall \boldsymbol{\alpha} \geqslant 0,$$

onde as variáveis $\alpha_i$ são conhecidas como variáveis de Lagrange ou variáveis duais, com $\boldsymbol{\alpha} = (\alpha_1, \ldots, \alpha_m)^\top$.

Qualquer restrição de igualdade da forma $g(\mathbf{x}) = 0$, para uma função $g$, pode ser expressa de forma equivalente por duas desigualdades: $-g(\mathbf{x}) \leqslant 0$ e $g(\mathbf{x}) \leqslant 0$. Seja $\alpha^- \geqslant 0$ a variável de

Lagrange associada à primeira restrição e $\alpha^+ \geqslant 0$ a associada à segunda. A soma dos termos correspondentes a essas restrições na definição da função de Lagrange pode, portanto, ser escrita como $\alpha g(\mathbf{x})$, com $\alpha = (\alpha^+ - \alpha^-)$.

Assim, em geral, para uma restrição de igualdade $g(\mathbf{x}) = 0$, o Lagrangiano é acrescido de um termo $\alpha g(\mathbf{x})$, mas com $\alpha \in \mathbb{R}$ não restrito a ser não negativo. Note que, no caso de um problema de otimização convexa, as restrições de igualdade $g(\mathbf{x})$ devem ser afins, uma vez que tanto $g(\mathbf{x})$ quanto $-g(\mathbf{x})$ devem ser convexas.

## A.3 Função dual

A função dual (de Lagrange) associada ao problema de otimização com restrições é definida por

$$\forall \boldsymbol{\alpha} \geqslant 0, \quad F(\boldsymbol{\alpha}) = \inf_{\mathbf{x} \in X} L(\mathbf{x}, \boldsymbol{\alpha}) = \inf_{\mathbf{x} \in X} \left[ f(\mathbf{x}) + \sum_{i=1}^{m} \alpha_i g_i(\mathbf{x}) \right].$$

Note que $F$ é sempre côncava, uma vez que o Lagrangiano é linear em relação a $\boldsymbol{\alpha}$ e que o ínfimo preserva a concavidade. Observamos ainda que,

$$\forall \boldsymbol{\alpha} \geqslant 0, \quad F(\boldsymbol{\alpha}) \leqslant p^*, \tag{A.1}$$

pois, para qualquer $\mathbf{x}$ viável, tem-se $f(\mathbf{x}) + \sum_{i=1}^{m} \alpha_i g_i(\mathbf{x}) \leqslant f(\mathbf{x})$. A função dual conduz naturalmente ao seguinte problema de otimização.

## A.4 Problema dual

O problema dual (de otimização) associado ao problema de otimização com restrições é

$$\begin{aligned} \max_{\boldsymbol{\alpha}} \quad & F(\boldsymbol{\alpha}) \\ \text{sujeito a:} \quad & \boldsymbol{\alpha} \geqslant 0. \end{aligned}$$

O problema dual é sempre um problema de otimização convexa (como a maximização de uma função côncava). Seja $d^*$ um valor ótimo. Pela Equação A.1, a seguinte desigualdade sempre vale:

$$d^* \leqslant p^* \quad \text{(dualidade fraca).}$$

A diferença $(p^* - d^*)$ é conhecida como gap de dualidade. O caso de igualdade

$$d^* = p^* \quad \text{(dualidade forte)}$$

não vale em geral. No entanto, a dualidade forte vale quando problemas convexos satisfazem uma condição de qualificação das restrições. Denotaremos por $\text{int}(X)$ o interior do conjunto $X$.

## A.5 Teorema de Karush-Kuhn-Tucker (KKT)

Suponha que $f, g_i : X \to \mathbb{R}$, $\forall i \in [m]$, sejam convexas e diferenciáveis e que as restrições sejam qualificadas. Então, $\bar{\mathbf{x}}$ é uma solução do problema de otimização com restrições se, e somente se, existe $\bar{\boldsymbol{\alpha}} \geqslant 0$ tal que,

$$\begin{aligned}
\nabla_{\mathbf{x}} L(\bar{\mathbf{x}}, \bar{\boldsymbol{\alpha}}) &= \nabla_{\mathbf{x}} f(\bar{\mathbf{x}}) + \bar{\boldsymbol{\alpha}} \cdot \nabla_{\mathbf{x}} g(\bar{\mathbf{x}}) = 0 \\
\nabla_{\boldsymbol{\alpha}} L(\bar{\mathbf{x}}, \bar{\boldsymbol{\alpha}}) &= g(\bar{\mathbf{x}}) \leqslant 0 \\
\bar{\boldsymbol{\alpha}} \cdot g(\bar{\mathbf{x}}) &= \sum_{i=1}^{m} \bar{\alpha}_i g_i(\bar{\mathbf{x}}) = 0
\end{aligned}$$

As condições anteriores são conhecidas como condições KKT. Note que as duas últimas condições KKT são equivalentes a

$$g(\bar{\mathbf{x}}) \leqslant 0 \wedge (\forall i \in \{1, \ldots, m\},\ \bar{\boldsymbol{\alpha}}_i g_i(\bar{\mathbf{x}}) = 0).$$

Essas igualdades são conhecidas como condições de complementaridade.

ICMC USP
SÃO CARLOS