UNIVERSIDADE DE SÃO PAULO
Instituto de Ciências Matemáticas e de Computação

Modelo de teses e dissertações em LaTeX do ICMC

Gabriel de Jesus Pereira

Dissertação de Mestrado do Programa Interinstitucional de Pós-Graduação em Estatística (PIPGEs)

ICMC USP
SÃO CARLOS

RESUMO

GABRIEL, J. P. **Modelo de teses e dissertações em LaTeX do ICMC**. 2021. 19 p. Dissertação (Mestrado em Estatística – Programa Interinstitucional de Pós-Graduação em Estatística) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2021.

Este trabalho é um breve modelo para a escrita de monografias de qualificação, dissertações e teses utilizando o ambiente LaTeX, de acordo com as normas exigidas pelo Instituto de Ciências Matemáticas e de Computação (ICMC), da Universidade de São Paulo (USP). Para a confecção deste modelo foi utilizado a última versão (1.9.7) do pacote de classes *abnTeX2* que segue as normas da Associação Brasileira de Normas Técnicas. A elaboração de uma monografia, dissertação ou tese pode ser feita sobrescrevendo o conteúdo deste modelo.

Palavras-chave: Modelo, Monografia de qualificação, Dissertação, Tese, Latex.

ABSTRACT

GABRIEL, J. P. **Model of theses and dissertations in LaTeX of the ICMC**. 2021. 19 p. Dissertação (Mestrado em Estatística – Programa Interinstitucional de Pós-Graduação em Estatística) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2021.

This paper is a brief model for writing qualification monographs, dissertations and thesis using LaTeXenvironment, in accordance with the standards required by the Institute of Mathematics and Computer Sciences (ICMC), University of São Paulo (USP). For making this model, the latest version (1.9.7) *abnTeX2* classes package was used. This package follow the rules of the Brazilian Association of Technical Standards. A drafting a monograph, dissertation or thesis can be done by overwriting the contents of this model.

Keywords: Template, Qualification monograph, Dissertation, Thesis, Latex.

LISTA DE ILUSTRAÇÕES

Figura 1 – Dois hiperplanos de separação. O hiperplano à direita é aquele que maximiza a margem de separação. 16

LISTA DE QUADROS

LISTA DE TABELAS

SUMÁRIO

1 INTRODUÇÃO 13

2 MÁQUINAS DE VETORES DE SUPORTE 15
2.1 Máquinas de Vetores de Suporte para Classificação 15

3 ANÁLISE DE SOBREVIVÊNCIA 17
3.1 Characteristics of Survival Data 17

REFERÊNCIAS 19

CAPÍTULO

1

INTRODUÇÃO

CAPÍTULO

2

MÁQUINAS DE VETORES DE SUPORTE

Proposto por (VAPNIK, 1997), o algoritmo de Máquinas de Vetores de Suporte (SVM) permite construir fronteiras de decisão não lineares por meio da indução de um hiperplano linear em um espaço de características de alta dimensão, obtido por meio de uma transformação do espaço original. Este capítulo aborda o SVM nos contextos de classificação, regressão e ranking. A apresentação do caso de classificação tem como objetivo servir de base para os demais, uma vez que estes herdam seus principais conceitos. Por fim, o capítulo se restringe à descrição dos casos não separáveis.

2.1 Máquinas de Vetores de Suporte para Classificação

O objetivo do SVM para classificação é encontrar um hiperplano que maximize a margem de separação entre as classes. Formalmente, conforme definido por Mohri, Rostamizadeh e Talwalkar (2018, p. 79), considere um espaço de covariáveis $\mathcal{X} \subseteq \mathbb{R}^{\mathrm{d}}$ e um espaço de rótulos $\mathcal{Y} = -1, +1$. Seja $f : \mathcal{X} \to \mathcal{Y}$ a função alvo desconhecida.

Dado um conjunto de hipóteses $\mathcal{H}$ de funções que mapeiam $\mathcal{X}$ em $\mathcal{Y}$, o problema de classificação binária consiste em encontrar uma hipótese $h \in \mathcal{H}$ que minimize o erro de generalização:

$$R_{\mathcal{D}}(h) = \mathop{\mathbb{P}}_{x \sim \mathcal{D}} [h(x) \neq f(x)],$$

em que $\mathcal{D}$ é uma distribuição desconhecida sobre $\mathcal{X}$.

Para isso, o modelo recebe um conjunto de treinamento $S = ((x_1, y_1), \ldots, (x_{\mathrm{m}}, y_{\mathrm{m}})) \in (\mathcal{X} \times \mathcal{Y})^{\mathrm{m}}$ composto por m observações i.i.d. de $\mathcal{X} \times \mathcal{Y}$, geradas segundo a distribuição $\mathcal{D}$, tais que $y_{\mathrm{i}} = f(x_{\mathrm{i}})$. Um conjunto de hipóteses natural é um hiperplano, definido da seguinte forma:

$$\mathcal{H} = \{\mathbf{x} \mapsto \operatorname{sgn}(\mathbf{w} \cdot \mathbf{x} + \mathrm{b}) : \mathbf{w} \in \mathbb{R}^{\mathrm{d}}, \mathrm{b} \in \mathbb{R}\}$$

Figura 1 – Dois hiperplanos de separação. O hiperplano à direita é aquele que maximiza a margem de separação.

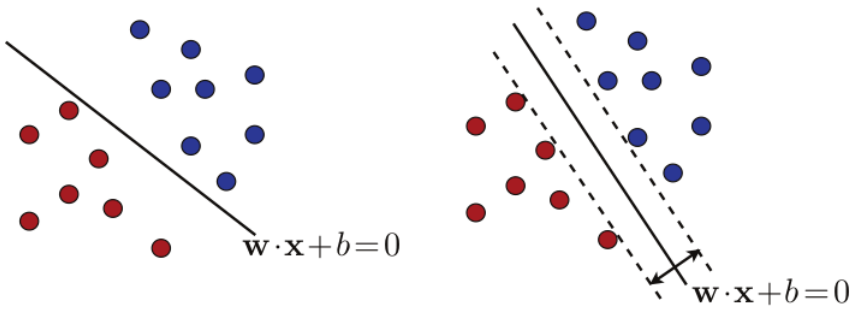

Fonte: Mohri, Rostamizadeh e Talwalkar (2018, p. 80)

em que $\mathbf{w}\cdot\mathbf{x}+\mathrm{b}=0$ é a equação de um hiperplano em $\mathbb{R}^{\mathrm{d}}$, com $\mathbf{w}\in\mathbb{R}^{\mathrm{d}}$ um vetor normal não nulo ao hiperplano e $\mathrm{b}\in\mathbb{R}$ um escalar. Dessa forma, a hipótese $\mathbf{x}\mapsto\mathrm{sgn}(\mathbf{w}\cdot\mathbf{x}+\mathrm{b})$ define a regra de classificação

$$h(\mathbf{x})=\mathrm{sgn}(\mathbf{w}\cdot\mathbf{x}+\mathrm{b})$$

como ilustrado na Figura 1.

Observe que, na Figura 1, podem existir infinitos hiperplanos que separam as classes. No entanto, conforme discutido anteriormente, a solução do SVM baseia-se na escolha do hiperplano que maximiza a margem geométrica entre as classes.

A margem geométrica $\rho_h(\mathbf{x})$ de um classificador $h:\mathbf{x}\mapsto\mathrm{sgn}(\mathbf{w}\cdot\mathbf{x}+\mathrm{b})$, em um ponto $\mathbf{x}$, é definida como a sua distância Euclidiana ao hiperplano $\mathbf{w}\cdot\mathbf{x}+\mathrm{b}=0$:

$$\rho_h(x)=\frac{|\mathbf{w}\cdot\mathbf{x}+\mathrm{b}|}{\|\mathbf{w}\|_2}.$$

Como a margem deve ser garantida para todas as observações, para uma amostra $S=(\mathbf{x}_1,\ldots,\mathbf{x}_{\mathrm{m}})$, define-se a margem geométrica do classificador h como o menor valor entre as margens dos pontos da amostra valor entre as margens dos pontos da amostra, isto é,

$$\rho_h=\min_{\mathrm{i}\in[m]}\rho_h(\mathbf{x}_{\mathrm{i}}),$$

que corresponde aos pontos da amostra mais próximos ao hiperplano.

CAPÍTULO

3

ANÁLISE DE SOBREVIVÊNCIA

In many real-world scenarios, understanding whether an event will occur is important. Nevertheless, understanding when it will occur is even more informative. Consider, for example, a patient with a chronic disease. Clinicians are often interested not only in the effectiveness of a treatment, but also in how long the patient is expected to survive under different therapeutic strategies. Similarly, in the financial sector, institutions may aim to monitor the time until a customer defaults on a loan, seeking to better manage risk exposure. In this regard, companies are also frequently concerned with customer churn, that is, the time until a client stops using a service or cancels a subscription. Anticipating when a customer is likely to leave allows organizations to implement targeted retention strategies and improve long-term profitability. All of these examples are ubiquitous, and survival analysis is particularly concerned with modeling the time until an event of interest especialy in the presence of incomplete observations.

3.1 Characteristics of Survival Data

According to Moore *et al.* (2016, p. 2), survival data are defined by two characteristics. The first one is that the response variable is a non-negative discrete or continuous random variable, and represents the time from a well-defined origin to a well-defined event. For example, the time elapsed between the starting point of a cancer diagnosis and the occurrence of a specified event of interest (e.g., the pacient death). The second on is censoring. Censoring occurs when the exact time of the event of interest is not fully observed. When censoring does not occurs, it is said that the individual failed.

Formally, let T^* denote a random variable representing the time to failure and U is a random variable representing the time to a censoring event. Therefore, the observed survival time is denoted as $T = \min(T^*, U)$. Following the previous definition,

$$\delta = \begin{cases} 1 & \text{if } T^* < U \\ 0 & \text{if } T^* \geqslant U \end{cases}$$

denotes a censoring indicator. That is, δ is 1 if T is a failured time and 0 if T is a censored time.

REFERÊNCIAS

MOHRI, M.; ROSTAMIZADEH, A.; TALWALKAR, A. **Foundations of machine learning**. [S.l.]: MIT press, 2018. Citado nas páginas 15 e 16.

MOORE, D. F. *et al.* **Applied survival analysis using R**. [S.l.]: Springer, 2016. v. 473. Citado na página 17.

VAPNIK, V. N. The support vector method. In: SPRINGER. **International conference on artificial neural networks**. [S.l.], 1997. p. 261–271. Citado na página 15.

ICMC USP
SÃO CARLOS