

EST 5105 – Tópicos de Pesquisa I

Gabriel de Jesus Pereira

Dissertação de Mestrado do Programa Interinstitucional de
Pós-Graduação em Estatística (PIPGes)

RESUMO

GABRIEL, J. P. **EST 5105 – Tópicos de Pesquisa I**. 2021. 39 p. Dissertação (Mestrado em Estatística – Programa Interinstitucional de Pós-Graduação em Estatística) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2021.

Este artigo introduz o GG-KM, uma nova abordagem semiparamétrica para modelagem de taxa de cura no modelo de tempo de promoção. Abordamos as limitações dos preditores lineares tradicionais ao empregar Máquinas de Kernel para modelar o componente de cura dentro de um Reproducing Kernel Hilbert Space (RKHS) (MOHRI; ROSTAMIZADEH; TALWALKAR, 2018). Para fornecer máxima flexibilidade à função de risco dos indivíduos suscetíveis, incorporamos a distribuição Gama Generalizada (STACY, 1962), que engloba diversos modelos clássicos de sobrevivência. Derivamos uma estrutura de log-verossimilhança penalizada e fornecemos gradientes analíticos explícitos para a otimização conjunta dos pesos do kernel, hiperparâmetros e parâmetros da distribuição. O desempenho do modelo é validado por meio do Integrated Brier Score (IBS) com ajuste por IPCW (PRINCE *et al.*, 2025).

Palavras-chave: Análise de Sobrevivência, Censura, Reproducing Kernel Hilbert Space, Gama Generalizada, Representer Theorem.

ABSTRACT

GABRIEL, J. P. **Model of theses and dissertations in LaTeX of the ICMC**. 2021. 39 p. Dissertação (Mestrado em Estatística – Programa Interinstitucional de Pós-Graduação em Estatística) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2021.

This paper introduces GG-KM, a novel semiparametric approach to promotion time cure rate modeling. We address the limitations of traditional linear predictors by employing Kernel Machines to model the cure component within a Reproducing Kernel Hilbert Space (RKHS) (MOHRI; ROSTAMIZADEH; TALWALKAR, 2018). To provide maximum flexibility for the hazard of susceptible individuals, we incorporate the Generalized Gamma (GG) distribution (STACY, 1962), which encompasses several standard survival models. We derive a penalized log-likelihood framework and provide explicit analytical gradients for the joint optimization of kernel weights, hyperparameters, and distribution parameters. Model performance is validated through the Integrated Brier Score (IBS) with IPCW adjustment (PRINCE *et al.*, 2025).

Keywords: Survival Analysis, Censoring, Reproducing Kernel Hilbert Space, Generalized Gamma, Representer Theorem.

LISTA DE ILUSTRAÇÕES

LISTA DE TABELAS

SUMÁRIO

1	INTRODUÇÃO	11
1.1	Organização do Trabalho	12
2	RECURSOS COMPUTACIONAIS	13
2.1	Ambiente de desenvolvimento e escrita	13
2.2	Linguagem de programação e implementação dos modelos	14
2.2.1	<i>Otimização convexa</i>	14
3	FUNDAÇÕES SOBRE MÉTODOS BASEADOS EM KERNEL	15
3.1	Kernels	15
3.1.1	<i>Kernels positivos definidos</i>	16
3.1.2	<i>Espaços de Hilbert</i>	16
3.1.3	<i>Reproducing Kernel Hilbert Spaces</i>	16
4	ANÁLISE DE SOBREVIVÊNCIA	19
4.1	Censura	19
4.2	Funções importantes para análise de sobrevivência e suas relações	20
4.3	Modelo de Riscos Proporcionais de Cox	22
4.4	Modelos de Longa Duração	23
4.4.1	<i>Modelo de Tempo de Promoção</i>	24
4.4.2	<i>Extensão não paramétrica via máquinas de kernel</i>	25
4.4.3	<i>Modelagem da sobrevivência dos suscetíveis</i>	26
4.4.4	<i>Estimação e verossimilhança penalizada</i>	27
4.4.5	<i>Gradientes analíticos</i>	29
5	METODOLOGIA	31
5.1	Particionamento dos dados	31
5.2	Seleção de hiperparâmetros	32
5.3	Estudo de simulação	32
6	RESULTADOS	35
7	CONCLUSÃO	37

REFERÊNCIAS	39
-----------------------	----

INTRODUÇÃO

A análise de sobrevivência constitui um dos principais ramos da estatística aplicada voltado ao estudo do tempo até a ocorrência de um evento de interesse, como falha de um sistema, recorrência de uma doença ou morte de um indivíduo. Uma característica central desse tipo de dado é a presença de censura, isto é, situações nas quais o tempo exato do evento não é completamente observado. Esse aspecto impõe desafios metodológicos relevantes, exigindo o desenvolvimento de modelos capazes de lidar adequadamente com informações incompletas.

Tradicionalmente, modelos como o de Cox têm sido amplamente utilizados nesse contexto, devido à sua flexibilidade semiparamétrica e interpretabilidade. No entanto, tais abordagens assumem, em geral, uma estrutura linear no preditor do risco, o que pode ser inadequado em cenários nos quais a relação entre as covariáveis e o tempo de sobrevivência apresenta padrões não lineares ou de alta complexidade.

Nesse contexto, métodos de aprendizado de máquina têm ganhado destaque como alternativas promissoras. Em particular, modelos baseados em máquinas de vetores de suporte têm sido adaptados para lidar com dados censurados, dando origem ao *Support Vector Censored Regression* (SVCR). Essas abordagens permitem incorporar funções kernel, possibilitando a modelagem de relações não lineares por meio de mapeamentos implícitos para espaços de maior dimensão. A escolha adequada do kernel torna-se, portanto, um elemento central para o desempenho desses modelos.

O presente trabalho tem como objetivo investigar o desempenho de diferentes variantes do SVCR, considerando uma variedade de funções kernel, e compará-las com abordagens clássicas, como o modelo de Cox e modelos lineares. Para isso, são conduzidos experimentos tanto em dados simulados, nos quais é possível controlar a estrutura geradora, quanto em bases de dados reais amplamente utilizadas na literatura. A avaliação é realizada por meio do índice de concordância, permitindo analisar a capacidade preditiva dos modelos sob diferentes cenários de tamanho amostral e proporção de censura.

Os resultados obtidos contribuem para uma melhor compreensão das condições sob as quais métodos mais flexíveis apresentam vantagens em relação a abordagens tradicionais, bem como das limitações associadas ao aumento da complexidade do modelo.

1.1 Organização do Trabalho

Este trabalho está estruturado da seguinte forma. No Capítulo 2, são apresentados os conceitos fundamentais de análise de sobrevivência, incluindo noções de censura, funções de sobrevivência e o modelo de Cox. No Capítulo 3, são introduzidos os principais fundamentos das máquinas de vetores de suporte, com ênfase em regressão e no papel das funções kernel. O Capítulo 4 descreve a formulação do *Support Vector Censored Regression* e suas extensões, incluindo a incorporação de diferentes kernels.

No Capítulo 5, é detalhada a metodologia adotada, abrangendo o particionamento dos dados, o processo de seleção de hiperparâmetros e a geração de dados simulados. O Capítulo 6 apresenta e discute os resultados obtidos tanto em dados simulados quanto em dados reais. Por fim, o Capítulo 7 apresenta as conclusões do trabalho, bem como possíveis direções para pesquisas futuras.

RECURSOS COMPUTACIONAIS

Nesta seção, são apresentados os principais recursos computacionais utilizados no desenvolvimento deste trabalho, incluindo ferramentas para escrita do documento, linguagens de programação empregadas na implementação dos modelos e bibliotecas utilizadas na resolução dos problemas de otimização convexa. A escolha dessas ferramentas foi guiada pela necessidade de garantir rigor científico, reprodutibilidade dos experimentos e eficiência computacional na implementação dos algoritmos propostos.

2.1 Ambiente de desenvolvimento e escrita

A redação deste trabalho foi realizada utilizando o sistema de preparação de documentos $\text{\LaTeX}$, amplamente adotado na comunidade científica devido à sua capacidade de lidar de forma robusta com expressões matemáticas, referências bibliográficas e formatação de documentos técnicos. O uso do $\text{\LaTeX}$ foi particularmente importante neste trabalho, dado o elevado número de equações e demonstrações envolvidas na formulação dos modelos baseados em máquinas de vetores de suporte.

Para a edição do código-fonte e do documento, foi utilizado o editor Visual Studio Code (VSCode), que oferece um ambiente leve e altamente configurável. O VSCode permite integração com diversas extensões, possibilitando suporte eficiente tanto para a escrita em $\text{\LaTeX}$ quanto para o desenvolvimento em linguagens de programação como Python. Entre as funcionalidades utilizadas, destacam-se a navegação facilitada entre arquivos, realce de sintaxe, execução de scripts e integração com sistemas de controle de versão.

2.2 Linguagem de programação e implementação dos modelos

A implementação dos modelos propostos neste trabalho foi realizada na linguagem de programação Python, devido à sua ampla adoção na área de ciência de dados e aprendizado de máquina, bem como à disponibilidade de bibliotecas eficientes para computação numérica.

O Python foi utilizado tanto para a geração de dados simulados quanto para a implementação dos algoritmos de Support Vector Regression (SVR) e sua extensão para dados censurados (SVCR e WSVCR). A manipulação de dados foi realizada com o auxílio da biblioteca NumPy, que oferece estruturas eficientes para operações matriciais e vetoriais, fundamentais para a implementação de métodos baseados em kernel.

Além disso, o Python permite uma integração natural com bibliotecas de otimização e facilita a prototipagem de modelos matemáticos complexos, o que foi essencial para o desenvolvimento e validação das abordagens propostas neste trabalho.

2.2.1 *Otimização convexa*

A resolução dos problemas de otimização associados aos modelos SVCR e WSVCR foi realizada por meio da biblioteca CVXOPT, uma biblioteca especializada em programação convexa desenvolvida para a linguagem Python.

A escolha do CVXOPT deve-se ao fato de que os problemas dual dos modelos baseados em máquinas de vetores de suporte podem ser formulados como problemas de programação quadrática convexa. Nesse contexto, o CVXOPT fornece rotinas eficientes e numericamente estáveis para a obtenção da solução ótima global, garantindo a correta resolução do problema sem a necessidade de implementação manual de algoritmos iterativos, como o Sequential Minimal Optimization (SMO).

O uso de uma biblioteca consolidada como o CVXOPT também contribui para a reprodutibilidade dos resultados, uma vez que os algoritmos de otimização empregados são amplamente testados e documentados na literatura.

FUNDAÇÕES SOBRE MÉTODOS BASEADOS EM KERNEL

Métodos baseados em Kernel são técnicas extremamente flexíveis que podem ser utilizados para estender modelos ou algoritmos para regiões de decisão não lineares (MOHRI; ROSTA-MIZADEH; TALWALKAR, 2018). Estes métodos são baseados nas conhecidas funções de kernel, os quais, sob condições de simetria e positiva definida, definem produtos internos em espaços de alta dimensão, conhecidos como espaços de Hilbert. Dessa forma, este capítulo terá como objetivo definir e apresentar os conceitos fundamentais sobre métodos baseados em kernel, incluindo a definição de funções de kernel, o teorema do representer e Reproducing Kernel Hilbert Space (RKHS).

3.1 Kernels

Por definição, uma função $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ é chamada de kernel sobre $\mathcal{X}$. A ideia central é construir um kernel K tal que, para quaisquer dois pontos $x, x' \in \mathcal{X}$, $K(x, x')$ corresponda ao produto interno entre duas representações desses pontos em um espaço de Hilbert $\mathcal{H}$, isto é,

$$\forall x, x' \in \mathcal{X}, \quad K(x, x') = \langle \phi(x), \phi(x') \rangle,$$

para algum mapeamento $\phi : \mathcal{X} \rightarrow \mathcal{H}$. O espaço $\mathcal{H}$ é chamado de feature space.

Sob essa perspectiva, o kernel pode ser interpretado como uma medida de similaridade entre elementos de $\mathcal{X}$, uma vez que o produto interno mensura a similaridade entre dois vetores.

Uma vantagem fundamental dessa abordagem é computacional. Isto é, muitas vezes é significativamente mais eficiente calcular diretamente $K(x, x')$ do que computar explicitamente $\phi(x)$ e $\phi(x')$ e então avaliar seu produto interno.

3.1.1 Kernels positivos definidos

Para que uma função K possa ser utilizada como kernel, é necessário que sejam satisfeitas duas condições, que a função seja simétrica e positiva definida. Satisfazendo essas condições, o kernel é capaz de induzir uma geometria em um espaço de Hilbert.

Formalmente, um kernel $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ é dito simétrico e positivo definido se, para qualquer conjunto finito $\{x_1, \dots, x_n\} \subset \mathcal{X}$, a matriz de Gram

$$\mathbf{K} = [K(x_i, x_j)]_{i,j=1}^n \in \mathbb{R}^{n \times n}$$

for positiva semidefinida. Isto é, para qualquer vetor $\mathbf{c} = (c_1, \dots, c_n)^\top \in \mathbb{R}^n$,

$$\mathbf{c}^\top \mathbf{K} \mathbf{c} = \sum_{i=1}^n \sum_{j=1}^n c_i c_j K(x_i, x_j) \geq 0.$$

Equivalentemente, todos os autovalores de $\mathbf{K}$ são não negativos. Essa propriedade é essencial, pois garante a existência de uma representação geométrica consistente do kernel.

3.1.2 Espaços de Hilbert

A noção de espaço de Hilbert fornece a estrutura matemática necessária para a teoria de kernels.

Por definição, um espaço de Hilbert $\mathcal{H}$ é um espaço vetorial munido de um produto interno $\langle \cdot, \cdot \rangle_{\mathcal{H}}$ e que é completo com relação à norma induzida por esse produto interno. A norma em $\mathcal{H}$ é definida por

$$\forall h \in \mathcal{H}, \quad \|h\|_{\mathcal{H}} = \sqrt{\langle h, h \rangle}.$$

A completude implica que toda sequência de Cauchy em $\mathcal{H}$ converge para um elemento do próprio espaço, garantindo estabilidade analítica para problemas de otimização e aproximação.

No contexto de kernels, o espaço de Hilbert atua como o espaço onde os dados são representados via o mapeamento ϕ .

3.1.3 Reproducing Kernel Hilbert Spaces

A relação entre kernels positivos definidos e espaços de Hilbert é formalizada pelo teorema.

Seja $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ um kernel simétrico e positivo definido. Então existe um espaço de Hilbert $\mathcal{H}$ e um mapeamento $\phi : \mathcal{X} \rightarrow \mathcal{H}$ tais que

$$\forall x, x' \in \mathcal{X}, \quad K(x, x') = \langle \phi(x), \phi(x') \rangle_{\mathcal{H}}.$$

Além disso, esse espaço satisfaz a chamada propriedade de reprodução:

$$\forall h \in \mathcal{H}, \forall x \in \mathcal{X}, \quad h(x) = \langle h, K(x, \cdot) \rangle_{\mathcal{H}}.$$

Essa propriedade estabelece que a avaliação funcional é contínua e pode ser representada por meio do próprio kernel.

O espaço $\mathcal{H}$ associado a K é chamado de Reproducing Kernel Hilbert Space (RKHS), desempenhando papel central em métodos de aprendizado estatístico, particularmente em problemas de regularização, estimação não paramétrica e aprendizado supervisionado.

ANÁLISE DE SOBREVIVÊNCIA

Em diversos contextos aplicados, não é suficiente determinar se um evento de interesse ocorrerá; torna-se igualmente, e frequentemente mais relevante, modelar o tempo até a sua ocorrência. Considere, por exemplo, um paciente acometido por uma doença crônica. Nesse caso, profissionais da saúde estão interessados não apenas em avaliar a eficácia de diferentes intervenções terapêuticas, mas também em estimar o tempo de sobrevivência associado a cada estratégia. De maneira análoga, no setor financeiro, instituições buscam modelar o tempo até a ocorrência de inadimplência de um cliente, com o objetivo de aprimorar mecanismos de controle e gestão de risco. De forma semelhante, em aplicações de marketing e negócios, o fenômeno de churn refere-se ao tempo até que um cliente deixe de utilizar um serviço, sendo sua antecipação fundamental para a implementação de políticas eficazes de retenção.

Esses exemplos evidenciam a ampla gama de aplicações em que o tempo até a ocorrência de um evento constitui a principal variável de interesse. Nesse contexto, a análise de sobrevivência emerge como um arcabouço estatístico voltado à modelagem de tempos até evento, caracterizando-se, em particular, pela presença de observações incompletas, decorrentes de mecanismos de censura. A incorporação adequada dessas informações parciais é um dos aspectos centrais que distinguem a análise de sobrevivência de abordagens tradicionais de modelagem estatística.

4.1 Censura

A principal característica que distingue a análise de sobrevivência de outras áreas da estatística é a presença de censura. De forma geral, diz-se que uma observação é censurada quando o tempo exato de ocorrência do evento de interesse não é completamente observado. Assim, enquanto para alguns indivíduos o tempo até o evento é conhecido, para outros apenas se dispõe de informação parcial, o que caracteriza a presença de dados censurados (CLARK *et al.*, 2003).

No contexto da análise de sobrevivência, a censura pode ser classificada em três categorias principais: à direita, à esquerda e intervalar. A censura à direita ocorre quando o evento de interesse não é observado durante o período de acompanhamento, seja em razão da saída do indivíduo do estudo antes de sua conclusão, seja pelo término do estudo sem a ocorrência do evento. A censura à esquerda, por sua vez, ocorre quando o evento já aconteceu antes do início do período de observação, embora o instante exato de sua ocorrência seja desconhecido. Por fim, a censura intervalar caracteriza-se pelo fato de que o evento é conhecido apenas como tendo ocorrido em algum instante dentro de um intervalo de tempo, delimitado por duas observações sucessivas.

Neste trabalho, o foco será direcionado aos casos de censura à esquerda e à direita, que são os mais frequentemente encontrados em aplicações práticas. Formalmente, uma observação censurada pode ser representada por um triplo $(\mathbf{x}_i, l_i, u_i)$, para $i = 1, \dots, m$, em que $\mathbf{x}_i \in \mathbb{R}^d$ denota o vetor de covariáveis, $l_i \in \mathbb{R} \cup \{-\infty\}$ representa o limite inferior e $u_i \in \mathbb{R} \cup \{+\infty\}$ o limite superior do intervalo no qual o tempo de ocorrência do evento está contido.

Nesse formalismo, a censura à direita é representada por observações da forma $(\mathbf{x}_i, l_i, +\infty)$, indicando que o evento ocorreu após o tempo l_i , mas seu instante exato é desconhecido. Analogamente, a censura à esquerda é representada por $(\mathbf{x}_i, -\infty, u_i)$, indicando que o evento ocorreu antes de u_i . Quando ambos os limites são finitos, isto é, $l_i < u_i < +\infty$, tem-se o caso de censura intervalar.

No caso particular de observações não censuradas, o tempo de ocorrência do evento é conhecido exatamente, de modo que $l_i = u_i = y_i$. Nesse caso, a observação pode ser representada simplesmente por $(\mathbf{x}_i, y_i)$, em que y_i corresponde ao tempo de sobrevivência observado.

Essa representação unificada permite tratar, de forma coerente, diferentes mecanismos de censura dentro de um mesmo arcabouço matemático, sendo particularmente útil na formulação de métodos de aprendizado que incorporam explicitamente a informação parcial disponível nos dados.

4.2 Funções importantes para análise de sobrevivência e suas relações

Os métodos de análise de sobrevivência são fundamentados na caracterização da distribuição do tempo até a ocorrência de um evento aleatório. As principais formas de descrever essa distribuição são por meio da função de sobrevivência e da função de risco, que oferecem interpretações complementares e desempenham papel central tanto na formulação teórica quanto na modelagem estatística.

A função de sobrevivência descreve a probabilidade de o evento de interesse não ter

ocorrido até um instante t , sendo definida por:

$$S(t) = P(T > t), \quad 0 < t < \infty. \quad (4.1)$$

Sob condições usuais, tem-se que $S(0) = 1$ e $\lim_{t \rightarrow \infty} S(t) = 0$. Além disso, a função de sobrevivência é não crescente e contínua à direita, propriedades que decorrem diretamente de sua definição probabilística.

Outra quantidade fundamental é a função de risco, que descreve a taxa instantânea de ocorrência do evento no tempo t , condicionada à sobrevivência até esse instante. Formalmente, a função de risco é definida por:

$$h(t) = \lim_{\delta \rightarrow 0} \frac{P(t < T \leq t + \delta \mid T > t)}{\delta}. \quad (4.2)$$

Essa definição evidencia que $h(t)$ não é uma probabilidade, mas sim uma taxa, podendo assumir valores maiores que 1. Intuitivamente, ela quantifica a propensão instantânea de ocorrência do evento em torno de t , dado que o indivíduo sobreviveu até esse momento.

A partir dessas definições, podem ser estabelecidas diversas relações que caracterizam completamente a distribuição de T . Em particular, a função de distribuição acumulada é dada por:

$$F(t) = P(T \leq t) = 1 - S(t), \quad 0 < t < \infty. \quad (4.3)$$

Assim como $S(t)$, a função $F(t)$ é contínua à direita e não decrescente. No contexto da análise de sobrevivência, $F(t)$ pode ser interpretada como a probabilidade acumulada de ocorrência do evento até o tempo t , não devendo ser confundida com a função de risco acumulado definida adiante.

Quando a distribuição de T admite densidade, a função densidade de probabilidade é obtida como:

$$f(t) = \frac{d}{dt} F(t) = -\frac{d}{dt} S(t). \quad (4.4)$$

A função de risco pode então ser expressa em termos da densidade e da função de sobrevivência como:

$$h(t) = \frac{f(t)}{S(t)}, \quad (4.5)$$

o que explicita sua interpretação como uma taxa condicional: trata-se da densidade de ocorrência do evento em t , ponderada pela probabilidade de sobrevivência até esse instante.

A integral da função de risco ao longo do tempo define a função de risco acumulado:

$$H(t) = \int_0^t h(u) du. \quad (4.6)$$

Essa função é não decrescente e desempenha papel central na teoria da sobrevivência, uma vez que estabelece uma relação direta e particularmente conveniente com a função de

sobrevivência. De fato, pode-se demonstrar que:

$$S(t) = \exp \left(- \int_0^t h(u) du \right) = \exp(-H(t)). \quad (4.7)$$

Essa expressão evidencia que a função de sobrevivência é completamente determinada pela função de risco, e vice-versa. Do ponto de vista prático, essa relação é de grande relevância, pois muitos modelos em análise de sobrevivência são especificados diretamente em termos da função de risco, como é o caso do modelo de riscos proporcionais de Cox. Além disso, a representação exponencial garante que $S(t)$ permaneça no intervalo unitário e preserve suas propriedades fundamentais.

Em conjunto, essas funções e suas inter-relações fornecem um arcabouço matemático consistente para a modelagem de dados de sobrevivência, permitindo diferentes formas de especificação de modelos conforme as características do problema e dos dados disponíveis.

4.3 Modelo de Riscos Proporcionais de Cox

O modelo de riscos proporcionais de Cox, proposto por (COX, 1972), constitui uma das abordagens mais influentes e amplamente empregadas na análise de sobrevivência. Sua principal característica reside na natureza semiparamétrica da modelagem, na qual a função de risco é decomposta em um componente basal arbitrário e um componente paramétrico associado às covariáveis, sem a necessidade de especificação explícita da forma funcional do risco basal ao longo do tempo.

Formalmente, seja $\mathbf{x}_i \in \mathbb{R}^p$ o vetor de covariáveis associado ao i -ésimo indivíduo. O modelo de Cox é definido por:

$$h(t | \mathbf{x}_i) = h_0(t) \exp \left(\mathbf{x}_i^\top \boldsymbol{\beta} \right), \quad (4.8)$$

em que $h_0(t)$ é a função de risco basal, comum a todos os indivíduos, e $\boldsymbol{\beta} \in \mathbb{R}^p$ é o vetor de parâmetros que quantifica o efeito das covariáveis sobre o risco.

A hipótese central do modelo é a de riscos proporcionais, segundo a qual a razão entre as funções de risco de quaisquer dois indivíduos permanece constante ao longo do tempo. Mais precisamente, para dois indivíduos com vetores de covariáveis $\mathbf{x}_i$ e $\mathbf{x}_j$, tem-se:

$$\frac{h(t | \mathbf{x}_i)}{h(t | \mathbf{x}_j)} = \exp \left((\mathbf{x}_i - \mathbf{x}_j)^\top \boldsymbol{\beta} \right), \quad (4.9)$$

o que evidencia que essa razão independe do tempo t . Essa propriedade confere ao modelo uma interpretação particularmente conveniente, pois o termo $\exp(\beta_k)$ pode ser interpretado como o efeito multiplicativo associado a um aumento unitário na k -ésima covariável sobre o risco instantâneo, mantendo as demais fixas.

Uma das principais vantagens do modelo de Cox é que a estimação do vetor de parâmetros β pode ser realizada sem a necessidade de especificar a função de risco basal $h_0(t)$. Esse resultado é obtido por meio da verossimilhança parcial, que explora apenas a informação contida na ordenação dos tempos de falha observados. Seja $t_{(1)} < \dots < t_{(D)}$ a sequência dos tempos de falha distintos e $\mathcal{R}(t_{(d)})$ o conjunto de risco imediatamente antes de $t_{(d)}$. A verossimilhança parcial é definida por:

$$L(\beta) = \prod_{d=1}^D \frac{\exp(\mathbf{x}_{(d)}^\top \beta)}{\sum_{j \in \mathcal{R}(t_{(d)})} \exp(\mathbf{x}_j^\top \beta)}. \quad (4.10)$$

Sob condições de regularidade, a maximização dessa função conduz a estimativas consistentes e assintoticamente normais para β , mesmo na presença de censura à direita. Uma vez obtidas as estimativas dos parâmetros, é possível recuperar a função de risco basal, tipicamente por meio do estimador de Breslow, e, conseqüentemente, a função de sobrevivência.

A função de sobrevivência condicional associada ao indivíduo i pode ser expressa como:

$$S(t | \mathbf{x}_i) = S_0(t) \exp(\mathbf{x}_i^\top \beta), \quad (4.11)$$

em que $S_0(t)$ denota a função de sobrevivência basal correspondente a $h_0(t)$. Essa expressão evidencia que o efeito das covariáveis atua de forma multiplicativa sobre o risco e, de maneira equivalente, exponencial sobre a função de sobrevivência.

Apesar de sua ampla aplicabilidade e interpretabilidade, o modelo de Cox depende criticamente da validade da hipótese de riscos proporcionais. Violações dessa suposição podem resultar em estimativas viesadas e comprometer a interpretação dos coeficientes. Nesse contexto, diversas extensões têm sido propostas na literatura, incluindo modelos com coeficientes dependentes do tempo, abordagens estratificadas e métodos baseados em aprendizado de máquina, que buscam maior flexibilidade na modelagem de relações complexas entre covariáveis e o risco de ocorrência do evento, especialmente em cenários de alta dimensionalidade.

4.4 Modelos de Longa Duração

Existem dados de sobrevivência em que uma porcentagem dos indivíduos não apresentará a ocorrência de um evento, mesmo se acompanhados por um longo período de tempo. Neste caso, diz-se que os indivíduos são imunes, ou curados, ao evento de interesse. Tem-se assim a análise de sobrevivência com dados de longa duração.

Diferentemente dos modelos tradicionais de sobrevivência, em que se assume que todos os indivíduos eventualmente experimentarão o evento de interesse, nos modelos de longa duração admite-se a existência de uma fração da população para a qual o evento nunca ocorrerá. Essa característica é usualmente denominada fração de cura.

Seja T uma variável aleatória representando o tempo até a ocorrência do evento. Em modelos clássicos de sobrevivência, a função de sobrevivência é definida por

$$S(t) = P(T > t), \quad t \geq 0,$$

satisfazendo $\lim_{t \rightarrow \infty} S(t) = 0$. Entretanto, em modelos com fração de cura, essa condição deixa de valer, pois há uma probabilidade positiva de o evento nunca ocorrer. Assim, a função de sobrevivência torna-se imprópria, isto é,

$$\lim_{t \rightarrow \infty} S(t) = p_0 > 0,$$

em que p_0 representa a fração de indivíduos curados.

Equivalentemente, pode-se escrever a função de sobrevivência populacional como

$$S_{\text{pop}}(t) = p_0 + (1 - p_0)S_0(t),$$

em que $S_0(t)$ representa a função de sobrevivência dos indivíduos suscetíveis ao evento. Nessa formulação, a população é vista como uma mistura entre indivíduos curados e suscetíveis.

Os modelos de fração de cura podem ser classificados em duas abordagens principais: os modelos de mistura e os modelos de não mistura. Nos modelos de mistura, a fração de cura é modelada explicitamente como uma combinação entre curados e suscetíveis. Já nos modelos de não mistura, a estrutura da função de sobrevivência incorpora a fração de cura de forma implícita.

Entre os modelos de não mistura, destaca-se o modelo de tempo de promoção, também conhecido como modelo de risco acumulado limitado.

4.4.1 Modelo de Tempo de Promoção

O modelo de tempo de promoção possui motivação biológica e foi proposto para situações em que o evento de interesse é desencadeado por múltiplos fatores latentes. Considere que cada indivíduo esteja exposto a N riscos latentes, por exemplo, células cancerígenas residuais após um tratamento.

Assume-se que o número de riscos latentes segue uma distribuição de Poisson com média $\theta(\mathbf{x}) > 0$, isto é,

$$N \sim \text{Poisson}(\theta(\mathbf{x})),$$

em que $\mathbf{x}$ representa o vetor de covariáveis.

Seja T_j o tempo necessário para que o j -ésimo risco latente produza o evento clínico, com função de distribuição acumulada $F(t)$. O tempo observado até a ocorrência do evento é definido pelo mínimo entre os tempos latentes:

$$T = \min(T_1, \dots, T_N).$$

Dessa forma, a função de sobrevivência populacional corresponde à probabilidade de que nenhum dos riscos latentes tenha promovido o evento até o tempo t , dada por

$$S_{\text{pop}}(t|\mathbf{x}) = P(N = 0) + P(N > 0, T_1 > t, \dots, T_N > t).$$

Sob as hipóteses de independência entre os riscos latentes, obtém-se

$$S_{\text{pop}}(t|\mathbf{x}) = \exp\{-\theta(\mathbf{x})F(t)\}.$$

Observa-se que, quando $t \rightarrow \infty$, tem-se $F(t) \rightarrow 1$, de modo que

$$\lim_{t \rightarrow \infty} S_{\text{pop}}(t|\mathbf{x}) = \exp\{-\theta(\mathbf{x})\}.$$

Portanto, a fração de cura é dada por

$$p_0(\mathbf{x}) = \exp\{-\theta(\mathbf{x})\}.$$

Uma característica importante desse modelo é que a probabilidade de cura está diretamente associada ao número esperado de riscos latentes. Quanto maior $\theta(\mathbf{x})$, menor a probabilidade de cura. Essa formulação torna o modelo particularmente atrativo por fornecer interpretação biológica clara e permitir a incorporação de covariáveis na modelagem da fração de cura.

4.4.2 Extensão não paramétrica via máquinas de kernel

Embora o modelo de tempo de promoção clássico permita incorporar covariáveis por meio de funções paramétricas para $\theta(\mathbf{x})$, essa abordagem pode ser restritiva em cenários onde a relação entre as covariáveis e a fração de cura apresenta estruturas complexas ou altamente não lineares.

Com o objetivo de contornar essa limitação, propõe-se modelar a intensidade média dos riscos latentes por meio de uma função não paramétrica. Para isso, define-se

$$f(\mathbf{x}) = \log(\theta(\mathbf{x})).$$

A utilização da função de ligação logarítmica garante que

$$\theta(\mathbf{x}) = \exp(f(\mathbf{x})) > 0,$$

preservando a interpretação probabilística da intensidade dos riscos latentes.

Assume-se que a função f pertence a um Reproducing Kernel Hilbert Space (RKHS) $\mathcal{H}_K$, associado a um kernel positivo definido $K(\cdot, \cdot)$. Dessa forma, pelo Teorema do Representante, a solução do problema de otimização penalizado pode ser expressa como uma combinação linear das funções kernel centradas nas observações:

$$f(\mathbf{x}) = \sum_{j=1}^n \alpha_j K(\mathbf{x}, \mathbf{x}_j),$$

em que $\alpha_1, \dots, \alpha_n \in \mathbb{R}$ são coeficientes a serem estimados.

Consequentemente, a intensidade média dos riscos latentes para o indivíduo i pode ser escrita como

$$\theta(\mathbf{x}_i) = \exp \left(\sum_{j=1}^n \alpha_j K(\mathbf{x}_i, \mathbf{x}_j) \right).$$

Neste trabalho, adota-se principalmente o kernel Gaussiano (RBF), definido por

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp \left(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2 \right),$$

onde $\gamma > 0$ é um hiperparâmetro que controla a influência local de cada observação.

Essa formulação amplia significativamente a flexibilidade do modelo, permitindo capturar relações complexas e interações entre covariáveis sem impor, a priori, uma estrutura funcional específica para a componente de cura.

4.4.3 Modelagem da sobrevivência dos suscetíveis

Além da modelagem flexível da fração de cura, é necessário especificar a distribuição dos tempos de falha dos indivíduos suscetíveis. Para isso, propõe-se o uso da distribuição Gama Generalizada (GG), devido à sua elevada flexibilidade e capacidade de acomodar diferentes formatos da função de risco.

A função densidade de probabilidade da distribuição GG é dada por

$$f_{GG}(t; a, d, p) = \frac{p t^{d-1} \exp(-(t/a)^p)}{a^d \Gamma(d/p)},$$

e sua função de distribuição acumulada é definida como

$$F_{GG}(t; a, d, p) = \frac{\gamma(d/p, (t/a)^p)}{\Gamma(d/p)},$$

onde $a > 0$ é o parâmetro de escala, $d > 0$ e $p > 0$ são parâmetros de forma, $\Gamma(\cdot)$ é a função gama e $\gamma(\cdot, \cdot)$ denota a função gama incompleta inferior.

A escolha dessa distribuição se justifica pelo fato de incluir importantes modelos clássicos como casos particulares:

- Weibull, quando $d = p$;
- Gama, quando $p = 1$;
- Log-normal, como caso limite quando $d/p \rightarrow \infty$.

Essa generalidade permite ao modelo adaptar-se a diferentes comportamentos da taxa de risco, incluindo funções monotônicas crescentes, decrescentes, unimodais e em formato de banheira.

4.4.4 Estimação e verossimilhança penalizada

Considere uma amostra observada composta por n indivíduos,

$$\mathcal{D} = \{(\mathbf{x}_i, t_i, \delta_i)\}_{i=1}^n,$$

em que $\mathbf{x}_i$ representa o vetor de covariáveis, t_i o tempo observado e δ_i o indicador de falha, tal que $\delta_i = 1$ indica ocorrência do evento e $\delta_i = 0$ indica censura.

No modelo de tempo de promoção, a contribuição individual para a função de verossimilhança é dada por

$$L_i = h_{\text{pop}}(t_i|\mathbf{x}_i)^{\delta_i} S_{\text{pop}}(t_i|\mathbf{x}_i),$$

de modo que a log-verossimilhança individual é

$$\ell_i = \delta_i \log(h_{\text{pop}}(t_i|\mathbf{x}_i)) + \log(S_{\text{pop}}(t_i|\mathbf{x}_i)).$$

No modelo GG-KM, a função de sobrevivência populacional é dada por

$$S_{\text{pop}}(t|\mathbf{x}) = \exp\{-\theta(\mathbf{x})F_{\text{GG}}(t)\},$$

enquanto a função de risco populacional pode ser escrita como

$$h_{\text{pop}}(t|\mathbf{x}) = \theta(\mathbf{x})f_{\text{GG}}(t).$$

Substituindo essas expressões na log-verossimilhança, obtém-se

$$\ell_i = \delta_i [\log(\theta(\mathbf{x}_i)) + \log(f_{\text{GG}}(t_i))] - \theta(\mathbf{x}_i)F_{\text{GG}}(t_i).$$

Como $\theta(\mathbf{x}) = \exp(f(\mathbf{x}))$ e

$$f(\mathbf{x}) = \sum_{j=1}^n \alpha_j K(\mathbf{x}, \mathbf{x}_j),$$

a log-verossimilhança conjunta torna-se

$$\ell(\Theta) = \sum_{i=1}^n \{\delta_i [f(\mathbf{x}_i) + \log(f_{GG}(t_i))] - \exp(f(\mathbf{x}_i)) F_{GG}(t_i)\},$$

onde $\Theta = (\alpha, a, d, p)$ representa o conjunto completo de parâmetros.

Para controlar a complexidade da função estimada no RKHS e evitar sobreajuste, adiciona-se um termo de penalização quadrática baseado na norma induzida pelo kernel. Assim, define-se a função objetivo penalizada:

$$J(\Theta) = -\ell(\Theta) + \frac{\lambda_{reg}}{2} \alpha^\top K \alpha.$$

Equivalentemente,

$$J(\Theta) = -\sum_{i=1}^n \{\delta_i [f(\mathbf{x}_i) + \log(f_{GG}(t_i))] - \exp(f(\mathbf{x}_i)) F_{GG}(t_i)\} + \frac{\lambda_{reg}}{2} \alpha^\top K \alpha.$$

Em notação matricial, essa expressão pode ser escrita como

$$J(\Theta) = -\left[\delta^\top (K\alpha + \log f_{GG}) - w^\top F_{GG} \right] + \frac{\lambda_{reg}}{2} \alpha^\top K \alpha,$$

em que:

- $\delta = (\delta_1, \dots, \delta_n)^\top$ é o vetor de indicadores de censura;
- K é a matriz de Gram associada ao kernel escolhido;
- $w = \exp(K\alpha)$ representa o vetor das intensidades latentes;
- $\log f_{GG} = (\log f_{GG}(t_1), \dots, \log f_{GG}(t_n))^\top$;
- $F_{GG} = (F_{GG}(t_1), \dots, F_{GG}(t_n))^\top$.

A estimação dos parâmetros é realizada por minimização numérica da função objetivo $J(\Theta)$. Como não existe solução analítica fechada, utiliza-se um algoritmo iterativo baseado em gradientes, especificamente o método L-BFGS, devido à sua eficiência em problemas de alta dimensão e sua boa estabilidade numérica.

4.4.5 Gradientes analíticos

Para tornar o processo de otimização mais eficiente, derivam-se explicitamente os gradientes da função objetivo em relação a todos os parâmetros do modelo.

O gradiente em relação aos coeficientes do kernel α é dado por

$$\nabla_{\alpha} J = -K(\delta - w \odot F_{GG}) + \lambda_{\text{reg}} K\alpha,$$

em que $\odot$ denota o produto de Hadamard.

Para os parâmetros da distribuição Gama Generalizada, define-se

$$u_i = \left(\frac{t_i}{a}\right)^p \quad \text{e} \quad s = \frac{d}{p}.$$

Os gradientes em relação aos parâmetros a , d e p são obtidos analiticamente e utilizados conjuntamente no procedimento iterativo de otimização.

Dessa forma, em cada iteração, atualizam-se simultaneamente os parâmetros

$$\Theta = (\alpha, a, d, p),$$

até a convergência do algoritmo.

Esse procedimento permite estimar de maneira conjunta tanto a estrutura não linear da fração de cura quanto a dinâmica paramétrica da sobrevivência dos indivíduos suscetíveis, resultando em um modelo semiparamétrico altamente flexível.

METODOLOGIA

Este capítulo descreve, de forma sistemática, os procedimentos adotados para a construção, treinamento e avaliação dos modelos considerados neste trabalho. Em particular, são detalhados os processos de particionamento dos dados, seleção de hiperparâmetros e geração de dados experimentais, seguindo práticas consolidadas na literatura de aprendizado de máquina aplicado à análise de sobrevivência.

5.1 Particionamento dos dados

A avaliação do desempenho preditivo dos modelos foi conduzida por meio de um esquema de validação baseado na divisão dos dados em conjuntos de treinamento e teste. Especificamente, adotou-se uma estratégia de holdout, na qual 70% das observações foram utilizadas para treinamento e os 30% restantes reservados para teste.

A separação foi realizada de forma aleatória, preservando, sempre que aplicável, a estrutura dos dados censurados, de modo a garantir que ambos os subconjuntos apresentassem proporções semelhantes de observações censuradas e não censuradas. Essa precaução é particularmente importante em problemas de análise de sobrevivência, uma vez que a distribuição dos tipos de censura pode influenciar significativamente o desempenho dos modelos.

Adicionalmente, com o objetivo de reduzir a variabilidade associada a uma única partição, o procedimento de holdout foi repetido múltiplas vezes. As métricas de desempenho foram então agregadas ao longo dessas repetições, considerando medidas como média, mediana e desvio padrão, proporcionando uma avaliação mais robusta e estável.

5.2 Seleção de hiperparâmetros

A escolha adequada dos hiperparâmetros é um elemento crucial para o desempenho de modelos baseados em máquinas de vetores de suporte. Nesse contexto, foi empregado um procedimento de busca em grade (grid search), amplamente utilizado devido à sua simplicidade e efetividade.

Para cada modelo considerado, definiu-se um conjunto finito de valores candidatos para os hiperparâmetros relevantes. No caso do SVR e de suas extensões, foram considerados, entre outros:

- o parâmetro de regularização C , que controla o equilíbrio entre ajuste aos dados e complexidade do modelo;
- o parâmetro ϵ , no caso do SVR, que define a largura do tubo de insensibilidade;
- os parâmetros específicos de cada função kernel, como o grau no kernel polinomial ou o parâmetro de escala em kernels gaussianos e wavelet.

Formalmente, seja Θ o espaço de hiperparâmetros. O grid search consiste em avaliar exaustivamente o desempenho do modelo para cada combinação $\theta \in \Theta$, selecionando aquela que otimiza uma métrica de interesse.

A avaliação das combinações foi realizada exclusivamente no conjunto de treinamento, utilizando validação interna, de modo a evitar vazamento de informação do conjunto de teste. O modelo final foi então treinado com os hiperparâmetros selecionados e avaliado no conjunto de teste.

Em acordo com o estudo de referência, foram considerados diferentes tipos de funções kernel, incluindo não apenas os kernels tradicionais (linear, polinomial e gaussiano), mas também alternativas como os kernels exponencial, Laplaciano e Cauchy, que têm demonstrado bom desempenho em cenários de dados censurados.

5.3 Estudo de simulação

Com o objetivo de avaliar o desempenho do modelo GG-KM em diferentes cenários de complexidade da fração de cura, foi conduzido um estudo de simulação via Monte Carlo, seguindo a mesma estrutura de geração de dados proposta por Pal e Aselisevine (2023), adaptada ao contexto do modelo de tempo de promoção.

Foram considerados dois tamanhos amostrais, $n = 300$ e $n = 600$. Em cada replicação, os dados foram particionados em conjunto de treinamento e teste, sendo dois terços das observações destinados ao treinamento e o terço restante utilizado para avaliação preditiva.

Cada conjunto de dados foi gerado a partir de duas covariáveis independentes,

$$x_1, x_2 \sim N(0, 1),$$

de modo que o vetor de covariáveis foi definido como

$$\mathbf{x} = (x_1, x_2).$$

A estrutura de cura foi construída a partir de três mecanismos distintos para a geração da probabilidade de não cura, permitindo avaliar o comportamento do modelo sob diferentes graus de linearidade e não linearidade.

O primeiro mecanismo considera uma fronteira linear, dada por

$$\pi(\mathbf{x}) = \frac{\exp(0.3 - 5x_1 - 3x_2)}{1 + \exp(0.3 - 5x_1 - 3x_2)}.$$

Esse cenário representa a estrutura clássica de regressão logística, em que indivíduos curados e não curados são linearmente separáveis.

O segundo mecanismo introduz uma relação quadrática entre as covariáveis:

$$\pi(\mathbf{x}) = \frac{\exp(0.3 + 5x_1^2 - 3x_2^2)}{1 + \exp(0.3 + 5x_1^2 - 3x_2^2)}.$$

Esse caso permite avaliar a capacidade do modelo em capturar superfícies de decisão não lineares.

O terceiro mecanismo considera uma estrutura altamente não linear e periódica:

$$\pi(\mathbf{x}) = \exp\{-\exp(0.3 - 5\cos(x_1) - 3\sin(x_2))\}.$$

Esse cenário impõe fronteiras de classificação complexas, sendo particularmente útil para avaliar a flexibilidade da abordagem baseada em kernels.

Para a componente de latência, os tempos associados aos riscos latentes foram gerados a partir de uma distribuição Weibull, cuja função de risco é dada por

$$h(t|\mathbf{x}) = h_0(t) \exp(\beta_1 x_1 + \beta_2 x_2),$$

onde a função de risco basal foi definida como

$$h_0(t) = \alpha t^{\alpha-1}, \quad \alpha > 0.$$

Essa especificação implica que os tempos latentes seguem uma distribuição Weibull com parâmetro de forma α e parâmetro de escala

$$\lambda(\mathbf{x}) = \{\exp(\beta_1 x_1 + \beta_2 x_2)\}^{-1/\alpha}.$$

Os valores verdadeiros utilizados para os parâmetros foram

$$(\alpha, \beta_1, \beta_2) = (2, 1, 0.5).$$

Os tempos de censura foram gerados independentemente a partir de uma distribuição exponencial com taxa igual a 0.2:

$$C_i \sim \text{Exp}(0.2).$$

A geração dos dados de sobrevivência foi realizada para cada indivíduo i segundo o seguinte algoritmo:

1. Gerar $U_i \sim \text{Uniform}(0, 1)$ e $C_i \sim \text{Exp}(0.2)$;
2. Se $U_i \leq 1 - \pi(\mathbf{x}_i)$, o indivíduo é considerado curado, definindo-se

$$t_i = C_i \quad \text{e} \quad \delta_i = 0.$$

3. Se $U_i > 1 - \pi(\mathbf{x}_i)$, o indivíduo é suscetível:

- a) Gerar $U_i^* \sim \text{Uniform}(1 - \pi(\mathbf{x}_i), 1)$;
- b) Obter o tempo latente Y_i resolvendo

$$(1 - \pi(\mathbf{x}_i))F(Y_i|\mathbf{x}_i) = U_i^*,$$

ou equivalentemente,

$$Y_i = F^{-1}\left(\frac{\log(U_i^*)}{\log(1 - \pi(\mathbf{x}_i))}\right);$$

- c) Definir o tempo observado:

$$t_i = \min(Y_i, C_i);$$

- d) Definir o indicador de falha:

$$\delta_i = \begin{cases} 1, & \text{se } t_i = Y_i, \\ 0, & \text{caso contrário.} \end{cases}$$

Esse procedimento foi repetido em 500 replicações de Monte Carlo para cada cenário.

O desempenho do modelo GG-KM foi avaliado com base no viés, erro quadrático médio (EQM) e no Integrated Brier Score (IBS), permitindo mensurar tanto a qualidade da estimação dos parâmetros quanto a capacidade preditiva do modelo.

RESULTADOS

CONCLUSÃO

Este trabalho investigou o desempenho de modelos de regressão para dados de sobrevivência com censura, com ênfase em abordagens baseadas em máquinas de vetores de suporte, em particular o Support Vector Censored Regression (SVCR) e suas extensões com diferentes funções kernel. A análise foi conduzida de forma sistemática, combinando experimentos em dados simulados, nos quais a estrutura geradora é conhecida, e aplicações em bases reais amplamente utilizadas na literatura.

Nos cenários simulados, caracterizados por relações não lineares entre covariáveis e o tempo de sobrevivência, observou-se de forma consistente a superioridade dos métodos baseados em kernels não lineares, com destaque para os kernels Laplaciano, Cauchy e Polinomial. Esses resultados corroboram a hipótese de que a flexibilidade funcional proporcionada por tais kernels é crucial para capturar estruturas complexas, nas quais modelos lineares ou semiparamétricos, como o modelo de Cox, tendem a apresentar limitações.

Por outro lado, na análise com dados reais, os resultados indicaram um comportamento distinto. Modelos mais simples, como o linear e o modelo de Cox, apresentaram desempenho competitivo e, em alguns casos, superior aos métodos mais flexíveis. Esse achado evidencia o papel fundamental do equilíbrio entre viés e variância, sugerindo que a maior capacidade de ajuste dos kernels não lineares nem sempre se traduz em ganhos empíricos quando a estrutura dos dados é mais regular ou quando o tamanho amostral é limitado.

De maneira geral, os resultados obtidos reforçam a importância de alinhar a escolha do modelo às características intrínsecas dos dados, particularmente no que diz respeito à presença de não linearidades, tamanho da amostra e proporção de censura. Além disso, evidenciam que métodos baseados em SVCR constituem uma alternativa promissora no contexto de análise de sobrevivência, especialmente em cenários mais complexos, embora demandem cuidadosa calibração de hiperparâmetros.

REFERÊNCIAS

CLARK, T. G.; BRADBURN, M. J.; LOVE, S. B.; ALTMAN, D. G. Survival analysis part i: basic concepts and first analyses. **British journal of cancer**, Nature Publishing Group, v. 89, n. 2, p. 232–238, 2003. Citado na página [19](#).

COX, D. R. Regression models and life-tables. **Journal of the royal statistical society: Series B (methodological)**, Wiley Online Library, v. 34, n. 2, p. 187–202, 1972. Citado na página [22](#).

MOHRI, M.; ROSTAMIZADEH, A.; TALWALKAR, A. **Foundations of machine learning**. [S.l.]: MIT press, 2018. Citado nas páginas [1](#), [3](#) e [15](#).

PRINCE, T.; BOMMERT, A.; RAHNENFÜHRER, J.; SCHMID, M. On the estimation of inverse-probability-of-censoring weights for the evaluation of survival prediction error. **PloS one**, Public Library of Science San Francisco, CA USA, v. 20, n. 1, p. e0318349, 2025. Citado nas páginas [1](#) e [3](#).

STACY, E. W. A generalization of the gamma distribution. **The Annals of mathematical statistics**, JSTOR, p. 1187–1192, 1962. Citado nas páginas [1](#) e [3](#).

