

Título - A Definir

Gabriel de Jesus Pereira

Qualificação de Mestrado do Programa Interinstitucional de
Pós-Graduação em Estatística (PIPGes)

DEDICATÓRIA!!!!

AGRADECIMENTOS

AGRADECIMENTOS!!!!

“EPÍGRAFE!!!!”

RESUMO

GABRIEL, J. P. **Título - A Definir**. 2021. 55 p. Monografia (Mestrado em Estatística – Programa Interinstitucional de Pós-Graduação em Estatística) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2021.

Este artigo introduz o GG-KM, uma nova abordagem semiparamétrica para modelagem de taxa de cura no modelo de tempo de promoção. Abordamos as limitações dos preditores lineares tradicionais ao empregar Máquinas de Kernel para modelar o componente de cura dentro de um Reproducing Kernel Hilbert Space (RKHS) (MOHRI; ROSTAMIZADEH; TALWALKAR, 2018). Para fornecer máxima flexibilidade à função de risco dos indivíduos suscetíveis, incorporamos a distribuição Gama Generalizada (STACY, 1962), que engloba diversos modelos clássicos de sobrevivência. Derivamos uma estrutura de log-verossimilhança penalizada e fornecemos gradientes analíticos explícitos para a otimização conjunta dos pesos do kernel, hiperparâmetros e parâmetros da distribuição. O desempenho do modelo é validado por meio do Integrated Brier Score (IBS) com ajuste por IPCW (PRINCE *et al.*, 2025).

Palavras-chave: Análise de Sobrevivência, Censura, Reproducing Kernel Hilbert Space, Gama Generalizada, Representer Theorem.

ABSTRACT

GABRIEL, J. P. **Model of theses and dissertations in LaTeX of the ICMC**. 2021. 55 p. Monografia (Mestrado em Estatística – Programa Interinstitucional de Pós-Graduação em Estatística) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos – SP, 2021.

This paper introduces GG-KM, a novel semiparametric approach to promotion time cure rate modeling. We address the limitations of traditional linear predictors by employing Kernel Machines to model the cure component within a Reproducing Kernel Hilbert Space (RKHS) (MOHRI; ROSTAMIZADEH; TALWALKAR, 2018). To provide maximum flexibility for the hazard of susceptible individuals, we incorporate the Generalized Gamma (GG) distribution (STACY, 1962), which encompasses several standard survival models. We derive a penalized log-likelihood framework and provide explicit analytical gradients for the joint optimization of kernel weights, hyperparameters, and distribution parameters. Model performance is validated through the Integrated Brier Score (IBS) with IPCW adjustment (PRINCE *et al.*, 2025).

Keywords: Survival Analysis, Censoring, Reproducing Kernel Hilbert Space, Generalized Gamma, Representer Theorem.

LISTA DE ILUSTRAÇÕES

Figura 1 – Simulação de curados e não curados sobre os três métodos descritos. Respec-	
tivamente, pode-se observar o método 1, 2 e 3.	43
Figura 2 – Distribuição do IBS em relação a cada kernel, para diferentes cenários de	
simulação.	48
Figura 3 – Comparação da curva de sobrevivência estimada pelo GG-KM e KME. . . .	48
Figura 4 – Curva de Kaplan Meier para o conjunto de dados de melanoma, comparando	
o modelo GG-KM.	50
Figura 5 – Distribuição do IBS em relação a cada kernel.	50

LISTA DE ALGORITMOS

Algoritmo 1 – Processo de estimação do modelo GG-KM	32
Algoritmo 2 – Algoritmo EM penalizado para estimar o modelo GG-KM	39
Algoritmo 3 – Geração de dados simulados com fração de cura	45

LISTA DE TABELAS

Tabela 1 – Resultados dos melhores kernels para cada tamanho amostral e método. . . .	49
Tabela 2 – Resultados do IBS médio e desvio padrão para cada kernel no conjunto de dados Melanoma.	51

SUMÁRIO

1	INTRODUÇÃO	19
1.1	Objetivo do Trabalho	20
1.2	Organização do Trabalho	20
2	FUNDAMENTOS DE ANÁLISE DE SOBREVIVÊNCIA	21
2.1	Introdução	21
2.2	Censura	21
2.3	Funções importantes para análise de sobrevivência e suas relações .	22
2.4	Modelo de Riscos Proporcionais de Cox	23
2.5	Modelos de Longa Duração	25
2.5.1	<i>Modelo de Tempo de Promoção</i>	26
2.5.2	<i>Distribuição Gama Generalizada</i>	29
2.5.3	<i>Estimação e verossimilhança penalizada</i>	29
2.5.4	<i>Gradientes analíticos</i>	31
3	MÉTODOS BASEADOS EM KERNEL	33
3.1	Kernels	33
3.1.1	<i>Kernels positivos definidos</i>	34
3.1.2	<i>Espaços de Hilbert</i>	34
3.1.3	<i>Reproducing Kernel Hilbert Spaces</i>	34
3.1.4	<i>Teorema do Representante</i>	35
3.2	GG-KM	35
3.2.1	<i>Extensão não paramétrica via kernel</i>	36
3.2.2	<i>Estimação via algoritmo EM penalizado</i>	36
4	AVALIAÇÃO EXPERIMENTAL	41
4.1	Recursos Computacionais	41
4.1.1	<i>Ambiente de desenvolvimento e escrita</i>	41
4.1.2	<i>Linguagem de programação e implementação dos modelos</i>	42
4.2	Particionamento dos dados	42
4.3	Estudo de simulação e Métricas de Erro	42
5	RESULTADOS	47
5.1	Aplicação a Dados Simulados	47

5.2	Aplicação a Dados Reais	49
6	CONCLUSÃO	53
	REFERÊNCIAS	55

INTRODUÇÃO

A análise de sobrevivência constitui um dos principais ramos da estatística aplicada voltado ao estudo do tempo até a ocorrência de um evento de interesse, como falha de um sistema, recorrência de uma doença ou morte de um indivíduo. Uma característica central desse tipo de dado é a presença de censura, isto é, situações nas quais o tempo exato do evento não é completamente observado. Esse aspecto impõe desafios metodológicos relevantes, exigindo o desenvolvimento de modelos capazes de lidar adequadamente com informações incompletas.

Além da presença de censura, em diversos contextos práticos observa-se a existência de uma fração de indivíduos que não experimentará o evento de interesse, mesmo sob longos períodos de acompanhamento. Essa característica motivou o desenvolvimento dos chamados modelos de fração de cura, que buscam representar explicitamente essa parcela da população.

Tradicionalmente, modelos como o de Cox têm sido amplamente utilizados nesse contexto, devido à sua flexibilidade semiparamétrica e interpretabilidade. No entanto, tais abordagens assumem, em geral, uma estrutura linear no preditor do risco, o que pode ser inadequado em cenários nos quais a relação entre as covariáveis e o tempo de sobrevivência apresenta padrões não lineares ou de maior complexidade.

Nesse cenário, métodos baseados em kernels surgem como alternativas promissoras, pois permitem incorporar flexibilidade ao processo de modelagem por meio de mapeamentos implícitos para espaços de maior dimensão. Essa abordagem possibilita capturar estruturas não lineares sem a necessidade de especificar explicitamente a forma funcional da relação entre covariáveis e sobrevivência.

O presente trabalho propõe um novo modelo semiparamétrico para dados de sobrevivência com fração de cura, denominado GG-KM, que combina a flexibilidade de métodos baseados em kernel com a estrutura do modelo de tempo de promoção. O objetivo principal é investigar o desempenho do modelo sob diferentes especificações de kernel, avaliando sua capacidade preditiva e sua adequação em cenários com diferentes graus de complexidade.

Para isso, são conduzidos experimentos em dados simulados, nos quais é possível controlar a estrutura geradora, e em bases de dados reais amplamente utilizadas na literatura. A avaliação é realizada principalmente por meio do Integrated Brier Score (IBS), permitindo analisar a qualidade preditiva do modelo e a influência da escolha do kernel sob diferentes cenários.

1.1 Objetivo do Trabalho

O objetivo deste trabalho é apresentar os fundamentos teóricos e os principais resultados relacionados à proposta de uma extensão do modelo de tempo de promoção, de modo que seja possível a incorporação de funções kernel na modelagem da fração de cura.

1.2 Organização do Trabalho

Este trabalho está estruturado da seguinte forma. No Capítulo 2 são apresentados fundamentos de análise de sobrevivência, incluindo noções de censura, funções de sobrevivência, modelo de Cox, além de descrever brevemente modelos com fração de cura. No Capítulo 3, são introduzidos alguns conceitos que fundamentam métodos baseados em kernel. Dessa forma, são apresentadas definições como espaços de Hilbert, kernels positivos definidos e alguns kernels principais.

No Capítulo 4, é detalhada a metodologia adotada, abrangendo os recursos computacionais utilizados, particionamento dos dados, a geração de dados simulados com fração de cura. O Capítulo 5 apresenta e discute os resultados obtidos tanto em dados simulados quanto em dados reais. Por fim, o Capítulo 6 apresenta as conclusões do trabalho.

FUNDAMENTOS DE ANÁLISE DE SOBREVIVÊNCIA

2.1 Introdução

Saber se um evento de interesse ocorrerá ou não é crucial. No entanto, em diversos cenários, saber quando ele ocorrerá pode ser ainda mais importante. Nesse contexto, surge uma metodologia estatística denominada análise de sobrevivência. O tempo transcorrido até a ocorrência de um evento de interesse é denominado tempo de sobrevivência ([AALEN; BORGAN; GJESSING, 2008](#)). Por exemplo, em um estudo cujo interesse seja a inadimplência de associados de uma cooperativa de crédito, o tempo de sobrevivência pode ser definido como o tempo até a ocorrência da inadimplência. Assim sendo, a análise de sobrevivência tem como objetivo modelar a distribuição desse tempo e investigar fatores que possam influenciar sua ocorrência. Portanto, este capítulo terá como objetivo apresentar conceitos que fundamentam a análise de sobrevivência.

2.2 Censura

A principal característica que distingue a análise de sobrevivência de outras áreas da estatística é a presença de censura nos dados. Por exemplo, considere que os associados de uma cooperativa de crédito estejam sendo acompanhados ao longo do tempo para analisar a ocorrência de inadimplência. Nesse contexto, duas situações podem ocorrer. Alguns associados podem se tornar inadimplentes durante o período de acompanhamento, enquanto outros podem não experimentar o evento até o término do estudo. Neste último caso, ocorre censura, pois o tempo de sobrevivência desses indivíduos não é observado completamente, mas é conhecido que o evento ocorrerá após um determinado instante de tempo.

A censura pode ocorrer de três formas diferentes. O exemplo dado anteriormente pode ser

entendido como sendo uma censura à direita. A censura à direita ocorre quando o evento ocorreu depois de um determinado tempo, mas o tempo exato não é conhecido. Outro tipo de censura é a censura à esquerda, que ocorre quando o evento ocorreu antes de um determinado tempo. Ainda no caso da inadimplência, um exemplo de censura à esquerda seria quando um associado já se encontrava inadimplente no início do estudo, mas o tempo exato de ocorrência da inadimplência não é conhecido. Por fim, a censura intervalar ocorre quando o evento ocorreu dentro de um intervalo de tempo, mas o tempo exato não é conhecido. No exemplo da inadimplência, a censura intervalar poderia ocorrer se os associados fossem avaliados periodicamente, e o evento de inadimplência fosse detectado apenas durante essas avaliações, sem que o tempo exato de ocorrência fosse conhecido.

2.3 Funções importantes para análise de sobrevivência e suas relações

Os métodos de análise de sobrevivência são fundamentados na caracterização da distribuição do tempo até a ocorrência de um evento aleatório. As principais formas de descrever essa distribuição são por meio da função de sobrevivência e da função de risco, que oferecem interpretações complementares e desempenham papel central tanto na formulação teórica quanto na modelagem estatística.

A função de sobrevivência descreve a probabilidade de o evento de interesse não ter ocorrido até um instante t , sendo definida por:

$$S(t) = P(T > t), \quad 0 < t < \infty. \quad (2.1)$$

Sob condições usuais, tem-se que $S(0) = 1$ e $\lim_{t \rightarrow \infty} S(t) = 0$. Além disso, a função de sobrevivência é não crescente e contínua à direita, propriedades que decorrem diretamente de sua definição probabilística.

Outra quantidade fundamental é a função de risco, que descreve a taxa instantânea de ocorrência do evento no tempo t , condicionada à sobrevivência até esse instante. Formalmente, a função de risco é definida por:

$$h(t) = \lim_{\delta \rightarrow 0} \frac{P(t < T \leq t + \delta \mid T > t)}{\delta}. \quad (2.2)$$

Essa definição evidencia que $h(t)$ não é uma probabilidade, mas sim uma taxa, podendo assumir valores maiores que 1. Intuitivamente, ela quantifica a propensão instantânea de ocorrência do evento em torno de t , dado que o indivíduo sobreviveu até esse momento.

A partir dessas definições, podem ser estabelecidas diversas relações que caracterizam completamente a distribuição de T . Em particular, a função de distribuição acumulada é dada

por:

$$F(t) = P(T \leq t) = 1 - S(t), \quad 0 < t < \infty. \quad (2.3)$$

Assim como $S(t)$, a função $F(t)$ é contínua à direita e não decrescente. No contexto da análise de sobrevivência, $F(t)$ pode ser interpretada como a probabilidade acumulada de ocorrência do evento até o tempo t , não devendo ser confundida com a função de risco acumulado definida adiante.

Quando a distribuição de T admite densidade, a função densidade de probabilidade é obtida como:

$$f(t) = \frac{d}{dt}F(t) = -\frac{d}{dt}S(t). \quad (2.4)$$

A função de risco pode então ser expressa em termos da densidade e da função de sobrevivência como:

$$h(t) = \frac{f(t)}{S(t)}, \quad (2.5)$$

o que explicita sua interpretação como uma taxa condicional: trata-se da densidade de ocorrência do evento em t , ponderada pela probabilidade de sobrevivência até esse instante.

A integral da função de risco ao longo do tempo define a função de risco acumulado:

$$H(t) = \int_0^t h(u) du. \quad (2.6)$$

Essa função é não decrescente e desempenha papel central na teoria da sobrevivência, uma vez que estabelece uma relação direta e particularmente conveniente com a função de sobrevivência. De fato, pode-se demonstrar que:

$$S(t) = \exp\left(-\int_0^t h(u) du\right) = \exp(-H(t)). \quad (2.7)$$

Essa expressão evidencia que a função de sobrevivência é completamente determinada pela função de risco, e vice-versa. Do ponto de vista prático, essa relação é de grande relevância, pois muitos modelos em análise de sobrevivência são especificados diretamente em termos da função de risco, como é o caso do modelo de riscos proporcionais de Cox. Além disso, a representação exponencial garante que $S(t)$ permaneça no intervalo unitário e preserve suas propriedades fundamentais.

Em conjunto, essas funções e suas inter-relações fornecem um arcabouço matemático consistente para a modelagem de dados de sobrevivência, permitindo diferentes formas de especificação de modelos conforme as características do problema e dos dados disponíveis.

2.4 Modelo de Riscos Proporcionais de Cox

O modelo de riscos proporcionais de Cox, proposto por (COX, 1972), constitui uma das abordagens mais influentes e amplamente empregadas na análise de sobrevivência. Sua principal

característica reside na natureza semiparamétrica da modelagem, na qual a função de risco é decomposta em um componente basal arbitrário e um componente paramétrico associado às covariáveis, sem a necessidade de especificação explícita da forma funcional do risco basal ao longo do tempo.

Formalmente, seja $\mathbf{x}_i \in \mathbb{R}^p$ o vetor de covariáveis associado ao i -ésimo indivíduo. O modelo de Cox é definido por:

$$h(t | \mathbf{x}_i) = h_0(t) \exp(\mathbf{x}_i^\top \boldsymbol{\beta}), \quad (2.8)$$

em que $h_0(t)$ é a função de risco basal, comum a todos os indivíduos, e $\boldsymbol{\beta} \in \mathbb{R}^p$ é o vetor de parâmetros que quantifica o efeito das covariáveis sobre o risco.

A hipótese central do modelo é a de riscos proporcionais, segundo a qual a razão entre as funções de risco de quaisquer dois indivíduos permanece constante ao longo do tempo. Mais precisamente, para dois indivíduos com vetores de covariáveis $\mathbf{x}_i$ e $\mathbf{x}_j$, tem-se:

$$\frac{h(t | \mathbf{x}_i)}{h(t | \mathbf{x}_j)} = \exp((\mathbf{x}_i - \mathbf{x}_j)^\top \boldsymbol{\beta}), \quad (2.9)$$

o que evidencia que essa razão independe do tempo t . Essa propriedade confere ao modelo uma interpretação particularmente conveniente, pois o termo $\exp(\beta_k)$ pode ser interpretado como o efeito multiplicativo associado a um aumento unitário na k -ésima covariável sobre o risco instantâneo, mantendo as demais fixas.

Uma das principais vantagens do modelo de Cox é que a estimação do vetor de parâmetros $\boldsymbol{\beta}$ pode ser realizada sem a necessidade de especificar a função de risco basal $h_0(t)$. Esse resultado é obtido por meio da verossimilhança parcial, que explora apenas a informação contida na ordenação dos tempos de falha observados. Seja $t_{(1)} < \dots < t_{(D)}$ a sequência dos tempos de falha distintos e $\mathcal{R}(t_{(d)})$ o conjunto de risco imediatamente antes de $t_{(d)}$. A verossimilhança parcial é definida por:

$$L(\boldsymbol{\beta}) = \prod_{d=1}^D \frac{\exp(\mathbf{x}_{(d)}^\top \boldsymbol{\beta})}{\sum_{j \in \mathcal{R}(t_{(d)})} \exp(\mathbf{x}_j^\top \boldsymbol{\beta})}. \quad (2.10)$$

Sob condições de regularidade, a maximização dessa função conduz a estimativas consistentes e assintoticamente normais para $\boldsymbol{\beta}$, mesmo na presença de censura à direita. Uma vez obtidas as estimativas dos parâmetros, é possível recuperar a função de risco basal, tipicamente por meio do estimador de Breslow, e, consequentemente, a função de sobrevivência.

A função de sobrevivência condicional associada ao indivíduo i pode ser expressa como:

$$S(t | \mathbf{x}_i) = S_0(t) \exp(-\mathbf{x}_i^\top \boldsymbol{\beta}), \quad (2.11)$$

em que $S_0(t)$ denota a função de sobrevivência basal correspondente a $h_0(t)$. Essa expressão evidencia que o efeito das covariáveis atua de forma multiplicativa sobre o risco e, de maneira equivalente, exponencial sobre a função de sobrevivência.

Apesar de sua ampla aplicabilidade e interpretabilidade, o modelo de Cox depende criticamente da validade da hipótese de riscos proporcionais. Violações dessa suposição podem resultar em estimativas viesadas e comprometer a interpretação dos coeficientes. Nesse contexto, diversas extensões têm sido propostas na literatura, incluindo modelos com coeficientes dependentes do tempo, abordagens estratificadas e métodos baseados em aprendizado de máquina, que buscam maior flexibilidade na modelagem de relações complexas entre covariáveis e o risco de ocorrência do evento, especialmente em cenários de alta dimensionalidade.

2.5 Modelos de Longa Duração

Existem dados de sobrevivência em que uma porcentagem dos indivíduos não apresentará a ocorrência de um evento, mesmo se acompanhados por um longo período de tempo. Neste caso, diz-se que os indivíduos são imunes, ou curados, ao evento de interesse. Tem-se assim a análise de sobrevivência com dados de longa duração.

Diferentemente dos modelos tradicionais de sobrevivência, em que se assume que todos os indivíduos eventualmente experimentarão o evento de interesse, nos modelos de longa duração admite-se a existência de uma fração da população para a qual o evento nunca ocorrerá. Essa característica é usualmente denominada fração de cura.

Seja T uma variável aleatória representando o tempo até a ocorrência do evento. Em modelos clássicos de sobrevivência, a função de sobrevivência é definida por

$$S(t) = P(T > t), \quad t \geq 0,$$

satisfazendo $\lim_{t \rightarrow \infty} S(t) = 0$. Entretanto, em modelos com fração de cura, essa condição deixa de valer, pois há uma probabilidade positiva de o evento nunca ocorrer. Assim, a função de sobrevivência torna-se imprópria, isto é,

$$\lim_{t \rightarrow \infty} S(t) = p_0 > 0,$$

em que p_0 representa a fração de indivíduos curados.

Os modelos de fração de cura podem ser classificados em duas abordagens principais. Isto é, os modelos de mistura e os modelos de não mistura. Nos modelos de mistura, a fração de cura é modelada explicitamente como uma combinação entre curados e suscetíveis. Já nos modelos de não mistura, a estrutura da função de sobrevivência incorpora a fração de cura de forma implícita.

Entre os modelos de não mistura, destaca-se o modelo de tempo de promoção, também conhecido como modelo de risco acumulado limitado.

2.5.1 Modelo de Tempo de Promoção

De uma forma geral a ideia básica do modelo unificado de fração de cura está baseada na noção de ocorrência do evento de interesse em um processo em dois estágios:

Estágio de iniciação. Seja N uma variável aleatória representando o número de causas ou riscos competitivos da ocorrência do evento de interesse. A causa de ocorrência do evento é desconhecida, e a variável N não é observada, com distribuição de probabilidade p_n e sua cauda dadas, respectivamente, por

$$p_n = P[N = n] \quad \text{e} \quad q_n = P[N > n], \quad (2.12)$$

com $n = 0, 1, 2, \dots$

Estágio de maturação. Dado $N = n$, sejam Z_k , $k = 1, \dots, n$, variáveis aleatórias contínuas (não-negativas) independentes com função distribuição acumulada $F(z) = 1 - S(z)$ e independentes de N , que representam o tempo de ocorrência do evento de interesse devido à k -ésima causa. Afim de incluir os indivíduos que não são suscetíveis ao evento de interesse, seu tempo de ocorrência é definido como

$$T = \min(Z_0, Z_1, Z_2, \dots, Z_N) \quad (2.13)$$

em que $P[Z_0 = \infty] = 1$, admitindo a possibilidade que uma proporção p_0 da população não apresenta a ocorrência do evento de interesse, T é uma variável aleatória observável ou censurada e Z_j e N são variáveis latentes.

Seja $\{a_n\}$ uma sequência de números reais. Se s pertence ao intervalo $[0, 1]$

$$A(s) = a_0 + a_1 s + a_2 s^2 + \dots \quad (2.14)$$

converge, então $A(s)$ é definida como a função geradora da sequência $\{a_n\}$.

A função de sobrevivência da variável aleatória T (função de sobrevivência da população) será indicada por

$$\begin{aligned} S_{\text{pop}}(t) &= P[N = 0] + P[Z_1 > t, Z_2 > t, \dots, Z_N > t, N \geq 1] \\ &= P[N = 0] + \sum_{n=1}^{\infty} P[N = n] P[Z_1 > t, Z_2 > t, \dots, Z_N > t] \\ &= p_0 + \sum_{n=1}^{\infty} p_n S(t)^n \\ &= A(S(t)), \end{aligned} \quad (2.15)$$

sendo que $A(\cdot)$ é a função geradora da sequência p_n . Ou seja, a função de sobrevivência da variável aleatória T , correspondente a um modelo de longa duração em dois estágios, é uma composição da função geradora de probabilidades e a função de sobrevivência. A função de

sobrevivência de longa duração em dois estágios $S_{\text{pop}}(t)$ não é uma função de sobrevivência própria.

Observe que, para a função de sobrevivência própria, $\lim_{t \rightarrow 0} S(t) = 1$ e $\lim_{t \rightarrow \infty} S(t) = 0$. Já para a função de sobrevivência imprópria, $\lim_{t \rightarrow 0} S(t) = 1$ e $\lim_{t \rightarrow \infty} S_{\text{pop}}(t) = P[N = 0] = p_0$. Dessa forma, p_0 é a proporção de não ocorrências do evento de interesse na população, ou seja, a fração de cura.

A função de sobrevivência populacional possui as seguintes propriedades:

- Se $p_0 = 1$, então $S_{\text{pop}}(t) = S(t)$;
- $S_{\text{pop}}(0) = 1$;
- $S_{\text{pop}}(t)$ é não crescente;
- $\lim_{t \rightarrow \infty} S_{\text{pop}}(t) = p_0$

As funções de densidade e de risco associadas à função de sobrevivência de longa duração são dadas, respectivamente, por

$$f_{\text{pop}}(t) = f(t) \frac{dA(s)}{ds} \Big|_{s=S(t)} \quad (2.16)$$

e

$$h_{\text{pop}}(t) = \frac{f_{\text{pop}}(t)}{S_{\text{pop}}(t)} = f(t) \frac{\frac{dA(s)}{ds} \Big|_{s=S(t)}}{S_{\text{pop}}(t)}. \quad (2.17)$$

Algumas distribuições são muito utilizadas para as funções geradoras de probabilidade, tais como Bernoulli, Binomial, Poisson, Binomial Negativa e Geométrica e contemplam diferentes modalidades de dispersão. Falaremos de cada uma delas a seguir.

Bernoulli

Seja N uma variável aleatória que representa o número de causas competitivas latentes necessárias para a ocorrência de um determinado evento de interesse, que segue uma distribuição Bernoulli, com parâmetro θ . Sua função de probabilidade de massa dada por

$$P[N = n] = \theta^n (1 - \theta)^{1-n}, \quad n = 0, 1, \dots, \text{ e } 0 < \theta < 1. \quad (2.18)$$

A função geradora de probabilidade de N é dada por

$$A(s) = 1 - \theta + \theta s, \quad 0 \leq s \leq 1. \quad (2.19)$$

E a função de função de sobrevivência de longa duração é dada por

$$S_{\text{pop}}(t) = A(S(t)) = 1 - \theta + \theta S(t), \quad (2.20)$$

obtendo, assim, o modelo conhecido como modelo de mistura padrão (BERKSON; GAGE, 1952), que é um dos mais utilizados na análise de sobrevivência para ajustar dados de longa duração. Ele recebe esse nome, pois consiste de uma mistura de distribuições paramétricas, sendo uma função de sobrevivência própria para a parte da população formada pelos não curados e uma função para os curados, em que a proporção de curados é

$$p_0 = \lim_{t \rightarrow \infty} S_{\text{pop}}(t) = 1 - \theta. \quad (2.21)$$

A função de densidade e de risco são dadas respectivamente por

$$f_{\text{pop}}(t) = \theta f(t) \quad (2.22)$$

e

$$h_{\text{pop}}(t) = \frac{\theta f(t)}{1 - \theta + \theta S(t)}. \quad (2.23)$$

• Binomial

Seja o número N de riscos latentes com distribuição binomial. Uma motivação biológica é, supondo-se que existe um número K de potenciais lugares para a mutação de tumores focalizados numa região do corpo de um indivíduo afetada por uma doença, tem-se que N lugares chegam a sofrer mutações.

Adotamos uma reparametrização do modelo binomial: $\theta^* = \theta / (1 + \theta)$. Assim, seja N uma variável aleatória que representa o número de causas competitivas latentes necessárias para a ocorrência de um determinado evento de interesse com distribuição binomial, sua função de probabilidade de massa é dada por

$$P[N = n^*] = \binom{K}{n^*} \theta^{*n^*} (1 - \theta^*)^{K-n^*}, \quad n^* = 0, 1, \dots, K, \quad 0 < \theta^* < 1, \quad (2.24)$$

com $E[N] = K\theta^*$ e $\text{Var}[N] = K\theta(1 - \theta^*)$, em que K é um número inteiro positivo. A função geradora de probabilidade de N é dada por

$$A(s) = (1 - \theta^* + \theta^* s)^K, \quad 0 \leq s \leq 1. \quad (2.25)$$

A função de função de sobrevivência de longa duração é dada por

$$S_{\text{pop}}(t) = A(S(t)) = S_{\text{pop}}(t) = [1 - \theta^* + \theta^* S(t)]^K, \quad (2.26)$$

sendo que a fração de cura p_0 é dada por

$$p_0 = \lim_{t \rightarrow \infty} S_{\text{pop}}(t) = (1 - \theta^*)^K > 0. \quad (2.27)$$

As funções de densidade e de risco associadas à função de sobrevivência de longa duração binomial são dadas respectivamente por

$$f_{\text{pop}}(t) = K\theta^* f(t) (1 - \theta^* + \theta^* S(t))^{(K-1)} \quad \text{e} \quad h_{\text{pop}}(t) = \frac{K\theta^* f(t)}{\{1 - \theta^* + \theta^* S(t)\}}, \quad (2.28)$$

em que $f(t) = -S'(t)$ é uma função de densidade própria.

Observa-se que, no caso em que K cresce a fração de cura p_0 decresce.

• **Poisson**

Seja o número N de causas do evento de interesse com distribuição de probabilidade de Poisson. Assim, considerando a função geradora de probabilidade da distribuição de Poisson $A(s) = \exp[\theta(1 - s)]$, obtemos as funções de sobrevivência, densidade e de risco da população, dadas respectivamente por

$$S_{\text{pop}}(t) = A(S(t)) = \exp[-\theta F(t)], \quad (2.29)$$

$$f_{\text{pop}}(t) = -\frac{dS_{\text{pop}}(t)}{dt} = \theta f(t) \exp[-\theta F(t)] \quad (2.30)$$

e

$$h_{\text{pop}}(t) = \theta f(t). \quad (2.31)$$

Dessa forma, de (2.29) tem-se a fração de cura dada por $p_0 = \lim_{t \rightarrow \infty} S_{\text{pop}}(t) = \exp(-\theta)$.

2.5.2 Distribuição Gama Generalizada

Em relação a distribuição dos tempos de falha dos indivíduos suscetíveis, propõe-se o uso da distribuição Gama Generalizada (GG), devido à sua elevada flexibilidade e capacidade de acomodar diferentes formatos da função de risco.

A função densidade de probabilidade da distribuição GG é dada por

$$f_{\text{GG}}(t; \alpha, d, p) = \frac{p t^{d-1} \exp(-(t/\alpha)^p)}{\alpha^d \Gamma(d/p)},$$

e sua função de distribuição acumulada é definida como

$$F_{\text{GG}}(t; \alpha, d, p) = \frac{\gamma(d/p, (t/\alpha)^p)}{\Gamma(d/p)},$$

onde $\alpha > 0$ é o parâmetro de escala, $d > 0$ e $p > 0$ são parâmetros de forma, $\Gamma(\cdot)$ é a função gama e $\gamma(\cdot, \cdot)$ denota a função gama incompleta inferior.

A escolha dessa distribuição se justifica pelo fato de incluir importantes modelos clássicos como casos particulares. Por exemplo, quando $d = p$, $p = 1$ ou $d/p \rightarrow \infty$, tem-se uma distribuição Weibull, Gama ou converge para uma Log-Normal

2.5.3 Estimação e verossimilhança penalizada

Considere uma amostra observada composta por n indivíduos,

$$\mathcal{D} = \{(\mathbf{x}_i, t_i, \delta_i)\}_{i=1}^n,$$

em que $\mathbf{x}_i$ representa o vetor de covariáveis, t_i o tempo observado e δ_i o indicador de falha, tal que $\delta_i = 1$ indica ocorrência do evento e $\delta_i = 0$ indica censura.

No modelo de tempo de promoção, a contribuição individual para a log-verossimilhança é dada por

$$\ell_i = \delta_i \log(h_{\text{pop}}(t_i|\mathbf{x}_i)) + \log(S_{\text{pop}}(t_i|\mathbf{x}_i)).$$

No modelo GG-KM, a função de sobrevivência populacional é definida por

$$S_{\text{pop}}(t|\mathbf{x}) = \exp\{-\theta(\mathbf{x})F_{\text{GG}}(t)\},$$

enquanto a função de risco populacional é dada por

$$h_{\text{pop}}(t|\mathbf{x}) = \theta(\mathbf{x})f_{\text{GG}}(t).$$

Substituindo essas expressões na log-verossimilhança e considerando a parametrização $\theta(\mathbf{x}) = \exp(f(\mathbf{x}))$, com $f(\mathbf{x}) = \sum_{j=1}^n \alpha_j K(\mathbf{x}, \mathbf{x}_j)$, obtém-se a função objetivo penalizada

$$J(\Theta) = -\left[\delta^\top (K\alpha + \log f_{\text{GG}}) - w^\top F_{\text{GG}}\right] + \frac{\lambda_{\text{reg}}}{2} \alpha^\top K\alpha,$$

em que:

- $\delta = (\delta_1, \dots, \delta_n)^\top$ é o vetor de indicadores de censura;
- K é a matriz de Gram associada ao kernel escolhido;
- $w = \exp(K\alpha)$ representa o vetor das intensidades latentes, com a exponencial aplicada elemento a elemento;
- $\log f_{\text{GG}} = (\log f_{\text{GG}}(t_1), \dots, \log f_{\text{GG}}(t_n))^\top$;
- $F_{\text{GG}} = (F_{\text{GG}}(t_1), \dots, F_{\text{GG}}(t_n))^\top$.

A expressão matricial acima pode ser expandida na forma escalar equivalente:

$$J(\Theta) = -\sum_{i=1}^n \left\{ \delta_i [f(\mathbf{x}_i) + \log f_{\text{GG}}(t_i)] - \exp(f(\mathbf{x}_i)) F_{\text{GG}}(t_i) \right\} + \frac{\lambda_{\text{reg}}}{2} \alpha^\top K\alpha.$$

Substituindo as expressões explícitas da distribuição Gama Generalizada, obtém-se:

$$J(\Theta) = -\sum_{i=1}^n \left\{ \delta_i \left[f_i + \log p + (d-1) \log t_i - \left(\frac{t_i}{a}\right)^p - d \log a - \log \Gamma\left(\frac{d}{p}\right) \right] \right\}$$

$$+ \sum_{i=1}^n \left[\exp(f_i) \frac{\gamma\left(\frac{d}{p}, \left(\frac{t_i}{a}\right)^p\right)}{\Gamma\left(\frac{d}{p}\right)} \right] + \frac{\lambda_{\text{reg}}}{2} \alpha^\top \mathbf{K} \alpha,$$

em que $f_i = f(\mathbf{x}_i)$.

A estimação dos parâmetros $\Theta = (\alpha, a, d, p)$ é realizada por minimização numérica da função objetivo $J(\Theta)$. Como não existe solução analítica fechada, utiliza-se o algoritmo L-BFGS (LIU; NOCEDAL, 1989), que apresenta boa eficiência computacional e estabilidade numérica em problemas de otimização de alta dimensão.

2.5.4 Gradientes analíticos

A otimização da função objetivo penalizada $J(\Theta)$ requer o cálculo de seus gradientes em relação a todos os parâmetros do modelo. A obtenção dessas expressões em forma analítica é fundamental para aumentar a eficiência computacional do algoritmo, além de melhorar sua estabilidade numérica durante o processo iterativo.

Seja

$$w_i = \exp(f(\mathbf{x}_i))$$

a intensidade estimada de riscos latentes para o indivíduo i . O gradiente em relação ao vetor de coeficientes do kernel $\alpha \in \mathbb{R}^n$ é dado por

$$\nabla_{\alpha} J = -\mathbf{K}(\delta - \mathbf{w} \odot \mathbf{F}_{GG}) + \lambda_{\text{reg}} \mathbf{K} \alpha,$$

em que $\odot$ representa o produto de Hadamard.

Para os parâmetros da distribuição Gama Generalizada, definem-se as quantidades auxiliares

$$u_i = \left(\frac{t_i}{a}\right)^p \quad \text{e} \quad s = \frac{d}{p}.$$

Os gradientes em relação aos parâmetros a , d e p são dados, respectivamente, por

$$\frac{\partial J}{\partial a} = - \sum_{i=1}^n \left[\delta_i \left(\frac{p u_i - d}{a} \right) + w_i \left(\frac{p e^{-u_i} u_i^s}{a \Gamma(s)} \right) \right],$$

$$\frac{\partial J}{\partial d} = - \sum_{i=1}^n \left[\delta_i \left(\log\left(\frac{t_i}{a}\right) - \frac{\psi(s)}{p} \right) - \frac{w_i}{p} G(s, u_i) \right],$$

$$\frac{\partial J}{\partial p} = - \sum_{i=1}^n \left[\delta_i \left(\frac{1}{p} - u_i \log\left(\frac{t_i}{a}\right) + \frac{s \psi(s)}{p} \right) - w_i \left(\frac{d G(s, u_i)}{p^2} + \frac{u_i^s e^{-u_i} \log(t_i/a)}{\Gamma(s)} \right) \right].$$

Nessas expressões:

- $\Gamma(s)$ é a função Gama;
- $\psi(s) = \frac{d}{ds} \log \Gamma(s)$ é a função digama;
- $G(s, u) = \frac{\partial P(s, u)}{\partial s}$ é a derivada parcial da função gama incompleta regularizada em relação ao seu primeiro argumento.

O processo de estimação do modelo GG-KM pode ser resumido pelo Algoritmo 1.

Algoritmo 1 – Processo de estimação do modelo GG-KM

- 1: **Entrada:** Dados (X, t, δ) , hiperparâmetros (λ_{reg}, γ)
 - 2: Inicializar $\alpha \leftarrow 0$ e $\theta_{GG} \leftarrow \{\alpha = 1, d = 1, p = 1\}$
 - 3: Construir a matriz de Gram K , com $K_{ij} = K(\mathbf{x}_i, \mathbf{x}_j)$
 - 4: **enquanto** critério de convergência não satisfeito **faça**
 - 5: Calcular $w_i = \exp\left(\sum_j \alpha_j K_{ij}\right)$
 - 6: Calcular $f_{GG}(t_i)$ e $F_{GG}(t_i)$ para os parâmetros atuais
 - 7: Avaliar a função objetivo $J(\alpha, \theta_{GG})$
 - 8: Calcular os gradientes $\nabla_{\alpha} J$ e $\nabla_{\theta_{GG}} J$
 - 9: Atualizar $\Theta = \{\alpha, d, p\}$ utilizando L-BFGS
 - 10: **fim enquanto**
 - 11: **Saída:** $\hat{\alpha}, \hat{d}, \hat{p}$
-

MÉTODOS BASEADOS EM KERNEL

Métodos baseados em Kernel são técnicas extremamente flexíveis que podem ser utilizados para estender modelos ou algoritmos para regiões de decisão não lineares ([MOHRI; ROSTA-MIZADEH; TALWALKAR, 2018](#)). Estes métodos são baseados nas conhecidas funções de kernel, os quais, sob condições de simetria e positiva definida, definem produtos internos em espaços de alta dimensão, conhecidos como espaços de Hilbert. Dessa forma, este capítulo terá como objetivo definir e apresentar os conceitos fundamentais sobre métodos baseados em kernel, incluindo a definição de funções de kernel, o teorema do representer e Reproducing Kernel Hilbert Space (RKHS).

3.1 Kernels

Por definição, uma função $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ é chamada de kernel sobre $\mathcal{X}$. A ideia central é construir um kernel K tal que, para quaisquer dois pontos $x, x' \in \mathcal{X}$, $K(x, x')$ corresponda ao produto interno entre duas representações desses pontos em um espaço de Hilbert $\mathcal{H}$, isto é,

$$\forall x, x' \in \mathcal{X}, \quad K(x, x') = \langle \phi(x), \phi(x') \rangle,$$

para algum mapeamento $\phi : \mathcal{X} \rightarrow \mathcal{H}$. O espaço $\mathcal{H}$ é chamado de feature space.

Sob essa perspectiva, o kernel pode ser interpretado como uma medida de similaridade entre elementos de $\mathcal{X}$, uma vez que o produto interno mensura a similaridade entre dois vetores.

Uma vantagem fundamental dessa abordagem é computacional. Isto é, muitas vezes é significativamente mais eficiente calcular diretamente $K(x, x')$ do que computar explicitamente $\phi(x)$ e $\phi(x')$ e então avaliar seu produto interno.

3.1.1 Kernels positivos definidos

Para que uma função K possa ser utilizada como kernel, é necessário que sejam satisfeitas duas condições, que a função seja simétrica e positiva definida. Satisfazendo essas condições, o kernel é capaz de induzir uma geometria em um espaço de Hilbert.

Formalmente, um kernel $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ é dito simétrico e positivo definido se, para qualquer conjunto finito $\{x_1, \dots, x_n\} \subset \mathcal{X}$, a matriz de Gram

$$\mathbf{K} = [K(x_i, x_j)]_{i,j=1}^n \in \mathbb{R}^{n \times n}$$

for positiva semidefinida. Isto é, para qualquer vetor $\mathbf{c} = (c_1, \dots, c_n)^\top \in \mathbb{R}^n$,

$$\mathbf{c}^\top \mathbf{K} \mathbf{c} = \sum_{i=1}^n \sum_{j=1}^n c_i c_j K(x_i, x_j) \geq 0.$$

Equivalentemente, todos os autovalores de $\mathbf{K}$ são não negativos. Essa propriedade é essencial, pois garante a existência de uma representação geométrica consistente do kernel.

3.1.2 Espaços de Hilbert

A noção de espaço de Hilbert fornece a estrutura matemática necessária para a teoria de kernels.

Por definição, um espaço de Hilbert $\mathcal{H}$ é um espaço vetorial munido de um produto interno $\langle \cdot, \cdot \rangle_{\mathcal{H}}$ e que é completo com relação à norma induzida por esse produto interno. A norma em $\mathcal{H}$ é definida por

$$\forall h \in \mathcal{H}, \quad \|h\|_{\mathcal{H}} = \sqrt{\langle h, h \rangle}.$$

A completude implica que toda sequência de Cauchy em $\mathcal{H}$ converge para um elemento do próprio espaço, garantindo estabilidade analítica para problemas de otimização e aproximação.

No contexto de kernels, o espaço de Hilbert atua como o espaço onde os dados são representados via o mapeamento ϕ .

3.1.3 Reproducing Kernel Hilbert Spaces

A relação entre kernels positivos definidos e espaços de Hilbert é formalizada pelo teorema.

Seja $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ um kernel simétrico e positivo definido. Então existe um espaço de Hilbert $\mathcal{H}$ e um mapeamento $\phi : \mathcal{X} \rightarrow \mathcal{H}$ tais que

$$\forall x, x' \in \mathcal{X}, \quad K(x, x') = \langle \phi(x), \phi(x') \rangle_{\mathcal{H}}.$$

Além disso, esse espaço satisfaz a chamada propriedade de reprodução:

$$\forall h \in \mathcal{H}, \forall x \in \mathcal{X}, \quad h(x) = \langle h, K(x, \cdot) \rangle_{\mathcal{H}}.$$

Essa propriedade estabelece que a avaliação funcional é contínua e pode ser representada por meio do próprio kernel.

O espaço $\mathcal{H}$ associado a K é chamado de Reproducing Kernel Hilbert Space (RKHS), desempenhando papel central em métodos de aprendizado estatístico, particularmente em problemas de regularização, estimação não paramétrica e aprendizado supervisionado.

3.1.4 Teorema do Representante

O resultado mais interessante para a definição do modelo GG-KM é o Teorema do Representante. Sua principal importância reside no fato de garantir que, embora a otimização ocorra em um espaço potencialmente infinito-dimensional, a solução ótima pode ser expressa em termos de uma combinação finita de kernels avaliados nas observações da amostra.

Formalmente, seja $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ um kernel positivo definido e $\mathcal{H}$ seu correspondente RKHS. Assim, para qualquer função $G : \mathbb{R} \rightarrow \mathbb{R}$ não decrescente e qualquer função perda $L : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$, o problema de otimização

$$\arg \min_{h \in \mathcal{H}} F(h) = \arg \min_{h \in \mathcal{H}} G(\|h\|_{\mathcal{H}}) + L(h(x_1), \dots, h(x_n))$$

admite uma solução na forma $h^* = \sum_{i=1}^n \alpha_i K(x_i, \cdot)$. Se G é assumido como sendo crescente, então qualquer solução tem esta forma.

Esse resultado é particularmente relevante porque reduz um problema de otimização funcional em dimensão infinita para um problema de otimização em dimensão finita, dependente apenas dos coeficientes $\alpha = (\alpha_1, \dots, \alpha_n)$. Na prática, isso torna viável o uso de métodos baseados em kernel, além de evidenciar que toda a informação necessária para a estimação está contida na matriz kernel K , sem necessidade de explicitar o mapeamento $\phi(\cdot)$.

A escolha do kernel determina implicitamente a classe de funções admissíveis no espaço RKHS e, conseqüentemente, o grau de complexidade que o modelo pode representar. Neste contexto, os kernels podem ser visto como um hiperparâmetro de complexidade do modelo, bem como as variáveis que os compõe, γ , d e σ .

3.2 GG-KM

O modelo proposto GG-KM, nada mais é que uma proposta de modelar o valor esperado dos riscos latentes do modelo de tempo de promoção a partir da integração de kernels, de forma que seja uma extensão semi-paramétrica. Esta seção terá como objetivo descrever o processo de estimação e fundamentação do modelo.

3.2.1 Extensão não paramétrica via kernel

Embora o modelo de tempo de promoção clássico permita incorporar covariáveis por meio de funções paramétricas para $\theta(\mathbf{x})$, essa abordagem pode ser restritiva em cenários onde a relação entre as covariáveis e a fração de cura apresenta estruturas complexas ou altamente não lineares.

Neste contexto, propõe-se modelar a intensidade média dos riscos latentes $\theta(\mathbf{x})$ por meio de uma função não paramétrica $f(\mathbf{x}) = \log(\theta(\mathbf{x})) > 0$. Dessa forma, suponha que a estimação do modelo de promoção de cura seja feita por meio da maximização da log-verossimilhança penalizada:

$$\max_f \sum_{i=1}^n l(\mathbf{x}_i) - \lambda \|f\|^2 = \min_f \sum_{i=1}^n -l(\mathbf{x}_i) + \lambda \|f\|^2 \quad (3.1)$$

em que $l(\mathbf{x}_i)$ representa a log-verossimilhança e λ é um parâmetro de regularização da complexidade do modelo. No entanto, supondo que a função f pertença a um Reproducing Kernel Hilbert Space (RKHS) $\mathcal{H}_K$, associado a um kernel positivo definido $K(\cdot, \cdot)$, o Teorema do Representante garante que a solução do problema da Equação 3.1 pode ser expressa da seguinte forma:

$$f^*(\mathbf{x}) = \sum_{i=1}^n \alpha_i K(\mathbf{x}, \mathbf{x}_i), \quad (3.2)$$

em que $\alpha_1, \dots, \alpha_n \in \mathbb{R}$ são coeficientes a serem estimados. Consequentemente, a intensidade média dos riscos latentes para o indivíduo i pode ser escrita como

$$\theta(\mathbf{x}_i) = \exp \left(\sum_{j=1}^n \alpha_j K(\mathbf{x}_i, \mathbf{x}_j) \right). \quad (3.3)$$

3.2.2 Estimação via algoritmo EM penalizado

A representação obtida pelo Teorema do Representante permite reescrever o modelo de tempo de promoção em termos de um número finito de parâmetros. Seja

$$f(\mathbf{x}_i) = \sum_{j=1}^n \alpha_j K(\mathbf{x}_i, \mathbf{x}_j), \quad (3.4)$$

Sob a formulação do modelo de tempo de promoção, assume-se que o número de riscos latentes associados ao indivíduo i segue uma distribuição de Poisson com média $\theta(\mathbf{x}_i)$, isto é,

$$N_i | \mathbf{x}_i \sim \text{Poisson}(\theta(\mathbf{x}_i)). \quad (3.5)$$

Entretanto, os riscos competitivos N_i associados ao evento de interesse não são observados. Assim, a estimação dos parâmetros pode ser conduzida por meio do algoritmo EM. Neste caso, considera-se o algoritmo EM penalizado (MCLACHLAN; KRISHNAN, 2008).

Dessa forma, considere os dados completos $D_{\text{comp}} = \{t_i, \delta_i, N_i, \mathbf{x}_i\}_{i=1}^n$, em que t_i representa o tempo observado, δ_i o indicador de falha e N_i o número de riscos latentes associados ao i -ésimo indivíduo. A log-verossimilhança completa, menos uma constante aditiva, pode ser escrita como

$$\begin{aligned} l_c = & \sum_{i=1}^n [-\exp(f(\mathbf{x}_i)) + N_i f(\mathbf{x}_i)] \\ & + \sum_{i=1}^n [\delta_i \log f_{\text{GG}}(t_i; \mathbf{a}, \mathbf{d}, \mathbf{p})] \\ & + \sum_{i=1}^n [(N_i - \delta_i) \log S_{\text{GG}}(t_i; \mathbf{a}, \mathbf{d}, \mathbf{p})]. \end{aligned} \quad (3.6)$$

Para controlar a complexidade da função estimada, adiciona-se uma penalização baseada na norma do RKHS. Dessa forma, obtém-se a log-verossimilhança completa penalizada

$$\ell_{c,p} = l_c - \frac{\lambda}{2} \boldsymbol{\alpha}^\top \mathbf{K} \boldsymbol{\alpha}, \quad (3.7)$$

em que

$$\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_n)^\top \quad (3.8)$$

e $\mathbf{K}$ denota a matriz de kernel com elementos $K_{ij} = K(\mathbf{x}_i, \mathbf{x}_j)$.

O algoritmo EM consiste em alternar entre o cálculo da esperança condicional dos riscos latentes e a maximização da esperança da log-verossimilhança completa penalizada.

No passo E, calcula-se

$$Q(\boldsymbol{\Theta} | \boldsymbol{\Theta}^{(k)}) = \mathbb{E} [\ell_{c,p} | \mathcal{D}_{\text{obs}}, \boldsymbol{\Theta}^{(k)}]. \quad (3.9)$$

em que $\boldsymbol{\Theta} = (\boldsymbol{\alpha}, \mathbf{a}, \mathbf{d}, \mathbf{p})$.

Utilizando propriedades do modelo de tempo de promoção, obtém-se que

$$\hat{N}_i^{(k+1)} = \mathbb{E} [N_i | \mathcal{D}_{\text{obs}}, \boldsymbol{\Theta}^{(k)}] = \delta_i + \theta_i^{(k)} S_{\text{GG}}(t_i; \mathbf{a}^{(k)}, \mathbf{d}^{(k)}, \mathbf{p}^{(k)}), \quad (3.10)$$

em que

$$\theta_i^{(k)} = \exp(f^{(k)}(\mathbf{x}_i)) = \exp\left(\sum_{j=1}^n \alpha_j^{(k)} K(\mathbf{x}_i, \mathbf{x}_j)\right). \quad (3.11)$$

Substituindo as quantidades não observadas por suas respectivas esperanças condicionais, a função auxiliar penalizada assume a forma

$$Q_P = Q_\alpha + Q_{\text{GG}}, \quad (3.12)$$

com

$$Q_\alpha = \sum_{i=1}^n [-\exp(f(\mathbf{x}_i)) + \hat{N}_i^{(k+1)} f(\mathbf{x}_i)] - \frac{\lambda}{2} \boldsymbol{\alpha}^\top \mathbf{K} \boldsymbol{\alpha}, \quad (3.13)$$

e

$$Q_{GG} = \sum_{i=1}^n \left[\delta_i \log f_{GG}(t_i; \alpha, d, p) + (\hat{N}_i^{(k+1)} - \delta_i) \log S_{GG}(t_i; \alpha, d, p) \right]. \quad (3.14)$$

Observa-se que a função auxiliar penalizada é separável em dois blocos de parâmetros, α e (α, d, p) . Consequentemente, o passo M pode ser realizado por otimização alternada.

Inicialmente, atualizam-se os coeficientes do kernel resolvendo

$$\alpha^{(k+1)} = \arg \max_{\alpha} Q_{\alpha}. \quad (3.15)$$

Em seguida, atualizam-se os parâmetros da distribuição Gama Generalizada por meio de

$$(\alpha^{(k+1)}, d^{(k+1)}, p^{(k+1)}) = \arg \max_{\alpha, d, p} Q_{GG}. \quad (3.16)$$

A otimização de ambos problemas de otimização é realizada numericamente através de L-BFGS-B, utilizando-se as derivadas analíticas das respectivas funções objetivos.

O processo iterativo é repetido até a convergência da log-verossimilhança penalizada observada,

$$\ell_p = \sum_{i=1}^n \left[\delta_i (f(\mathbf{x}_i) + \log f_{GG}(t_i; \alpha, d, p)) - \exp(f(\mathbf{x}_i)) F_{GG}(t_i; \alpha, d, p) \right] - \frac{\lambda}{2} \alpha^\top K \alpha, \quad (3.17)$$

sendo adotado como critério de parada

$$\left| \ell_p^{(k+1)} - \ell_p^{(k)} \right| < \varepsilon, \quad (3.18)$$

em que $\varepsilon > 0$ representa uma tolerância previamente especificada.

Algoritmo 2 – Algoritmo EM penalizado para estimar o modelo GG-KM

1: Inicialize $\alpha^{(0)}$, $\mathbf{a}^{(0)}$, $\mathbf{d}^{(0)}$, $\mathbf{p}^{(0)}$ e escolha uma tolerância $\varepsilon > 0$.

2: Defina $k \leftarrow 0$.

3: **repita**

4: Calcule

$$\theta_i^{(k)} = \exp \left(\sum_{j=1}^n \alpha_j^{(k)} K(x_i, x_j) \right), \quad i = 1, \dots, n.$$

5: Calcule

$$F_i^{(k)} = F_{GG}(t_i; \mathbf{a}^{(k)}, \mathbf{d}^{(k)}, \mathbf{p}^{(k)}), \quad S_i^{(k)} = 1 - F_i^{(k)}.$$

6: **E-step:** para $i = 1, \dots, n$, calcule

$$\hat{N}_i^{(k+1)} = \delta_i + \theta_i^{(k)} S_i^{(k)}.$$

7: **M-step (α):**

$$\alpha^{(k+1)} = \arg \max_{\alpha} \left\{ \sum_{i=1}^n \left[-\theta_i + \hat{N}_i^{(k+1)} \log(\theta_i) \right] - \frac{\lambda_{\text{reg}}}{2} \alpha^\top K \alpha \right\},$$

onde

$$\theta_i = \exp \left(\sum_{j=1}^n \alpha_j K(x_i, x_j) \right).$$

8: **M-step (GG):**

$$(\mathbf{a}^{(k+1)}, \mathbf{d}^{(k+1)}, \mathbf{p}^{(k+1)}) = \arg \max_{\mathbf{a}, \mathbf{d}, \mathbf{p}} \sum_{i=1}^n \left[\delta_i \log f_{GG}(t_i; \mathbf{a}, \mathbf{d}, \mathbf{p}) + (\hat{N}_i^{(k+1)} - \delta_i) \log S_{GG}(t_i; \mathbf{a}, \mathbf{d}, \mathbf{p}) \right].$$

9: Calcule

$$f_i^{(k+1)} = \sum_{j=1}^n \alpha_j^{(k+1)} K(x_i, x_j), \quad \theta_i^{(k+1)} = \exp(f_i^{(k+1)}).$$

10: Calcule a log-verossimilhança penalizada observada

$$\begin{aligned} \ell_p^{(k+1)} = & \sum_{i=1}^n \left[\delta_i \left(f_i^{(k+1)} + \log f_{GG}(t_i; \mathbf{a}^{(k+1)}, \mathbf{d}^{(k+1)}, \mathbf{p}^{(k+1)}) \right) \right. \\ & \left. - \theta_i^{(k+1)} F_{GG}(t_i; \mathbf{a}^{(k+1)}, \mathbf{d}^{(k+1)}, \mathbf{p}^{(k+1)}) \right] \\ & - \frac{\lambda_{\text{reg}}}{2} (\alpha^{(k+1)})^\top K \alpha^{(k+1)}. \end{aligned}$$

11: Calcule

$$\Delta^{(k+1)} = \left| \ell_p^{(k+1)} - \ell_p^{(k)} \right|.$$

12: $k \leftarrow k + 1$.

13: **até** $\Delta^{(k+1)} < \varepsilon$

AVALIAÇÃO EXPERIMENTAL

Este capítulo descreve, de forma sistemática, os procedimentos adotados para a construção, treinamento e avaliação dos modelos considerados neste trabalho. Em particular, são detalhados os processos de particionamento dos dados, seleção de hiperparâmetros e geração de dados experimentais, seguindo práticas consolidadas na literatura de aprendizado de máquina aplicado à análise de sobrevivência.

4.1 Recursos Computacionais

Nesta seção, são apresentados os principais recursos computacionais utilizados no desenvolvimento deste trabalho, incluindo ferramentas para escrita do documento, linguagens de programação empregadas na implementação dos modelos e bibliotecas utilizadas na resolução dos problemas de otimização convexa. A escolha dessas ferramentas foi guiada pela necessidade de garantir rigor científico, reprodutibilidade dos experimentos e eficiência computacional na implementação dos algoritmos propostos.

4.1.1 *Ambiente de desenvolvimento e escrita*

A redação deste trabalho foi realizada utilizando o sistema de preparação de documentos $\text{\LaTeX}$, amplamente adotado na comunidade científica devido à sua capacidade de lidar de forma robusta com expressões matemáticas, referências bibliográficas e formatação de documentos técnicos. O uso do $\text{\LaTeX}$ foi particularmente importante neste trabalho, dado o elevado número de equações e demonstrações envolvidas na formulação dos modelos baseados em máquinas de vetores de suporte.

Para a edição do código-fonte e do documento, foi utilizado o editor Visual Studio Code (VSCode), que oferece um ambiente leve e altamente configurável. O VSCode permite integração com diversas extensões, possibilitando suporte eficiente tanto para a escrita em $\text{\LaTeX}$ quanto

para o desenvolvimento em linguagens de programação como Python. Entre as funcionalidades utilizadas, destacam-se a navegação facilitada entre arquivos, realce de sintaxe, execução de scripts e integração com sistemas de controle de versão.

4.1.2 Linguagem de programação e implementação dos modelos

A implementação dos modelos propostos neste trabalho foi realizada na linguagem de programação Python, devido à sua ampla adoção na área de ciência de dados e aprendizado de máquina, bem como à disponibilidade de bibliotecas eficientes para computação numérica.

O Python foi utilizado tanto para a geração de dados simulados quanto para a implementação do algoritmo proposto, o GG-KM. As bibliotecas utilizadas para estimação do modelo foram NumPy ([HARRIS *et al.*, 2020](#)), que oferece estruturas eficientes para operações matriciais e vetoriais, e o SciPy ([VIRTANEN *et al.*, 2020](#)), que contém diferentes métodos de otimização, como, por exemplo, o L-BFGS.

4.2 Particionamento dos dados

A avaliação do desempenho preditivo dos modelos foi conduzida por meio de um esquema de validação baseado na divisão dos dados em conjuntos de treinamento e teste. Especificamente, adotou-se uma estratégia de holdout, na qual 70% das observações foram utilizadas para treinamento e os 30% restantes reservados para teste.

A separação foi realizada de forma aleatória, preservando, sempre que aplicável, a estrutura dos dados censurados, de modo a garantir que ambos os subconjuntos apresentassem proporções semelhantes de observações censuradas e não censuradas. Essa precaução é particularmente importante em problemas de análise de sobrevivência, uma vez que a distribuição dos tipos de censura pode influenciar significativamente o desempenho dos modelos.

Adicionalmente, com o objetivo de reduzir a variabilidade associada a uma única partição, o procedimento de holdout foi repetido múltiplas vezes. As métricas de desempenho foram então agregadas ao longo dessas repetições, considerando medidas como média, mediana e desvio padrão, proporcionando uma avaliação mais robusta e estável.

4.3 Estudo de simulação e Métricas de Erro

Com o objetivo de avaliar o desempenho do modelo GG-KM em diferentes cenários de complexidade da fração de cura, foi conduzido um estudo de simulação, seguindo a mesma estrutura de geração de dados proposta por [Pal e Aselisewine \(2023\)](#), adaptada ao contexto do modelo de tempo de promoção.

Foram considerados dois tamanhos de amostra, $n = 300$ e $n = 600$. Em cada replicação, os dados foram particionados em conjunto de treinamento e teste, sendo dois terços das observações destinados ao treinamento e o terço restante utilizado para avaliação preditiva.

Cada conjunto de dados foi gerado a partir de duas covariáveis independentes,

$$x_1, x_2 \sim N(0, 1).$$

A estrutura de cura foi construída a partir de três métodos distintos para a geração da probabilidade de não cura, permitindo avaliar o comportamento do modelo sob diferentes graus de linearidade e não linearidade. Para o primeiro caso, considera-se uma fronteira linear, dada por

$$\pi(\mathbf{x}) = \frac{\exp(0.3 - 5x_1 - 3x_2)}{1 + \exp(0.3 - 5x_1 - 3x_2)}.$$

Esse cenário representa a estrutura clássica de regressão logística, em que indivíduos curados e não curados são linearmente separáveis.

No segundo método, é introduzido uma relação quadrática entre as covariáveis, com o objetivo de avaliar a capacidade do modelo em capturar superfícies de decisão não lineares. Portanto, tem-se:

$$\pi(\mathbf{x}) = \frac{\exp(0.3 + 5x_1^2 - 3x_2^2)}{1 + \exp(0.3 + 5x_1^2 - 3x_2^2)}.$$

Por fim, o para o terceiro método, é considerado uma estrutura não linear e periódica:

$$\pi(\mathbf{x}) = \exp\{-\exp(0.3 - 5\cos(x_1) - 3\sin(x_2))\}.$$




Figura 1 – Simulação de curados e não curados sobre os três métodos descritos. Respectivamente, pode-se observar o método 1, 2 e 3.

Esse cenário impõe fronteiras de classificação complexas, sendo particularmente útil para avaliar a flexibilidade da abordagem baseada em kernels. Os dados simulados, considerando cada um dos três casos, pode ser visualizado na Figura 1.

Para a componente de latência, os tempos associados aos riscos latentes foram gerados a partir de uma distribuição Weibull, cuja função de risco é dada por

$$h(t|\mathbf{x}) = h_0(t) \exp(\beta_1 x_1 + \beta_2 x_2),$$

onde a função de risco basal foi definida como

$$h_0(t) = \alpha t^{\alpha-1}, \quad \alpha > 0.$$

Essa especificação implica que os tempos latentes seguem uma distribuição Weibull com parâmetro de forma α e parâmetro de escala

$$\lambda(\mathbf{x}) = \{\exp(\beta_1 x_1 + \beta_2 x_2)\}^{-1/\alpha}.$$

Os valores utilizados para os parâmetros foram $(\alpha, \beta_1, \beta_2) = (2, 1, 0.5)$. Os tempos de censura foram gerados independentemente a partir de uma distribuição exponencial com taxa igual a 0.2, isto é $C_i \sim \text{Exp}(0.2)$. A partir desta configuração, a proporção de censura obtida para o método 1, 2 e 3 é de aproximadamente 0,60, 0,50 e 0,40, respectivamente. Para a proporção de cura foi obtido aproximadamente 0,50, 0,60 e 0,20.

A geração dos dados simulados foi realizada com base na estrutura do modelo de fração de cura em tempo de promoção. Nesse contexto, cada indivíduo pode pertencer a um de dois grupos: curados ou suscetíveis ao evento de interesse. A probabilidade de um indivíduo ser suscetível é dada por $\pi(\mathbf{x}_i)$, enquanto a probabilidade de ser curado é $1 - \pi(\mathbf{x}_i)$.

O processo de simulação ocorre em duas etapas. Inicialmente, para cada indivíduo, gera-se uma variável uniforme U_i e um tempo de censura C_i . O valor de U_i é utilizado para determinar se o indivíduo pertence ao grupo curado ou suscetível. Caso $U_i \leq 1 - \pi(\mathbf{x}_i)$, o indivíduo é classificado como curado e seu tempo observado corresponde apenas ao tempo de censura.

Por outro lado, se $U_i > 1 - \pi(\mathbf{x}_i)$, o indivíduo é considerado suscetível. Nesse caso, gera-se um tempo latente de falha Y_i utilizando o método da transformada inversa aplicado à função de sobrevivência populacional. Para isso, sorteia-se uma nova variável uniforme no intervalo $(1 - \pi(\mathbf{x}_i), 1)$ e resolve-se a equação associada à função de sobrevivência, obtendo assim o tempo de falha latente.

Por fim, o tempo observado é definido como o mínimo entre o tempo latente de falha e o tempo de censura. O indicador de falha é então determinado de acordo com qual desses tempos ocorreu primeiro. Esse procedimento garante que os dados simulados preservem simultaneamente a estrutura de fração de cura e a presença de censura à direita. O algoritmo pode ser visualizado no Algoritmo 3

Algoritmo 3 – Geração de dados simulados com fração de cura

```

1: para  $i = 1, \dots, n$  faça
2:   Gerar  $U_i \sim \text{Uniform}(0, 1)$ 
3:   Gerar  $C_i \sim \text{Exp}(0.2)$ 
4:   se  $U_i \leq 1 - \pi(\mathbf{x}_i)$  então
5:     Definir  $t_i \leftarrow C_i$ 
6:     Definir  $\delta_i \leftarrow 0$ 
7:   senão
8:     Gerar  $U_i^* \sim \text{Uniform}(1 - \pi(\mathbf{x}_i), 1)$ 
9:     Resolver

```

$$(1 - \pi(\mathbf{x}_i))^{F(Y_i|\mathbf{x}_i)} = U_i^*$$

```

10:   Obter

```

$$Y_i = F^{-1} \left(\frac{\log(U_i^*)}{\log(1 - \pi(\mathbf{x}_i))} \right)$$

```

11:   Definir  $t_i \leftarrow \min(Y_i, C_i)$ 
12:   se  $t_i = Y_i$  então
13:     Definir  $\delta_i \leftarrow 1$ 
14:   senão
15:     Definir  $\delta_i \leftarrow 0$ 
16:   fim se
17: fim se
18: fim para

```

O desempenho do modelo GG-KM foi avaliado com base no viés, erro quadrático médio (EQM) e no *Integrated Brier Score* (IBS) com ajuste IPCW (*Inverse Probability of Censoring Weighting*) (DONG *et al.*, 2020), permitindo mensurar tanto a qualidade da estimação dos parâmetros quanto a capacidade preditiva do modelo.

Seja $\hat{S}_i(t)$ a probabilidade de sobrevivência estimada para o indivíduo i no tempo t , e T_i^* o tempo observado. Os pesos IPCW são definidos por

$$\omega_i(t) = \frac{\mathbb{I}(T_i^* \leq t, \delta_i = 1)}{\hat{G}(T_i^*)} + \frac{\mathbb{I}(T_i^* > t)}{\hat{G}(t)},$$

em que $\hat{G}(t)$ representa a função de sobrevivência do mecanismo de censura, geralmente estimada pelo método de Kaplan-Meier.

Com isso, o Brier Score ajustado por IPCW no tempo t é dado por

$$BS_{IPCW}(t) = \frac{1}{\tilde{n}(t)} \sum_{i=1}^n \left[\hat{S}_i(t)^2 \frac{\mathbb{I}(T_i^* \leq t, \delta_i = 1)}{\hat{G}(T_i^*)} + (1 - \hat{S}_i(t))^2 \frac{\mathbb{I}(T_i^* > t)}{\hat{G}(t)} \right],$$

em que

$$\tilde{n}(t) = \sum_{i=1}^n \omega_i(t)$$

corresponde à soma dos pesos IPCW no tempo t .

O IBS é então definido como a integral do Brier Score ao longo do intervalo de acompanhamento:

$$\text{IBS} = \frac{1}{\tau} \int_0^{\tau} \text{BS}_{\text{IPCW}}(t) dt,$$

em que τ representa o tempo máximo de observação.

Por fim, a estimativa do EQM e do viés em relação à probabilidade dos não curados foi obtida a partir das seguintes expressões, respectivamente ([PAL; ASELISEWINE, 2023](#)):

$$\text{Viés}(\hat{\pi}(\mathbf{x})) = \frac{1}{N_1} \sum_{r=1}^{N_1} \left[\frac{1}{n} \sum_{i=1}^n \{ \pi^{(r)}(\mathbf{x}_i) - \pi^{(r)}(\mathbf{x}_i) \} \right],$$

$$\text{EQM}(\hat{\pi}(\mathbf{x})) = \frac{1}{N_1} \sum_{r=1}^{N_1} \left[\frac{1}{n} \sum_{i=1}^n \left\{ \pi^{(r)}(\mathbf{x}_i) - \pi^{(r)}(\mathbf{x}_i) \right\}^2 \right].$$

RESULTADOS

5.1 Aplicação a Dados Simulados

Nesta seção, avalia-se o desempenho do modelo proposto GG-KM em diferentes cenários de simulação, com o objetivo de investigar sua capacidade de adaptação sob diferentes estruturas do componente de cura. Para isso, foram considerados dois tamanhos de amostra ($n = 300$ e $n = 600$) e três métodos para geração de dados, representando diferentes relações entre covariáveis e fração de cura.

A Figura 2 apresenta a distribuição do IBS para cada kernel, obtida ao longo das replicações da validação cruzada. Como medida global de desempenho preditivo em análise de sobrevivência, menores valores de IBS indicam melhor ajuste.

De forma geral, observa-se que a escolha do kernel impacta diretamente a qualidade das estimativas, sobretudo em cenários mais complexos. No método 1, o desempenho entre os kernels é relativamente mais heterogêneo, com vantagem para kernels como cauchy, exponential e sigmoid, que apresentam menores valores centrais de IBS e menor variabilidade.

Nos métodos 2 e 3, por outro lado, o padrão é mais consistente: kernels não lineares, em especial rbf, cauchy, exponential e polynomial, tendem a apresentar melhor desempenho e maior estabilidade quando comparados ao kernel linear. Esse comportamento sugere que tais cenários envolvem estruturas mais complexas, cuja modelagem é favorecida por espaços de maior flexibilidade induzidos por esses kernels.

Dessa forma, os resultados mostram que o desempenho do GG-KM é fortemente dependente da especificação do kernel, sendo os kernels não lineares particularmente mais adequados em cenários com maior complexidade nos dados.

Como indicativo da capacidade do modelo proposto em capturar a fração de cura presente nos dados, foi realizada também uma comparação entre o estimador de Kaplan-Meier e a curva de




Figura 2 – Distribuição do IBS em relação a cada kernel, para diferentes cenários de simulação.

sobrevivência estimada pelo modelo GG-KM. Essa comparação pode ser observada na Figura 3. De modo geral, observa-se que o modelo GG-KM apresenta boa aderência ao comportamento do estimador de Kaplan-Meier, sugerindo que o componente de cura está sendo adequadamente modelado. Contudo, no cenário em que $n = 600$ para o método 3, nota-se um afastamento maior entre as curvas, indicando um ajuste inferior nesse caso específico.




Figura 3 – Comparação da curva de sobrevivência estimada pelo GG-KM e KME.

A Tabela 1 complementa a análise anterior ao sintetizar, para cada cenário, o kernel com melhor desempenho segundo o critério de menor IBS médio. Os resultados reforçam a evidência de que kernels não lineares tendem a oferecer melhor capacidade de adaptação às diferentes estruturas simuladas.

Observa-se que o kernel cauchy foi selecionado nos cenários com $n = 300$ para os métodos 1 e 2, enquanto os kernels exponential, rbf, sigmoid e polynomial também se destacaram em diferentes configurações.

Além disso, nota-se que o aumento do tamanho amostral resultou, em geral, em redução do IBS médio e do viés absoluto, especialmente nos métodos 2 e 3, indicando ganhos em precisão e estabilidade na estimação da fração de cura. Em particular, o cenário com $n = 600$ e método 3 apresentou o melhor desempenho, com menor IBS e menor EQM.

Tabela 1 – Resultados dos melhores kernels para cada tamanho amostral e método.

n	Método	K	Média IBS	Viés ($\hat{\pi}(\mathbf{x})$)	EQM ($\hat{\pi}(\mathbf{x})$)
300	1	cauchy	0.1198	-0.0229	0.0264
300	2	cauchy	0.1564	0.0574	0.0710
300	3	exponential	0.1295	-0.0103	0.0220
600	1	sigmoid	0.1027	0.0210	0.0363
600	2	rbf	0.1456	-0.0043	0.0307
600	3	polynomial	0.0863	-0.0043	0.0192

5.2 Aplicação a Dados Reais

O conjunto de dados reais escolhido para aplicação do modelo foi o Melanoma, amplamente utilizado em estudos de análise de sobrevivência. Esse conjunto contém informações de 205 pacientes diagnosticados com melanoma maligno, um tipo agressivo de câncer de pele, submetidos a cirurgia radical no Hospital Universitário de Odense, na Dinamarca, entre os anos de 1962 e 1977.

Os pacientes foram acompanhados até o final de 1977, período no qual 134 indivíduos permaneceram vivos, enquanto 71 evoluíram para óbito, sendo 57 mortes atribuídas diretamente ao melanoma e 14 decorrentes de outras causas. Este conjunto de dados, especificamente, é utilizado em textos de modelos com fração de cura, pois há o conhecimento de que existe de fato uma fração de cura no conjunto de dados.

A base é composta por sete variáveis: tempo de acompanhamento em dias (time), status do paciente ao final do estudo (status), sexo (sex), idade no momento da cirurgia (age), ano da cirurgia (year), espessura do tumor em milímetros (thickness) e presença de ulceração (ulcer).

Para fins de modelagem, consideramos como evento de interesse o óbito por melanoma, tratando os demais casos, pacientes vivos ao final do estudo ou óbitos por outras causas, como observações censuradas. Portanto, ao final, tem-se aproximadamente 73% de observações censuradas.

Inicialmente, assim como foi feito com os dados simulados, foi realizada a comparação entre a curva de sobrevivência estimada pelo modelo proposto e o estimador de Kaplan-Meier, conforme apresentado na Figura 4. Como pode ser observado a partir da figura, há de fato indícios de que o modelo está conseguindo capturar adequadamente a fração de cura presente nos dados.




Figura 4 – Curva de Kaplan Meier para o conjunto de dados de melanoma, comparando o modelo GG-KM.




Figura 5 – Distribuição do IBS em relação a cada kernel.

Na Figura 5, pode-se observar a variação do desempenho do modelo GG-KM para cada kernel, com base na distribuição do IBS. Nota-se que o kernel cauchy, embora tenha alcançado um dos menores valores de IBS, foi também o que apresentou maior variabilidade nessa métrica. Os kernels linear e gaussiano apresentaram desempenhos bastante semelhantes entre si. De forma análoga, os kernels laplaciano e exponencial também exibiram resultados próximos, destacando-se por apresentarem menor variabilidade, embora não tenham atingido os menores valores de IBS. Por fim, os kernels sigmoid e polinomial também apresentaram comportamento semelhante, tanto em termos de nível quanto de dispersão do erro.

A Tabela 2 resume esses resultados ao apresentar o IBS médio e seu respectivo desvio padrão para cada kernel. Observa-se que o kernel linear apresentou o menor IBS médio, indicando

Tabela 2 – Resultados do IBS médio e desvio padrão para cada kernel no conjunto de dados Melanoma.

Kernel	Média IBS	DP IBS
linear	0.1517	0.0295
exponential	0.1536	0.0170
polynomial	0.1539	0.0295
rbf	0.1562	0.0312
laplacian	0.1584	0.0192
sigmoid	0.1586	0.0231
cauchy	0.1663	0.0439

o melhor desempenho preditivo global nesse conjunto de dados, seguido de perto pelos kernels exponential e polynomial.

Embora o kernel cauchy tenha apresentado alguns bons resultados, seu IBS médio mais elevado e maior variabilidade indicam menor estabilidade no processo de estimação. Por outro lado, o kernel exponential se destaca por combinar desempenho preditivo próximo ao melhor observado com a menor dispersão entre todos os kernels avaliados, sugerindo maior robustez. De modo geral, os resultados indicam que, para o conjunto de dados Melanoma, estruturas mais simples ou moderadamente flexíveis parecem ser suficientes para capturar adequadamente a dinâmica da sobrevivência e a fração de cura presente nos dados.

CONCLUSÃO

Este trabalho apresentou uma extensão do modelo de tempo de promoção para a modelagem da componente de cura por meio da incorporação de funções kernel, resultando no modelo GG-KM. Essa abordagem permite maior flexibilidade na estimação, tornando possível capturar relações complexas e não lineares entre as covariáveis e a fração de cura.

Nos experimentos com dados simulados, os resultados evidenciaram que kernels não lineares apresentaram desempenho superior em cenários com maior complexidade, particularmente nos métodos 2 e 3, nos quais alcançaram os menores valores de IBS. Em contrapartida, o kernel linear apresentou desempenho inferior nesses cenários, reforçando a importância da flexibilidade introduzida pelos kernels.

Além disso, tanto nos dados simulados quanto na aplicação ao conjunto de dados reais, observou-se bom ajuste entre a curva de sobrevivência estimada pelo modelo GG-KM e o estimador de Kaplan-Meier. Esse comportamento fornece evidências de que o modelo proposto é capaz de representar adequadamente a fração de cura presente nos dados.

De forma geral, os resultados obtidos indicam que o GG-KM constitui uma alternativa promissora para modelagem de sobrevivência com fração de cura, especialmente em contextos onde a estrutura da relação entre covariáveis e sobrevivência apresenta maior complexidade.

REFERÊNCIAS

- AALLEN, O. O.; BORGAN, Ø.; GJESSING, H. K. **Survival and event history analysis: a process point of view**. [S.l.]: Springer, 2008. Citado na página 21.
- BERKSON, J.; GAGE, R. P. Survival curve for cancer patients following treatment. **Journal of the American Statistical Association**, Taylor & Francis, v. 47, n. 259, p. 501–515, 1952. Citado na página 28.
- COX, D. R. Regression models and life-tables. **Journal of the royal statistical society: Series B (methodological)**, Wiley Online Library, v. 34, n. 2, p. 187–202, 1972. Citado na página 23.
- DONG, G.; MAO, L.; HUANG, B.; GAMALO-SIEBERS, M.; WANG, J.; YU, G.; HOAGLIN, D. C. The inverse-probability-of-censoring weighting (ipcw) adjusted win ratio statistic: an unbiased estimator in the presence of independent censoring. **Journal of biopharmaceutical statistics**, Taylor & Francis, v. 30, n. 5, p. 882–899, 2020. Citado na página 45.
- HARRIS, C. R.; MILLMAN, K. J.; WALT, S. J. V. D.; GOMMERS, R.; VIRTANEN, P.; COURNAPEAU, D.; WIESER, E.; TAYLOR, J.; BERG, S.; SMITH, N. J. *et al.* Array programming with numpy. **nature**, Nature Publishing Group UK London, v. 585, n. 7825, p. 357–362, 2020. Citado na página 42.
- LIU, D. C.; NOCEDAL, J. On the limited memory bfgs method for large scale optimization. **Mathematical programming**, Springer, v. 45, n. 1, p. 503–528, 1989. Citado na página 31.
- MCLACHLAN, G. J.; KRISHNAN, T. **The EM algorithm and extensions**. [S.l.]: John Wiley & Sons, 2008. Citado na página 36.
- MOHRI, M.; ROSTAMIZADEH, A.; TALWALKAR, A. **Foundations of machine learning**. [S.l.]: MIT press, 2018. Citado nas páginas 7, 9 e 33.
- PAL, S.; ASELISEWINE, W. A semiparametric promotion time cure model with support vector machine. **The Annals of Applied Statistics**, Institute of Mathematical Statistics, v. 17, n. 3, p. 2680–2699, 2023. Citado nas páginas 42 e 46.
- PRINCE, T.; BOMMERT, A.; RAHNENFÜHRER, J.; SCHMID, M. On the estimation of inverse-probability-of-censoring weights for the evaluation of survival prediction error. **PloS one**, Public Library of Science San Francisco, CA USA, v. 20, n. 1, p. e0318349, 2025. Citado nas páginas 7 e 9.
- STACY, E. W. A generalization of the gamma distribution. **The Annals of mathematical statistics**, JSTOR, p. 1187–1192, 1962. Citado nas páginas 7 e 9.
- VIRTANEN, P.; GOMMERS, R.; OLIPHANT, T. E.; HABERLAND, M.; REDDY, T.; COURNAPEAU, D.; BUROVSKI, E.; PETERSON, P.; WECKESSER, W.; BRIGHT, J. *et al.* Scipy 1.0: fundamental algorithms for scientific computing in python. **Nature methods**, Nature Publishing Group US New York, v. 17, n. 3, p. 261–272, 2020. Citado na página 42.

